Introduction à l'analyse des données

Chapitre 12 : Du khi-deux à l'analyse des correspondances

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 22 octobre 2026

Plan du chapitre

Un autre type de tableau

L'écart à l'indépendance

L'inertie d'un tableau croisé

Les profils

La distance du khi-deux

Sur machine

S'entraîner

Ce qu'il faut retenir

Un autre type de tableau

La situation

Deux variables **qualitatives** croisées : chaque case porte un **effectif**, non une mesure.

L'ACP ne s'applique pas : ni moyenne, ni variance, ni corrélation sur des catégories.

Le tableau du calcul à la main : type de client et canal d'achat

	Magasin	Web	Téléphone	**Total**
Jeunes	30	60	10	100
Familles	80	40	30	150
Seniors	90	20	40	150
Total	**200**	**120**	**80**	**400**

Un tableau pour calculer, un tableau réel

Comme pour l'ACP, deux fils rouges : ce petit tableau 3×3, qui se calcule entièrement à la main, et le croisement réel de la **CSP** et du **motif de visite** des 300 clients.

Le tableau réel : CSP et motif de visite

	Choix	Prix	Proximité	Service	**Total**
Cadre	40	8	8	16	72
Employé	20	45	26	10	101
Étudiant	2	14	5	1	22
Indépendant	19	12	12	32	75
Retraité	1	5	17	7	30
Total	**82**	**84**	**68**	**66**	**300**

L’écart à l’indépendance

Sous indépendance

Si les deux variables étaient sans lien, chaque case vaudrait

$$\text{attendu} = \frac{\text{total ligne} \times \text{total colonne}}{\text{total général}}$$

Une case, en détail

Jeunes et web : $100 \times 120/400 = 30$. Sous l'indépendance, les jeunes représentent $25\,\%$ des clients ; ils devraient donc faire $25\,\%$ des 120 achats sur le web.

Effectif observé, et attendu entre parenthèses

	Magasin	Web	Téléphone
Jeunes	30 (50)	60 (30)	10 (20)
Familles	80 (75)	40 (45)	30 (30)
Seniors	90 (75)	20 (45)	40 (30)

Les jeunes achètent **deux fois plus** sur le web qu'attendu, les seniors **deux fois moins** : c'est là qu'est l'information.

Les marges sont respectées

Le tableau des attendus a **les mêmes totaux** de lignes et de colonnes que le tableau observé. Il ne change que la façon dont les effectifs se répartissent à l'intérieur.

La mesure de l'écart

$$\chi^2 = \sum_{\text{cases}} \frac{(\text{observé} - \text{attendu})^2}{\text{attendu}}$$

Le calcul

$$\chi^2 = \frac{400}{50} + \frac{900}{30} + \frac{100}{20} + \frac{25}{75} + \frac{25}{45} + 0 + \frac{225}{75} + \frac{625}{45} + \frac{100}{30}$$

$$\chi^2 = 8 + 30 + 5 + 0{,}33 + 0{,}56 + 0 + 3 + 13{,}89 + 3{,}33 \approx \mathbf{64{,}1}$$

pour $(3-1)(3-1) = 4$ degrés de liberté.

La part de chaque case dans le khi-deux

	Magasin	Web	Téléphone
Jeunes	12,5 %	**46,8** %	7,8 %
Familles	0,5 %	0,9 %	0
Seniors	4,7 %	**21,7** %	5,2 %

Deux cases font les deux tiers

Les jeunes sur le web et les seniors sur le web portent à eux seuls 68,5 % du khi-deux. La ligne des familles n'y contribue presque pas : **leur répartition ressemble à celle de l'ensemble**. Le chapitre 13 retrouvera tout cela sur une figure.

Un test, et une conclusion en un mot

Le chapitre 18 de *Statistique inférentielle* comparait ce $64{,}1$ au seuil du khi-deux à 4 degrés de liberté, $9{,}49$, et concluait au **rejet de l'indépendance** ($p \approx 4 \times 10^{-13}$).

Conclusion en un mot : *il y a un lien*. Elle ne dit **pas lequel** — ni quelles catégories s'attirent, ni selon quelles dimensions.

L'AFC prend le relais

L'analyse des correspondances reprend exactement le même nombre et le décompose : par case, par ligne, par colonne, et surtout par **axe**.

Le tableau réel, observé et attendu

observés	Prix	Choix	Proximité	Service	**total**
Étudiant	14	2	5	1	22
Employé	45	20	26	10	101
Cadre	8	40	8	16	72
Indépendant	12	19	12	32	75
Retraité	5	1	17	7	30
total	84	82	68	66	300

théoriques	Prix	Choix	Proximité	Service
Étudiant	6,16	6,01	4,99	4,84
Employé	28,28	27,61	22,89	22,22
Cadre	20,16	19,68	16,32	15,84
Indépendant	21,00	20,50	17,00	16,50
Retraité	8,40	8,20	6,80	6,60

Le khi-deux du chapitre 18 de l'inférence.

$$\chi^2 = \sum \frac{(n_{ij} - t_{ij})^2}{t_{ij}} = 110{,}41$$

Avec 12 degrés de liberté, le seuil à 5 % vaut 21,03.
L'indépendance est rejetée sans hésitation.

Et ensuite ? Le test dit qu'il y a une liaison. **Il ne dit pas laquelle.**

Cinq lignes, quatre colonnes, vingt écarts à commenter — l'AFC va les mettre sur un plan.

CSP et motif de visite

$$\chi^2 = 110{,}41 \quad \text{pour} \quad (5-1)(4-1) = 12 \text{ degrés de liberté}$$

Le seuil à $5\,\%$ vaut $21{,}03$: l'indépendance est rejetée sans hésitation ($p \approx 5 \times 10^{-18}$).

Une réserve pour le test, pas pour la description

Deux effectifs attendus sont **inférieurs à** 5 : étudiants et service ($4{,}84$), étudiants et proximité ($4{,}99$). La condition de validité du test n'est pas tout à fait remplie — R l'affichera. L'écart est si grand que la conclusion ne change pas ; et l'AFC, qui **décrit**, n'a pas besoin de cette condition.

Les cases qui font le khi-deux réel

	Choix	Prix	Proximité	Service
Cadre	20,98 +	7,33 −	4,24 −	0,00 +
Employé	2,10 −	9,89 +	0,42 +	6,72 −
Étudiant	2,68 −	9,98 +	0,00 +	3,05 −
Indépendant	0,11 −	3,86 −	1,47 −	14,56 +
Retraité	6,32 −	1,38 −	15,30 +	0,02 +

chaque case : $(\text{observé} - \text{attendu})^2/\text{attendu}$; vert : plus qu'attendu (+), orange : moins (−) ; total 110,41

Quatre associations fortes

Les **cadres** viennent pour le **choix** (40 pour $19{,}7$ attendus : $19\,\%$ du khi-deux), les **retraités** pour la **proximité** (17 pour $6{,}8$), les **indépendants** pour le **service** (32 pour $16{,}5$), les **employés** et les **étudiants** pour le **prix**.

L’inertie d’un tableau croisé

Le phi-deux

$$\Phi^2 = \frac{\chi^2}{n}$$

C'est le khi-deux **rapporté à l'effectif total** — et c'est l'**inertie totale** du tableau.

Sur nos deux tableaux

Tableau	χ^2	n	Φ^2
type × canal	$64{,}1$	400	$\mathbf{0{,}160}$
CSP × motif	$110{,}41$	300	$\mathbf{0{,}368}$

Le khi-deux grandit avec l'effectif

Doubler tous les effectifs, sans changer les proportions, double le khi-deux. La **liaison** n'a pourtant pas changé. Φ^2 ne dépend que des **proportions** : c'est une mesure de l'intensité de la liaison, et non de la taille de l'échantillon.

Le V de Cramér

$$V = \sqrt{\frac{\Phi^2}{\min(\text{lignes}, \text{colonnes}) - 1}} \qquad \text{entre } 0 \text{ et } 1$$

Type × canal : $V = \sqrt{0{,}160/2} = 0{,}28$. CSP × motif : $V = \sqrt{0{,}368/3} = 0{,}35$. Deux liaisons nettes, la seconde plus forte.

Le centre est l'indépendance

Le chapitre 6 avait défini l'inertie comme la dispersion d'un nuage autour de son centre.

Ici, le « centre » est la situation d'**indépendance**, et l'inertie mesure de combien le tableau s'en écarte. Un tableau parfaitement indépendant aurait une inertie **nulle** : rien à représenter.

La démarche est donc identique à celle de l'ACP — décomposer une inertie totale sur des axes hiérarchisés — appliquée à un écart à l'indépendance plutôt qu'à une dispersion de mesures.

La décomposition

$$\Phi^2 = \lambda_1 + \lambda_2 + ...$$

Le nombre d'axes vaut $\min(\text{lignes}, \text{colonnes}) - 1$: $\min(3,3) - 1 = 2$ axes pour le petit tableau, $\min(5,4) - 1 = 3$ pour le tableau réel.

Les profils

Profil-ligne

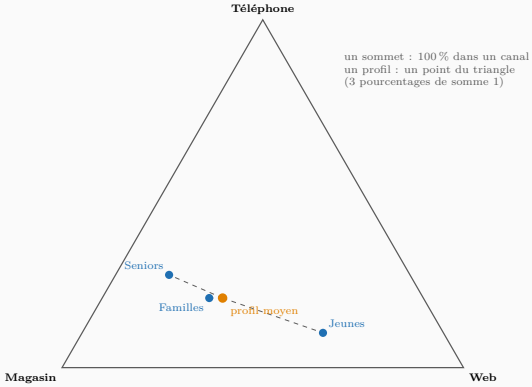
Le **profil** d'une ligne est sa répartition en pourcentages :

$$\text{profil}_{ij} = \frac{n_{ij}}{\text{total de la ligne } i}$$

Les trois profils-lignes du petit tableau

	Magasin	Web	Téléphone
Jeunes	30 %	**60** %	10 %
Familles	53 %	27 %	20 %
Seniors	60 %	13 %	27 %
Ensemble	50 %	30 %	20 %

Les profils, dans un triangle



Un profil est un point

Trois pourcentages de somme 1 se placent dans un **triangle** : plus un profil est proche d'un sommet, plus il est concentré sur ce canal. Les familles sont **presque confondues** avec le profil moyen ; les jeunes s'en écartent vers le web, les seniors vers le magasin et le téléphone.

Taille et comportement

Les jeunes sont 100 et les seniors 150 : comparer les effectifs bruts confondrait la **taille** du groupe et son **comportement**.

Les profils suppriment cet effet : les jeunes achètent sur le web dans $60\,\%$ des cas contre $30\,\%$ en moyenne, les seniors dans $13\,\%$.

Le nuage de l'AFC est un nuage de profils, non d'effectifs.

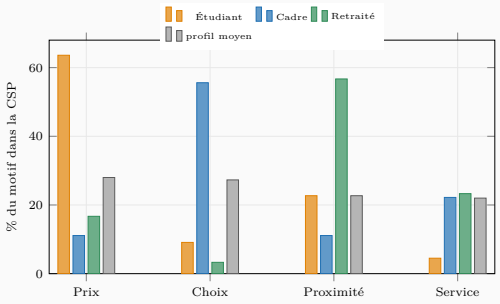
Chaque profil a un poids

Chaque profil-ligne pèse le **poids de sa ligne** dans le total : $100/400 = 0{,}25$ pour les jeunes, $0{,}375$ pour les familles et les seniors. Le profil moyen est la moyenne des profils, pondérée par ces poids.

Le motif de visite, par CSP

	Choix	Prix	Proximité	Service
Cadre	**55,6** %	11,1 %	11,1 %	22,2 %
Employé	19,8 %	**44,6** %	25,7 %	9,9 %
Étudiant	9,1 %	**63,6** %	22,7 %	4,5 %
Indépendant	25,3 %	16,0 %	16,0 %	**42,7** %
Retraité	3,3 %	16,7 %	**56,7** %	23,3 %
Ensemble	27,3 %	28,0 %	22,7 %	22,0 %

Les profils réels, en image



L'AFC compare des profils, pas des effectifs.

Il y a 22 étudiants et 101 employés : les comparer en effectifs n'aurait aucun sens.

En **pourcentages de ligne**, la comparaison redevient possible — et l'écart au **profil moyen**devient l'objet de l'analyse.

Un profil ligne égal au profil moyen n'apporte rien : il ira au centre du plan factoriel. C'est exactement ce que dit l'indépendance.

La distance du khi-deux

La distance

$$d^2(i, \text{moyen}) = \sum_j \frac{\left(\text{profil}_{ij} - \text{profil moyen}_j\right)^2}{\text{profil moyen}_j}$$

Chaque écart est divisé par la part de la colonne : un écart sur une colonne **rare** pèse plus qu'un même écart sur une colonne fréquente.

C'est la réduction de l'AFC

Diviser par la part de la colonne joue le rôle de la **réduction** du chapitre 2 : sans cela, les colonnes de gros effectif domineraient toutes les distances, comme le panier en dirhams dominait les notes.

Les trois distances au profil moyen (0,5 ; 0,3 ; 0,2)

Jeunes : $\dfrac{(0{,}3-0{,}5)^2}{0{,}5}+\dfrac{(0{,}6-0{,}3)^2}{0{,}3}+\dfrac{(0{,}1-0{,}2)^2}{0{,}2}=0{,}08+0{,}30+0{,}05=0{,}430$

Familles : $\dfrac{0{,}033^2}{0{,}5}+\dfrac{0{,}033^2}{0{,}3}+0=0{,}006$; Seniors : $0{,}020+0{,}093+0{,}022=0{,}135$

L'inertie retrouvée

$$\Phi^2=\sum_i \text{poids}_i\times d^2(i,\text{moyen})=0{,}25\times 0{,}430+0{,}375\times 0{,}006+0{,}375\times 0{,}135=0{,}160$$

L'inertie est la moyenne pondérée des carrés des distances au centre — exactement la définition du chapitre 6.

Les cinq CSP

CSP	Poids	d^2 au profil moyen	Part de l'inertie
Cadre	$0{,}240$	$0{,}452$	$29{,}5\,\%$
Employé	$0{,}337$	$0{,}189$	$17{,}3\,\%$
Étudiant	$0{,}073$	$0{,}714$	$14{,}2\,\%$
Indépendant	$0{,}250$	$0{,}267$	$18{,}1\,\%$
Retraité	$0{,}100$	$\mathbf{0{,}767}$	$20{,}9\,\%$
Total	1		$\Phi^2 = 0{,}368$

Petit poids, grand écart

Les retraités et les étudiants ont les profils **les plus extrêmes**, mais ne pèsent que $10\,\%$ et $7\,\%$ des clients. Les cadres, moins extrêmes mais nombreux, font la plus grande part de l'inertie.

Deux nuages, une seule analyse

On peut construire le nuage des **profils-lignes** ou celui des **profils-colonnes**.

Les deux ont **la même inertie Φ^2**, **les mêmes valeurs propres**, et deux représentations qui se superposent.

La dualité, portée à sa forme la plus complète

C'est la **dualité** du chapitre 5. Dans l'ACP, individus et variables n'étaient pas de même nature ; ici, lignes et colonnes sont deux catégories **symétriques**. C'est ce qui permettra, au chapitre 13, de les lire sur **une seule** figure.

Sur machine

table, puis chisq.test

```r
clients <- read.csv("clients.csv")
tab <- table(clients$csp, clients$motif)
chisq.test(tab)
#   Pearson's Chi-squared test
# data:  tab
# X-squared = 110.41, df = 12, p-value < 2.2e-16
# Warning message:
# In chisq.test(tab) : Chi-squared approximation may be incorrect
```

L'avertissement

R signale que des effectifs **attendus** sont inférieurs à 5 — les étudiants. Le test reste ici sans ambiguïté, mais l'avertissement mérite toujours d'être lu.

La fonction CA de FactoMineR

```
library(FactoMineR)
afc <- CA(as.data.frame.matrix(tab), graph = FALSE)
round(sum(afc$eig[, 1]), 4)                    # [1] 0.368
```

Le khi-deux décomposé

La somme des valeurs propres de l'AFC est $\Phi^2 = 110{,}41/300 = 0{,}368$. Le chapitre 13 lira ces valeurs propres une à une, comme celles de l'ACP au chapitre 8.

Le tableau croisé, le test, le phi-deux et le V de Cramér

```
import numpy as np
import pandas as pd
from scipy.stats import chi2_contingency
clients = pd.read_csv("clients.csv")
tab = pd.crosstab(clients.csp, clients.motif)
chi2, p, ddl, attendus = chi2_contingency(tab)
print(round(chi2, 2), ddl, f"{p:.1e}")       # 110.41 12 5.0e-18
phi2 = chi2 / tab.to_numpy().sum()
print(round(phi2, 4), round(np.sqrt(phi2 / 3), 3))    # 0.368 0.35
profils = tab.div(tab.sum(axis=1), axis=0)       # profils-lignes
```

S’entraîner

Exercice 1 : un tableau deux sur trois

Sexe et canal préféré

	Magasin	Web	Téléphone	Total
Femmes	50	30	20	100
Hommes	30	50	20	100
Total	80	80	40	200

1. Calculer les effectifs attendus sous l'indépendance.
2. Calculer le khi-deux, Φ^2 et le V de Cramér.
3. Combien d'axes aurait l'AFC de ce tableau ?

Khi-deux 10, un seul axe

1. 40 ; 40 ; 20 dans chaque ligne.
2. Quatre cases s'écartent de $10 : 4 \times 100/40 = 10$; le téléphone, rien. $\chi^2 = 10$, $\Phi^2 = 10/200 = 0{,}05$, $V = \sqrt{0{,}05/1} = 0{,}22$.
3. $\min(2, 3) - 1 = 1$ axe, qui porte toute l'inertie $0{,}05$ et oppose femmes-magasin à hommes-web.

Le même tableau, en profils

Reprendre le tableau de l'exercice 1.

1. Calculer les deux profils-lignes et le profil moyen.
2. Calculer la distance du khi-deux de chaque profil au profil moyen.
3. Retrouver Φ^2 comme moyenne pondérée de ces distances.

Deux profils symétriques

1. Femmes $(0{,}5; 0{,}3; 0{,}2)$, hommes $(0{,}3; 0{,}5; 0{,}2)$, moyen $(0{,}4; 0{,}4; 0{,}2)$.
2. Femmes : $0{,}1^2/0{,}4 + 0{,}1^2/0{,}4 + 0 = 0{,}05$. Hommes : la même chose, $0{,}05$.
3. $0{,}5 \times 0{,}05 + 0{,}5 \times 0{,}05 = 0{,}05 = \Phi^2$. Les deux lignes sont à égale distance du centre, de part et d'autre.

Ce que disent quelques chiffres

1. Combien d'axes aura l'AFC du tableau CSP × motif ? Que vaut la somme de leurs valeurs propres ?
2. La case cadres × choix contribue $20{,}98$ au khi-deux. Quelle part du total ?
3. Les retraités ont le profil le plus éloigné du profil moyen ($d^2 = 0{,}767$) et ne portent que $20{,}9\,\%$ de l'inertie. Pourquoi ?

Trois axes, une inertie de 0,368

1. $\min(5,4)-1=3$ axes ; la somme des valeurs propres est $\Phi^2=0{,}368$.
2. $20{,}98/110{,}41=19\,\%$: à elle seule, près d'un cinquième de l'écart à l'indépendance.
3. Ils ne sont que 30 sur 300 : leur poids $0{,}10$ multiplie leur distance, $0{,}10\times 0{,}767=0{,}077$, soit $0{,}077/0{,}368=20{,}9\,\%$. Une catégorie rare au profil extrême peut néanmoins **tirer un axe** à elle seule : le chapitre 13 le vérifiera.

Ce qu’il faut retenir

Six points

1. Un tableau de **contingence** croise deux variables qualitatives ; l'ACP ne s'y applique pas.
2. Le **khi-deux** mesure l'écart à l'indépendance : $64{,}1$ pour 4 ddl sur le petit tableau, $110{,}41$ pour 12 ddl sur le tableau réel.
3. L'inertie totale est $\Phi^2 = \chi^2/n$: $0{,}160$ et $0{,}368$; le V de Cramér en donne l'intensité ($0{,}28$ et $0{,}35$).
4. Le nuage est fait de **profils** pondérés par leurs effectifs, ce qui neutralise les différences de taille.
5. La **distance du khi-deux** divise chaque écart par la part de la colonne ; Φ^2 est la moyenne pondérée des d^2 au profil moyen.
6. L'AFC **décompose** cette inertie sur $\min(l, c) - 1$ axes, là où le test se contentait de conclure.

Lire la figure

L'inertie est décomposée. Reste à lire la figure — et les règles de lecture ne sont pas tout à fait celles de l'ACP.

Ce qu'on y fera

On calculera les deux axes du petit tableau, on placera lignes et colonnes sur un même plan, et l'on verra les retraités fabriquer presque la moitié du second axe du tableau réel.