Introduction à l'analyse des données

Chapitre 13 : Lire un plan de correspondances, et la suite

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 22 octobre 2026

Plan du chapitre

Les axes du petit tableau

Lire le plan du tableau réel

Les règles de lecture

Les mêmes prudences qu'en ACP

Sur machine

Ce que ce cours a construit

La suite, au Master

S'entraîner

Ce qu'il faut retenir

Les axes du petit tableau

Deux valeurs propres

Type de client et canal d'achat

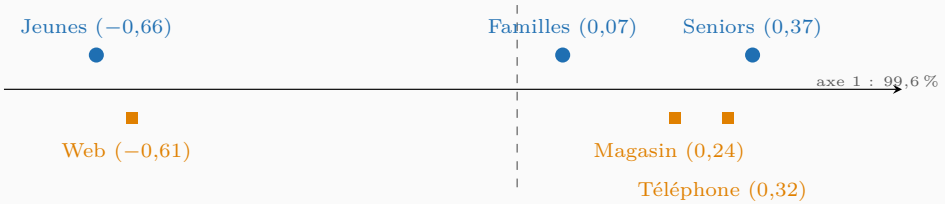
L'AFC du tableau 3×3 du chapitre 12 donne $\min(3,3) - 1 = 2$ axes :

Axe	Valeur propre	Part
1	0,1597	**99,6 %**
2	0,0006	0,4 %
Total	$\mathbf{0{,}1603} = \Phi^2$	100 %

Un seul axe suffit

La somme des valeurs propres est l'inertie $\Phi^2 = 0{,}160$ du chapitre 12, comme la somme des valeurs propres de l'ACP valait p. Ici, **un seul axe** porte presque toute l'information : l'écart à l'indépendance de ce tableau tient en une seule opposition.

L'axe unique, en image



Ce qu'on y lit

Le premier axe oppose le **web** $(-0{,}61)$ au **magasin** $(0{,}24)$ et au **téléphone** $(0{,}32)$. Du côté web se placent les **jeunes** $(-0{,}66)$; de l'autre, les **seniors** $(0{,}37)$. Les **familles** $(0{,}07)$ occupent une position presque centrale : leur profil est proche du profil moyen.

La relation de transition

La coordonnée d'une ligne est la **moyenne des coordonnées des colonnes**, pondérée par son profil, puis dilatée par $1/\sqrt{\lambda}$:

$$F_i = \frac{1}{\sqrt{\lambda}} \sum_j \text{profil}_{ij}\, G_j$$

Et réciproquement pour une colonne, avec les profils-colonnes.

La vérification, sur les jeunes

Profil des jeunes : $(0{,}3; 0{,}6; 0{,}1)$; coordonnées des colonnes : $0{,}237$; $-0{,}609$; $0{,}320$.

$$F_{\text{jeunes}} = \frac{0{,}3 \times 0{,}237 + 0{,}6 \times (-0{,}609) + 0{,}1 \times 0{,}320}{\sqrt{0{,}1597}} = \frac{-0{,}262}{0{,}400} = -0{,}656$$

Pourquoi « du même côté » veut dire « associés »

Une ligne est attirée par les colonnes où elle est forte

Les jeunes mettent $60\,\%$ de leurs achats sur le web : la moyenne des colonnes, pondérée par leur profil, est **tirée vers le web**. C'est pourquoi une ligne se place du côté des colonnes où elle est **surreprésentée**.

Ce que la relation justifie

La lecture conjointe de l'AFC n'est pas une commodité : elle découle de cette **relation barycentrique**. Elle autorise à lire des **directions communes** entre lignes et colonnes — jamais des distances entre une ligne et une colonne.

Lire le plan du tableau réel

CSP et motif de visite

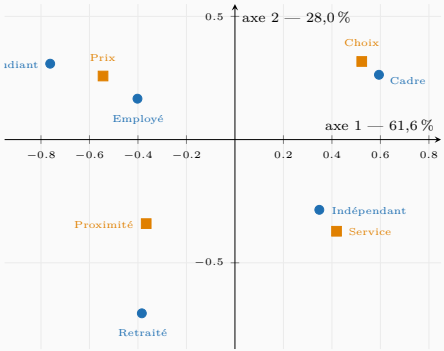
Axe	Valeur propre	Part	Cumul
1	0,2267	61,6 %	61,6 %
2	0,1030	28,0 %	**89,6** %
3	0,0384	10,4 %	100 %

$0{,}2267 + 0{,}1030 + 0{,}0384 = 0{,}368 = \Phi^2$.

Un plan presque complet

Le plan des deux premiers axes conserve près de $90\,\%$ de l'écart à l'indépendance. On peut le commenter avec confiance — en vérifiant, comme toujours, la qualité de chaque modalité.

Le plan, lignes et colonnes ensemble



Le privilège de l'AFC : les deux nuages sur le même plan.

Ligneset **colonnes**sont projetées dans le même repère — ce qu'aucune ACP ne permet.

Axe 1 : *Prix* et les étudiants et employés d'un côté ; *Choix*, *Service* et les cadres et indépendants de l'autre. C'est la contrainte budgétaire.

Axe 2 : *Proximité* et les retraités, seuls en bas.

Attention : entre une ligne et une colonne, on lit une direction, pas une distance. « Retraité est du côté de Proximité » se lit ; « Retraité est à trois centimètres de Proximité » ne se lit pas.

Le privilège de l'AFC

Le plan porte **simultanément** les modalités des lignes et celles des colonnes.

C'est l'avantage décisif de l'AFC sur l'ACP, où variables et individus exigeaient deux figures séparées.

Les coordonnées

CSP	axe 1	axe 2	Motif	axe 1	axe 2
Cadre	0,59	0,26	Choix	0,52	0,32
Employé	−0,40	0,17	Prix	−0,54	0,26
Étudiant	−0,76	0,31	Proximité	−0,37	−0,34
Indépendant	0,35	−0,29	Service	0,42	−0,37
Retraité	−0,38	−0,71			

Nommer les deux axes

Axe 1 : le prix contre le choix et le service

À gauche, le **prix** avec les **étudiants** et les **employés** ; à droite, le **choix** et le **service** avec les **cadres** et les **indépendants**. L'axe oppose les clients qui viennent pour **payer moins** à ceux qui viennent pour **être mieux servis** : c'est la contrainte budgétaire.

Axe 2 : la proximité, et les retraités

En bas, la **proximité** et les **retraités**, avec le service et les indépendants ; en haut, le choix et le prix. Le deuxième axe isole surtout une clientèle **de quartier**, qui vient parce que le magasin est près de chez elle.

Les règles de lecture

Quatre règles

Comparaison	Interprétation
Deux **lignes** proches	profils semblables
Deux **colonnes** proches	profils semblables
Une ligne et une colonne du **même côté**	**attirance** — effectif supérieur à l'attendu
Un point **loin du centre**	modalité au profil très particulier

Sur le plan réel

Étudiants et employés sont proches : leurs profils se ressemblent (prix d'abord). Les cadres sont du côté du choix : 40 cadres sur 72 viennent pour le choix, contre $19{,}7$ attendus.

Pas de distance entre une ligne et une colonne

On ne mesure pas une distance entre une ligne et une colonne.

« Les retraités sont à trois centimètres de la proximité, donc plus proches que les employés » n'a pas de sens : les deux nuages ne vivent pas dans le même espace.

On lit une **direction commune**, jamais une distance croisée : *les retraités et la proximité sont du même côté de l'axe* 2*, donc associés.*

Le centre du plan

L'origine représente le **profil moyen**. Une modalité proche du centre a un profil banal. Sur le petit tableau, ce sont les **familles** ($d^2 = 0{,}006$) ; sur le tableau réel, les **employés** ($d^2 = 0{,}189$, le plus faible des cinq).

Les mêmes prudences qu'en ACP

Le cosinus carré d'une modalité

Comme en ACP, la qualité d'une modalité sur le plan est la part de sa distance au centre que le plan restitue.

Les cinq CSP

CSP	$\cos^2$ axe 1	$\cos^2$ axe 2	$\cos^2$ plan
Cadre	0,78	0,15	0,93
Employé	0,85	0,15	1,00
Étudiant	0,81	0,13	0,95
Indépendant	0,46	0,31	0,76
Retraité	0,19	0,65	0,84

Les contributions des CSP

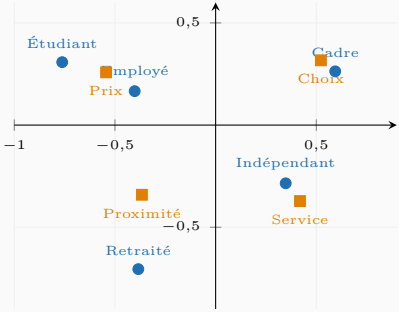
CSP	Poids	ctr axe 1	ctr axe 2
Cadre	24 %	**37,3** %	16,1 %
Employé	34 %	24,0 %	9,1 %
Étudiant	7 %	18,8 %	6,8 %
Indépendant	25 %	13,4 %	19,8 %
Retraité	10 %	6,5 %	**48,3** %

Un dixième des clients, la moitié d'un axe

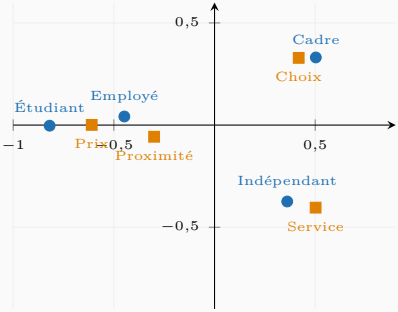
Les retraités ne sont que 30 sur 300, et fabriquent **à eux seuls près de la moitié** du deuxième axe. C'est le défaut le plus fréquent de l'AFC : une catégorie **rare** au profil extrême capte un axe.

Refaire l'analyse sans eux

avec les retraités : axes à 61,6 et 28,0 %



sans les retraités : axes à 76,5 et 22,5 %



Sans les 30 retraités

Le premier axe **résiste** : il oppose toujours le prix (étudiants, employés) au choix et au service (cadres, indépendants), et porte désormais $76{,}5\,\%$ de l'inertie.

Le deuxième axe **change de nature** : il n'oppose plus la proximité au reste, mais le **service** (indépendants) au **choix** (cadres). La proximité revient près du centre.

La conclusion à écrire

Le premier axe est une **structure** de la clientèle. Le deuxième, dans l'analyse complète, décrivait surtout **un groupe** : les retraités venus par proximité. Les deux sont vrais, mais il faut le dire — c'est exactement la vérification demandée au chapitre 11 pour un individu de forte contribution.

Sur machine

Les valeurs propres

```
library(FactoMineR)
tab <- as.data.frame.matrix(table(clients$csp, clients$motif))
afc <- CA(tab, graph = FALSE)
e <- afc$eig
colnames(e) <- c("valeur", "pct", "cumul")
round(e, 4)
#       valeur     pct    cumul
# dim 1 0.2267 61.5955  61.5955
# dim 2 0.1030 27.9772  89.5726
# dim 3 0.0384 10.4274 100.0000
```

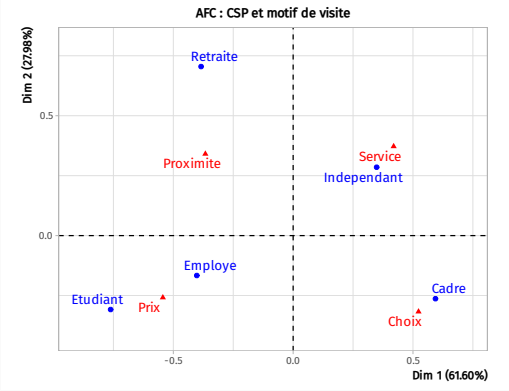
Les cinq CSP

```
round(cbind(afc$row$coord[, 1:2], ctr2 = afc$row$contrib[, 2]), 3)
#              Dim 1  Dim 2   ctr2
# Cadre         0.594 -0.263 16.145
# Employe      -0.402 -0.166  9.059
# Etudiant     -0.762 -0.308  6.769
# Independant   0.348  0.285 19.755
# Retraite     -0.384  0.705 48.272
```

Les colonnes

`afc$col$coord`, `afc$col$contrib` et `afc$col$cos2` donnent la même chose pour les quatre motifs ; `afc$row$cos2` les qualités des lignes.

Le plan tracé par R



Le signe, une dernière fois

`plot(afc)` place les retraités **en haut** : `FactoMineR` donne au deuxième axe le signe opposé à celui des figures du cours. Les associations — retraités et proximité du même côté — sont les mêmes.

numpy suffit : une décomposition en valeurs singulières

```
tab = pd.crosstab(clients.csp, clients.motif)
P = tab.to_numpy() / tab.to_numpy().sum()
r, c = P.sum(axis=1), P.sum(axis=0)
S = (P - np.outer(r, c)) / np.sqrt(np.outer(r, c))
u, s, vt = np.linalg.svd(S, full_matrices=False)
lam = s[:3] ** 2
print(lam.round(4), (100 * lam / lam.sum()).round(1))
# [0.2267 0.103  0.0384] [61.6 28.  10.4]
lignes = u[:, :2] * s[:2] / np.sqrt(r)[:, None]
colonnes = vt.T[:, :2] * s[:2] / np.sqrt(c)[:, None]
sg = np.array([np.sign(lignes[0, 0]), -np.sign(lignes[4, 1])])
lignes, colonnes = lignes * sg, colonnes * sg    # convention du cours
```

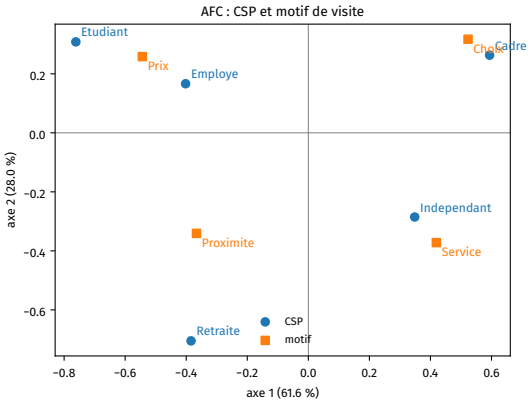
La matrice S

Chaque case de S vaut $\dfrac{p_{ij} - r_i c_j}{\sqrt{r_i c_j}}$: l'écart à l'indépendance, **réduit**. La somme de ses carrés est exactement $\Phi^2 = \chi^2/n$ – la case du khi-deux divisée par n.

Pourquoi une décomposition en valeurs singulières

Les carrés des valeurs singulières de S sont les valeurs propres de l'AFC, et ses vecteurs singuliers donnent les coordonnées. C'est la même diagonalisation qu'en ACP, appliquée à un écart à l'indépendance : **le cours de Master** montre que l'ACP et l'AFC sont un seul et même calcul.

Le plan tracé par matplotlib



Avec la convention du cours

Les retraités en bas, du côté de la proximité ; les cadres en haut à droite, du côté du choix. Le code de la figure est dans `figsrc/gen/fig_py.py`.

Ce que ce cours a construit

L'introduction et les treize chapitres

Unités	Acquis
Intro, 1	le problème de la dimension ; ce cours est de la descriptive **multivariée**
2–4	centrer et réduire, **covariance**, **corrélation**
5–6	le **nuage**, et l'**inertie** qui mesure son information
7–11	l'**ACP** : axes, valeurs propres, nombre d'axes, cercle, plan des individus
12–13	l'**AFC** : du khi-deux à la représentation

Cinq clients, accueil et fidélité

Chapitre	Grandeur	Valeur
2	moyennes ; variances	12 et 12 ; 8 et 32
3	covariance	$72/5 = 14{,}4$
4	$s_x s_y = \sqrt{256}$; **corrélation**	16 ; $14{,}4/16 = \mathbf{0{,}9}$
6	inertie des données réduites	2
8	valeurs propres	1,9 et 0,1
8	**inertie du premier axe**	$\mathbf{95}\,\%$
11	coordonnées sur l'axe 1	-2 ; $-0{,}5$; $-0{,}5$; 1 ; 2

Et pour l'AFC à la main : $\chi^2 = 64{,}1$, $\Phi^2 = 0{,}160$, un axe à $99{,}6\,\%$.

Trois cents clients

Chapitre	Grandeur	Valeur
1	clients 36 et 246	même moyenne, 13,9
6	inertie des huit notes réduites	8
8	deux premières valeurs propres	4,535 et 1,645
9	**inertie du plan**	**77,3 %**
10	les deux axes	niveau ; offre contre service
11	clients hebdomadaires sur l'axe 1	1,41
12	χ^2 CSP × motif ; Φ^2	110,41 ; 0,368
13	plan de l'AFC ; retraités sur l'axe 2	89,6 % ; 48,3 %

Trouver l'angle, et dire ce qu'il coûte

L'introduction posait une question : quel angle perd le moins d'information, et combien perd-il ?

Le chapitre 8 y a répondu par un nombre : sur nos cinq clients, le meilleur axe conserve $95\,\%$ de l'inertie. Sur les huit notes des trois cents clients, le meilleur plan en conserve $77{,}3\,\%$.

C'est tout ce que fait l'analyse des données : trouver l'angle, et dire ce qu'il coûte.

La suite, au Master

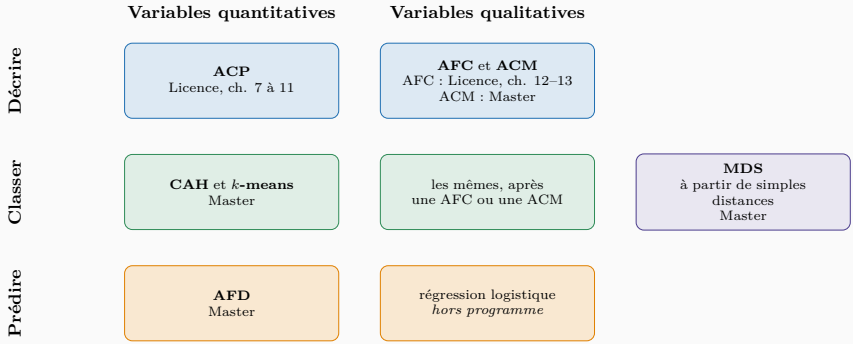
Ce qui reste à voir

Le cours d'analyse des données du niveau Master

Il reprend l'ensemble depuis le début, sur le même fichier clients.csv, et le prolonge :

Prolongement	Question à laquelle il répond
Correspondances **multiples**	et si l'on a **dix** variables qualitatives ?
Classification	comment constituer des groupes de clients ?
Analyse **discriminante**	dans quel groupe placer un **nouveau** client ?
Positionnement multidimensionnel	comment cartographier des ressemblances ?
Le formalisme	pourquoi ACP et AFC sont **le même calcul**

La carte des méthodes



Une seule question commande le choix : quelle est la nature des variables, et que veut-on en faire ?

Décrire un nuage, y former des groupes, ou séparer des groupes déjà connus. Les méthodes de l'analyse des données remplissent ce tableau — il n'y a pas d'autre case.

L'ACP sous d'autres noms

L'ACP réapparaîtra :

- en **économétrie financière**, comme méthode d'extraction de facteurs de risque ;
- en **apprentissage statistique**, comme réduction de dimension avant régression ;
- partout où le nombre de variables dépasse ce qu'on peut regarder.

Ce cours n'était donc pas une parenthèse : c'est l'un des outils les plus réemployés de tout le cursus.

Et l'AFC

L'AFC se retrouve partout où l'on croise des catégories : enquêtes, études de marché, textes (mots × documents). Son prolongement, l'ACM, est l'outil standard du traitement des questionnaires.

S’entraîner

Retrouver la coordonnée des seniors

Sur le petit tableau, $\lambda_1 = 0{,}1597$ et les colonnes ont pour coordonnées $0{,}237$ (magasin), $-0{,}609$ (web), $0{,}320$ (téléphone). Le profil des seniors est $(0{,}6; 0{,}133; 0{,}267)$.

1. Calculer la coordonnée des seniors sur l'axe 1.
2. Pourquoi est-elle positive ?

Exercice 1 : solution

0,367

1. $\dfrac{0{,}6 \times 0{,}237 + 0{,}133 \times (-0{,}609) + 0{,}267 \times 0{,}320}{0{,}400} = \dfrac{0{,}142 - 0{,}081 + 0{,}085}{0{,}400} = \dfrac{0{,}146}{0{,}400} = 0{,}366$, soit $0{,}367$ aux arrondis près.
2. Les seniors achètent surtout en **magasin** et par **téléphone**, deux colonnes de coordonnée positive, et très peu sur le web : la moyenne pondérée est tirée du côté positif.

Contribution et poids

Sur le tableau réel, $\lambda_2 = 0{,}1030$; les retraités pèsent $0{,}10$ et ont pour coordonnée $-0{,}705$ sur l'axe 2.

1. Calculer leur contribution à l'axe 2, sachant que ctr $=$ poids $\times\, F^2/\lambda$.
2. Pourquoi faut-il refaire l'analyse sans eux ? Que montre-t-elle ?

48,3 pour cent

1. $0{,}10 \times 0{,}705^2 / 0{,}1030 = 0{,}10 \times 0{,}497 / 0{,}1030 = 0{,}483$, soit $48{,}3\,\%$ — près de la moitié de l'axe pour un dixième des clients.
2. Pour savoir si l'axe décrit une **structure** ou un **groupe**. Sans eux, le premier axe reste le même et le deuxième oppose désormais le service au choix : l'ancien axe 2 était surtout celui des retraités.

Exercice 3 : vrai ou faux ?

Cinq phrases sur le plan réel

1. Les étudiants et les employés ont des profils de motif semblables.
2. Les retraités sont plus proches de la proximité que les indépendants du service, donc plus associés.
3. Les cadres viennent plus souvent pour le choix que l'ensemble des clients.
4. Le plan conserve $89{,}6\,\%$ de l'écart à l'indépendance.
5. L'AFC prouve que la CSP **cause** le motif de visite.

Exercice 3 : solution

Trois vrais, deux faux

1. **Vrai** : deux lignes proches ont des profils semblables (prix d'abord).
2. **Faux** : on ne compare pas des distances entre une ligne et une colonne ; on dit seulement que chacun est du côté de l'autre.
3. **Vrai** : même côté du plan, et $55{,}6\,\%$ contre $27{,}3\,\%$.
4. **Vrai** : $61{,}6 + 28{,}0 = 89{,}6\,\%$ de Φ^2.
5. **Faux** : l'AFC décrit une **association**. L'âge, le revenu ou le lieu de résidence peuvent expliquer à la fois la CSP et le motif.

Ce qu’il faut retenir

Six points, pour quatorze unités

1. Réduire la dimension, c'est **perdre de l'information** — la seule question est combien.
2. L'**inertie** mesure cette information ; sur données réduites, elle vaut p.
3. Les axes sont les **vecteurs propres** de la matrice des corrélations, les inerties leurs **valeurs propres** : $95\,\%$ sur un axe pour les cinq clients, $77{,}3\,\%$ sur deux pour les huit notes.
4. On ne commente **que** ce qui est bien représenté, et l'on vérifie qui a **construit** chaque axe.
5. L'AFC applique la même démarche à un écart à l'**indépendance**, mesuré par le khi-deux : $\Phi^2 = \lambda_1 + \lambda_2 + \ldots$
6. Lignes et colonnes se lisent par **directions communes** ; une catégorie rare peut fabriquer un axe.

Décrire, et bien

Aucune de ces méthodes ne teste quoi que ce soit, et aucune n'établit de causalité. Elles décrivent, et elles décrivent bien.

Leur mérite est de rendre **visible** une structure que trente colonnes de chiffres gardaient cachée. Ce que cette structure signifie, et ce qu'il faut en faire, relève du jugement — et des cours qui suivent.

Sur notre fichier, en deux phrases

Les clients se distinguent d'abord par leur **niveau** de satisfaction, puis par ce qu'ils apprécient : l'**offre** ou le **service**. Leur motif de visite oppose d'abord ceux qui viennent pour le **prix** à ceux qui viennent pour le **choix** et le **service**, et isole une clientèle **de proximité**.