


# Introduction à l'analyse des données

Chapitre 1 : Voir en deux dimensions ce qui en a beaucoup



---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 23 août 2026

Prérequis

Une photographie de chameau

Le même problème, en gestion

L'objet du cours

Ce qu'il faut retenir

## Prérequis

---

## Le cours qui précède

*Statistique descriptive*, en particulier la **covariance** et la **corrélation** — ce cours n'en est que le prolongement à plus de deux variables.

## Les notions mobilisées

Moyenne, variance, écart-type, covariance, corrélation. La variable centrée réduite, qui commande tout le reste.

Les trois premiers chapitres les rappellent : ce n'est pas une formalité, c'est là que se joue la compréhension de la suite.

### Ce cours ne suppose pas l'algèbre linéaire


Vecteur propre et valeur propre sont **rappelés au moment où ils servent**, sans démonstration.

C'est le parti pris du niveau Licence : montrer ce que font les méthodes. *Analyse des données avancée*, au Master, reprend l'ensemble et démontre pourquoi elles le font — et là, l'algèbre linéaire est exigée.

Une photographie de chameau


---

# Le problème du photographe



vue de face

qu'est-ce que c'est ?



vue de profil

deux bosses, une encolure : aucun doute

**Le même animal, le même appareil : seul l'angle a changé.**

Un chameau a *trois* dimensions ; une photographie n'en a que *deux*. Passer de l'un à l'autre détruit forcément de l'information — et le photographe choisit l'angle qui en détruit le moins.

**L'analyse des données fait exactement cela, sur un tableau de trente variables au lieu d'un animal.**

## Ce que l'image montre

### Le même animal, deux clichés

De **face**, un chameau photographié en noir et blanc est une colonne étroite surmontée d'une tache. Rien ne permet de reconnaître l'animal : ni les bosses, ni l'encolure, ni la ligne du dos.

De **profil**, il n'y a plus le moindre doute. Deux bosses, un long cou, une démarche caractéristique.

Pourtant, c'est le même animal, le même appareil, la même lumière. **Seul l'angle de prise de vue a changé.**

### Pourquoi l'angle décide de tout

Un chameau est un objet à **trois dimensions**. Une photographie est une surface à **deux dimensions**.

Passer de trois à deux **détruit nécessairement** de l'information : c'est le prix de l'aplatissement.

La seule question qui reste au photographe est donc : **quel angle en détruit le moins ?**

### Le métier du photographe, en une phrase

Il tourne autour de son sujet et cherche la position d'où la silhouette reste la plus reconnaissable.

Il ne cherche pas à conserver *toute* l'information — c'est impossible. Il cherche à conserver **la plus grande part possible**.



Le même problème, en gestion


---

## La situation ordinaire d'une entreprise

Une enseigne dispose d'un fichier de **trois cents clients**, chacun décrit par une **douzaine de variables** : montant dépensé, fréquence de visite, ancienneté, notes de satisfaction sur plusieurs critères, part des achats en promotion.

La direction pose une question simple : **quels sont les profils de nos clients?**

Le tableau, lui, ne répond rien. Trois cents lignes de chiffres ne se regardent pas.



**Et le problème n'est pas seulement le nombre de graphiques.**

Vingt-huit nuages pris deux à deux ne montrent que des liaisons *par paires*. Une structure qui n'apparaît qu'en combinant quatre variables reste invisible sur les vingt-huit.

**L'analyse des données ne fait pas plus de graphiques : elle en fait un seul, et le bon.**

# Pourquoi les graphiques usuels échouent

## Le décompte

Avec  $p$  variables, on peut tracer

$$\binom{p}{2} = \frac{p(p-1)}{2} \text{ nuages de points}$$

| Variables | Nuages à examiner |
|-----------|-------------------|
| 2         | 1                 |
| 8         | 28                |
| 12        | 66                |
| 30        | 435               |

## Et le nombre n'est pas le vrai problème

Même en acceptant d'examiner quatre cent trente-cinq graphiques, on ne verrait que des liaisons **deux à deux**.

## L'objet du cours

---

# La correspondance, terme à terme

## Deux problèmes, une seule méthode

| Le chameau                   | Le fichier clients                |
|------------------------------|-----------------------------------|
| un objet à 3 dimensions      | un tableau à $p$ variables        |
| une feuille à 2 dimensions   | un graphique plan                 |
| l'angle de prise de vue      | les <b>axes factoriels</b>        |
| la silhouette reconnaissable | la structure des données          |
| ce que la photo perd         | l' <b>inertie</b> non représentée |

## Analyse des données

L'**analyse des données** est l'ensemble des méthodes qui **réduisent la dimension** d'un tableau, en cherchant la représentation plane qui conserve la plus grande part de l'information.

## Ce que le cours va donc devoir faire

Trois choses, dans cet ordre :

1. **Mesurer l'information** contenue dans un tableau — sans quoi on ne peut pas dire qu'on en

# Ce que le cours ne fait pas

## Une mise au point utile dès maintenant

L'analyse des données ne **teste** rien. Elle ne calcule aucune  $p$ -value, ne rejette aucune hypothèse, ne conclut à aucune significativité.

Elle **explore** : elle fait apparaître des structures qu'on ne soupçonnait pas, et qu'il appartiendra ensuite de confirmer par d'autres moyens.

C'est pourquoi on l'appelle aussi **statistique exploratoire** — et c'est pourquoi elle vient *avant* l'inférence dans une démarche d'analyse, jamais après.

### Démarche confirmatoire

Statistique inférentielle, économétrie

une hypothèse **posée d'avance**



les données tranchent

on sait ce qu'on cherche

### Démarche exploratoire

Analyse des données

aucune hypothèse préalable



les données suggèrent

on cherche ce qu'on ne sait pas

**Les deux démarches ne s'opposent pas : elles se suivent.**

L'exploration fait *naître* les hypothèses ; la confirmation les *juge*. Une segmentation obtenue par classification n'est pas un résultat prouvé : c'est une hypothèse de travail, qu'il faudra tester sur d'autres données.

Ce qu'il faut retenir

---

## Cinq points

1. Un objet à trois dimensions photographié sur une feuille **perd** de l'information : la seule question est **combien**.
2. Le photographe cherche l'**angle** qui en perd le moins; l'analyse des données cherche les **axes**.
3. Avec  $p$  variables, il y a  $p(p - 1)/2$  nuages — et ils ne montrent que des liaisons **deux à deux**.
4. La méthode ne fait pas plus de graphiques : **elle en fait un seul, et le bon**.
5. C'est une démarche **exploratoire**, qui décrit et suggère, sans tester.

## La suite

Avant de construire quoi que ce soit, il faut situer ce cours par rapport à celui que vous connaissez déjà — la statistique descriptive. C'est l'objet du chapitre 2, et la réponse est plus simple qu'on ne l'imagine.