Introduction à l'analyse des données

Chapitre 11 : Le plan des individus

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 22 octobre 2026

Plan du chapitre

Placer les individus

Sur le fil rouge

Lire correctement le plan

La contribution d'un individu

Les variables illustratives

Croiser les deux plans

Sur machine

S'entraîner

Ce qu'il faut retenir

Placer les individus

Les coordonnées factorielles

Chaque **individu** est placé selon ses coordonnées sur les axes retenus — c'est-à-dire sa **projection** sur ces axes. Sa coordonnée sur l'axe k est la valeur, pour lui, de la composante C_k du chapitre 7 :

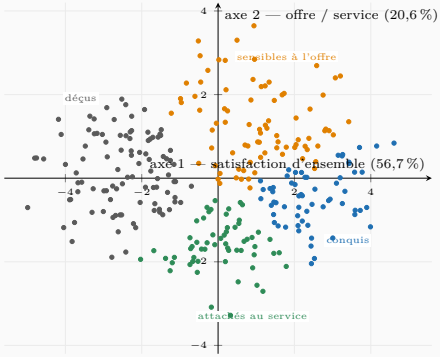
$$F_{ik} = \sum_{j=1}^{p} u_{jk}\, z_{ij}$$

C'est la photographie de l'introduction, enfin tirée.

Deux propriétés déjà vues

La moyenne des coordonnées sur un axe est **nulle** — le nuage est centré. Leur variance est la **valeur propre** : $V(F_k) = \lambda_k$. Et les coordonnées sur deux axes différents sont **non corrélées**.

Le plan des trois cents clients



Le même plan, vu du côté des clients.

Le cercle des corrélations disait ce que *signifient* les axes. Ce plan-ci dit *qui* se trouve où.

À droite : les clients satisfaits de tout. **À gauche** : les mécontents.

En haut : ceux qui louent l'offre et taisent le service. **En bas** : l'inverse.

Les quatre couleurs ne sont pas dans les données : elles viendront de la classification, étudiée au Master. Le nuage, lui, les suggérait déjà.

Ce que la position signifie

Quatre lectures

Position	Lecture
Proches l'un de l'autre	individus de profils semblables
Éloignés	profils différents
Loin du **centre**	individu atypique, fortement marqué
Près du **centre**	individu moyen, ou mal représenté

L'ambiguïté du centre

Un point proche de l'origine signifie soit un individu **moyen sur tout**, soit un individu **mal représenté** par ce plan. La figure seule ne tranche pas : d'où la **qualité de représentation**, plus bas.

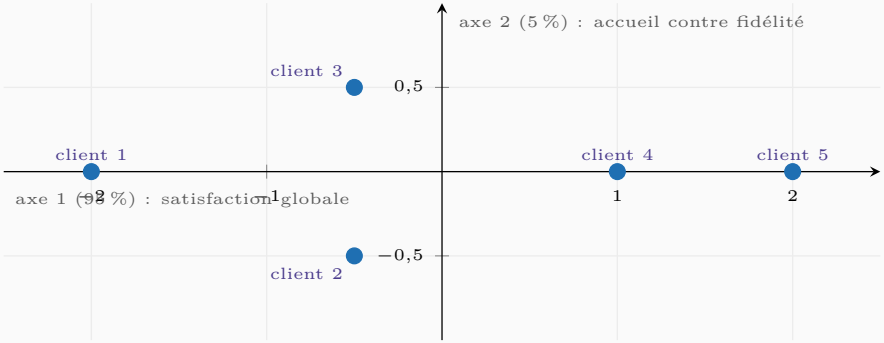
Sur le fil rouge

Coordonnées sur les deux axes

$F_1 = (z_x + z_y)/\sqrt{2}$ et $F_2 = (z_x - z_y)/\sqrt{2}$ – les composantes du chapitre 7 :

Client	Accueil	Fidélité	F_1	F_2
1	8	4	−2	0
2	10	12	−0,5	−0,5
3	12	8	−0,5	0,5
4	14	16	1	0
5	16	20	2	0

Les cinq clients, dans le plan



Ce que la figure montre

Sur l'axe 1, les clients s'ordonnent du moins au plus satisfait : 1, puis 2 et 3 **à égalité**, puis 4 et 5. Les clients 2 et 3 ne se distinguent que sur le **second** axe.

Les extrêmes, et les deux cas mixtes

Les clients 1 et 5 sont aux extrémités de l'axe 1 : l'un est faible sur les deux critères, l'autre fort sur les deux. Sur l'axe 2, ils sont à 0 : leurs deux notes réduites sont égales.

Le client 2 ($F_2 = -0{,}5$) est **plus fidèle qu'accueilli** ; le client 3 ($F_2 = +0{,}5$) l'inverse. C'est précisément l'information que porte l'axe à $5\,\%$.

Une erreur de l'ancienne version du cours

L'ancien tableau rangeait le client 3 sous le client 2 sur le premier axe. Le calcul les donne **égaux** ($-0{,}5$) : leurs sommes de notes réduites sont les mêmes ($-0{,}707$). Ce sont les écarts entre leurs deux notes, non leur niveau, qui les distinguent.

Lire correctement le plan

Le cosinus carré d'un individu

Elle mesure la part de l'inertie d'un individu **effectivement restituée** par le plan :

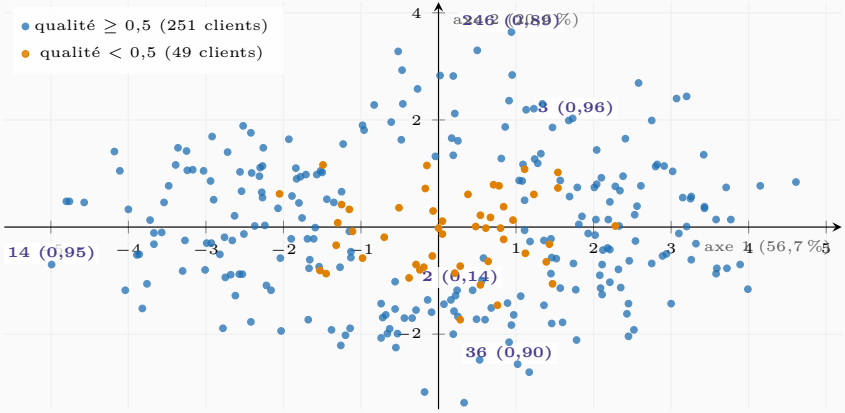
$$\cos_i^2 = \frac{F_{i1}^2 + F_{i2}^2}{d^2(i,G)}$$

Elle se lit comme un pourcentage : $0{,}85$ signifie que le plan rend compte de $85\,\%$ de la position réelle de cet individu.

Sur les cinq clients, avec le seul axe 1

Client	1	2	3	4	5
F_1^2	4	0,25	0,25	1	4
$d^2(i,G)$	4	0,5	0,5	1	4
$\cos^2$ sur l'axe 1	1	0,5	0,5	1	1

Qui est bien représenté, sur le fichier réel



251 clients bien représentés, 49 mal

La qualité médiane vaut $0{,}77$. Mais 49 clients sont représentés à moins de $50\,\%$, et 18 à moins de $20\,\%$. Les points orange se concentrent **près du centre**.

Les clients 3 et 2

Client	$\cos^2$	prix	choix	qualité	rapidité	conseil	accueil
3	0,96	15,2	16,1	17,1	11,5	11,3	12,7
2	0,14	10,2	11,0	14,9	10,4	15,9	14,9

Coordonnées : client 3 en $(1{,}23\,;\ 2{,}21)$, client 2 en $(0{,}28\,;\ -0{,}73)$. Moyennes de l'ensemble : $11{,}4$; $13{,}2$; $14{,}1$; $12{,}3$; $12{,}8$; $13{,}9$.

Ce qu'on peut dire de chacun

Le client 3 est représenté à $96\,\%$: on peut affirmer qu'il **loue l'offre** (prix, choix, qualité) et juge le service moyen. Le client 2 n'est représenté qu'à $14\,\%$: sa position, près du centre, ne dit rien — ses notes s'écartent de la moyenne de façon **désordonnée**, dans des directions que le plan ne montre pas.

Ne jamais commenter un individu mal représenté

Un client dont la qualité vaut $0{,}12$ apparaît quelque part sur la figure, mais cette position ne veut rien dire : il vit dans des dimensions qu'on n'a pas tracées.

C'est exactement la même prudence qu'au chapitre 10 pour les variables proches du centre — et elle est aussi souvent oubliée.

Le rappel du chapitre 9

Les clients 28 et 79, presque superposés sur le plan, étaient à $4{,}00$ l'un de l'autre dans l'espace des huit notes. Leurs qualités ($0{,}08$ et $0{,}11$) **interdisaient** de les dire semblables.

La contribution d’un individu

La part d'un individu dans un axe

$$\text{ctr}_{ik} = \frac{F_{ik}^2}{n\,\lambda_k}$$

Elle mesure la part d'un individu dans la **construction** de l'axe k. Les contributions à un axe somment à $100\,\%$, et leur moyenne vaut $1/n$.

Une autre question que la qualité

La qualité dit si **l'axe représente bien l'individu** ; la contribution dit si **l'individu a fabriqué l'axe**. Un individu peut être parfaitement représenté sans avoir rien construit — et l'inverse.

Les contributions aux deux axes

Client	1	2	3	4	5
axe 1	42,1 %	2,6 %	2,6 %	10,5 %	42,1 %
axe 2	0	50 %	50 %	0	0

Axe 1 : $F_1^2/(5 \times 1{,}9)$, par exemple $4/9{,}5 = 42{,}1\,\%$. Axe 2 : $F_2^2/(5 \times 0{,}1)$, soit $0{,}25/0{,}5 = 50\,\%$.

Deux clients ont fait l'axe 2 à eux seuls

Sur cinq individus, la moyenne est de $20\,\%$. Les clients 1 et 5 font $84\,\%$ de l'axe 1 ; les clients 2 et 3 font **tout** l'axe 2. Avec si peu d'individus, chaque axe décrit quelques cas particuliers : c'est la limite du fil rouge.

Les plus gros contributeurs

Client	F_1	F_2	ctr axe 1	ctr axe 2
14	$-4{,}99$	$-0{,}70$	$\mathbf{1{,}83}\,\%$	$0{,}10\,\%$
168	$-4{,}80$	$0{,}48$	$1{,}70\,\%$	$0{,}05\,\%$
246	$0{,}94$	$3{,}64$	$0{,}06\,\%$	$\mathbf{2{,}69}\,\%$

La moyenne vaut $1/300 = 0{,}33\,\%$.

Aucun client ne domine

Le client 14, mécontent de tout (prix $6{,}2$, conseil $8{,}3$), pèse $5{,}5$ fois la moyenne de l'axe 1 ; le client 246, l'amateur d'offre du chapitre 1, 8 fois la moyenne de l'axe 2. C'est beaucoup, mais **aucun** n'approche $10\,\%$: les axes décrivent une structure partagée par l'ensemble des clients.

Une contribution anormale

Si une contribution dépasse largement la moyenne $1/n$ — par exemple 10 ou 20 fois —, il faut se demander si cet individu est une **erreur de saisie** ou un cas réellement exceptionnel.

Refaire l'analyse sans lui

Dans les deux cas, refaire l'analyse **sans lui** et comparer les résultats. Si les axes changent complètement, le premier résultat ne décrivait pas la population : il décrivait un point. C'était le sixième client du chapitre 4, qui faisait tomber la corrélation de $0{,}9$ à $0{,}035$.

Les variables illustratives

Deux rôles

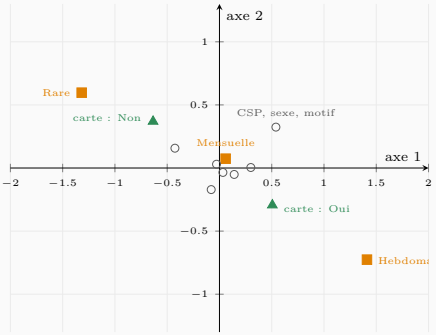
Une variable **active** participe au calcul des axes. Une variable **illustrative** n'y participe pas : on la projette après coup, pour aider à l'interprétation.

Comment on projette

Une modalité qualitative (« client hebdomadaire ») se place au **barycentre** des individus qui la portent : la moyenne de leurs coordonnées.

Une variable quantitative (l'âge) se place, sur le cercle, selon ses corrélations avec les axes.

La fréquence de visite, en illustratif



Deux variables parlent, cinq se taisent.

La **fréquences**'étire le long de l'axe 1, de −1,32 à +1,41 : *le client satisfait revient.* La **carte de fidélité**raconte la même histoire.

La CSP, le sexe et le motif de visite s'agglutinent au centre. Leurs coordonnées restent sous 0,6 en valeur absolue.

C'est un résultat, pas un échec. La satisfaction ne dépend pas de qui l'on est. Un service marketing qui segmente par âge et par CSP passe à côté de ce qui structure réellement sa clientèle.

Les modalités de quatre variables

Variable	Modalité	Effectif	F_1	F_2
fréquence	hebdomadaire	101	1,41	−0,73
	mensuelle	87	0,06	0,07
	rare	112	−1,32	0,60
carte	oui	167	0,51	−0,29
	non	133	−0,64	0,37
sexe	femme / homme	162 / 138	∓0,03	±0,03

Ce que disent ces nombres

Les clients hebdomadaires sont en moyenne à $1{,}41$ sur l'axe du niveau général : **le client satisfait revient**. Les deux sexes sont confondus avec l'origine : la satisfaction ne dépend pas du sexe.

La structure d'abord, l'explication ensuite

On construit les axes sur les seules notes de satisfaction — variables actives. Puis on projette, en illustratif, la fréquence, la carte de fidélité, la CSP.

Si les clients hebdomadaires se groupent d'un côté du premier axe, on a trouvé un lien entre fréquence et satisfaction **sans que la fréquence ait construit les axes**. L'ordre inverse serait circulaire.

Les illustratives quantitatives

Leurs corrélations avec les deux axes : panier $0{,}20$ et $-0{,}14$; ancienneté $0{,}14$ et $-0{,}04$; âge $-0{,}05$ et $-0{,}03$. Trois flèches **près du centre** du cercle : aucune de ces variables n'est vraiment liée aux deux dimensions de la satisfaction.

Croiser les deux plans

La règle de lecture conjointe

Un individu situé du côté où pointe une variable a une **valeur élevée** sur cette variable.

C'est ce qui permet de **nommer les groupes** : les individus placés là où pointent les critères de service sont les clients satisfaits du service.

Une précaution sur la superposition

Les deux nuages ne vivent pas dans le même espace — l'un dans $\mathbb{R}^p$, l'autre dans $\mathbb{R}^n$, comme au chapitre 5.

Les superposer sur une même figure est une **commodité de lecture**, pas une identité mathématique. On lit des **directions**, jamais des distances entre un individu et une variable.

Quatre profils, et une figure

Au terme de l'analyse, on sait dire : *il existe des clients satisfaits de tout, des clients déçus de tout, et, à niveau égal, des clients sensibles à l'offre et d'autres attachés au service* — et l'on sait montrer sur quelle figure cela se lit.

C'est un résultat descriptif, obtenu sans avoir posé aucune hypothèse. Le vérifier, le tester, en tirer une politique commerciale relève d'autres cours.

Sur le fichier réel

Les clients hebdomadaires et porteurs de la carte se placent du côté des satisfaits, et légèrement du côté du **service** ($F_2 < 0$) ; les clients rares, du côté des déçus et de l'**offre**.

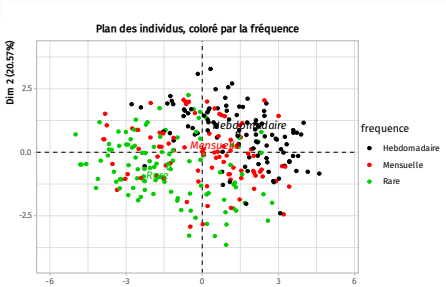
Sur machine

Coordonnées, qualités et contributions

```
clients <- read.csv("clients.csv", stringsAsFactors = TRUE)
acp <- PCA(clients[, c(notes, "frequence")], quali.sup = 9,
           graph = FALSE)      # colonne 9 illustrative
ind <- cbind(acp$ind$coord[, 1:2],
             cos2 = rowSums(acp$ind$cos2[, 1:2]),
             ctr1 = acp$ind$contrib[, 1])
round(ind[c(2, 14, 36, 246), ], 2)
#     Dim.1 Dim.2 cos2 ctr1
# 2    0.28  0.73 0.14 0.01
# 14  -4.99  0.70 0.95 1.83
# 36   0.91  2.15 0.90 0.06
# 246  0.94 -3.64 0.89 0.06
```

Les barycentres, puis la figure

```
round(acp$quali.sup$coord[, 1:2], 2)
#               Dim.1 Dim.2
# Hebdomadaire  1.41  0.73
# Mensuelle     0.06 -0.07
# Rare         -1.32 -0.60
plot(acp, choix = "ind", habillage = 9, label = "quali")
```



Coordonnées, qualités et contributions

```
X = clients[notes]
Z = ((X - X.mean()) / X.std(ddof=0)).to_numpy()
lam, U = np.linalg.eigh(np.corrcoef(Z.T))
lam, U = lam[::-1], U[:, ::-1]
U = U * np.sign(U[0])                    # prix positif sur chaque axe
F = Z @ U                                # coordonnées des individus
cos2 = (F[:, :2] ** 2).sum(axis=1) / (Z ** 2).sum(axis=1)
ctr1 = 100 * F[:, 0] ** 2 / (len(Z) * lam[0])
print(round(ctr1.max(), 2), clients.id[ctr1.argmax()])   # 1.83 14
print((cos2 < 0.5).sum())                                # 49
```

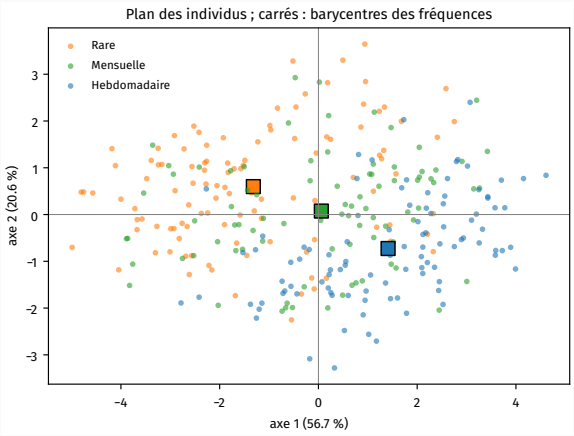
Un groupby suffit

```
bary = pd.DataFrame(F[:, :2], columns=["F1", "F2"])
print(bary.groupby(clients.frequence).mean().round(2))
#                  F1    F2
# frequence
# Hebdomadaire   1.41 -0.73
# Mensuelle      0.06  0.07
# Rare          -1.32  0.60
```

Un barycentre est une moyenne

Projeter une modalité illustrative, c'est **moyenner** les coordonnées des individus qui la portent : `groupby` puis `mean`. Avec la convention du cours, les hebdomadaires sont en bas, côté service.

Le plan tracé par matplotlib



Un nuage, trois couleurs, trois barycentres

Les carrés sont les barycentres des trois fréquences : $1{,}41$, $0{,}06$ et $-1{,}32$ sur l'axe 1.

S’entraîner

Projeter un individu supplémentaire

Un sixième client note l'accueil 13 et la fidélité 9. On le projette sur les axes des cinq clients, sans refaire l'analyse.

1. Calculer ses valeurs réduites (moyennes 12 et 12, écarts-types $2{,}83$ et $5{,}66$).
2. Calculer ses coordonnées F_1 et F_2.
3. Est-il bien représenté par le seul axe 1 ? Que dit l'axe 2 de lui ?

Un client mal représenté par l'axe 1

1. $z_x = 1/2{,}83 = 0{,}354$; $z_y = -3/5{,}66 = -0{,}530$.
2. $F_1 = (0{,}354 - 0{,}530)/\sqrt{2} = -0{,}125$; $F_2 = (0{,}354 + 0{,}530)/\sqrt{2} = 0{,}625$.
3. $\cos^2$ sur l'axe $1 : 0{,}0156/(0{,}0156 + 0{,}391) = 0{,}04$. **Très mal représenté** : il n'est ni satisfait ni mécontent dans l'ensemble, mais il est nettement **mieux accueilli que fidèle** ($F_2 = 0{,}625$, plus que le client 3). Il est tout entier sur l'axe à $5\,\%$.

Trois clients du fichier réel

Client	F_1	F_2	$d^2(i, G)$
4	$-3{,}30$	$-0{,}82$	$13{,}55$
36	$0{,}91$	$-2{,}15$	$6{,}01$
246	$0{,}94$	$3{,}64$	$15{,}88$

1. Calculer la qualité de représentation de chacun sur le plan.
2. Calculer leur contribution à l'axe 2 ($n = 300$, $\lambda_2 = 1{,}645$).
3. Lequel pèse le plus dans l'axe 2 ? Est-ce inquiétant ?

Bien représentés, sans dominer

1. Client 4 : $(10{,}89 + 0{,}67)/13{,}55 = 0{,}85$. Client 36 : $(0{,}83 + 4{,}62)/6{,}01 = 0{,}91$. Client 246 : $(0{,}88 + 13{,}25)/15{,}88 = 0{,}89$.
2. Dénominateur $300 \times 1{,}645 = 493{,}5$. Client 4 : $0{,}67/493{,}5 = 0{,}14\,\%$; client 36 : $4{,}62/493{,}5 = 0{,}94\,\%$; client 246 : $13{,}25/493{,}5 = \mathbf{2{,}7}\,\%$.
3. Le client 246, huit fois la moyenne ($0{,}33\,\%$). Ce n'est pas inquiétant : $2{,}7\,\%$ ne suffit pas à fabriquer un axe, et son profil (offre excellente, service médiocre) est bien celui que l'axe décrit.

Un barycentre à la main

Parmi les cinq clients du fil rouge, les clients 1, 2 et 3 n'ont pas la carte de fidélité ; les clients 4 et 5 l'ont.

1. Calculer les barycentres des deux modalités sur les deux axes.
2. Vérifier que la moyenne pondérée des deux barycentres est nulle.
3. Interpréter.

La carte du côté des satisfaits

1. Sans carte : $F_1 = (-2 - 0{,}5 - 0{,}5)/3 = -1$, $F_2 = (0 - 0{,}5 + 0{,}5)/3 = 0$. Avec carte : $F_1 = (1 + 2)/2 = 1{,}5$, $F_2 = 0$.
2. $(3 \times (-1) + 2 \times 1{,}5)/5 = 0$: les barycentres pondérés par les effectifs retombent sur le centre, puisque les coordonnées sont centrées.
3. Les porteurs de carte sont du côté **satisfait** de l'axe 1, comme sur le fichier réel ($0{,}51$ contre $-0{,}64$). La carte n'a pas servi à construire l'axe : le lien est une **découverte**, non un artefact.

Ce qu’il faut retenir

Six points

1. Les individus sont placés selon leurs **projections** $F_{ik} = \sum_j u_{jk} z_{ij}$; sur le fil rouge, $(-2\,;0)$, $(-0{,}5\,;-0{,}5)$, $(-0{,}5\,;0{,}5)$, $(1\,;0)$, $(2\,;0)$.
2. Un point **central** est soit moyen, soit mal représenté — la figure ne tranche pas.
3. La **qualité de représentation** ($\cos^2$) décide de ce qu'on a le droit de commenter : 49 clients sur 300 sont sous $0{,}5$.
4. La **contribution** $F_{ik}^2/(n\lambda_k)$ dit qui a construit l'axe ; au plus $1{,}83\,\%$ et $2{,}69\,\%$ sur nos axes, pour une moyenne de $0{,}33\,\%$.
5. Les variables **illustratives** se projettent après coup : les clients hebdomadaires à $1{,}41$, les rares à $-1{,}32$.
6. On lit individus et variables ensemble par **directions**, jamais par distances croisées.

Et les variables qualitatives ?

Tout ce qui précède suppose des variables **quantitatives**. Que faire d'un tableau de catégories — CSP, motif de visite, canal d'achat ?

Le chapitre 12

La réponse commence par un test que vous connaissez déjà, le khi-deux, appliqué au croisement de la CSP et du motif de visite des trois cents clients.