


# Introduction à l'analyse des données

## Chapitre 3 : Rappels sur une variable : centrer et réduire



---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 23 août 2026

Le fil rouge du cours

La moyenne et la variance

Centrer et réduire

Ce qu'il faut retenir

## Le fil rouge du cours

---

## Cinq clients, deux critères

### Le tableau qui portera tout le cours

Cinq clients ont noté l'enseigne sur deux critères, de 0 à 20 :

| Client | Accueil $X$ | Fidélité $Y$ |
|--------|-------------|--------------|
| 1      | 8           | 4            |
| 2      | 10          | 12           |
| 3      | 12          | 8            |
| 4      | 14          | 16           |
| 5      | 16          | 20           |

### Pourquoi cinq lignes

Un fichier réel en compte des milliers. Cinq permettent de **tout vérifier à la main**, et c'est le seul moyen de comprendre ce que les logiciels calculent.

Ce tableau reviendra à chaque chapitre jusqu'à l'analyse en composantes principales.

## La moyenne et la variance

---

### La moyenne

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

### Sur nos données

$$\bar{x} = \frac{8 + 10 + 12 + 14 + 16}{5} = \frac{60}{5} = 12 \qquad \bar{y} = \frac{4 + 12 + 8 + 16 + 20}{5} = \frac{60}{5} = 12$$

Les deux variables ont la **même moyenne**. Elles ne se ressemblent pourtant pas du tout, et c'est la variance qui va le dire.

## Définition

$$V(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

C'est la **moyenne des carrés des écarts** à la moyenne. L'**écart-type**  $s_x = \sqrt{V(x)}$  la ramène à l'unité de la variable.

## Le calcul, écart par écart

### Les cinq écarts, et leurs carrés

| Client | $x_i - \bar{x}$ | $(x_i - \bar{x})^2$ | $y_i - \bar{y}$ | $(y_i - \bar{y})^2$ |
|--------|-----------------|---------------------|-----------------|---------------------|
| 1      | -4              | 16                  | -8              | 64                  |
| 2      | -2              | 4                   | 0               | 0                   |
| 3      | 0               | 0                   | -4              | 16                  |
| 4      | 2               | 4                   | 4               | 16                  |
| 5      | 4               | 16                  | 8               | 64                  |
| Somme  | <b>0</b>        | <b>40</b>           | <b>0</b>        | <b>160</b>          |

$$V(x) = \frac{40}{5} = 8 \quad V(y) = \frac{160}{5} = 32$$

$$s_x = \sqrt{8} \approx 2,83 \quad s_y = \sqrt{32} \approx 5,66$$



Centrer et réduire

---

# L'opération qui commande tout le cours

## La variable centrée réduite

$$z_i = \frac{x_i - \bar{x}}{s_x}$$

**Centrer**, c'est retrancher la moyenne. **Réduire**, c'est diviser par l'écart-type.

## Sur l'accueil

| Client | $x_i$ | $x_i - 12$ | $z_i = \frac{x_i - 12}{2,83}$ |
|--------|-------|------------|-------------------------------|
| 1      | 8     | -4         | -1,414                        |
| 2      | 10    | -2         | -0,707                        |
| 3      | 12    | 0          | 0                             |
| 4      | 14    | 2          | 0,707                         |
| 5      | 16    | 4          | 1,414                         |

Moyenne nulle, variance unité

$$\bar{z} = 0 \qquad V(z) = 1$$



**Toute** variable centrée réduite a une moyenne nulle et une variance de un, quelles que soient ses valeurs de départ.

# Pourquoi c'est indispensable ici

## Le problème des unités

Un fichier client mêle des variables sans commune mesure : un montant en dirhams qui varie de 200 à 50 000, une note de satisfaction entre 1 et 5, une ancienneté en années.

La variance du montant se compte en millions; celle de la note, en dixièmes. Sans précaution, **le montant écraserait tout** : compter en milliers de dirhams plutôt qu'en dirhams changerait les conclusions. C'est inacceptable.



Ce qu'il faut retenir

---

### Cinq points

1. Le fil rouge : **cinq clients**, accueil et fidélité, moyennes toutes deux égales à 12.
2.  $V(x) = 8$  et  $V(y) = 32$  : même moyenne, dispersions très différentes.
3. La somme des écarts à la moyenne vaut **toujours zéro** — c'est un contrôle.
4. La variable **centrée réduite**  $z = (x - \bar{x})/s_x$  a une moyenne de 0 et une variance de 1.
5. Réduire donne à chaque variable **le même poids** et supprime l'effet des unités.

### La suite

Une variable est décrite. Il faut maintenant en relier **deux** — et le chapitre 4 montre que l'outil pour le faire n'est pas nouveau : c'est la variance, généralisée.