


# Introduction à l'analyse des données

## Chapitre 6 : Le tableau de données et le nuage



---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 23 août 2026

Le tableau

Les deux nuages

Le centre de gravité

Ce que le nuage permet de dire

Ce qu'il faut retenir

## Le tableau

---

| client | 8 notes de satisfaction |       |     |         | signalétique |           |
|--------|-------------------------|-------|-----|---------|--------------|-----------|
|        | prix                    | choix | ... | accueil | CSP          | fréquence |
| 1      | 13,2                    | 15,4  | ... | 16,1    | Cadre        | Hebdo.    |
| 2      | 9,8                     | 11,0  | ... | 10,4    | Employé      | Rare      |
| ⋮      | ⋮                       | ⋮     |     | ⋮       | ⋮            | ⋮         |
| 300    | 12,5                    | 13,9  | ... | 14,8    | Retraité     | Mensuelle |

variables **actives** : elles construisent les axes      variables **illustratives** : on les projette ensuite

**Le choix des variables actives est la seule décision vraiment engageante de toute l'analyse.**

Elles fixent la géométrie du nuage — donc les axes, donc l'interprétation. Les illustratives n'y participent pas : on les superpose après coup pour *éclairer* les axes, jamais pour les construire.

Mettre le chiffre d'affaires en actif quand on étudie la satisfaction, c'est laisser la taille des clients écraser leur opinion.

## Le tableau individus-variables

$n$  lignes — les **individus** — et  $p$  colonnes — les **variables**. La case  $(i, j)$  porte la valeur de la variable  $j$  pour l'individu  $i$ .

C'est le format d'entrée de toute l'analyse des données.

## Les deux nuages

---

# Un tableau, deux lectures

## Le nuage des individus


Chaque **ligne** devient un **point** dans un espace à  $p$  dimensions : ses coordonnées sont ses  $p$  valeurs.

Cinq clients notés sur deux critères donnent cinq points dans un plan.

## Le nuage des variables

Chaque **colonne** devient un **point** dans un espace à  $n$  dimensions.

Deux variables observées sur cinq clients donnent deux points dans un espace à cinq dimensions.



**Une seule ACP, deux lectures — c'est ce qu'on appelle la dualité.**

On ne fait pas deux calculs : la décomposition de la matrice des corrélations donne *en même temps* les axes des individus et ceux des variables. Le pourcentage d'inertie est donc le même des deux côtés.

**D'où la méthode de lecture, invariable :** on interprète d'abord le *cercle des corrélations* — il donne le *sens* des axes — puis le *plan des individus* — il dit *qui* se trouve où. Jamais l'inverse.

## Cinq points dans le plan

| Client | Accueil | Fidélité |
|--------|---------|----------|
| 1      | 8       | 4        |
| 2      | 10      | 12       |
| 3      | 12      | 8        |
| 4      | 14      | 16       |
| 5      | 16      | 20       |

Placés dans un repère, ces cinq points s'alignent presque : c'est la traduction visuelle du  $r = 0,9$  du chapitre 5.

**Avec deux variables, on voit tout.** Le problème du chapitre 1 ne se pose pas encore — il commencera à trois.

## Le centre de gravité

---

# Le point moyen

## Centre de gravité

Le **centre de gravité**  $G$  du nuage est le point dont les coordonnées sont les **moyennes** de chaque variable :

$$G = (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_p)$$

## Sur le fil rouge

$$G = (12; 12)$$

Les deux moyennes valant 12, le centre du nuage est le point (12 ; 12).

## Ce que centrer signifie géométriquement

Centrer les variables, comme au chapitre 3, revient à **déplacer l'origine du repère en  $G$** .

Le nuage ne change ni de forme, ni de taille, ni d'orientation : seul le point d'où on le regarde a bougé.

C'est une préparation nécessaire, car les axes qu'on cherchera **passeront tous par le centre du nuage**.

Un axe qui n'y passerait pas ne pourrait pas résumer l'ensemble.

## Après centrage et réduction

Ce que le nuage permet de dire

---

# Distances et ressemblances

## La distance entre deux individus

Sur données réduites, la distance entre deux individus  $i$  et  $i'$  se calcule par le théorème de Pythagore, étendu à  $p$  dimensions :

$$d(i, i') = \sqrt{\sum_{j=1}^p (z_{ij} - z_{i'j})^2}$$

## Ce que la géométrie apporte

Deux clients **proches** dans le nuage ont des valeurs semblables sur l'ensemble des critères. Deux clients **éloignés** diffèrent.

Toute la question « quels clients se ressemblent ? » devient donc une question de **distance** — et c'est ce basculement du tableau vers la géométrie qui rend la suite possible.

## Pourquoi la réduction est ici décisive

Sans réduction, la distance serait dominée par la variable de plus grande dispersion : deux clients seraient jugés éloignés parce qu'ils diffèrent en montant dépensé, quelle que soit leur satisfaction.

Ce qu'il faut retenir

---

### Cinq points

1. Le tableau **individus-variables** est le format d'entrée :  $n$  lignes,  $p$  colonnes.
2. Il se lit de **deux façons** : nuage des individus dans  $\mathbb{R}^p$ , nuage des variables dans  $\mathbb{R}^n$ .
3. Le **centre de gravité** a pour coordonnées les moyennes — ici (12 ; 12).
4. **Centrer** revient à placer l'origine en  $G$  ; la forme du nuage ne change pas.
5. La **ressemblance** entre individus devient une **distance**, ce qui rend la géométrie utilisable.

### La suite

Le nuage est en place. Reste à mesurer l'information qu'il contient — sans quoi on ne pourra pas dire qu'une projection en conserve beaucoup ou peu.

C'est l'inertie, et c'est le chapitre 7.