

Modélisation ARMA des rentabilités financières

Chapitre 16 : Mise en œuvre sur R

Jaouad Madkour

25 septembre 2026

Plan du chapitre

Avant de commencer	2
Le jeu de données	2
Les bibliothèques	2
Étape 1 — Lire et décrire	2
Charger la série	2
Les faits stylisés, en trois nombres	2
Regarder la série	3
Étape 2 — La stationnarité	3
Les trois tests du chapitre 8	3
Croiser les conclusions	4
Étape 3 — Identifier	4
Les corrélogrammes	4
Le test de blancheur, d'emblée	4
La sélection automatique	5
Comparer les candidats à la main	5
Étape 4 — Estimer et valider	5
Estimer, pour la démonstration	5
Valider	6
Valider (suite)	6
Valider (suite 2)	6
Étape 5 — Prévoir	6
Prévision ponctuelle et intervalle	6
Étape 6 — Ce qui a échappé	7
Regarder les résidus au carré	7
Le test ARCH	7
Ce qu'il faut modéliser maintenant	7
Synthèse	8

Avant de commencer

Le jeu de données

Le fichier rentabilites.csv

2 000 rentabilités quotidiennes **simulées**, fournies avec le cours. Trois colonnes : **date**, **prix**, **rentabilite** (en pourcentage).

Pourquoi des données simulées

Parce qu'on sait ce qu'on y a mis. Le mécanisme générateur est connu : aucune mémoire en niveau, une forte persistance de la volatilité. On peut donc vérifier que la démarche **re-trouve** ce qui s'y trouve — et ne trouve pas ce qui ne s'y trouve pas. Sur données réelles, on ne peut jamais faire cette vérification.

Les bibliothèques

```
install.packages(c("forecast", "tseries", "FinTS"))
library(forecast) # Acf, Pacf, auto.arima, forecast, checkresiduals
library(tseries) # adf.test, kpss.test, jarque.bera.test
library(FinTS)   # ArchTest
```

Étape 1 — Lire et décrire

Charger la série

```
don <- read.csv("rentabilites.csv", stringsAsFactors = FALSE)
don$date <- as.Date(don$date)
r <- don$rentabilite
T <- length(r) # 2000
```

```
c(moyenne = mean(r),
  ecart_type = sd(r),
  minimum = min(r),
  maximum = max(r))
```

moyenne	ecart_type	minimum	maximum
0.0300	1.1764	-5.8412	4.9037

Les faits stylisés, en trois nombres


```
library(moments)
skewness(r) # -0.19
kurtosis(r) # 6.60
jarque.bera.test(r)
```

Ce que ces nombres disent

Un kurtosis de 6,6 contre 3 pour une gaussienne : les valeurs extrêmes sont bien plus fréquentes que la loi normale ne l'autorise. Jarque-Bera rejette massivement. Ce n'est **pas** un obstacle à la modélisation ARMA — le chapitre 13 l'a établi, l'estimateur reste convergent. C'est un obstacle aux **intervalles de prévision**.

Regarder la série

```
plot(don$date, r, type = "l", col = "steelblue",  
      xlab = "", ylab = "rentabilité (%)")  
abline(h = 0, lty = 2, col = "grey40")
```



Ce qu'on voit avant tout calcul

Pas de tendance, pas de dérive : la moyenne semble stable. Mais l'amplitude, elle, ne l'est pas — des blocs calmes alternent avec des blocs agités. Retenez cette observation : le test formel viendra à la fin.

Étape 2 — La stationnarité

Les trois tests du chapitre 8

```
adf.test(r)           # H0 : racine unitaire  
pp.test(r)            # idem, Phillips-Perron  
kpss.test(r, null = "Level") # H0 : stationnarité
```

Augmented Dickey-Fuller Test

Dickey-Fuller = -12.517, Lag order = 12, p-value = 0.01

alternative hypothesis: stationary

KPSS Test for Level Stationarity

KPSS Level = 0.1174, Truncation lag parameter = 8, p-value = 0.1

Croiser les conclusions

Lecture

ADF **rejette** la racine unitaire ($p < 0,01$). KPSS **ne rejette pas** la stationnarité ($p > 0,1$). C'est la première ligne de la table de décision du chapitre 8 : conclusion **sans ambiguïté**, la série est $I(0)$.


Un avertissement de R à ne pas mal lire

R affiche `p-value smaller than printed p-value`. Cela signifie que la p -valeur est **hors table**, donc encore plus petite que 0,01 — pas qu'il y a un problème.

Étape 3 — Identifier

Les corrélogrammes

```
par(mfrow = c(1, 2))
Acf(r, lag.max = 20, main = "ACF des rentabilités")
Pacf(r, lag.max = 20, main = "PACF des rentabilités")
```



Le diagnostic, et il est décevant

Les 20 autocorrélations sont **toutes** à l'intérieur des bandes $\pm 1,96/\sqrt{2000} = \pm 0,044$. La plus forte vaut 0,034 au retard 3.

Aucune structure. Le candidat naturel est ARMA(0,0) — le bruit blanc.

Le test de blancheur, d'emblée

```
Box.test(r, lag = 20, type = "Ljung-Box")
```

Box-Ljung test

X-squared = 20.351, df = 20, p-value = 0.4368

Conclusion

$Q_{LB}(20) = 20,4$ contre une valeur critique de 31,4. On ne rejette pas : **les rentabilités sont un bruit blanc au sens linéaire**.

C'est l'efficacité faible, mesurée. Le cours pourrait s'arrêter là — et c'est précisément pour cela qu'il ne s'arrête pas là.

La sélection automatique

```
auto.arima(r, max.p = 4, max.q = 4, d = 0,  
           seasonal = FALSE, ic = "bic", stepwise = FALSE)
```

Series: r
ARIMA(0,0,0) with non-zero mean

sigma² = 1.3841: log likelihood = -3157.62
AIC=6319.24 AICc=6319.25 BIC=6330.44

Ce que le BIC retient

Le modèle vide, avec une simple constante. La procédure du chapitre 12 confirme la lecture des corrélogrammes.

Comparer les candidats à la main

```
grille <- expand.grid(p = 0:3, q = 0:3)  
res <- t(apply(grille, 1, function(o) {  
  m <- try(arima(r, order = c(o[1], 0, o[2])), silent = TRUE)  
  if (inherits(m, "try-error")) c(NA, NA)  
  else c(AIC = AIC(m), BIC = BIC(m))  
}))  
cbind(grille, res)[order(res[, 2]), ][1:4, ]
```

	p	q	AIC	BIC
1	0	0	6319.240	6330.442
2	1	0	6320.518	6337.321
3	0	1	6320.531	6337.334
5	1	1	6321.921	6344.325

La lecture

Le minimum du BIC est atteint en (0,0), et les écarts avec les voisins sont de l'ordre de 7 points — c'est net. Ajouter un paramètre coûte $\ln(2000) = 7,6$ et ne rapporte presque rien.

Étape 4 — Estimer et valider

Estimer, pour la démonstration

```
mod <- arima(r, order = c(1, 0, 0))  
mod
```

Coefficients:
ar1 intercept

	0.0192	0.0300
s.e.	0.0224	0.0269

Comment lire ce tableau

$\hat{\alpha}_1 = 0,019$ avec un écart-type de 0,022 : le rapport de Student vaut 0,86, très loin de 1,96. Le coefficient n'est **pas significatif**.
Et même s'il l'avait été : un α de 0,02 signifie que la rentabilité d'hier explique 0,04 % de celle d'aujourd'hui. Aucun coût de transaction ne le laisserait exploiter.

Valider


```
checkresiduals(mod, lag = 20)
```

Ljung-Box test

Q* = 20.06, df = 19, p-value = 0.3907

```
res <- residuals(mod)
jarque.bera.test(res) # rejeté : queues épaisses
```

Valider (suite)



Valider (suite 2)

Verdict

Résidus non autocorrélés, mais non gaussiens. Le modèle est **valide au sens linéaire**, et ses intervalles de prévision sont suspects.

Étape 5 — Prévoir

Prévision ponctuelle et intervalle

```
p <- forecast(mod, h = 10, level = c(80, 95))
p
```

	Point Forecast	Lo 95	Hi 95
2001	0.0300	-2.2762	2.3362
2002	0.0300	-2.2766	2.3366

2005 0.0300 -2.2766 2.3366

Le chapitre 15, illustré en trois lignes

La prévision ponctuelle est **constante et égale à la moyenne** dès le premier pas — puisque $\alpha \simeq 0$, il n'y a rien à propager.

L'intervalle est lui aussi constant : $\pm 2,31$, soit $1,96 \times 1,176$. C'est la volatilité **moyenne** de tout l'échantillon, appliquée indifféremment à demain.

Étape 6 — Ce qui a échappé

Regarder les résidus au carré

```
Acf(res^2, lag.max = 20, main = "ACF des résidus au carré")
Box.test(res^2, lag = 20, type = "Ljung-Box")
```

Box-Ljung test

X-squared = 814.02, df = 20, p-value < 2.2e-16

Le contraste, en deux nombres

Série testée	$Q_{LB}(20)$	p -valeur
résidus $\hat{\varepsilon}_t$	20,1	0,39
résidus au carré $\hat{\varepsilon}_t^2$	814,0	$< 10^{-16}$

Le test ARCH

```
ArchTest(res, lags = 12)
```

ARCH LM-test; Null hypothesis: no ARCH effects

Chi-squared = 274.53, df = 12, p-value < 2.2e-16

La conclusion de tout le cours, obtenue en une commande

Les rentabilités sont **non corrélées** — Ljung-Box ne rejette pas. Elles ne sont **pas indépendantes** — le test ARCH rejette avec une force écrasante.

Bruit blanc faible, pas bruit blanc fort. La distinction du chapitre 2 se lit ici dans deux p -valeurs.

Ce qu'il faut modéliser maintenant

La suite, en R

```
library(rugarch)
spec <- ugarchspec(
  variance.model = list(model = "sGARCH", garchOrder = c(1, 1)),
  mean.model      = list(armaOrder = c(0, 0), include.mean = TRUE),
  distribution.model = "std")      # Student : queues épaisses
fit <- ugarchfit(spec, data = r)
```

L'`armaOrder` est ce que ce cours a déterminé. Le `variance.model` est l'objet du cours suivant.

Synthèse

Ce qu'il faut retenir

L'essentiel du chapitre 16

- `adf.test` et `kpss.test` se lisent **ensemble** ; ici, série $I(0)$ sans ambiguïté.
- `Acf` / `Pacf` : rien hors des bandes. `Box.test` : $Q = 20,4$, non rejeté.
- `auto.arima` avec `ic = "bic"` retient ARMA(0,0).
- `forecast` donne une prévision constante et un intervalle constant — la volatilité moyenne.
- `Box.test` sur les **carrés** : $Q = 814$. `ArchTest` : rejet massif.
- Le diagnostic complet tient en six commandes, et il désigne les GARCH.

Vers le chapitre 17

La même démarche, la même série, les mêmes conclusions — en Python. L'intérêt n'est pas la répétition : c'est de constater que la méthode ne dépend pas de l'outil.