

Chapitre 20

Étude de cas sur données réelles — Python

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Modélisation GARCH

1 Exercices du chapitre

Exercice 1 — Les trois vérifications qui évitent des heures perdues

Un étudiant télécharge, avec `yfinance`, dix ans de cotations quotidiennes (du 1er janvier 2015 au 1er janvier 2025). Il obtient 1 260 cotations, 0 valeur manquante et 0 doublon.

- (a) À raison d'environ 252 jours de bourse par an, combien de cotations devrait-il s'attendre à obtenir sur dix ans ?
- (b) Calculer le ratio entre le nombre obtenu et le nombre attendu.
- (c) L'absence de valeurs manquantes et de doublons garantit-elle que les données sont correctes ? Proposer une explication plausible à cet écart (indice : le ratio obtenu est une fraction très simple du nombre attendu).
- (d) Pourquoi le cours insiste-t-il pour que ces trois vérifications soient faites **avant** de calculer quoi que ce soit, plutôt qu'après avoir observé un résultat étrange plus loin dans l'analyse ?

Exercice 2 — Lire un tableau de comparaison R contre Python

Après avoir répliqué la même étude de cas en R (chapitre 19) et en Python (ce chapitre), un analyste obtient : $\hat{\alpha}_1^R = 0,0421$, $\hat{\alpha}_1^{Py} = 0,0423$; $\hat{\beta}_1^R = 0,8890$, $\hat{\beta}_1^{Py} = 0,8887$; persistance $\hat{\pi}^R = 0,9834$, $\hat{\pi}^{Py} = 0,9839$; log-vraisemblance $-3\,200,4$ (R) contre $-3\,200,55$ (Python); 24 dépassements de VaR (R) contre 25 (Python).

- (a) $\hat{\alpha}_1$ et $\hat{\beta}_1$ coïncident-ils à la troisième décimale, comme l'exige le tableau de tolérance du cours ?
- (b) La persistance coïncide-t-elle à la quatrième décimale, comme l'exige ce même tableau ?
- (c) La log-vraisemblance et le nombre de dépassements respectent-ils leurs tolérances respectives (moins de 0,1 pour la première, identiques pour le second) ?
- (d) Au vu de (a), (b) et (c), ce contrôle croisé R/Python doit-il être considéré comme réussi dans son ensemble, ou révèle-t-il un problème à investiguer ?

Exercice 3 — Diagnostiquer un écart R/Python

Poursuivant l'exercice 2, l'analyste constate que l'écart dépasse les tolérances sur trois des quatre lignes du tableau.

- (a) Citer, dans l'ordre suggéré par le cours, les trois points à vérifier avant de soupçonner un bogue dans l'une des deux bibliothèques.
- (b) L'analyste découvre que le script R utilise $T = 2\,500$ observations de rentabilités après un seul `na.omit()`, tandis que le script Python en utilise 2 498 après deux appels successifs à `dropna()` (un après le calcul des rentabilités, un second après le calcul des résidus standardisés, qui a retiré deux observations supplémentaires par erreur). Laquelle des trois causes possibles explique cet écart ?
- (c) Pourquoi une différence de seulement deux observations sur 2 500 peut-elle suffire à faire sortir la persistance de sa tolérance à la quatrième décimale, alors qu'elle laisse $\hat{\alpha}_1$ et $\hat{\beta}_1$ correctement alignés à la troisième ?
- (d) En quoi ce genre d'écart, une fois sa cause identifiée et corrigée, renforce-t-il — plutôt qu'il n'affaiblit — la confiance dans la méthode globale ?

2 Exercice cumulatif (chapitre 20, chapitre 19 et chapitre 17)

Exercice 4 — Trois contrôles croisés, un seul principe

Le chapitre 17 comparait R et Python sur la série **simulée** des chapitres 17-18 (BIC 7 000,5 contre 7 000,52, un écart de 0,0003 %). Le chapitre 19 puis ce chapitre comparent maintenant R et Python sur une série **réelle**, avec le tableau de tolérance de l'exercice 2.

- (a) Sur données simulées (chapitre 17), l'écart de BIC était pratiquement nul. Sur données réelles (exercice 2), certains écarts dépassent la tolérance. Cette différence de comportement remet-elle en cause la méthode elle-même ?
- (b) En quoi les données **simulées** des chapitres 17-18 constituaient-elles, par construction, un cas plus favorable à un accord parfait entre R et Python que les données **réelles** des chapitres 19-20 ?
- (c) Le chapitre 17 (exercice 3 de ce chapitre) avait déjà établi la bonne pratique face à un désaccord entre bibliothèques : vérifier d'abord la spécification avant de soupçonner un bug. L'exercice 3 de ce chapitre applique ce même principe à un cas concret (le double `dropna()`). Formuler, en une phrase, le principe méthodologique commun aux deux exercices.
- (d) Le cours affirme que la reproductibilité croisée entre deux bibliothèques est « la seule [preuve de fiabilité] qui soit à la portée d'un étudiant ». Pourquoi une divergence **correctement diagnostiquée** (comme à l'exercice 3) est-elle, en un sens, une meilleure preuve de rigueur qu'un accord parfait obtenu sans jamais avoir vérifié où les deux scripts pourraient différer ?

3 Applications en sciences économiques

Exercice 5 — La fiche de poste, décomposée

Le cours affirme que la démarche de ce chapitre est « exactement le contenu d'une fiche de poste de risk analyst junior » : prendre une série de prix inconnue, la transformer, tester sa stationnarité, ajuster l'équation de moyenne, détecter et modéliser l'hétéroscédasticité, valider le résultat, en tirer une VaR et démontrer qu'elle est correcte.

- (a) Associer chacune des huit tâches de cette phrase à l'étape numérotée correspondante du chapitre (étapes 1 à 6, sachant que certaines tâches partagent la même étape).
- (b) Laquelle de ces huit tâches, si elle était omise, laisserait le reste du travail **apparemment** correct tout en étant en réalité non fiable, sans qu'aucun message d'erreur ne le signale ?
- (c) Un candidat qui saurait exécuter `ugarchfit` ou `arch_model` sans savoir interpréter un test de Ljung-Box aurait-il, selon vous, la compétence que ce chapitre cherche à transmettre ?
- (d) En quoi le fait que ce protocole se termine par un **backtesting** (et non par l'estimation du modèle) reflète-t-il une différence essentielle entre « ajuster un modèle » et « mesurer un risque » ?

Exercice 6 — Ce que le cours a démontré, du premier au dernier chapitre

Le mot de la fin du cours résume l'ensemble en une phrase : « la variance est un processus, non un paramètre ».

- (a) Le cours s'ouvrait sur une observation de Mandelbrot sur le prix du coton (introduction). En quoi cette phrase de conclusion est-elle une reformulation, vingt chapitres plus tard, de la même observation empirique initiale ?
- (b) Citer trois chapitres du cours (autres que celui-ci) qui ont chacun apporté une pièce nécessaire à la formule finale de la VaR, $VaR_{\alpha, T+1} = -[\hat{\mu} + \sqrt{\hat{h}_{T+1|T}} z_{\alpha}]$, en précisant ce que chacun a apporté.
- (c) Le chapitre 16 avait montré que la VaR conditionnelle et la VaR inconditionnelle peuvent avoir exactement le même nombre de dépassements tout en ayant des propriétés statistiques opposées. Ce chapitre retrouve-t-il ce même résultat sur des données réelles (comparer les paragraphes sur le backtesting de ce chapitre et du chapitre 19) ?
- (d) En une phrase, pourquoi la phrase de conclusion (« la variance est un processus ») est-elle une

idée **économique**, et pas seulement statistique ?