

# Modélisation GARCH de la volatilité

Chapitre 14 : L'estimation par quasi-maximum  
de vraisemblance



---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 29 août 2026

Avant de commencer

La vraisemblance

Le quasi-maximum

Une loi non gaussienne

Les difficultés numériques

Les propriétés asymptotiques

Synthèse

Avant de commencer

---

### Le chapitre 9 a fermé cette voie

Le GARCH est un ARMA sur les carrés — on pourrait donc l'estimer par MCO. Mais l'innovation  $v_t = \varepsilon_t^2 - h_t$  est fortement hétéroscédastique, très asymétrique, et rien ne garantirait la positivité des coefficients.

La méthode de référence est le **maximum de vraisemblance**.

## La vraisemblance

---

## Décomposition en produit de lois conditionnelles

$$L(\vartheta) = \prod_{t=1}^T f(r_t \mid \Omega_{t-1}; \vartheta).$$

Sous  $z_t \sim \mathcal{N}(0, 1)$ , la loi de  $r_t$  sachant le passé est  $\mathcal{N}(\mu, h_t)$ , d'où :

$$\ln L(\vartheta) = -\frac{T}{2} \ln(2\pi) - \frac{1}{2} \sum_{t=1}^T \left[ \ln h_t + \frac{(r_t - \mu)^2}{h_t} \right].$$

## Comment lire cette expression

Deux termes qui s'opposent.  $\ln h_t$  **pénalise** les variances élevées : le modèle ne peut pas gonfler  $h_t$  partout pour se mettre à l'abri. Et  $\varepsilon_t^2/h_t$  **pénalise** les variances trop faibles là où le choc a été grand.

L'optimum réalise l'équilibre :  $h_t$  doit être grande exactement les jours où  $\varepsilon_t^2$  l'est.

## Le point technique central

$h_t$  n'est pas un paramètre : c'est une **fonction récursive** des paramètres et des données passées.

$$h_t(\vartheta) = \omega + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 h_{t-1}(\vartheta).$$

## La conséquence pratique

Chaque évaluation de la vraisemblance exige de parcourir toute la série, de  $t = 1$  à  $t = T$ . Il n'existe **aucune** formule fermée : l'optimisation est nécessairement numérique.

C'est pourquoi l'estimation d'un GARCH est instantanée sur 2 500 points, et sensiblement plus lente sur un million.

## Il faut une valeur pour $h_1$

Trois conventions courantes :

- $h_1 = \hat{\sigma}^2$ , la variance empirique de l'échantillon — la plus employée;
- $h_1 = \omega / (1 - \alpha_1 - \beta_1)$ , la variance de long terme du modèle;
- $h_1$  traitée comme un paramètre supplémentaire à estimer.

## L'effet, et il est mesurable

L'influence de  $h_1$  décroît en  $\beta_1^t$ . Avec  $\beta_1 = 0,89$ , elle est divisée par 100 au bout de 40 périodes.

Sur 2 500 observations, le choix est sans conséquence. Sur 200, il change la troisième décimale — et c'est pourquoi les logiciels ne donnent pas tous exactement les mêmes chiffres.



## Le quasi-maximum

---

## Une incohérence apparente

Le chapitre 10 a établi que  $z_t$  n'est pas gaussienne. Or nous venons d'écrire la vraisemblance **sous hypothèse gaussienne**.

Est-ce que cela invalide l'estimation ?

## Bollerslev et Wooldridge (1992)

Si l'équation de variance est **correctement spécifiée**, l'estimateur du maximum de vraisemblance **gaussien** est convergent et asymptotiquement normal, **même si la vraie loi de  $z_t$  n'est pas normale**.

On l'appelle estimateur du **quasi-maximum de vraisemblance** (QMV).

## Pourquoi cela fonctionne

La vraisemblance gaussienne ne fait intervenir que les deux premiers moments conditionnels. Tant que  $E(\varepsilon_t \mid \Omega_{t-1}) = 0$  et  $V(\varepsilon_t \mid \Omega_{t-1}) = h_t$  sont exacts, les équations de score sont satisfaites en moyenne — quelle que soit la forme de la loi.

### Écart-types robustes (sandwich)

$$\widehat{V}(\hat{\vartheta}) = \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1},$$

où  $\mathbf{A}$  est le hessien et  $\mathbf{B}$  la matrice des produits de scores. Sous normalité,  $\mathbf{A} = \mathbf{B}$  et l'expression se simplifie; sinon, non.

### Un réglage à ne jamais négliger

Les écart-types non robustes sont **sous-estimés** — souvent de 20 à 40 % sur données financières. On conclurait à tort à la significativité.

En R : `ugarchfit(..., solver.control = list(...))` fournit les deux jeux, sous les intitulés « Std.Error » et « Robust Std.Error ». **Toujours lire la seconde colonne.**

## Une loi non gaussienne

---

## Vraisemblance de Student

$$\ln L = \sum_{t=1}^T \left[ \ln \Gamma\left(\frac{\nu+1}{2}\right) - \ln \Gamma\left(\frac{\nu}{2}\right) - \frac{1}{2} \ln (\pi(\nu-2)) - \frac{1}{2} \ln h_t - \frac{\nu+1}{2} \ln \left(1 + \frac{\varepsilon_t^2}{h_t(\nu-2)}\right) \right]$$

Le paramètre  $\nu$  est estimé **conjointement** avec les autres.

## Le compromis

Si la loi est bien spécifiée, l'estimateur est **efficace** : il fait mieux que le QMV gaussien.

Si elle est mal spécifiée, la propriété de convergence est **perdue** — contrairement au QMV gaussien, qui reste robuste.

En pratique : la Student est presque toujours meilleure que la normale sur données financières, donc le risque de mauvaise spécification est faible, et on l'emploie.

## Les difficultés numériques

---

## Quatre symptômes et leurs causes

| Symptôme                                         | Cause probable              | Remède                        |
|--------------------------------------------------|-----------------------------|-------------------------------|
| non-convergence                                  | mauvaises valeurs initiales | partir d'un GARCH(1,1) simple |
| $\hat{\alpha}_1$ ou $\hat{\beta}_1$ collé à zéro | modèle sur-paramétré        | réduire $p$ et $q$            |
| $\hat{\pi}$ estimé à 0,9999                      | rupture de régime           | découper l'échantillon        |
| écarts-types absurdes                            | quasi-non-identification    | simplifier le modèle          |



### Travailler en pourcentage

Si les rentabilités sont exprimées en décimal — 0,012 pour 1,2 % — alors  $\omega$  est de l'ordre de  $10^{-6}$ . L'optimiseur travaille alors sur des échelles très différentes selon les paramètres, et converge mal.

**Multiplier les rentabilités par 100** avant estimation. Les logiciels le font parfois automatiquement, et affichent un avertissement quand ils ne le font pas — il faut le lire.

### Vérifier la contrainte de stationnarité après coup

Un optimiseur non contraint peut renvoyer  $\hat{\alpha}_1 + \hat{\beta}_1 > 1$ . Ce n'est pas nécessairement une erreur de calcul : c'est le signe que le modèle n'est pas adapté, ou que l'échantillon contient une rupture.

## Les propriétés asymptotiques

---

## Convergence et normalité asymptotique

Sous stationnarité stricte, identification et existence de moments suffisants :

$$\sqrt{T}(\hat{\vartheta} - \vartheta_0) \xrightarrow{d} \mathcal{N}(0, \mathbf{A}^{-1}\mathbf{B}\mathbf{A}^{-1}).$$

## Une réserve à connaître

Les conditions de régularité exigent l'existence de moments d'ordre élevé de  $\varepsilon_t$  — que le chapitre 8 a montrés souvent absents en finance.

La théorie asymptotique du GARCH repose donc sur des hypothèses plus fragiles qu'il n'y paraît. C'est une raison de plus d'employer les écarts-types robustes, et de se méfier de la troisième décimale.

## Synthèse

---

## L'essentiel du chapitre 14

- La vraisemblance équilibre deux pénalités :  $\ln h_t$  contre  $\varepsilon_t^2/h_t$ .
- $h_t$  est une **fonction réursive** des paramètres : pas de formule fermée, optimisation numérique obligatoire.
- **QMV** : le maximum de vraisemblance gaussien reste convergent même si  $z_t$  n'est pas gaussienne.
- Il faut alors des **écarts-types robustes** (sandwich) : les autres sont sous-estimés de 20 à 40 %.
- La vraisemblance de Student est plus efficace, et presque toujours préférable en finance.
- Précautions : rentabilités en pourcentage, bonnes valeurs initiales, vérification de  $\hat{\pi} < 1$ .

## Vers le chapitre 15

Un modèle estimé n'est pas un modèle valide. Il faut interroger ses résidus standardisés — et le critère sera exactement celui du cours ARMA, transposé aux carrés.