


Probabilités

Chapitre 20 : La loi des grands nombres



La promesse du chapitre 1

La moyenne d'un échantillon


Le théorème

Les limites, à connaître absolument

L'application majeure

Ce qu'il faut retenir

La promesse du chapitre 1



Une dette contractée dès la première page

Le chapitre 1 définissait la probabilité comme la limite d'une fréquence. Il l'avait **observé** sur une figure, sans rien prouver.

Toute la construction du cours repose sur cette affirmation. Il est temps de la démontrer — et de mesurer sa portée exacte.

La question

On répète une expérience n fois de façon indépendante, et l'on calcule la moyenne des résultats :

$$\overline{X}_n = \frac{X_1 + X_2 + \cdots + X_n}{n}$$

Que devient cette moyenne quand n grandit ?

La moyenne d'un échantillon

Espérance et variance de la moyenne

Si les X_i sont indépendantes, de même espérance m et de même écart-type σ :

$$E(\bar{X}_n) = m \qquad V(\bar{X}_n) = \frac{\sigma^2}{n} \qquad \sigma(\bar{X}_n) = \frac{\sigma}{\sqrt{n}}$$

Le calcul, en deux lignes

$$E(\bar{X}_n) = \frac{1}{n} [E(X_1) + \dots + E(X_n)] = \frac{nm}{n} = m$$

$$V(\bar{X}_n) = \frac{1}{n^2} [V(X_1) + \dots + V(X_n)] = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}$$

La seconde ligne utilise $V(aX) = a^2V(X)$ **et** l'indépendance, sans laquelle les variances ne s'additionneraient pas.

Le premier : la moyenne vise juste

$E(\bar{X}_n) = m$, quel que soit n . Même sur trois observations, la moyenne d'échantillon ne se trompe pas *en moyenne*.

On dit qu'elle est un estimateur **sans biais** de m . C'est le vocabulaire de la statistique inférentielle, et il commence ici.

Le second : elle devient de plus en plus précise

$\sigma(\bar{X}_n) = \sigma/\sqrt{n}$ décroît vers zéro. La moyenne se resserre autour de m .

Mais elle décroît en racine de n , non en n . Quadrupler la taille de l'échantillon ne divise l'erreur que par deux.

Le coût de la précision

Un institut de sondage veut réduire de moitié sa marge d'erreur. Il doit **quadrupler** son échantillon, donc à peu près quadrupler son budget.

Précision voulue	Taille nécessaire
$\pm 3\%$	$\approx 1\,100$
$\pm 1,5\%$	$\approx 4\,400$
$\pm 0,75\%$	$\approx 17\,800$

La précision est un bien à rendement fortement décroissant. C'est pourquoi les sondages s'arrêtent tous autour de mille personnes.

Le théorème

Loi des grands nombres

Soit $X_1, X_2, \dots$ des variables **indépendantes**, de **même loi**, d'espérance m finie. Alors

$$\overline{X}_n \longrightarrow m \quad \text{quand } n \rightarrow \infty$$


La moyenne empirique converge vers l'espérance.

Pourquoi c'est vrai, en une phrase

La moyenne est centrée sur m et son écart-type $\sigma/\sqrt{n}$ tend vers zéro.

Une variable centrée sur m dont la dispersion s'annule ne peut converger que vers m . Le théorème n'est rien de plus que cette observation, rendue rigoureuse.

Ce que la figure montre



La boucle est bouclée.

Le cours a commencé en *observant* que la fréquence se stabilise. La loi des grands nombres le *démontre* :

$$\bar{X}_n \rightarrow E(X)$$

En prenant X égale à 1 si la face 6 sort et 0 sinon, la moyenne *devient* la fréquence et $E(X)$ *devient* la probabilité.

C'est le théorème qui autorise à estimer : il justifie tout ce que fera la statistique inférentielle.

Le cas de l'indicatrice

Prenons $X_i = 1$ si l'événement A se produit à la i -ième répétition, 0 sinon. Alors

$$\overline{X}_n = \text{fréquence observée de } A \quad \text{et} \quad E(X_i) = P(A)$$

Le théorème dit donc : **la fréquence converge vers la probabilité.**

La définition du chapitre 1 est désormais un théorème

Ce que le premier chapitre posait comme une définition empirique est maintenant une conséquence des axiomes.

L'édifice est cohérent : on est parti de la fréquence, on a construit un calcul, et le calcul redonne la fréquence.

Les limites, à connaître absolument

Trois contresens fréquents

1. Il ne dit pas que la moyenne **atteint** m : elle s'en approche, sans jamais s'y fixer.
2. Il ne dit rien sur **la vitesse** — c'est le chapitre 21 qui la donne.
3. Il ne dit rien sur **la prochaine observation**. Absolument rien.

L'erreur du joueur, une dernière fois

« Le rouge est sorti dix fois : le noir doit rattraper. » C'est faux.

La roulette n'a pas de mémoire. Le déséquilibre n'est pas **compensé** par des tirages contraires : il est **dilué** par le nombre. Dix rouges d'avance sur cent tours pèsent lourd ; sur un million, ils ne pèsent plus rien.

La loi des grands nombres n'annule pas les écarts, elle les rend négligeables.

Il faut l'indépendance et l'identité de distribution

Sans indépendance, les variances ne s'additionnent plus et $\sigma(\bar{X}_n)$ peut ne pas tendre vers zéro.

Sans loi commune, il n'y a pas de m vers lequel converger.

Où l'hypothèse tombe, en pratique

- Un assureur qui couvre mille maisons **du même quartier** : une seule tempête les frappe toutes.
- Une banque dont les emprunteurs vivent de la même économie.
- Un sondage dont les répondants se recrutent dans le même réseau.

Le nombre ne protège que si les risques sont vraiment indépendants. C'est la raison d'être de la réassurance et de la diversification géographique.

L'application majeure

Pourquoi le métier est possible

Un assureur ignore totalement quelle maison brûlera. Mais il sait, avec une précision croissante, **combien** brûleront.

$$\sigma(\overline{X}_n) = \frac{\sigma}{\sqrt{n}} \rightarrow 0$$

Sur cent contrats, la charge moyenne est très incertaine. Sur cent mille, elle est presque connue d'avance.

La mutualisation, en une ligne

L'assurance ne supprime aucun risque individuel : elle le **remplace par une moyenne**, dont la loi des grands nombres garantit la stabilité.

C'est le seul théorème mathématique sur lequel repose une industrie entière.

Ce qu'il faut retenir

Six points

1. $E(\overline{X}_n) = m$: la moyenne d'échantillon est **sans biais**.
2. $\sigma(\overline{X}_n) = \sigma/\sqrt{n}$: elle se resserre, mais **en racine de n** .
3. Quadrupler l'échantillon divise l'erreur par deux : la précision coûte cher.
4. **Loi des grands nombres** : $\overline{X}_n \rightarrow m$; pour une indicatrice, la fréquence tend vers la probabilité.
5. Elle ne dit **rien** sur la prochaine observation : les écarts sont dilués, non compensés.
6. Elle exige **indépendance** et loi commune; sans cela, le nombre ne protège pas.

La suite

Nous savons *vers quoi* la moyenne converge. Nous ne savons pas *comment* elle est distribuée autour de cette limite.

Le chapitre 21 y répond — et la réponse est le résultat le plus surprenant de tout le cours.