

Chapitre 5

Score et notation de crédit — corrigés

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Risque de crédit

1 Corrigés des exercices du chapitre

Corrigé de l'exercice 1 — Score, notation, et leurs déclinaisons

- (a) Par leur *nature* : le score de crédit est un « indicateur numérique », une valeur cardinale produite automatiquement, tandis que la notation de crédit se lit sur « une échelle qualitative ordinale », où seul l'ordre des classes (et la PD associée à chacune) compte, non la valeur numérique brute d'un score sous-jacent. Par leur *usage* : le score est « généralement à usage strictement interne », réservé aux décisions d'octroi de la banque elle-même, tandis que la notation « concerne typiquement les prêts aux entreprises, les émissions obligataires et les États — avec, fréquemment, une publication externe », donc destinée aussi à des tiers (investisseurs, marchés). S'appuyer sur un seul système n'est généralement pas optimal car un score interne et une notation externe sont « développés dans des contextes différents, avec des données d'entrée différentes » : leurs erreurs respectives ne sont pas parfaitement corrélées, de sorte que les combiner « enrichit l'analyse du risque de crédit » en révélant des signaux que l'un des deux systèmes, pris isolément, aurait pu manquer.
- (b) La notation à travers le cycle a une « orientation de long terme couvrant au moins un cycle économique complet », est « robuste aux fluctuations de court terme », est « mise à jour peu fréquemment », et est « privilégiée par les grandes agences de notation ». La notation ponctuelle se concentre sur « l'état actuel de l'emprunteur sur un horizon généralement inférieur à un an », est « plus volatile », est « mise à jour rapidement dès qu'une nouvelle information est disponible », et est « typique des systèmes internes bancaires ». Le cours indiquant que les preuves empiriques sur leur pouvoir prédictif relatif restent mitigées, cela implique que le choix entre les deux n'est pas tranché par une supériorité prédictive démontrée d'une philosophie sur l'autre : il « dépend avant tout du contexte et des besoins de l'analyse », c'est-à-dire de considérations d'usage (stabilité recherchée pour une notation publique, réactivité recherchée pour une décision de crédit interne) plutôt que de performance statistique pure.
- (c) La notation d'émetteur est « une opinion prospective sur la solvabilité globale d'un débiteur (contrepartie, entreprise, État souverain) », tandis que la notation d'émission « évalue spécifiquement une obligation financière donnée (un prêt particulier), en tenant compte de sa durée, de ses garanties et de son usage » : la première porte sur l'emprunteur en général, la seconde sur une transaction précise de cet emprunteur, et peut donc différer de la notation d'émetteur si, par exemple, cette transaction bénéficie de garanties spécifiques. Le score comportemental « s'applique aux clients existants du crédit à la consommation et se met à jour fréquemment (souvent mensuellement) à partir de données dynamiques (soldes de comptes, changements d'emploi, impayés) », tandis que le score statique s'applique « aux nouveaux clients » et n'est, par construction, pas mis à jour de la même façon puisqu'il repose sur l'information disponible au seul moment de la demande initiale.
- (d) Le risque de défaut y est généralement plus élevé « faute de collatéral et de garanties », une caractéristique structurelle des plateformes de social lending qui empêche la banque (ou la plateforme) de compter sur une source secondaire de remboursement en cas de défaillance de l'emprunteur. Cela exige, selon le cours, « d'adapter les modèles de score classiques aux spécificités de ces plateformes non régulées » : un modèle calibré sur des données de crédit bancaire traditionnel, où le collatéral joue un rôle prédictif important, ne peut être transposé tel quel à un contexte où cette variable est structurellement absente ou de nature différente.

Corrigé de l'exercice 2 — Exigences réglementaires et données du modèle

- (a) Les cinq exigences minimales sont : une différenciation significative du risque, une réévaluation continue des emprunteurs (au minimum annuelle), une supervision de son fonctionnement, une sélection correcte des attributs de risque, et une base de données substantielle. La précision selon laquelle « l'objectif premier est de distinguer les niveaux de risque, non de minimiser les exigences de fonds propres réglementaires » cherche à écarter la tentation, pour une banque concevant son propre système de notation interne (méthode IRB), de calibrer ce système de

façon à minimiser artificiellement ses actifs pondérés du risque et donc ses exigences de fonds propres, plutôt que de produire une mesure fidèle et différenciée du risque réel : sans ce garde-fou explicite, l'incitation économique de la banque (moins de capital immobilisé) entrerait directement en conflit avec l'objectif prudentiel du système de notation.

- (b) Les quatre familles sont : la **rentabilité** (rendement des actifs, rendement des fonds propres, marges) ; la **solvabilité** (dette sur actifs, dette sur fonds propres, couverture des intérêts) ; la **liquidité** (fonds de roulement, ratio courant, ratio de liquidité immédiate) ; et l'**efficacité de gestion** (rotation des stocks, rotation des créances, rotation des dettes fournisseurs).
- (c) Les quatre dimensions de gouvernance citées sont : la composition du conseil d'administration, la compétence des dirigeants, la transparence de la gouvernance, et la protection des actionnaires. La tendance plus récente exploite les données non structurées issues du web et des réseaux sociaux pour capter trois catégories d'information : les fusions-acquisitions, la réputation, et le réseau de fournisseurs et de clients de l'entreprise — donnant naissance à des approches de big data pour l'analyse crédit. Le défi qu'elle pose, selon le cours, concerne « l'extraction et le traitement de l'information » : ces données, par nature non structurées, exigent des méthodes de collecte et de traitement radicalement différentes de celles utilisées pour les ratios financiers classiques.
- (d) L mesure « l'écart entre la sortie du modèle et la classification réelle des cas d'apprentissage » : c'est une fonction de perte qui pénalise, pour chaque emprunteur de l'échantillon de calibrage, l'écart entre le score prédit par $f(x)$ et son statut réel (défaut ou non-défaut) effectivement observé. Le cours qualifie cette minimisation d'« approximation empirique du véritable objectif » car $\beta^* = \arg \min_{\beta} L(\beta, X)$ ne minimise la perte que sur l'échantillon d'apprentissage X disponible, alors que le véritable objectif serait de « minimiser la perte sur l'ensemble de la population des emprunteurs » — population qui, par définition, inclut aussi les emprunteurs futurs et non observés, et n'est donc « pas observable dans son intégralité » au moment du calibrage.

Corrigé de l'exercice 3 — Validation, implémentation et l'industrie de la notation

- (a) Les tests hors échantillon « appliquent le modèle à des emprunteurs non inclus dans l'échantillon d'apprentissage » (même période, autres individus) ; les tests hors période « l'appliquent à des données postérieures à la période de construction » (mêmes individus ou non, période différente). Le test glissant opère sur « $T + 1$ passages successifs », en répétant à chaque passage t la construction du modèle sur les données jusqu'à la période t et son test sur la période $t + 1$: chaque passage produit ainsi un couple calibrage/test décalé d'une période. Ce test réduit la dépendance des résultats à un échantillon ou une période particuliers car il ne repose plus sur un unique partage arbitraire des données en un échantillon de calibrage et un échantillon de test : la performance du modèle est évaluée de façon répétée, sur des fenêtres temporelles glissantes successives, ce qui moyenne l'effet d'une période atypique ou d'un échantillon non représentatif qu'un test hors échantillon ou hors période isolé ne pourrait, à lui seul, détecter.
- (b) Le back-testing « compare, par des méthodes statistiques, les estimations du modèle aux résultats effectivement réalisés » — une comparaison interne, quantitative, entre prédiction et réalisation. Le benchmarking « compare, de façon plus qualitative et jugementale, les résultats du modèle interne à des évaluations externes (notations d'agences) » — une comparaison externe, à un référentiel tiers. Le benchmarking ne visant pas à « reproduire exactement » ces références externes, son véritable objectif est « d'identifier et de comprendre les écarts significatifs » entre le modèle interne et les évaluations externes. Un écart significatif ainsi détecté peut, selon le cours, « révéler un besoin de recalibrage du modèle interne » : le benchmarking n'entraîne donc pas un ajustement mécanique vers la référence externe, mais déclenche un examen qualitatif des raisons de la divergence.
- (c) Les trois agences sont Moody's (environ 40 % du marché mondial), Standard & Poor's (environ 40 % également), et Fitch (environ 15 %, avec environ 350 000 notations en circulation). Le cours situe le seuil séparant catégories investissement et catégories spéculatives à un taux de défaut à

un an « inférieur à 0,2 % en moyenne » pour les catégories investissement, contre une fourchette « de 0,7 % pour les catégories spéculatives les plus solides jusqu'à plus de 25 % pour les catégories les plus risquées » au sein même des catégories spéculatives.

- (d) Les quatre critiques sont : (i) le **manque de transparence et les conflits d'intérêts**, la méthodologie n'étant « généralement pas rendue publique » et le modèle « émetteur-payeur » (les agences rémunérées par les entités qu'elles notent) alimentant les soupçons ; (ii) le **pouvoir prédictif limité**, la crise de 2007-2008 et les faillites de Lehman Brothers, Enron et WorldCom ayant mis en question la capacité des notations à anticiper les défaillances majeures, « plusieurs études montrant que les notations d'agences prédisent moins bien le défaut que les modèles internes » ; (iii) la **pro-cyclicité**, les agences étant accusées d'avoir été « trop optimistes en période d'expansion et trop pessimistes en récession, amplifiant ainsi les cycles économiques », en dépit de leur revendication de notations « à travers le cycle » ; (iv) la **promotion de l'endettement**, l'amélioration de la mesure du risque ayant permis « d'abaisser [les] primes de risque et le coût du crédit », rendant la dette plus accessible « au risque de nourrir des bulles de crédit et donc le risque systémique ». Malgré ces critiques, le cours affirme que les notations restent intégrales aux dispositifs de gestion du risque car « elles ne se substituent pas aux modèles internes, mais les complètent, en particulier pour capturer certaines composantes du risque systématique », comme en témoigne leur rôle dans la détermination des spreads de crédit sur les marchés obligataires.

2 Corrigé de l'exercice cumulatif

Corrigé de l'exercice 4 — Score et notation à la lumière des quatre chapitres précédents

- (a) Le score de crédit de ce chapitre — « un indicateur numérique de la solvabilité d'un emprunteur, produit par un modèle analytique automatisé », calibré comme $\beta^* = \arg \min_{\beta} L(\beta, X)$ pour une forme linéaire $f(x) = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$ — est bien une instance précise des « modèles empiriques » du chapitre 4 : il « identifie des relations explicites entre la probabilité de défaut et des variables explicatives, à l'aide de méthodes statistiques », exactement comme le chapitre 4 les définit, et sa forme linéaire est la structure même du Z-score d'Altman auquel le chapitre 4 fait remonter cette famille d'approches. Ce que ce chapitre ajoute, et que le chapitre 4 ne détaillait pas, est l'*appareil complet* qui transforme une idée de modélisation en système opérationnel : le problème d'optimisation du calibrage lui-même (L, β^*), la distinction entre validation hors échantillon et hors période, le test glissant qui les combine, et la construction puis la validation de classes de notation différenciées. Le chapitre 4 situait cette famille de modèles historiquement et par principe (« des données historiques [...] des méthodes statistiques ») ; ce chapitre en fournit le mode d'emploi méthodologique, de la collecte des données à l'implémentation opérationnelle sous surveillance continue.
- (b) La phrase du chapitre 3 — un capital économique « cohérent avec la notation de crédit cible de l'établissement » — présuppose exactement le dispositif que ce chapitre construit : une notation cible n'a de sens que si elle repose sur un système capable de produire des classes dont la probabilité de défaut est mesurée et « bien différenciée des classes voisines », l'exigence même que ce chapitre pose comme première des cinq spécifications minimales. Sans un système satisfaisant cette exigence de différenciation, le « degré de risque des actifs de la banque » évoqué au chapitre 3 comme second déterminant du capital économique ne pourrait être mesuré que de façon grossière et non différenciée — rendant impossible le calibrage fin de PD , EA et LR sur lequel repose la formule $EL = PD \times EA \times LR$ du chapitre 3. En ce sens, ce chapitre ne se contente pas de compléter le chapitre 3 : il en fournit un *prérequis méthodologique*, la formule de capital économique du chapitre 3 étant, sans un système de notation validé au sens de ce chapitre, une coquille formelle dont les paramètres d'entrée resteraient indéterminés.
- (c) Le chapitre 2 ne fournit, avec ses cinq catégories — « standard/pass [...] sous surveillance/watch [...] sous-standard [...] douteux [...] perte » —, qu'un classement prudentiel grossier de

l'exposition, conçu pour déclencher des règles de provisionnement homogènes par grande catégorie, non pour produire une estimation fine et continue de la PD que sa propre formule $EL = PD \times LGD \times EAD$ exige comme premier facteur. Ce chapitre fournit précisément cette estimation fine par le système de notation en « généralement au moins dix » classes, chacune associée à une « probabilité de défaut empirique bien différenciée des classes voisines » — exactement la source que le chapitre 2 anticipait en indiquant que « la PD peut être estimée [...] de notations d'agences externes ». La comparaison révèle une différence de granularité et de finalité entre les deux dispositifs : les cinq catégories du chapitre 2 répondent à une exigence *réglementaire minimale et binaire* (provisionner ou non, à quel stade), tandis que le système de notation de ce chapitre, à plusieurs dizaines de classes potentiellement, répond à une exigence de *mesure quantitative continue*, seule capable d'alimenter un calcul de perte attendue précis plutôt qu'une simple classification qualitative.

- (d) La « supervision de son fonctionnement, avec des contrôles suffisants (tests de résistance) et un mécanisme de rétroaction garantissant son intégrité » de ce chapitre est une application directe, au cas particulier des systèmes de score et de notation, du principe général de supervision (oversight) posé au chapitre 1 — « du personnel qualifié disposant d'une indépendance suffisante ». De même, la « sélection correcte des attributs de risque, fondée sur des facteurs dont la capacité prédictive peut être démontrée » de ce chapitre applique, au développement du modèle lui-même, l'exigence de compétence (skills) du chapitre 1 — une délégation de cette tâche à des personnes dotées des compétences analytiques appropriées. En transposant le modèle des trois lignes de défense du chapitre 1 à la gouvernance d'un système de notation interne : la **première ligne** (les propriétaires du métier, ici les équipes de modélisation et d'octroi) devrait porter la sélection des attributs de risque et le développement du modèle lui-même ; la **deuxième ligne** (gestion des risques d'entreprise), qui « établit les politiques et procédures » et « surveille et supervise la performance de la première ligne » selon le chapitre 1, devrait porter la validation indépendante et le contrôle continu de la supervision de fonctionnement (tests de résistance, mécanisme de rétroaction) ; et la **troisième ligne** (audit interne), qui « apporte une assurance indépendante sur la qualité de la gestion et de la surveillance des risques assurées par les deux premières lignes », devrait vérifier *a posteriori* que les deux premières lignes ont effectivement respecté les cinq exigences minimales de ce chapitre.

3 Corrigé des applications en sciences économiques

Corrigé de l'exercice 5 — Calibrer un score linéaire et le valider hors échantillon et hors période, chiffrés

On a $f(x) = 12,0 + 4,5x_1 - 0,08x_2 + 0,6x_3$ et un cutoff de 20 points.

- (a) Client 1 : $f = 12,0 + 4,5 \times 3,5 - 0,08 \times 120 + 0,6 \times 6 = 12,0 + 15,75 - 9,60 + 3,60 = 21,75$ — score ≥ 20 : **APPROUVÉ**. Client 2 : $f = 12,0 + 4,5 \times 1,2 - 0,08 \times 260 + 0,6 \times 1 = 12,0 + 5,40 - 20,80 + 0,60 = -2,80$ — score < 20 : **REJETÉ**. Client 3 : $f = 12,0 + 4,5 \times 6,0 - 0,08 \times 70 + 0,6 \times 10 = 12,0 + 27,00 - 5,60 + 6,00 = 39,40$ — score ≥ 20 : **APPROUVÉ**.
- (b) Parmi les 220 dossiers approuvés, 14 défauts, soit $PD_{\text{approuvés}} = 14/220 = 6,3636\%$. Parmi les 80 dossiers rejetés, 22 auraient fait défaut, soit $PD_{\text{rejetés}} = 22/80 = 27,5000\%$. Le rapport est $27,5000/6,3636 = 4,3214$: un dossier rejeté par le modèle *a posteriori*, une probabilité de défaut plus de quatre fois supérieure à celle d'un dossier approuvé — la preuve directe du pouvoir de différenciation du score hors échantillon. La PD non conditionnelle sur les 300 dossiers ($14 + 22 = 36$ défauts au total) est $36/300 = 12,0000\%$. Le taux de défaut du livre effectivement financé ($6,3636\%$) est donc inférieur de $12,0000 - 6,3636 = 5,6364$ points de pourcentage à ce qu'aurait été le taux de défaut sans filtrage, soit une réduction relative de $5,6364/12,0000 = 46,97\%$: le score réduit de près de moitié le taux de défaut du portefeuille financé par rapport à un octroi non discriminant.
- (c) Fenêtre 1 : $PD_1 = 9/150 = 6,0000\%$. Fenêtre 2 : $PD_2 = 11/180 = 6,1111\%$. Fenêtre 3 : $PD_3 = 15/200 = 7,5000\%$. La moyenne simple des trois PD est $(6,0000 + 6,1111 + 7,5000)/3 = 6,5370\%$.

La moyenne pondérée (poolée), sur un total de $150 + 180 + 200 = 530$ dossiers et $9 + 11 + 15 = 35$ défauts, est $35/530 = 6,6038\%$. Cette moyenne poolée ($6,6038\%$) est proche de la PD hors échantillon du (b) sur les approuvés ($6,3636\%$), l'écart n'étant que de $6,6038 - 6,3636 = 0,2401$ point de pourcentage — une cohérence rassurante entre les deux modes de validation (hors échantillon au (b), hors période et glissant ici), qui suggère que le pouvoir prédictif du modèle ne s'est pas significativement dégradé d'une période à l'autre.

- (d) Les 14 défauts sur les 220 dossiers approuvés et les 58 ($= 80 - 22$) dossiers rejetés qui n'auraient pourtant pas fait défaut illustrent, ensemble, que le score ne cherche pas à annuler toute erreur de classement : il cherche à « distinguer les niveaux de risque », c'est-à-dire à orienter le crédit vers les dossiers dont la probabilité de défaut est statistiquement plus faible, non à garantir un taux de défaut nul parmi les approuvés ni un taux de refus nul parmi les bons payeurs. Un score qui ramènerait les 14 défauts à zéro sans rien changer d'autre ne serait pas nécessairement meilleur au sens du cours : un tel resserrement du cutoff écarterait presque certainement bien plus de bons dossiers au passage (le nombre de « bons rejetés » augmenterait), et un système de score jugé sur le seul critère de zéro défaut parmi les approuvés — au prix d'un cutoff extrêmement restrictif — irait à l'encontre de la fonction même du crédit, qui est d'accepter un niveau de risque mesuré et différencié plutôt que de l'éliminer.




FIG. 1 : Validation hors échantillon (PD des approuvés, des rejetés, et PD non conditionnelle, en bleu) et test glissant sur trois fenêtres hors période plus PD poolée (en orange) — exercice 5.

Corrigé de l'exercice 6 — Classes de notation : différenciation, concentration et benchmarking, chiffrés

On a les cinq classes avec (n, d) : Classe 1 (500, 1), Classe 2 (800, 6), Classe 3 (650, 18), Classe 4 (400, 28), Classe 5 (150, 33), pour un total de 2 500 emprunteurs et 86 défauts.

- (a) $PD_1 = 1/500 = 0,2000\%$. $PD_2 = 6/800 = 0,7500\%$. $PD_3 = 18/650 = 2,7692\%$. $PD_4 = 28/400 = 7,0000\%$. $PD_5 = 33/150 = 22,0000\%$. La PD globale du portefeuille est $86/2\,500 = 3,4400\%$.
- (b) Les parts de chaque classe dans la population totale sont : Classe 1 = $500/2\,500 = 20,00\%$, Classe 2 = $800/2\,500 = 32,00\%$, Classe 3 = $650/2\,500 = 26,00\%$, Classe 4 = $400/2\,500 = 16,00\%$, Classe 5 = $150/2\,500 = 6,00\%$. La classe la plus peuplée, la classe 2, atteint 32,00 %, ce qui **respecte** le plafond interne de 35 % — avec toutefois une marge limitée de seulement 3 points. Les ratios de PD entre classes adjacentes sont : $PD_2/PD_1 = 0,7500/0,2000 = 3,75$, $PD_3/PD_2 = 2,7692/0,7500 = 3,69$, $PD_4/PD_3 = 7,0000/2,7692 = 2,53$, $PD_5/PD_4 = 22,0000/7,0000 = 3,14$. Ces quatre ratios, tous nettement supérieurs à 1 (chaque classe affichant une PD au moins 2,5 fois supérieure à sa voisine moins risquée), sont compatibles avec l'exigence d'une « probabilité de défaut empirique bien différenciée des classes voisines » : aucune paire de classes adjacentes ne présente de PD proches l'une de l'autre qui trahirait un système de notation insuffisamment discriminant.
- (c) La PD de la classe 1 ($0,2000\%$) est exactement égale au seuil de 0,2 % cité par le cours pour les catégories investissement : elle est donc à la limite haute, mais cohérente avec un classement

investment grade. La PD de la classe 5 (22,0000 %) reste inférieure au plafond de 25 % des catégories spéculatives les plus risquées, la situant dans le haut de cette fourchette sans le dépasser. La PD de la classe 2 (0,7500 %) est **supérieure** au plancher spéculatif de 0,7 % cité par le cours pour les catégories spéculatives les plus solides : au sens strict des seuils du cours, cette classe se situe donc en **catégorie spéculative**, et non en catégorie investissement, en dépit de son étiquette interne « BBB », une notation que les agences externes classent habituellement en investment grade. Cet écart entre l'étiquette et le classement objectif par PD illustre précisément le rôle du benchmarking décrit par le cours : comparer les résultats du modèle interne à une évaluation externe ne vise pas à « reproduire exactement » celle-ci, mais à « identifier et comprendre les écarts significatifs » — ici, un écart entre une dénomination interne inspirée du vocabulaire des agences et le comportement empirique réel de la classe, qui pourrait « révéler un besoin de recalibrage du modèle interne », par exemple en renommant cette classe ou en resserrant ses bornes de score.

- (d) Le taux de stabilité de la classe 2 est $680/800 = 85,00\%$. Le taux de dégradation (migration vers la classe 3) est $90/800 = 11,25\%$. Le taux d'amélioration (migration vers la classe 1) est $30/800 = 3,75\%$. Le rapport entre dégradations et améliorations est $90/30 = 3,00$: les emprunteurs de la classe 2 qui migrent le font trois fois plus souvent vers le bas que vers le haut. Ce calcul illustre directement la « validation spécifique [...] portant sur la stabilité dans le temps (migrations de notation) » exigée par le cours : un taux de stabilité de 85 % signale une classe raisonnablement stable d'une année sur l'autre, mais l'asymétrie marquée entre dégradations et améliorations (rapport de 3) mérite d'être suivie dans la durée — une classe qui perdrait ainsi, année après année, davantage d'emprunteurs vers le bas que vers le haut verrait sa composition se dégrader progressivement, ce qui justifierait, en pratique, un examen de la cohérence entre sa PD estimée initialement et sa PD réalisée sur les emprunteurs qui y restent.




FIG. 2 : PD empirique des cinq classes de notation, comparées aux seuils du cours séparant catégories investissement ($< 0,2\%$) et catégories spéculatives ($\geq 0,7\%$). La classe 2 (« BBB »), à 0,75 %, franchit déjà le plancher spéculatif.