

Chapitre 13

Corrélation et droite d'ajustement

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Statistique descriptive

1 Exercices du chapitre

Correction — Exercice 1

(a) $\sigma_x = \sqrt{17,6} \approx 4,195$. $\sigma_y = \sqrt{104,64} \approx 10,229$.

(b) $r = \frac{-41,8}{4,195 \times 10,229} = \frac{-41,8}{42,91} \approx -0,974$.


(c) $|r| \approx 0,974$ appartient à la tranche « très forte » (0,8 à 1) de l'échelle du cours. Le signe de r est bien **négatif**, cohérent avec la covariance négative calculée au chapitre 12 : prix et quantité varient en sens contraire, et cette liaison linéaire est ici quasiment parfaite.

Correction — Exercice 2

(a) $\hat{b} = \frac{-41,8}{17,6} \approx -2,375$.

(b) $\hat{a} = 44,6 - (-2,375 \times 13) = 44,6 + 30,875 = 75,475$.

(c) quantité = $75,475 - 2,375 \times \text{prix}$. En français prudent : « chaque dirham de prix supplémentaire est **associé, en moyenne**, à une baisse d'environ 2,375 unités de quantité demandée » (et non « fait chuter la demande de », formulation causale que ce calcul ne permet pas). Pour un prix de 25 dh : $\hat{y} = 75,475 - 2,375 \times 25 = 75,475 - 59,375 = 16,1$ unités. Comme 25 dh est **au-delà** de l'intervalle des prix observés (8 à 20 dh), il s'agit d'une **extrapolation**, à interpréter avec prudence : rien ne garantit que la relation linéaire estimée reste valable en dehors du domaine observé.



Correction — Exercice 3

(a) $r^2 = (-0,974)^2 \approx 0,949$.

(b) Environ 94,9 % de la variance de la quantité demandée est expliquée **linéairement** par le prix. Les 5,1 % restants pourraient tenir à d'autres déterminants de la demande (revenu des consommateurs, prix des produits substitués ou complémentaires, préférences, saisonnalité) ou simplement à un bruit d'échantillonnage sur seulement 5 observations.

(c) Ce r^2 est effectivement **très élevé**, presque parfait, ce qui est plausible sur un petit jeu de données artificiellement propre, mais serait plus rare sur des données réelles bruitées à plus grande échelle. **Non**, un r^2 élevé ne garantit **jamais** la causalité : le quartet d'Anscombe et l'exemple des pompiers (exercice 5) montrent qu'une corrélation forte, même linéaire et bien ajustée, peut coexister avec une causalité inverse, une troisième variable, ou même une coïncidence.

2 Exercices cumulatifs (chapitres 3 à 13)

Correction — Exercice 4

(a) $\sigma_x = \sqrt{7,556} \approx 2,749$. $\sigma_y = \sqrt{483\,333,3} \approx 695,22$. $r = \frac{1\,900}{2,749 \times 695,22} \approx \frac{1\,900}{1\,911,3} \approx 0,994$. $r^2 \approx 0,988$.

(b) $\hat{b} = \frac{1\,900}{7,556} \approx 251,47$. $\hat{a} = 5\,200 - 251,47 \times 5,667 \approx 5\,200 - 1\,425,0 = 3\,775$. Droite : $\widehat{\text{sal\`a}ire} = 3\,775 + 251,47 \times \text{anciennet\`e}$.

(c) Avec $r^2 \approx 98,8\%$, l'anciennet\`e seule explique, sur ces 6 employ\`es, une part de la dispersion des salaires **bien plus grande** que ce que le dipl\`ome expliquait dans l'exemple du cours ( $\eta^2 = 25,8\%$ ). Cette comparaison n'est cependant **pas rigoureusement valide** : les deux r\`esultats portent sur des **populations totalement diff\`erentes** (nos 6 employ\`es fictifs contre les 500 salari\`es de l'exemple du cours), de tailles tr\`es diff\`erentes, et  $r^2$  et  $\eta^2$  ne mesurent d'ailleurs pas exactement la m\`eme chose (liaison lin\`eaire avec une variable quantitative contre variance expliqu\`ee par une variable qualitative, chapitre 11). Sur un \`echantillon de seulement 6 observations choisies pour illustrer une tendance nette, un  $r^2$  proche de 1 n'a rien d'\`etonnant et ne permet aucune g\`en\`eralisation.

3 Applications en sciences \`economiques

Correction — Exercice 5

(a) $\bar{x} \approx 6,67$ camions, $\bar{y} \approx 36,67$ milliers de dh, $\text{cov}(x, y) \approx 78,89$, $V(x) \approx 13,22$, $V(y) \approx 472,22$.
 $r = \frac{78,89}{\sqrt{13,22 \times 472,22}} \approx \frac{78,89}{79,02} \approx 0,998$.

(b) **Oui**, la corr\`elation est extr\`emement forte ($r \approx 0,998$). Pourtant, il serait absurde d'en conclure qu'« envoyer plus de camions cause davantage de d\`eg\`ats » et qu'il faudrait en envoyer **moins** : une telle politique aggraverait au contraire les d\`eg\`ats en retardant l'intervention.

(c) La troisi\`eme variable, non observ\`ee directement ici, est la **gravit\`e de l'incendie** : un incendie plus grave n\`ecessite l'envoi de davantage de camions **et** cause, ind\`ependamment de cela, davantage de d\`eg\`ats. C'est le cas « une troisi\`eme variable cause les deux » — exactement comme l'exemple du cours sur les ventes de cr\`eme solaire et les noyades, o\`u c'est la chaleur estivale qui cause les deux ph\`enom\`enes sans lien causal direct entre eux.

Correction — Exercice 6

(a) Service Support : $\bar{x} = 3$, $\bar{y} = 8$, $\text{cov} = -2$, $V(x) = V(y) = 2$, donc $r = -2/2 = -1$ (corr\`elation parfaitement n\`egative). Service Direction : $\bar{x} = 8$, $\bar{y} = 28$, $\text{cov} = -2$, $V(x) = V(y) = 2$, donc $r = -1$ \`egalement.

(b) Sur l'ensemble des 10 employ\`es : $\bar{x} = 5,5$, $\bar{y} = 18$, $\text{cov}(x, y) = 23$, $V(x) = 8,25$, $V(y) = 102$.
 $r = \frac{23}{\sqrt{8,25 \times 102}} = \frac{23}{29,0} \approx 0,793$.

(c) **Oui**, le signe change radicalement : **n\`egatif** ( $r = -1$ ) dans chaque service pris s\`epar\`ement, mais **positif** ( $r \approx 0,793$ ) sur l'ensemble. L'explication tient \`a l'\`ecart de niveau de salaire **entre** les deux services : le Service Direction, bien que ses employ\`es soient globalement plus anciens (anciennet\`e 6 \`a 10 ans), est **beaucoup mieux pay\`e** (salaires 26 \`a 30) que le Service Support (anciennet\`e 1 \`a 5 ans, salaires 6 \`a 10). Cet \`ecart de niveau **entre groupes** domine compl\`etement les tendances **internes** \`a chaque groupe (o\`u, \`a l'int\`erieur d'un m\`eme service, plus d'anciennet\`e est en r\`ealit\`e associ\`e \`a un salaire l\`eg\`erement **plus faible**). La r\`egle de prudence \`a en tirer : **ne jamais interpr\`eter une corr\`elation calcul\`ee sur une population h\`et\`erog\`ene sans avoir v\`erifi\`e, par sous-groupes, qu'elle ne dissimule pas des relations de sens contraire** — c'est le paradoxe de Simpson, d\`ej\`a rencontr\`e au chapitre 10 pour les tableaux de contingence, et qui s'applique ici de fa\`con identique \`a la corr\`elation.

