

Statistique descriptive

Chapitre 13 : Corrélation et droite d'ajustement

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique descriptive

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Le coefficient de corrélation

On reprend les données prix-quantité du chapitre 12 : $\text{cov}(x, y) = -41,8$, $V(x) = 17,6$, $V(y) = 104,64$.

- (a) Calculer σ_x et σ_y .
- (b) En déduire le coefficient de corrélation linéaire $r = \text{cov}(x, y) / (\sigma_x \sigma_y)$.
- (c) Situer $|r|$ sur l'échelle du cours (négligeable, faible, modérée, forte, très forte). Le signe de r est-il cohérent avec celui de la covariance ?

Exercice 2 — La droite d'ajustement par les moindres carrés

On reprend les mêmes données prix (x) - quantité (y) : $\bar{x} = 13$, $\bar{y} = 44,6$, $\text{cov}(x, y) = -41,8$, $V(x) = 17,6$.

- (a) Calculer la pente $\hat{b} = \text{cov}(x, y) / V(x)$ de la droite $\hat{y} = \hat{a} + \hat{b}x$.
- (b) Calculer l'ordonnée à l'origine $\hat{a} = \bar{y} - \hat{b}\bar{x}$.
- (c) Écrire l'équation de la droite estimée, et l'interpréter en une phrase économique (sans employer de vocabulaire causal). Que prédit-elle pour un prix de 25 dh ? Cette prédiction est-elle une interpolation ou une extrapolation par rapport aux prix observés (8 à 20 dh) ?

Exercice 3 — Le coefficient de détermination r^2

On reprend le résultat de l'exercice 1, $r \approx -0,974$.

- (a) Calculer r^2 .
- (b) Quelle part de la variance de la quantité demandée est expliquée **linéairement** par le prix ? Quelle part reste inexpliquée, et à quels facteurs pourrait-elle être attribuée ?
- (c) Ce r^2 est-il très élevé pour une relation de ce type (prix-quantité, sur seulement 5 observations) ? Cela garantit-il que la relation est **causale** ?

2 Exercices cumulatifs (chapitres 3 à 13)

Exercice 4 — La droite salaire-ancienneté du chapitre 10, chiffrée

Le chapitre 10 avait décrit qualitativement le nuage ancienneté-salaire de 6 employés, et le chapitre 12 en avait calculé la covariance (1 900). On donne : $\bar{x} = 5,667$ ans, $\bar{y} = 5 200$ dh, $V(x) = 7,556$, $V(y) = 483 333,3$.

- (a) Calculer r , puis r^2 .
- (b) Calculer la droite d'ajustement $\hat{y} = \hat{a} + \hat{b}x$ (salaire prédit en fonction de l'ancienneté).
- (c) En reliant ce résultat à celui du chapitre 11 (où le diplôme expliquait $\eta^2 = 25,8\%$ de la variance des salaires dans l'exemple du cours), commenter : sur ces 6 employés, l'ancienneté seule explique-t-elle une part de la dispersion des salaires plus grande, égale, ou plus petite que ce que le diplôme expliquait dans l'exemple du cours ? Cette comparaison est-elle rigoureusement valide, sachant que les deux exemples portent sur des données différentes ?

3 Applications en sciences économiques

Exercice 5 — Corrélation et causalité : les pompiers et les dégâts

On observe, pour 6 incendies, le nombre de camions de pompiers envoyés et le montant des dégâts (en milliers de dh) : (2, 10), (3, 15), (5, 25), (8, 45), (10, 55), (12, 70).

- (a) Calculer le coefficient de corrélation entre le nombre de camions envoyés et le montant des dégâts.
- (b) Cette corrélation est-elle forte? Un observateur naïf pourrait-il en conclure que « envoyer plus de camions cause davantage de dégâts », et donc qu'il faudrait envoyer moins de camions pour limiter les dégâts?
- (c) Identifier la **troisième variable** qui explique à la fois le nombre de camions envoyés et le montant des dégâts. Parmi les quatre explications possibles d'une corrélation vues en cours (x cause y ; y cause x ; une troisième variable cause les deux; coïncidence), laquelle s'applique ici?

Exercice 6 — Le paradoxe de Simpson appliqué à la corrélation

Une entreprise compte deux services. Service Support (5 employés) : ancienneté (ans) = (1, 2, 3, 4, 5), salaire (milliers de dh) = (10, 9, 8, 7, 6). Service Direction (5 employés) : ancienneté = (6, 7, 8, 9, 10), salaire = (30, 29, 28, 27, 26).

- (a) Calculer le coefficient de corrélation entre ancienneté et salaire **au sein du** Service Support seul, puis **au sein du** Service Direction seul.
- (b) Calculer le coefficient de corrélation entre ancienneté et salaire sur l'**ensemble** des 10 employés (les deux services confondus).
- (c) Le signe de la corrélation change-t-il selon qu'on regarde chaque service séparément ou les deux réunis? Expliquer ce paradoxe à partir des niveaux de salaire moyens très différents entre les deux services, et formuler la règle de prudence qu'il faut en tirer avant de commenter une corrélation calculée sur une population hétérogène.

1 Exercices du chapitre

Correction — Exercice 1

(a) $\sigma_x = \sqrt{17,6} \approx 4,195$. $\sigma_y = \sqrt{104,64} \approx 10,229$.

(b) $r = \frac{-41,8}{4,195 \times 10,229} = \frac{-41,8}{42,91} \approx -0,974$.


(c) $|r| \approx 0,974$ appartient à la tranche « très forte » (0,8 à 1) de l'échelle du cours. Le signe de r est bien **négalif**, cohérent avec la covariance négative calculée au chapitre 12 : prix et quantité varient en sens contraire, et cette liaison linéaire est ici quasiment parfaite.

Correction — Exercice 2

(a) $\hat{b} = \frac{-41,8}{17,6} \approx -2,375$.

(b) $\hat{a} = 44,6 - (-2,375 \times 13) = 44,6 + 30,875 = 75,475$.

(c) quantité = $75,475 - 2,375 \times$ prix. En français prudent : « chaque dirham de prix supplémentaire est **associé, en moyenne**, à une baisse d'environ 2,375 unités de quantité demandée » (et non « fait chuter la demande de », formulation causale que ce calcul ne permet pas). Pour un prix de 25 dh : $\hat{y} = 75,475 - 2,375 \times 25 = 75,475 - 59,375 = 16,1$ unités. Comme 25 dh est **au-delà** de l'intervalle des prix observés (8 à 20 dh), il s'agit d'une **extrapolation**, à interpréter avec prudence : rien ne garantit que la relation linéaire estimée reste valable en dehors du domaine observé.



Correction — Exercice 3

(a) $r^2 = (-0,974)^2 \approx 0,949$.

(b) Environ 94,9 % de la variance de la quantité demandée est expliquée **linéairement** par le prix. Les 5,1 % restants pourraient tenir à d'autres déterminants de la demande (revenu des consommateurs, prix des produits substitués ou complémentaires, préférences, saisonnalité) ou simplement à un bruit d'échantillonnage sur seulement 5 observations.

(c) Ce r^2 est effectivement **très élevé**, presque parfait, ce qui est plausible sur un petit jeu de données artificiellement propre, mais serait plus rare sur des données réelles bruitées à plus grande échelle. **Non**, un r^2 élevé ne garantit **jamais** la causalité : le quartet d'Anscombe et l'exemple des pompiers (exercice 5) montrent qu'une corrélation forte, même linéaire et bien ajustée, peut coexister avec une causalité inverse, une troisième variable, ou même une coïncidence.

2 Exercices cumulatifs (chapitres 3 à 13)

Correction — Exercice 4

- (a) $\sigma_x = \sqrt{7,556} \approx 2,749$. $\sigma_y = \sqrt{483\,333,3} \approx 695,22$. $r = \frac{1\,900}{2,749 \times 695,22} \approx \frac{1\,900}{1\,911,3} \approx 0,994$. $r^2 \approx 0,988$.
- (b) $\hat{b} = \frac{1\,900}{7,556} \approx 251,47$. $\hat{a} = 5\,200 - 251,47 \times 5,667 \approx 5\,200 - 1\,425,0 = 3\,775$. Droite : $\widehat{\text{salaire}} = 3\,775 + 251,47 \times \text{ancienneté}$.
- (c) Avec $r^2 \approx 98,8\%$, l'ancienneté seule explique, sur ces 6 employés, une part de la dispersion des salaires **bien plus grande** que ce que le diplôme expliquait dans l'exemple du cours ($\eta^2 = 25,8\%$). Cette comparaison n'est cependant **pas rigoureusement valide** : les deux résultats portent sur des **populations totalement différentes** (nos 6 employés fictifs contre les 500 salariés de l'exemple du cours), de tailles très différentes, et r^2 et η^2 ne mesurent d'ailleurs pas exactement la même chose (liaison linéaire avec une variable quantitative contre variance expliquée par une variable qualitative, chapitre 11). Sur un échantillon de seulement 6 observations choisies pour illustrer une tendance nette, un r^2 proche de 1 n'a rien d'étonnant et ne permet aucune généralisation.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) $\bar{x} \approx 6,67$ camions, $\bar{y} \approx 36,67$ milliers de dh, $\text{cov}(x, y) \approx 78,89$, $V(x) \approx 13,22$, $V(y) \approx 472,22$.
 $r = \frac{78,89}{\sqrt{13,22 \times 472,22}} \approx \frac{78,89}{79,02} \approx 0,998$.
- (b) **Oui**, la corrélation est extrêmement forte ($r \approx 0,998$). Pourtant, il serait absurde d'en conclure qu'« envoyer plus de camions cause davantage de dégâts » et qu'il faudrait en envoyer **moins** : une telle politique aggraverait au contraire les dégâts en retardant l'intervention.
- (c) La troisième variable, non observée directement ici, est la **gravité de l'incendie** : un incendie plus grave nécessite l'envoi de davantage de camions **et** cause, indépendamment de cela, davantage de dégâts. C'est le cas « une troisième variable cause les deux » — exactement comme l'exemple du cours sur les ventes de crème solaire et les noyades, où c'est la chaleur estivale qui cause les deux phénomènes sans lien causal direct entre eux.

Correction — Exercice 6

- (a) Service Support : $\bar{x} = 3$, $\bar{y} = 8$, $\text{cov} = -2$, $V(x) = V(y) = 2$, donc $r = -2/2 = -1$ (corrélation parfaitement négative). Service Direction : $\bar{x} = 8$, $\bar{y} = 28$, $\text{cov} = -2$, $V(x) = V(y) = 2$, donc $r = -1$ également.
- (b) Sur l'ensemble des 10 employés : $\bar{x} = 5,5$, $\bar{y} = 18$, $\text{cov}(x, y) = 23$, $V(x) = 8,25$, $V(y) = 102$.
 $r = \frac{23}{\sqrt{8,25 \times 102}} = \frac{23}{29,0} \approx 0,793$.
- (c) **Oui**, le signe change radicalement : **négatif** ($r = -1$) dans chaque service pris séparément, mais **positif** ($r \approx 0,793$) sur l'ensemble. L'explication tient à l'écart de niveau de salaire **entre** les deux services : le Service Direction, bien que ses employés soient globalement plus anciens (ancienneté 6 à 10 ans), est **beaucoup mieux payé** (salaires 26 à 30) que le Service Support (ancienneté 1 à 5 ans, salaires 6 à 10). Cet écart de niveau **entre groupes** domine complètement les tendances **internes** à chaque groupe (où, à l'intérieur d'un même service, plus d'ancienneté est en réalité associé à un salaire légèrement **plus faible**). La règle de prudence à en tirer : **ne jamais interpréter une corrélation calculée sur une population hétérogène sans avoir vérifié, par sous-groupes, qu'elle ne dissimule pas des relations de sens contraire** — c'est le paradoxe de Simpson, déjà rencontré au chapitre 10 pour les tableaux de contingence, et qui s'applique ici de façon identique à la corrélation.

