

Chapitre 10

Croiser deux variables

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Statistique descriptive

1 Exercices du chapitre

Correction — Exercice 1

- (a) Fréquence conjointe = $n_{ij}/n = 60/200 = 0,30$, soit 30 % : 30 % de l'**ensemble** des salariés ont une Licence **et** un CDI.
- (b) Profil-ligne = $n_{ij}/n_{i\bullet} = 60/75 \approx 0,80$, soit 80 % : parmi les diplômés **Licence**, 80 % sont en CDI.
- (c) Profil-colonne = $n_{ij}/n_{\bullet j} = 60/150 = 0,40$, soit 40 % : parmi les salariés en **CDI**, 40 % ont une Licence. Ces trois nombres, bien qu'issus de la même case du tableau, répondent à **trois questions différentes** et ne doivent jamais être confondus : la première décrit l'ensemble de l'entreprise, la deuxième décrit les diplômés Licence, la troisième décrit les salariés en CDI.

Correction — Exercice 2

- (a) $n_{\text{Licence, CDI}}^{\text{th}} = \frac{75 \times 150}{200} = 56,25$.
- (b) $n_{\text{Bac, CDI}}^{\text{th}} = \frac{60 \times 150}{200} = 45$. $n_{\text{Bac+2, CDI}}^{\text{th}} = \frac{65 \times 150}{200} = 48,75$.
- (c)


	Licence, CDI	Bac, CDI	Bac+2, CDI
observé	60	40	50
théorique	56,25	45	48,75

Les Licenciés sont légèrement **sur-représentés** en CDI ($60 > 56,25$), les Bac légèrement **sous-représentés** ($40 < 45$), et les Bac+2 très proches de l'indépendance ($50 \approx 48,75$). Il semble donc y avoir un **léger** début de liaison positive entre niveau de diplôme et probabilité d'obtenir un CDI. Mais ces écarts sont modestes, et la statistique **descriptive** ne permet pas de dire s'ils sont **significatifs** ou s'ils relèvent simplement du hasard d'échantillonnage : cela relève du test du khi-deux, vu en statistique inférentielle.

Correction — Exercice 3

- (a) $\bar{x} = \frac{2 + 5 + 8 + 3 + 10 + 6}{6} = \frac{34}{6} \approx 5,67$ ans. $\bar{y} = \frac{4200 + 5100 + 5800 + 4500 + 6200 + 5400}{6} = \frac{31\,200}{6} = 5\,200$ dh. $G \approx (5,67; 5\,200)$.
- (b) **Sens** : le nuage monte clairement — plus l'ancienneté est grande, plus le salaire est élevé. **Forme** : la tendance paraît linéaire, un ajustement par une droite semble raisonnable. **Intensité** : le nuage est plutôt **resserré** autour de sa tendance (peu de dispersion perpendiculaire à la droite). **Anomalies** : aucun point ne se détache nettement des autres.

salaire (dh)



(c) Un salaire de 9 000 dh pour seulement 1 an d'ancienneté est **fortement incompatible** avec la tendance observée (qui associerait plutôt, à 1 an d'ancienneté, un salaire proche de 4 000 dh). Ce serait donc un **point atypique** qui, ajouté au nuage, réduirait l'intensité apparente de la liaison ancienneté-salaire et pourrait fausser un futur ajustement linéaire (chapitre 13) s'il n'est pas identifié et traité au préalable.

2 Exercices cumulatifs (chapitres 3 à 10)

Correction — Exercice 4

(a) Fréquence conjointe = $45/500 = 0,09$ (9 % de l'ensemble des ménages ont un revenu $[40, 80[$ et vivent en milieu urbain). Profil-ligne = $45/50 = 0,90$ (90 % des ménages à haut revenu vivent en milieu urbain). Profil-colonne = $45/350 \approx 0,129$ (12,9 % des ménages urbains ont un revenu $[40, 80[$).

(b) $n_{[40,80[, \text{Urbain}}^{\text{th}} = \frac{50 \times 350}{500} = 35$. $n_{[0,10[, \text{Rural}}^{\text{th}} = \frac{200 \times 150}{500} = 60$.

(c)

	observé	théorique
$[40, 80[, \text{Urbain}$	45	35
$[0, 10[, \text{Rural}$	80	60

Dans les deux cas, l'écart entre observé et théorique est **important et de même sens** : les hauts revenus sont **sur-représentés** en milieu urbain (45 contre 35 attendus) et les bas revenus sont **sur-représentés** en milieu rural (80 contre 60 attendus). Il existe donc une **liaison nette** entre revenu et milieu de résidence : les ménages aisés se concentrent en ville, les ménages modestes davantage à la campagne. Ce constat est parfaitement **cohérent** avec les résultats des chapitres précédents : la forte asymétrie à droite de la distribution des revenus (chapitre 5), l'écart considérable entre les déciles extrêmes ($D_9/D_1 = 16$, chapitre 6) et la forte concentration mesurée au chapitre 9 trouvent ici un début d'explication géographique — les emplois les mieux rémunérés se concentrant dans les zones urbaines, exactement comme le signalait déjà le cours à propos des diplômés du supérieur.

chapitres 5, 6, 9 : forte asymétrie et concentration des revenus



un facteur explicatif

chapitre 10 : les hauts revenus sont concentrés en milieu urbain

3 Applications en sciences économiques

Correction — Exercice 5

(a) Agence Facile : taux X = $720/800 = 0,90$ (90 %) ; taux Y = $95/100 = 0,95$ (95 %). Agence Difficile : taux X = $30/100 = 0,30$ (30 %) ; taux Y = $280/800 = 0,35$ (35 %). Dans **chaque** agence, le client Y est mieux traité que X (taux d'octroi plus élevé de 5 points dans les deux cas).

(b) Taux global X = $\frac{720 + 30}{800 + 100} = \frac{750}{900} \approx 0,833$ (83,3 %). Taux global Y = $\frac{95 + 280}{100 + 800} = \frac{375}{900} \approx 0,417$ (41,7 %).

(c) **Oui**, le résultat global **inverse totalement** le constat par agence : globalement, X semble deux fois mieux traité que Y (83,3 % contre 41,7 %), alors que Y est en réalité **mieux** traité dans chacune des deux agences prises séparément. L'explication tient à la répartition des demandes : les clients X déposent massivement leur demande dans l'agence **Facile** (800 sur 900, soit 89 %), où le taux d'octroi est structurellement élevé pour tout le monde, tandis que les clients Y déposent massivement la leur

dans l'agence **Difficile** (800 sur 900), où le taux d'octroi est structurellement bas pour tout le monde. Le facteur « agence » (une troisième variable, cachée dans l'agrégat) domine entièrement le résultat global. C'est le **paradoxe de Simpson**, et il illustre un risque méthodologique réel et documenté dans l'analyse de discrimination : conclure à une discrimination (ou à son absence) à partir de taux agrégés, sans contrôler pour une variable de confusion comme le type de dossier ou le service concerné, peut conduire à une conclusion **exactement inverse** de la réalité — c'est précisément ce qui s'est produit dans le célèbre cas des admissions de l'université de Berkeley en 1973.

Correction — Exercice 6

(a) Avec les 7 entreprises : $\bar{x} = \frac{1 + 2 + 3 + 4 + 5 + 6 + 0,5}{7} = \frac{21,5}{7} \approx 3,07$; $\bar{y} = \frac{5 + 8 + 12 + 15 + 18 + 20 + 45}{7} = \frac{123}{7} \approx 17,57$. Sans la start-up virale (les 6 premières) : $\bar{x} = \frac{21}{6} = 3,5$; $\bar{y} = \frac{78}{6} = 13$.

(b) Sur les 6 premières entreprises seules, le nuage **monte régulièrement** et de façon quasiment **linéaire** : chaque million de dh de R&D supplémentaire semble associé à une croissance plus élevée, dans une progression très régulière (5, 8, 12, 15, 18, 20).

(c) **Non**, l'ajout du septième point détruit visuellement la netteté de la tendance : ce point, avec un R&D quasi nul (0,5) et pourtant la croissance la plus forte de tout l'échantillon (45 %), va exactement à l'**encontre** du message porté par les six autres. Le risque pour un décideur qui calculerait directement un coefficient de liaison sur les 7 points, **sans avoir regardé le nuage au préalable**, est double : soit ce point unique **affaiblit fortement** un coefficient de corrélation qui serait sinon très net (masquant une réalité solide sur la majorité des entreprises), soit, dans d'autres configurations de données, un point isolé de ce type peut au contraire **fabriquer de toutes pièces** une corrélation apparente qui n'existe pas dans les données réelles. Dans les deux cas, la règle du cours s'applique : **toujours regarder le nuage avant de calculer un coefficient, jamais l'inverse**.