

Statistique descriptive

Chapitre 10 : Croiser deux variables

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique descriptive

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Lire un tableau de contingence

Une entreprise de 200 salariés est répartie selon son niveau de diplôme et son type de contrat :

	CDI	CDD	Total
Bac	40	20	60
Bac+2	50	15	65
Licence	60	15	75
Total	150	50	200

- (a) Calculer la fréquence **conjointe** de la case (Licence, CDI).
- (b) Calculer le **profil-ligne** de cette même case : parmi les diplômés Licence, quelle proportion est en CDI ?
- (c) Calculer le **profil-colonne** de cette même case : parmi les salariés en CDI, quelle proportion a une Licence ? Ces trois nombres répondent-ils à la même question ?

Exercice 2 — Effectifs théoriques et indépendance

On reprend le tableau de l'exercice 1.

- (a) Calculer l'effectif théorique de la case (Licence, CDI) sous l'hypothèse d'indépendance entre diplôme et type de contrat.
- (b) Calculer de même les effectifs théoriques des cases (Bac, CDI) et (Bac+2, CDI).
- (c) Comparer, pour ces trois cases, effectifs observés et effectifs théoriques. Diplôme et type de contrat semblent-ils indépendants, ou y a-t-il un début de liaison ? Cette descriptive permet-elle de conclure définitivement ?

Exercice 3 — Lire un nuage de points

On observe, pour 6 employés, l'ancienneté (en années) et le salaire mensuel (en dh) : (2, 4 200), (5, 5 100), (8, 5 800), (3, 4 500), (10, 6 200), (6, 5 400).

- (a) Calculer le point moyen $G = (\bar{x}, \bar{y})$ de ce nuage.
- (b) Décrire le nuage selon les quatre questions du cours : sens, forme, intensité, anomalies.
- (c) Un neuvième employé, avec 1 an d'ancienneté et un salaire de 9 000 dh, rejoint l'entreprise. Sans recalculer précisément, cet ajout est-il compatible avec la tendance générale du nuage, ou s'agit-il d'un point atypique susceptible de perturber l'analyse ultérieure (chapitre 13) ?

2 Exercices cumulatifs (chapitres 3 à 10)

Exercice 4 — Croiser le revenu des chapitres 3–9 avec le milieu de résidence

On reprend les 500 ménages des chapitres 3 à 9, répartis en classes de revenu $[0, 10[$ (200), $[10, 20[$ (150), $[20, 40[$ (100), $[40, 80[$ (50) (en milliers de dh), et on les croise avec leur milieu de résidence :

	Urbain	Rural	Total
[0, 10[	120	80	200
[10, 20[	100	50	150
[20, 40[	85	15	100
[40, 80[	45	5	50
Total	350	150	500

- Calculer la fréquence conjointe, le profil-ligne et le profil-colonne de la case ([40, 80[, Urbain).
- Calculer les effectifs théoriques des cases ([40, 80[, Urbain) et ([0, 10[, Rural) sous l'hypothèse d'indépendance entre revenu et milieu.
- Comparer effectifs observés et théoriques pour ces deux cases. Que suggère cette comparaison sur le lien entre revenu et milieu de résidence? Ce constat est-il cohérent avec la très forte asymétrie et la forte concentration des revenus déjà mises en évidence aux chapitres 5, 6 et 9?

3 Applications en sciences économiques

Exercice 5 — Le paradoxe de Simpson dans l'octroi de crédit

Une banque possède deux agences, « Facile » et « Difficile », qui traitent des demandes de crédit de deux types de clients, X et Y.

	Agence Facile	Agence Difficile
Client X	720 accordés / 800 demandes	30 accordés / 100 demandes
Client Y	95 accordés / 100 demandes	280 accordés / 800 demandes

- Calculer le taux d'octroi de crédit de X et de Y dans **chaque** agence séparément. Quel type de client est mieux traité, agence par agence?
- Calculer le taux d'octroi **global** (toutes agences confondues) pour X et pour Y.
- Le résultat de (b) contredit-il celui de (a)? Expliquer ce paradoxe en observant comment se répartissent les demandes de X et de Y entre les deux agences. Pourquoi cet exemple illustre-t-il un risque méthodologique réel dans l'analyse de discrimination (par exemple entre catégories de clients ou entre genres)?

Exercice 6 — Un point isolé peut-il fabriquer une tendance ?

Sept jeunes entreprises affichent les couples (dépenses de R&D en millions de dh ; croissance annuelle du chiffre d'affaires en %) suivants : (1, 5), (2, 8), (3, 12), (4, 15), (5, 18), (6, 20), et (0, 5, 45) — cette dernière étant une start-up devenue virale avec un budget R&D minimal.

- Calculer le point moyen du nuage avec les 7 entreprises, puis sans la start-up virale (sur les 6 autres).
- Décrire, sur les 6 premières entreprises seules, le sens et la forme apparente du nuage.
- En ajoutant le septième point, la tendance « plus de R&D, plus de croissance » reste-t-elle aussi nette visuellement? Quel est le risque, pour un décideur, de calculer un coefficient de liaison (chapitre 13) sur les 7 points sans avoir d'abord regardé le nuage?

1 Exercices du chapitre

Correction — Exercice 1

- (a) Fréquence conjointe = $n_{ij}/n = 60/200 = 0,30$, soit 30 % : 30 % de l'ensemble des salariés ont une Licence et un CDI.
- (b) Profil-ligne = $n_{ij}/n_{i\bullet} = 60/75 \approx 0,80$, soit 80 % : parmi les diplômés Licence, 80 % sont en CDI.
- (c) Profil-colonne = $n_{ij}/n_{\bullet j} = 60/150 = 0,40$, soit 40 % : parmi les salariés en CDI, 40 % ont une Licence. Ces trois nombres, bien qu'issus de la même case du tableau, répondent à trois questions différentes et ne doivent jamais être confondus : la première décrit l'ensemble de l'entreprise, la deuxième décrit les diplômés Licence, la troisième décrit les salariés en CDI.

Correction — Exercice 2

- (a) $n_{\text{Licence, CDI}}^{\text{th}} = \frac{75 \times 150}{200} = 56,25$.
- (b) $n_{\text{Bac, CDI}}^{\text{th}} = \frac{60 \times 150}{200} = 45$. $n_{\text{Bac+2, CDI}}^{\text{th}} = \frac{65 \times 150}{200} = 48,75$.
- (c)


	Licence, CDI	Bac, CDI	Bac+2, CDI
observé	60	40	50
théorique	56,25	45	48,75

Les Licenciés sont légèrement **sur-représentés** en CDI ($60 > 56,25$), les Bac légèrement **sous-représentés** ($40 < 45$), et les Bac+2 très proches de l'indépendance ($50 \approx 48,75$). Il semble donc y avoir un léger début de liaison positive entre niveau de diplôme et probabilité d'obtenir un CDI. Mais ces écarts sont modestes, et la statistique **descriptive** ne permet pas de dire s'ils sont **significatifs** ou s'ils relèvent simplement du hasard d'échantillonnage : cela relève du test du khi-deux, vu en statistique inférentielle.

Correction — Exercice 3

- (a) $\bar{x} = \frac{2 + 5 + 8 + 3 + 10 + 6}{6} = \frac{34}{6} \approx 5,67$ ans. $\bar{y} = \frac{4200 + 5100 + 5800 + 4500 + 6200 + 5400}{6} = \frac{31\,200}{6} = 5\,200$ dh. $G \approx (5,67; 5\,200)$.
- (b) **Sens** : le nuage monte clairement — plus l'ancienneté est grande, plus le salaire est élevé. **Forme** : la tendance paraît linéaire, un ajustement par une droite semble raisonnable. **Intensité** : le nuage est plutôt **resserré** autour de sa tendance (peu de dispersion perpendiculaire à la droite). **Anomalies** : aucun point ne se détache nettement des autres.

salaire (dh)



(c) Un salaire de 9 000 dh pour seulement 1 an d'ancienneté est **fortement incompatible** avec la tendance observée (qui associerait plutôt, à 1 an d'ancienneté, un salaire proche de 4 000 dh). Ce serait donc un **point atypique** qui, ajouté au nuage, réduirait l'intensité apparente de la liaison ancienneté-salaire et pourrait fausser un futur ajustement linéaire (chapitre 13) s'il n'est pas identifié et traité au préalable.

2 Exercices cumulatifs (chapitres 3 à 10)

Correction — Exercice 4

(a) Fréquence conjointe = $45/500 = 0,09$ (9 % de l'ensemble des ménages ont un revenu $[40, 80[$ et vivent en milieu urbain). Profil-ligne = $45/50 = 0,90$ (90 % des ménages à haut revenu vivent en milieu urbain). Profil-colonne = $45/350 \approx 0,129$ (12,9 % des ménages urbains ont un revenu $[40, 80[$).

(b) $n_{[40,80[, \text{Urbain}}^{\text{th}} = \frac{50 \times 350}{500} = 35$. $n_{[0,10[, \text{Rural}}^{\text{th}} = \frac{200 \times 150}{500} = 60$.

(c)

	observé	théorique
$[40, 80[, \text{Urbain}$	45	35
$[0, 10[, \text{Rural}$	80	60

Dans les deux cas, l'écart entre observé et théorique est **important et de même sens** : les hauts revenus sont **sur-représentés** en milieu urbain (45 contre 35 attendus) et les bas revenus sont **sur-représentés** en milieu rural (80 contre 60 attendus). Il existe donc une **liaison nette** entre revenu et milieu de résidence : les ménages aisés se concentrent en ville, les ménages modestes davantage à la campagne. Ce constat est parfaitement **cohérent** avec les résultats des chapitres précédents : la forte asymétrie à droite de la distribution des revenus (chapitre 5), l'écart considérable entre les déciles extrêmes ($D_9/D_1 = 16$, chapitre 6) et la forte concentration mesurée au chapitre 9 trouvent ici un début d'explication géographique — les emplois les mieux rémunérés se concentrant dans les zones urbaines, exactement comme le signalait déjà le cours à propos des diplômés du supérieur.

chapitres 5, 6, 9 : forte asymétrie et concentration des revenus

↓ un facteur explicatif

chapitre 10 : les hauts revenus sont concentrés en milieu urbain

3 Applications en sciences économiques

Correction — Exercice 5

(a) Agence Facile : taux X = $720/800 = 0,90$ (90 %) ; taux Y = $95/100 = 0,95$ (95 %). Agence Difficile : taux X = $30/100 = 0,30$ (30 %) ; taux Y = $280/800 = 0,35$ (35 %). Dans **chaque** agence, le client Y est mieux traité que X (taux d'octroi plus élevé de 5 points dans les deux cas).

(b) Taux global X = $\frac{720 + 30}{800 + 100} = \frac{750}{900} \approx 0,833$ (83,3 %). Taux global Y = $\frac{95 + 280}{100 + 800} = \frac{375}{900} \approx 0,417$ (41,7 %).

(c) **Oui**, le résultat global **inverse totalement** le constat par agence : globalement, X semble deux fois mieux traité que Y (83,3 % contre 41,7 %), alors que Y est en réalité **mieux** traité dans chacune des deux agences prises séparément. L'explication tient à la répartition des demandes : les clients X déposent massivement leur demande dans l'agence **Facile** (800 sur 900, soit 89 %), où le taux d'octroi est structurellement élevé pour tout le monde, tandis que les clients Y déposent massivement la leur

dans l'agence **Difficile** (800 sur 900), où le taux d'octroi est structurellement bas pour tout le monde. Le facteur « agence » (une troisième variable, cachée dans l'agrégat) domine entièrement le résultat global. C'est le **paradoxe de Simpson**, et il illustre un risque méthodologique réel et documenté dans l'analyse de discrimination : conclure à une discrimination (ou à son absence) à partir de taux agrégés, sans contrôler pour une variable de confusion comme le type de dossier ou le service concerné, peut conduire à une conclusion **exactement inverse** de la réalité — c'est précisément ce qui s'est produit dans le célèbre cas des admissions de l'université de Berkeley en 1973.

Correction — Exercice 6

(a) Avec les 7 entreprises : $\bar{x} = \frac{1 + 2 + 3 + 4 + 5 + 6 + 0,5}{7} = \frac{21,5}{7} \approx 3,07$; $\bar{y} = \frac{5 + 8 + 12 + 15 + 18 + 20 + 45}{7} = \frac{123}{7} \approx 17,57$. Sans la start-up virale (les 6 premières) : $\bar{x} = \frac{21}{6} = 3,5$; $\bar{y} = \frac{78}{6} = 13$.

(b) Sur les 6 premières entreprises seules, le nuage **monte régulièrement** et de façon quasiment **linéaire** : chaque million de dh de R&D supplémentaire semble associé à une croissance plus élevée, dans une progression très régulière (5, 8, 12, 15, 18, 20).

(c) **Non**, l'ajout du septième point détruit visuellement la netteté de la tendance : ce point, avec un R&D quasi nul (0,5) et pourtant la croissance la plus forte de tout l'échantillon (45 %), va exactement à l'**encontre** du message porté par les six autres. Le risque pour un décideur qui calculerait directement un coefficient de liaison sur les 7 points, **sans avoir regardé le nuage au préalable**, est double : soit ce point unique **affaiblit fortement** un coefficient de corrélation qui serait sinon très net (masquant une réalité solide sur la majorité des entreprises), soit, dans d'autres configurations de données, un point isolé de ce type peut au contraire **fabriquer de toutes pièces** une corrélation apparente qui n'existe pas dans les données réelles. Dans les deux cas, la règle du cours s'applique : **toujours regarder le nuage avant de calculer un coefficient, jamais l'inverse**.