

Statistique descriptive

Chapitre 11 : Distributions conjointe, marginales, conditionnelles

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique descriptive

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Le théorème de la moyenne totale

L'ancienneté moyenne des salariés d'une entreprise, répartie par service, est : service A (80 salariés, ancienneté moyenne 5 ans), service B (150 salariés, 8 ans), service C (70 salariés, 12 ans).

- (a) Calculer l'ancienneté moyenne **générale** de l'entreprise, en pondérant chaque moyenne de service par son effectif.
- (b) Calculer la moyenne **simple** des trois moyennes de service, $(5 + 8 + 12)/3$.
- (c) Les deux résultats diffèrent-ils ? Pourquoi le premier est-il le seul correct ?

Exercice 2 — Décomposer la variance et calculer η^2

Trois groupes d'une population présentent les caractéristiques suivantes pour une variable y : groupe 1 ($n_1 = 100$, $\bar{y}_1 = 50$, $V_1 = 25$), groupe 2 ($n_2 = 150$, $\bar{y}_2 = 65$, $V_2 = 36$), groupe 3 ($n_3 = 50$, $\bar{y}_3 = 80$, $V_3 = 49$).

- (a) Calculer la moyenne totale $\bar{y}$.
- (b) Calculer la variance intra-groupe et la variance inter-groupes.
- (c) Vérifier que $V(y) = V_{\text{intra}} + V_{\text{inter}}$, puis calculer le rapport de corrélation η^2 . Que signifie sa valeur ?

Exercice 3 — Distributions conditionnelles et marginales

On interroge 270 habitants sur leur mode de transport principal et leur lieu de résidence :

	Centre-ville	Périphérie	Total
Voiture	30	90	120
Transport en commun	70	30	100
Vélo	40	10	50
Total	140	130	270

- (a) Calculer la distribution **conditionnelle** du mode de transport **sachant** que l'habitant réside en centre-ville. Vérifier que ses fréquences somment à 1.
- (b) Calculer la distribution **marginale** du mode de transport (sur l'ensemble des 270 habitants).
- (c) Comparer la distribution conditionnelle (centre-ville) à la distribution marginale. Résider en centre-ville semble-t-il changer significativement les habitudes de transport ?

2 Exercices cumulatifs (chapitres 3 à 11)

Exercice 4 — Le milieu de résidence explique-t-il le revenu des chapitres 3–10 ?

On reprend le tableau croisé revenu $\times$ milieu du chapitre 10 (classes de revenu en milliers de dh, centres 5, 15, 30, 60) :

	Urbain	Rural	Total
[0, 10[	120	80	200
[10, 20[	100	50	150
[20, 40[	85	15	100
[40, 80[	45	5	50
Total	350 ¹	150	500

- (a) En utilisant les centres de classe, calculer le revenu moyen **conditionnel** des ménages urbains, puis celui des ménages ruraux.
- (b) Vérifier, par le théorème de la moyenne totale, que ces deux moyennes conditionnelles redonnent bien la moyenne générale $\bar{x} = 18,5$ calculée au chapitre 5.
- (c) Calculer la variance intra-groupe, la variance inter-groupes, puis le rapport de corrélation η^2 (on admettra que la variance totale vaut 275,25, calculée au chapitre 7). Le milieu de résidence explique-t-il une grande part de la dispersion des revenus ? Ce résultat contredit-il le constat du chapitre 10 (liaison visible entre revenu et milieu) ?

3 Applications en sciences économiques

Exercice 5 — L'effet de structure sur le salaire moyen national

Un pays compte trois secteurs d'activité. Les salaires moyens par secteur restent **strictement identiques** sur deux années : agriculture (3 000 dh), industrie (6 000 dh), services (8 000 dh). Seule change la répartition de l'emploi total (1 000 actifs) entre les secteurs : année 1, 200 en agriculture, 300 en industrie, 500 dans les services ; année 2, 100 en agriculture, 300 en industrie, 600 dans les services.

- (a) Calculer le salaire moyen national l'année 1, puis l'année 2.
- (b) Le salaire moyen national a-t-il augmenté entre les deux années ? Un individu quelconque de ce pays a-t-il pourtant vu son salaire augmenter ?
- (c) Expliquer ce phénomène à l'aide du théorème de la moyenne totale. Quelle erreur d'interprétation commettrait un commentateur qui conclurait, à partir de la seule évolution du salaire moyen national, que « les salaires ont augmenté » ?

Exercice 6 — Comparer deux variables explicatives avec η^2

Une étude sur la rentabilité des entreprises d'un pays calcule le rapport de corrélation entre rentabilité et deux variables qualitatives : la région d'implantation ($\eta^2_{\text{région}} = 0,12$) et le secteur d'activité ($\eta^2_{\text{secteur}} = 0,35$).

- (a) Laquelle des deux variables explique la plus grande part de la variance de la rentabilité ?
- (b) Quelle part de la variance de la rentabilité reste inexpliquée par le secteur d'activité seul ?
- (c) Un consultant affirme : « Puisque le secteur explique 35 % de la rentabilité, il suffit de bien choisir son secteur pour réussir. » Commenter cette affirmation à la lumière du résultat de la question (b).

1 Exercices du chapitre

Correction — Exercice 1

$$(a) \bar{x} = \frac{80 \times 5 + 150 \times 8 + 70 \times 12}{300} = \frac{400 + 1\,200 + 840}{300} = \frac{2\,440}{300} \approx 8,13 \text{ ans.}$$

$$(b) \text{Moyenne simple} = \frac{5 + 8 + 12}{3} = \frac{25}{3} \approx 8,33 \text{ ans.}$$

(c) **Oui**, les deux résultats diffèrent (8,13 contre 8,33). Seul le premier, pondéré par les effectifs, est correct : le service B, le plus nombreux (150 salariés sur 300), doit peser plus lourd dans la moyenne générale que les services A et C, moins fournis. La moyenne simple traite à tort les trois services comme s'ils avaient le même poids.

Correction — Exercice 2

$$(a) \bar{y} = \frac{100 \times 50 + 150 \times 65 + 50 \times 80}{300} = \frac{5\,000 + 9\,750 + 4\,000}{300} = \frac{18\,750}{300} = 62,5.$$

$$(b) V_{\text{intra}} = \frac{100 \times 25 + 150 \times 36 + 50 \times 49}{300} = \frac{2\,500 + 5\,400 + 2\,450}{300} = \frac{10\,350}{300} = 34,5. V_{\text{inter}} = \frac{100(50 - 62,5)^2 + 150(65 - 62,5)^2 + 50(80 - 62,5)^2}{300} = \frac{15\,625 + 937,5 + 15\,312,5}{300} = \frac{31\,875}{300} = 106,25.$$

(c) $V(y) = 34,5 + 106,25 = 140,75$. $\eta^2 = \frac{106,25}{140,75} \approx 0,755$. Une part très importante (75,5 %) de la dispersion totale de y est **expliquée** par l'appartenance au groupe : les trois groupes sont très **nettement différenciés** les uns des autres, la variabilité résiduelle à l'intérieur de chaque groupe étant comparativement faible.

Correction — Exercice 3

(a) $f(\text{Voiture}|\text{Centre}) = 30/140 \approx 0,214$; $f(\text{TC}|\text{Centre}) = 70/140 = 0,5$; $f(\text{Vélo}|\text{Centre}) = 40/140 \approx 0,286$. Somme = $0,214 + 0,5 + 0,286 = 1 \checkmark$.

(b) Marginale : $f(\text{Voiture}) = 120/270 \approx 0,444$; $f(\text{TC}) = 100/270 \approx 0,370$; $f(\text{Vélo}) = 50/270 \approx 0,185$.

(c)

	marginale (ensemble)	conditionnelle (centre-ville)
Voiture	44,4 %	21,4 %
Transport en commun	37,0 %	50,0 %
Vélo	18,5 %	28,6 %

Oui, résider en centre-ville change nettement les habitudes : la part de la voiture y chute de moitié (44,4 % $\rightarrow$ 21,4 %) au profit du transport en commun et du vélo. Les deux distributions sont loin d'être identiques, ce qui signale une **liaison forte** entre lieu de résidence et mode de transport — cohérent avec l'intuition que les transports alternatifs à la voiture sont plus praticables (et la voiture plus contrainte, stationnement compris) en centre-ville.

2 Exercices cumulatifs (chapitres 3 à 11)

Correction — Exercice 4

$$(a) \text{ Urbain : } \bar{x}_U = \frac{5 \times 120 + 15 \times 100 + 30 \times 85 + 60 \times 45}{350} = \frac{600 + 1\,500 + 2\,550 + 2\,700}{350} = \frac{7\,350}{350} = 21$$

$$\text{milliers de dh. Rural : } \bar{x}_R = \frac{5 \times 80 + 15 \times 50 + 30 \times 15 + 60 \times 5}{150} = \frac{400 + 750 + 450 + 300}{150} = \frac{1\,900}{150} \approx 12,67$$

milliers de dh.

$$(b) \bar{x} = \frac{350 \times 21 + 150 \times 12,67}{500} = \frac{7\,350 + 1\,900}{500} = \frac{9\,250}{500} = 18,5 \checkmark \text{ — on retrouve exactement la moyenne générale du chapitre 5, ce qui valide le théorème de la moyenne totale appliqué à cette répartition urbain/rural.}$$

$$(c) \text{ En utilisant } \bar{x}^2 \text{ par groupe (centres de classe) : } V_U \approx 313,29, V_R \approx 137,89 \text{ (milliers de dh)}^2. \text{ Variance intra} = \frac{350 \times 313,29 + 150 \times 137,89}{500} = \frac{109\,650 + 20\,683}{500} \approx 260,67. \text{ Variance inter}$$

$$= \frac{350(21 - 18,5)^2 + 150(12,67 - 18,5)^2}{500} = \frac{350 \times 6,25 + 150 \times 34,03}{500} = \frac{2\,187,5 + 5\,104,2}{500} \approx 14,58.$$

Vérification : $260,67 + 14,58 \approx 275,25 \checkmark$, exactement la variance totale du chapitre 7. $\eta^2 = 14,58/275,25 \approx 0,053$.

Non, ce résultat ne contredit **pas** le constat du chapitre 10 : il le **nuance**. Le milieu de résidence déplace bien la moyenne (de 12,67 à 21, un écart net) — c'est ce que la comparaison des effectifs observés et théoriques du chapitre 10 avait détecté. Mais avec $\eta^2 \approx 5,3\%$ seulement, le milieu de résidence n'explique qu'une **toute petite part** de la dispersion totale des revenus : l'essentiel de l'inégalité des revenus (94,7 % de la variance) provient de l'**intérieur** même de chaque milieu — aussi bien en ville qu'à la campagne, les revenus sont très dispersés (variance intra $\approx 260,67$, à comparer à une variance inter de seulement 14,58). **Une liaison visible dans un tableau de contingence n'implique donc pas nécessairement un fort pouvoir explicatif en termes de variance.**

3 Applications en sciences économiques

Correction — Exercice 5

$$(a) \text{ Année 1 : } \bar{s}_1 = \frac{200 \times 3\,000 + 300 \times 6\,000 + 500 \times 8\,000}{1\,000} = \frac{600\,000 + 1\,800\,000 + 4\,000\,000}{1\,000} = 6\,400$$

$$\text{dh. Année 2 : } \bar{s}_2 = \frac{100 \times 3\,000 + 300 \times 6\,000 + 600 \times 8\,000}{1\,000} = \frac{300\,000 + 1\,800\,000 + 4\,800\,000}{1\,000} = 6\,900$$

dh.

(b) **Oui**, le salaire moyen national augmente de 6 400 à 6 900 dh (soit +7,8 %). Pourtant, **aucun** individu n'a vu son salaire personnel changer : les trois salaires sectoriels sont restés rigoureusement identiques d'une année sur l'autre.

(c) C'est un **effet de structure** pur : seule la répartition de l'emploi entre secteurs a changé (les poids f_j), au profit du secteur des services, le mieux rémunéré des trois. Le théorème de la moyenne totale, $\bar{y} = \sum_j f_j \bar{y}_j$, montre que la moyenne générale peut varier uniquement parce que les f_j varient, même si tous les $\bar{y}_j$ restent fixes. Un commentateur qui conclurait « les salaires ont augmenté » à partir de la seule hausse du salaire moyen national commettait une erreur d'interprétation classique : il attribuerait à une amélioration individuelle des rémunérations ce qui n'est en réalité qu'une **recomposition sectorielle** de l'emploi (ici, une tertiarisation de l'économie) — un phénomène statistique très différent, aux implications économiques et sociales totalement distinctes.

Correction — Exercice 6

(a) Le **secteur d'activité** explique la plus grande part de la variance de la rentabilité ($\eta^2 = 0,35$ contre 0,12 pour la région).

(b) La part de variance **inexpliquée** par le secteur est $1 - 0,35 = 0,65$, soit 65 %.

(c) L'affirmation du consultant est **trompeuse**. Certes, le secteur d'activité est la variable la plus

explicative des deux étudiées, mais il laisse tout de même 65 % de la variance de la rentabilité **inexpliquée** — bien davantage que ce qu'il explique. « Bien choisir son secteur » n'est donc, au mieux, qu'un facteur parmi d'autres, et un facteur minoritaire dans la réussite d'une entreprise : la qualité de gestion, la stratégie commerciale, la structure des coûts, la conjoncture ou encore le hasard entrepreneurial jouent collectivement un rôle plus important, selon ces chiffres, que le seul choix du secteur. Réduire la recette du succès à une seule variable explicative, même la meilleure des deux disponibles, revient à ignorer l'essentiel de ce qui reste à expliquer.