

# Statistique descriptive

## Chapitre 11 : Distributions conjointe, marginales, conditionnelles

Jaouad Madkour

24 septembre 2026

### Plan du chapitre

|                                                      |          |
|------------------------------------------------------|----------|
| <b>Trois familles de lois</b>                        | <b>2</b> |
| Les trois définitions . . . . .                      | 2        |
| Les trois définitions (suite) . . . . .              | 2        |
| Les trois définitions (suite 2) . . . . .            | 2        |
| <b>Distributions conditionnelles</b>                 | <b>2</b> |
| La définition . . . . .                              | 2        |
| Sur nos données . . . . .                            | 3        |
| Le tableau des conditionnelles . . . . .             | 3        |
| Le tableau des conditionnelles (suite) . . . . .     | 3        |
| <b>La moyenne totale</b>                             | <b>3</b> |
| L'énoncé . . . . .                                   | 3        |
| L'énoncé (suite) . . . . .                           | 4        |
| <b>Décomposer la variance</b>                        | <b>4</b> |
| Le second théorème . . . . .                         | 4        |
| Le second théorème (suite) . . . . .                 | 4        |
| Le rapport de corrélation . . . . .                  | 5        |
| Le rapport de corrélation (suite) . . . . .          | 5        |
| Le rapport de corrélation (suite 2) . . . . .        | 5        |
| <b>Moyennes, variances marginales</b>                | <b>6</b> |
| Un rappel utile . . . . .                            | 6        |
| Un rappel utile (suite) . . . . .                    | 6        |
| <b>Le tableau de synthèse</b>                        | <b>6</b> |
| Les trois familles, récapitulées . . . . .           | 6        |
| Les trois familles, récapitulées (suite) . . . . .   | 7        |
| Les trois familles, récapitulées (suite 2) . . . . . | 7        |
| <b>Ce qu'il faut retenir</b>                         | <b>7</b> |
| Le résumé du chapitre . . . . .                      | 7        |

## Trois familles de lois

### Les trois définitions

#### Les trois familles

| Distribution          | Ce qu'elle décrit                  | Combien                 |
|-----------------------|------------------------------------|-------------------------|
| <b>conjointe</b>      | le couple $(x; y)$                 | une seule               |
| <b>marginale</b>      | une variable, l'autre oubliée      | deux                    |
| <b>conditionnelle</b> | une variable, l'autre <b>fixée</b> | autant que de modalités |

### Les trois définitions (suite)

#### Où elles se lisent dans le tableau

- La **conjointe** est l'intérieur du tableau : les  $n_{ij}$ .
- Les **marginales** sont la dernière colonne et la dernière ligne.
- Les **conditionnelles** sont les lignes ou les colonnes prises **une par une**, chacune ramenée à son propre total.

### Les trois définitions (suite 2)

#### Trois questions distinctes

- Conjointe : « Quelle part des salariés est Bac+5 et gagne plus de 10 000 dirhams ? »
- Marginale : « Quel est le salaire moyen de l'entreprise ? »
- Conditionnelle : « Quel est le salaire moyen **des Bac+5** ? »

**La troisième est celle qui intéresse presque toujours le décideur.** C'est elle qui permet de comparer des groupes.

## Distributions conditionnelles

### La définition

#### Distribution conditionnelle

La distribution de  $y$  **sachant**  $x = x_i$  est la répartition de  $y$  **restreinte aux individus** pour lesquels  $x$  vaut  $x_i$ .

Ses fréquences sont les profils-lignes du chapitre 10 :


$$f_{j|i} = \frac{n_{ij}}{n_{i\bullet}} \quad \text{avec} \quad \sum_j f_{j|i} = 1$$

#### Le geste, en une phrase

**Conditionner, c'est réduire la population, puis recalculer.**

On ne travaille plus sur 500 salariés mais sur les 107 Bac+5. Tous les indicateurs des chapitres 5 à 9 s'appliquent alors à cette sous-population.

## Sur nos données



### Les trois moyennes conditionnelles

$$\bar{y}_{\text{Bac}} = 6\,059 \quad \bar{y}_{\text{Bac}+2} = 7\,081 \quad \bar{y}_{\text{Bac}+5} = 9\,534$$

Leur moyenne, *pondérée par les effectifs*, redonne exactement la moyenne générale 7 158 : c'est le **théorème de la moyenne totale**.

### Et la variance se décompose

$$\underbrace{6\,750\,122}_{\text{totale}} = \underbrace{5\,010\,426}_{\text{intra, résiduelle}} + \underbrace{1\,739\,696}_{\text{inter, expliquée}}$$

$\eta^2 = 1\,739\,696 / 6\,750\,122 = 0,258$  : le diplôme explique 25,8 % de la variance des salaires.

## Le tableau des conditionnelles

### Le salaire selon le diplôme

| Diplôme         | $n_j$      | Moyenne      | Écart-type   | Médiane      |
|-----------------|------------|--------------|--------------|--------------|
| Bac             | 219        | 6 059        | 2 021        | 5 690        |
| Bac+2           | 174        | 7 081        | 2 045        | 6 875        |
| Bac+5           | 107        | 9 534        | 2 872        | 8 900        |
| <b>Ensemble</b> | <b>500</b> | <b>7 158</b> | <b>2 598</b> | <b>6 770</b> |

## Le tableau des conditionnelles (suite)

### La lecture, en trois constats

1. **Le niveau monte avec le diplôme** : +17 % du Bac au Bac+2, +35 % du Bac+2 au Bac+5. La prime au diplôme n'est pas linéaire, elle s'accélère.
2. **La dispersion aussi** : l'écart-type des Bac+5 dépasse celui des deux autres groupes. Les carrières de cadres sont plus différenciées.
3. **La moyenne d'ensemble n'est celle d'aucun groupe** : 7 158 dirhams tombe entre le Bac+2 et le Bac+5, et ne décrit personne.

Ce troisième point justifie à lui seul le conditionnement.

## La moyenne totale

### L'énoncé

#### Théorème de la moyenne totale

$$\bar{y} = \frac{1}{n} \sum_j n_j \bar{y}_j = \sum_j f_j \bar{y}_j$$

La moyenne générale est la moyenne des moyennes conditionnelles, pondérée par

les effectifs.

#### Vérification

$$\frac{219 \times 6\,059 + 174 \times 7\,081 + 107 \times 9\,534}{500} = \frac{3\,579\,000}{500} \simeq 7\,158 \quad \checkmark$$

Moyenne **simple** des trois :  $(6\,059 + 7\,081 + 9\,534)/3 = 7\,558$ . **Faux de 400 dirhams.**

### L'énoncé (suite)

#### L'effet de structure

Ce théorème explique un phénomène qui déroute les non-statisticiens : **la moyenne générale peut évoluer alors qu'aucune moyenne conditionnelle ne bouge.**

Supposons que l'entreprise recrute 50 Bac+5 de plus. Aucun salaire individuel ne change, aucune moyenne par diplôme ne change — et pourtant la moyenne générale augmente, parce que les **poids**  $f_j$  ont changé.

C'est l'**effet de structure**, et il est au cœur de toute analyse de l'évolution des salaires, des prix ou de la productivité. Une hausse du salaire moyen ne signifie pas que quelqu'un a été augmenté.

## Décomposer la variance

### Le second théorème

#### Décomposition de la variance

$$\underbrace{V(y)}_{\text{totale}} = \underbrace{\frac{1}{n} \sum_j n_j V_j(y)}_{\text{variance intra-groupe}} + \underbrace{\frac{1}{n} \sum_j n_j (\bar{y}_j - \bar{y})^2}_{\text{variance inter-groupes}}$$

#### Ce que chaque terme représente

- La variance **intra** est la moyenne des variances internes aux groupes : c'est ce que le diplôme **n'explique pas**. On l'appelle aussi variance **résiduelle**.
- La variance **inter** mesure l'écartement des moyennes de groupe : c'est ce que le diplôme **explique**. On l'appelle variance **expliquée**.

Autrement dit : la dispersion totale se partage entre **ce qui sépare les groupes** et **ce qui subsiste à l'intérieur** de chacun.

### Le second théorème (suite)

#### Le calcul sur nos données

$$\underbrace{6\,750\,122}_{\text{totale}} = \underbrace{5\,010\,426}_{\text{intra}} + \underbrace{1\,739\,696}_{\text{inter}}$$

## Le rapport de corrélation

### Rapport de corrélation

$$\eta^2 = \frac{\text{variance inter}}{\text{variance totale}} \quad 0 \leq \eta^2 \leq 1$$

C'est la **part de la variance expliquée** par la variable qualitative.

### Sur nos données

$$\eta^2 = \frac{1\,739\,696}{6\,750\,122} = 0,258$$

**Le diplôme explique 25,8 % de la variance des salaires.**

## Le rapport de corrélation (suite)

### Comment on commente ce nombre

Un quart de la dispersion salariale s'explique par le seul diplôme. **Les trois quarts restants tiennent à autre chose** : l'ancienneté, le poste, la région, la performance individuelle — et une part irréductible d'arbitraire.

C'est un résultat mesuré, et il vaut mieux qu'une opinion. Il permet de répondre à « le diplôme détermine-t-il le salaire ? » par « il pèse pour un quart », ce qui est autrement plus utile qu'un oui ou un non.

### Les deux cas extrêmes

- $\eta^2 = 0$  : toutes les moyennes conditionnelles sont égales. La variable qualitative **n'apporte rien**.
- $\eta^2 = 1$  : aucune variance à l'intérieur des groupes. Connaître le groupe donne **exactement** la valeur.

## Le rapport de corrélation (suite 2)

(suite)

### Une remarque importante

$\eta^2$  ne suppose **aucune forme** de relation : il fonctionne avec une variable explicative purement nominale, sans ordre.

C'est ce qui le distingue du coefficient de corrélation du chapitre 13, qui n'existe qu'entre deux variables quantitatives et ne capte que la liaison **linéaire**.

## Moyennes, variances marginales

### Un rappel utile

#### Distribution marginale

Elle s'obtient en **oubliant** l'autre variable : ce sont les distributions étudiées dans toute la partie III.

$$f_{i\bullet} = \sum_j f_{ij} \qquad f_{\bullet j} = \sum_i f_{ij}$$

#### Le lien entre les trois familles

$$f_{ij} = f_{i\bullet} \times f_{j|i}$$

**Conjointe** = **marginale**  $\times$  **conditionnelle**. Cette relation reviendra en probabilités sous la forme  $P(A \cap B) = P(A) P(B|A)$  : c'est le même énoncé, écrit dans un autre langage.

### Un rappel utile (suite)

#### Le cas de l'indépendance

$x$  et  $y$  sont indépendantes si et seulement si

$$f_{ij} = f_{i\bullet} \times f_{\bullet j} \quad \text{pour toutes les cases}$$

Toutes les conditionnelles sont alors égales à la marginale : conditionner n'apporte **rien**.

## Le tableau de synthèse

### Les trois familles, récapitulées

#### Ce qu'il faut savoir de chacune

|                  | Conjointe             | Marginale                     | Conditionnelle                   |
|------------------|-----------------------|-------------------------------|----------------------------------|
| Où               | intérieur du tableau  | les marges                    | une ligne, ramenée à son total   |
| Fréquences       | $f_{ij}$              | $f_{i\bullet}, f_{\bullet j}$ | $f_{j i}$                        |
| Somme            | 1 sur tout le tableau | 1                             | 1 <b>par ligne</b>               |
| Combien          | une                   | deux                          | $k$                              |
| Ce qu'elle donne | la liaison            | le profil d'ensemble          | la <b>comparaison de groupes</b> |

## Les trois familles, récapitulées (suite)

### Les deux théorèmes

$$\bar{y} = \sum_j f_j \bar{y}_j \qquad V(y) = \underbrace{\overline{V_j(y)}}_{\text{intra}} + \underbrace{V(\bar{y}_j)}_{\text{inter}}$$

**La moyenne des moyennes redonne la moyenne. La moyenne des variances ne redonne pas la variance** — il manque la variance des moyennes.

## Les trois familles, récapitulées (suite 2)

### La phrase à retenir

C'est la formulation la plus compacte du chapitre, et elle vaut d'être apprise telle quelle.

## Ce qu'il faut retenir

### Le résumé du chapitre

#### Six points

1. Trois familles : **conjointe**, **marginales**, **conditionnelles**.
2. Conditionner, c'est **réduire la population puis recalculer**.
3. **Moyenne totale** : moyenne des moyennes conditionnelles, pondérée par les effectifs.  
D'où l'**effet de structure**.
4. **Décomposition de la variance** : totale = intra + inter.
5.  $\eta^2$  : part de variance expliquée par la variable qualitative. Ici 25,8 % pour le diplôme.
6.  $f_{ij} = f_{i\bullet} f_{\bullet j}$  caractérise l'**indépendance**.

### La suite

Quand les **deux** variables sont quantitatives, on peut faire mieux qu'une comparaison de groupes : mesurer directement dans quel sens et avec quelle force elles varient ensemble. Cet indicateur s'appelle la **covariance**, et sa formule se déduit directement de celle de la variance. C'est le chapitre 12.