

Statistique descriptive

Chapitre 8 : Les indicateurs de forme

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique descriptive

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Le coefficient de Fisher sur données brutes

On reprend les temps de trajet (en minutes) de 8 employés du chapitre 7 : 15, 22, 18, 30, 25, 20, 28, 24, de moyenne $\bar{x} = 22,75$ et d'écart-type $\sigma_x \approx 4,71$.

- (a) Calculer le moment centré d'ordre 3, $m_3 = \frac{1}{n} \sum (x_i - \bar{x})^3$.
- (b) En déduire le coefficient d'asymétrie de Fisher $\gamma_1 = m_3 / \sigma_x^3$.
- (c) Au vu du repère usuel ($|\gamma_1| < 0,5$: à peu près symétrique; entre 0,5 et 1 : modérément asymétrique; au-delà de 1 : fortement asymétrique), que peut-on dire de la forme de cette distribution?

Exercice 2 — Le coefficient de Yule à partir des quartiles

Les notes (sur 100) d'un examen présentent les quartiles suivants : $Q_1 = 40$, $Me = 55$, $Q_3 = 60$.

- (a) Calculer $(Q_3 - Me)$ et $(Me - Q_1)$. Lequel des deux écarts est le plus grand?
- (b) En déduire le coefficient de Yule $A_Y = \frac{(Q_3 - Me) - (Me - Q_1)}{Q_3 - Q_1}$.
- (c) Le signe de A_Y indique-t-il un étalement à droite ou à gauche du cœur de la distribution (entre Q_1 et Q_3)? Justifier.

Exercice 3 — La fragilité des coefficients de forme

Les notes (sur 100) de 7 étudiants à un contrôle sont : 60, 62, 58, 61, 59, 95, 57 (un étudiant a obtenu un score exceptionnel de 95).

- (a) Calculer la moyenne, l'écart-type, puis les coefficients γ_1 et γ_2 de cette série.
- (b) Cette distribution est-elle leptokurtique, mésokurtique ou platykurtique? Est-elle asymétrique?
- (c) On découvre que la note de 95 était en réalité une erreur de saisie : la vraie note était 63. Recalculer γ_1 et γ_2 avec cette correction. Commenter l'ampleur du changement, et expliquer pourquoi les coefficients de forme sont particulièrement sensibles à ce type d'erreur (en comparaison, par exemple, de la médiane).

2 Exercices cumulatifs (chapitres 3 à 8)

Exercice 4 — Réconcilier Yule et Fisher sur les salaires du chapitre 6

Le chapitre 6 a étudié les salaires (en dh) de 11 employés : 3200, 3400, 3600, 3700, 3800, 3900, 4000, 4100, 4300, 4500, 9800, avec $Q_1 = 3600$, $Me = 3900$, $Q_3 = 4300$ (et 9800 identifié comme valeur atypique par la règle des $1,5 IQ$).

- (a) Calculer le coefficient de Yule A_Y à partir de ces trois quartiles. Le cœur de la distribution (entre Q_1 et Q_3) est-il proche de la symétrie?
- (b) Calculer la moyenne, l'écart-type, puis le coefficient de Fisher γ_1 à partir des 11 valeurs brutes (y compris 9800).
- (c) Calculer également γ_2 . Ces deux derniers résultats contredisent-ils celui de la question (a), ou bien racontent-ils une histoire complémentaire? Expliquer, en s'appuyant sur ce que le chapitre 6 avait déjà révélé sur la valeur 9800.

3 Applications en sciences économiques

Exercice 5 — L'aplatissement des rendements financiers

Les rendements journaliers (en %) d'une action sur 7 séances sont : 0,5, -0,3, 0,2, -0,1, 3,0, -2,8, 0,4.

- (a) Calculer la moyenne, l'écart-type, puis les coefficients γ_1 et γ_2 de cette série de rendements.
- (b) Cette distribution de rendements est-elle mésokurtique, leptokurtique ou platykurtique par rapport à la loi normale ($\gamma_2 = 3$) ?
- (c) Un modèle de gestion des risques qui suppose que les rendements suivent une loi normale sous-estime-t-il ou surestime-t-il la probabilité des pertes extrêmes sur cette action ? Quel lien peut-on faire avec les critiques adressées à la Value at Risk gaussienne ?

Exercice 6 — Une seule valeur peut-elle changer le diagnostic d'inégalité ?


Les revenus (en milliers de dh) de 6 ménages d'un petit village sont : 18, 22, 20, 25, 19, 40.

- (a) Calculer la moyenne, l'écart-type et le coefficient γ_1 de cette série.
- (b) Un ménage supplémentaire, mal recensé au départ, voit en réalité son revenu corrigé à 400 (au lieu de 40) milliers de dh. Recalculer la moyenne, l'écart-type et γ_1 avec cette correction.
- (c) Un décideur public qui utiliserait uniquement γ_1 pour communiquer sur les inégalités de ce village verrait-il son message bouleversé par une simple erreur de saisie sur un seul ménage ? Quel indicateur, vu dans les chapitres précédents (chapitre 6), serait moins sensible à ce type d'erreur, et pourquoi ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) Les écarts à la moyenne $x_i - 22,75$ sont : $-7,75, -0,75, -4,75, 7,25, 2,25, -2,75, 5,25, 1,25$. En les élevant au cube puis en moyennant : $m_3 = \frac{(-7,75)^3 + (-0,75)^3 + (-4,75)^3 + 7,25^3 + 2,25^3 + (-2,75)^3 + 5,25^3 + 1,25^3}{8} = -6,84$.
- (b) $\gamma_1 = \frac{m_3}{\sigma_x^3} = \frac{-6,84}{4,71^3} = \frac{-6,84}{104,49} \approx -0,0655$.
- (c) $|\gamma_1| \approx 0,066 < 0,5$: la distribution des temps de trajet est **à peu près symétrique**. Le signe légèrement négatif suggère un très faible étalement à gauche, mais l'ampleur est si faible qu'on peut raisonnablement parler de symétrie approximative.



Lecture : les écarts positifs (bleu) et négatifs (orange) se compensent à peu près en ampleur cubique, d'où un γ_1 proche de 0.

Correction — Exercice 2

- (a) $Q_3 - Me = 60 - 55 = 5$. $Me - Q_1 = 55 - 40 = 15$. L'écart **bas** ($Me - Q_1 = 15$) est nettement plus grand que l'écart **haut** ($Q_3 - Me = 5$).
- (b) $A_Y = \frac{(Q_3 - Me) - (Me - Q_1)}{Q_3 - Q_1} = \frac{5 - 15}{60 - 40} = \frac{-10}{20} = -0,5$.
- (c) $A_Y < 0$ indique un étalement **à gauche** du cœur de la distribution : la moitié inférieure des notes (entre Q_1 et Me) est plus étalée que la moitié supérieure (entre Me et Q_3) — beaucoup d'étudiants avec des notes nettement en-dessous de la médiane, alors que ceux au-dessus sont plus regroupés près de Me .

Correction — Exercice 3

- (a) $\bar{x} = \frac{60 + 62 + 58 + 61 + 59 + 95 + 57}{7} = \frac{452}{7} \approx 64,57$. $\sigma_x \approx 12,52$. $\gamma_1 \approx 1,973$. $\gamma_2 \approx 5,019$.
- (b) $\gamma_2 \approx 5,02 > 3$: la distribution est **leptokurtique** (queues plus épaisses que la loi normale). $\gamma_1 \approx 1,97 > 1$: elle est également **fortement asymétrique** (étalée à droite), l'unique score de 95 tirant la moyenne et gonflant considérablement les moments d'ordre 3 et 4.
- (c) Avec la correction ($95 \rightarrow 63$) : $\bar{x} = 60$, $\sigma_x = 2$, $\gamma_1 = 0$, $\gamma_2 = 1,75$. Le changement est **radical** : γ_1 passe de 1,973 à 0 (symétrie parfaite), et γ_2 passe de 5,02 (leptokurtique) à 1,75 (platykurtique, en-dessous de la référence 3). Une seule valeur, sur sept, a suffi à faire basculer entièrement le diagnostic. Cela s'explique par les puissances élevées (cube et puissance quatre) utilisées dans le calcul de m_3 et m_4 : un écart de $95 - 64,57 \approx 30$ contribue pour $30^3 \approx 27\,000$ et $30^4 \approx 810\,000$ au numérateur, un poids sans commune mesure avec celui des autres observations — alors qu'une médiane, insensible au rang des valeurs extrêmes tant qu'elles restent extrêmes, n'aurait presque pas bougé.

2 Exercices cumulatifs (chapitres 3 à 8)

Correction — Exercice 4

(a) $A_Y = \frac{(4300 - 3900) - (3900 - 3600)}{4300 - 3600} = \frac{400 - 300}{700} = \frac{100}{700} \approx 0,143$. Cette valeur, proche de 0, indique que le **cœur** de la distribution (les 50 % centraux, entre Q_1 et Q_3) est **presque symétrique**.

(b) $\bar{x} \approx 4\,390,9$ dh, $\sigma_x \approx 1\,747,96$ dh. $\gamma_1 = \frac{m_3}{\sigma_x^3} \approx 2,628$: une valeur **très fortement positive**, signe d'un étalement à droite marqué sur l'ensemble de la distribution.

(c) $\gamma_2 \approx 8,373$, très supérieur à 3 : distribution nettement **leptokurtique**. Ces deux résultats ne **contredisent pas** celui de la question (a), ils le **complètent** exactement comme dans l'exemple du cours sur les salaires de 500 ménages : le chapitre 6 avait déjà identifié 9 800 dh comme une valeur **atypique** (bien au-delà du seuil haut 5 350 dh de la règle des $1,5 IQ$). Cette unique valeur, absente du calcul de A_Y (qui ne regarde que Q_1 , Me , Q_3), pèse en revanche énormément dans γ_1 et γ_2 (élevés respectivement au cube et à la puissance quatre). **Conclusion** : la masse des 10 salaires « ordinaires » est répartie de façon presque symétrique ; c'est la seule valeur extrême de 9 800 dh qui crée à elle seule toute l'asymétrie et tout l'aplatissement mesurés par les moments.

chapitre 6 : $A_Y \approx 0,143$ (cœur symétrique, robuste)

↓ même donnée, deux histoires

chapitre 8 : $\gamma_1 \approx 2,63$, $\gamma_2 \approx 8,37$ (moments, sensibles à 9 800)

3 Applications en sciences économiques

Correction — Exercice 5

(a) $\bar{x} \approx 0,129\%$, $\sigma_x \approx 1,571\%$, $\gamma_1 \approx -0,054$, $\gamma_2 \approx 3,322$.

(b) $\gamma_2 \approx 3,32$ est légèrement supérieur à 3 : la distribution des rendements est **légèrement leptokurtique** par rapport à la loi normale — les deux séances extrêmes (+3,0 % et -2,8 %) donnent déjà, sur seulement 7 observations, des queues plus épaisses que sous la normalité (et $\gamma_1 \approx -0,05$ indique une quasi-symétrie).

(c) Un modèle qui suppose la normalité **sous-estime** la probabilité des pertes extrêmes sur cette action : la loi normale attribue une probabilité très faible aux événements à plusieurs écarts-types de la moyenne, alors qu'ici de tels événements (le -2,8 %) se produisent plus souvent qu'attendu. C'est exactement la critique adressée à la **Value at Risk gaussienne** : en calibrant le risque sur une hypothèse de normalité alors que $\gamma_2 > 3$, elle sous-évalue systématiquement le risque de pertes extrêmes (« fat tails »), un des mécanismes cités dans l'analyse de la crise financière de 2008.

Correction — Exercice 6

(a) $\bar{x} = \frac{18 + 22 + 20 + 25 + 19 + 40}{6} = \frac{144}{6} = 24$ milliers de dh. $\sigma_x \approx 7,506$. $\gamma_1 \approx 1,452$ (asymétrie forte, étalement à droite).

(b) Avec le revenu corrigé à 400 : $\bar{x} = \frac{18 + 22 + 20 + 25 + 19 + 400}{6} = \frac{504}{6} = 84$ milliers de dh. $\sigma_x \approx 141,34$. $\gamma_1 \approx 1,788$.

(c) **Oui**, le message serait profondément affecté : la moyenne bondit de 24 à 84 milliers de dh (multipliée par 3,5) et l'écart-type explose de 7,5 à 141,3 (multiplié par ≈ 19), rendant toute communication fondée sur ces deux indicateurs immédiatement caduque en cas d'erreur de saisie. γ_1 lui-même passe de 1,45 à 1,79, un changement plus modéré en proportion mais qui reste sensible à cette valeur unique. Un indicateur **plus robuste** vu au chapitre 6, comme le **rapport interdécile** D_9/D_1 ou l'intervalle interquartile IQ , serait beaucoup **moins** affecté par cette erreur : ces indicateurs, fondés sur des rangs plutôt que sur des valeurs élevées à une puissance, ne changeraient que marginalement

(voire pas du tout, si le ménage corrigé restait en dehors des rangs utilisés par D_1 et D_9) — ce qui en fait des outils de communication publique plus fiables lorsque la qualité des données ne peut être garantie à 100 %.