

Chapitre 15

Mise en œuvre sur Python

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Statistique descriptive

1 Exercices du chapitre

Correction — Exercice 1

- (a) `np.var(x)` divise par $n = 8$: il renverrait **exactement** 22,1875, la variance descriptive du chapitre 7.
- (b) `pd.Series(x).var()` divise par $n - 1 = 7$: $\sum (x_i - \bar{x})^2 = 8 \times 22,1875 = 177,5$, donc le résultat serait $177,5/7 \approx 25,357$.
- (c) L'écart vient uniquement du **changement de convention par défaut** entre les deux bibliothèques : numpy utilise `ddof=0` (division par n , la convention **descriptive** du cours), tandis que pandas utilise `ddof=1` (division par $n - 1$, la convention **inférentielle**). Les données n'ont pourtant pas changé d'une virgule : c'est le simple fait de convertir le tableau en `pd.Series` qui a changé la formule appliquée. La solution est d'écrire explicitement `pd.Series(x).var(ddof=0)` pour retrouver 22,1875.

`np.var(x)` (`ddof=0` par défaut) → 22,1875

↓ même donnée, deux défauts opposés

`pd.Series(x).var()` (`ddof=1` par défaut) → 25,357

Correction — Exercice 2

- (a) Excès = $\gamma_2 - 3 \approx 5,02 - 3 = 2,02$.
- (b) Il faut préciser `scipy.stats.kurtosis(x, fisher=False)` pour obtenir directement $\gamma_2 \approx 5,02$ plutôt que l'excès.
- (c) Selon la convention **excès** (référence 0, celle par défaut de `scipy`), $2,02 > 0$ signale une distribution **leptokurtique** (queues plus épaisses que la normale) — c'est la bonne lecture ici, puisque `kurtosis()` sans argument renvoie l'excès par défaut. Mais un lecteur habitué à la convention γ_2 (référence 3) et ignorant qu'il s'agit d'un excès pourrait, à tort, lire $2,02 < 3$ et conclure à une distribution **platykurtique** (moins pointue que la normale) — une lecture **opposée** à la réalité. C'est exactement l'avertissement du chapitre 8 et du chapitre 14 : un coefficient d'aplatissement ne s'interprète jamais sans connaître sa convention.

Correction — Exercice 3

- (a) Selon $[a; b[$, un revenu de 40 tombe dans la classe $[40, 80[$ (borne inférieure incluse).
- (b) Avec la convention par défaut de `pd.cut` (`right=True`, donc $]a; b]$), un revenu de 40 tomberait dans la classe **précédente**, $]20, 40]$ (borne supérieure incluse).
- (c) Il faut écrire `pd.cut(revenu, bins=[0, 10, 20, 40, 80], right=False)`. **Non**, ce piège n'est pas propre à Python : c'est exactement le même problème rencontré au chapitre 14 avec la fonction `cut()` de R, qui partage la même convention par défaut $]a; b]$ et se corrige de la même façon avec `right = FALSE`. Deux langages différents, syntaxe presque identique, même piège.

2 Exercices cumulatifs (chapitres 3 à 15)

Correction — Exercice 4

- (a) `x.mean()` renverrait $\frac{200 \times 5 + 150 \times 15 + 100 \times 30 + 50 \times 60}{500} = \frac{9\,250}{500} = 18,5$ — exactement la moyenne du chapitre 5.
- (b) `x.var()` sur un tableau numpy (`ddof=0` par défaut) renverrait **exactement** 275,25, la variance descriptive du chapitre 7, puisque numpy divise par $n = 500$ par défaut, en accord avec la convention du cours.
- (c) `pd.Series(x).var()` divise par $n - 1 = 499$: $\sum (x_i - \bar{x})^2 = 500 \times 275,25 = 137\,625$, donc le résultat

serait $137\,625/499 \approx 275,802$. La différence, bien que faible en valeur relative (0,2 % environ, comme dans l'exemple du cours sur les 500 salariés), vient du **même** mécanisme qu'à l'exercice 1 : seule la conversion en `pd.Series` change la convention de calcul (`ddof=1` au lieu de `ddof=0`), les données étant rigoureusement identiques dans les deux cas.

3 Applications en sciences économiques

Correction — Exercice 5

(a) **Non**, pas sans précaution : `sd()` en R et `.std()` en pandas divisent tous deux par $n - 1$ par défaut, mais `np.std()` divise par n par défaut. Les analystes A et B obtiendront donc la **même** valeur entre eux, tandis que l'analyste C obtiendra une valeur légèrement **différente**, sauf à préciser explicitement `ddof=1` dans son appel à `numpy`.

(b) Sur 2 000 observations, l'écart relatif entre les conventions n et $n - 1$ est de l'ordre de $1/(2n) \approx 0,025\%$: totalement **négligeable** et invisible dans un rapport arrondi à l'unité. En revanche, pour un sous-groupe de seulement 8 observations (comme dans une analyse détaillée par petite région), l'écart relatif $1/(2 \times 8) \approx 6,25\%$ devient potentiellement **visible**, et pourrait faire diverger deux analyses menées sur le même sous-groupe avec des outils différents.

(c) Une règle de gestion de projet raisonnable serait : « préciser explicitement et documenter, dans le code et dans le rapport, la convention de degrés de liberté (`ddof`) utilisée pour **chaque** calcul de variance ou d'écart-type, quel que soit l'outil employé, plutôt que de se fier aux valeurs par défaut de chaque bibliothèque » — cette seule discipline élimine la quasi-totalité des écarts inexpliqués entre collaborateurs utilisant des outils différents.

Correction — Exercice 6

(a) $\gamma_2 \approx 3,32$ (convention du cours) donne un excès $\gamma_2 - 3 \approx 0,32$ ✓, ce qui correspond bien au chiffre obtenu par défaut avec `scipy.stats.kurtosis()` (qui renvoie l'excès, `fisher=True` par défaut).

(b) **Oui**, absolument : un collègue habitué à la convention γ_2 (référence 3), s'il voit seulement le chiffre « 0,32 » sans savoir qu'il s'agit d'un **excès**, pourrait le comparer à tort au seuil 3 et conclure à une distribution **extrêmement** platykurtique (bien en-dessous de 3), alors qu'en réalité — dans la bonne convention — cette distribution est **légèrement leptokurtique** ($\gamma_2 \approx 3,32 > 3$), donc à queues plus épaisses que la normale.

(c) Cette confusion aurait des conséquences **concrètes** en gestion des risques : comme le rappelle le chapitre 8, un γ_2 supérieur à 3 (ou un excès positif) signale que les pertes extrêmes sont **plus fréquentes** que ne le prédit un modèle gaussien — c'est précisément l'un des mécanismes à l'origine des défaillances de la Value at Risk gaussienne lors de la crise de 2008. Un analyste convaincu à tort que ses rendements sont « quasiment normaux, voire moins risqués que la normale » (mauvaise lecture de l'excès) pourrait **sous-calibrer** une réserve de capital ou une limite de risque, avec des conséquences potentiellement sérieuses en cas de choc de marché. La bonne pratique rédactionnelle qui élimine ce risque : **toujours accompagner tout coefficient d'aplatissement de sa convention explicite dans le texte même du rapport** (par exemple « excès d'aplatissement (référence 0) = 0,32 » ou « γ_2 (référence 3) = 3,32 »), sans jamais se contenter du mot « aplatissement » suivi d'un simple nombre.