

Chapitre 15

Mise en œuvre sur Python

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Statistique descriptive

1 Exercices du chapitre

Exercice 1 — numpy contre pandas : deux conventions opposées

On reprend les temps de trajet (en minutes) de 8 employés du chapitre 7 : 15, 22, 18, 30, 25, 20, 28, 24, de variance **descriptive** $V(x) = 22,1875$.

- (a) Sachant que numpy utilise par défaut `ddof=0` (division par n), que renverrait `np.var(x)` ?
- (b) Sachant que pandas utilise par défaut `ddof=1` (division par $n - 1$), que renverrait `pd.Series(x).var()` ?
- (c) Un étudiant convertit son tableau numpy en `pd.Series` avant de calculer la variance, et s'étonne que le résultat ne corresponde plus à son calcul manuel. Expliquer précisément l'origine de cet écart.

Exercice 2 — L'argument fisher de scipy.stats.kurtosis

On reprend les notes du chapitre 8 : 60, 62, 58, 61, 59, 95, 57, pour lesquelles $\gamma_2 \approx 5,02$ (convention du cours, référence 3).

- (a) Calculer l'excès d'aplatissement $\gamma_2 - 3$.
- (b) Sachant que `scipy.stats.kurtosis()` renvoie par défaut l'excès (`fisher=True`), que faut-il préciser pour obtenir directement $\gamma_2 \approx 5,02$?
- (c) Un rapport indique « aplatissement = 2,02 » sans préciser la convention utilisée. Ce chiffre est-il, selon la convention, synonyme d'une distribution **leptokurtique** ou **platykurtique** ? Justifier dans les deux cas de figure possibles.

Exercice 3 — pd.cut et la borne right

On reprend les classes de revenu des chapitres 3 à 9 : bornes 0, 10, 20, 40, 80 (milliers de dh), convention $[a ; b[$.

- (a) Un ménage a un revenu de **exactement** 40. Dans quelle classe tombe-t-il selon la convention $[a ; b[$ du cours ?
- (b) Avec `pd.cut(revenu, bins=[0,10,20,40,80])` (sans préciser `right=False`), quelle classe pandas attribuerait-il à ce même ménage ?
- (c) Quelle instruction complète faut-il écrire pour obtenir la convention du cours ? Ce piège est-il propre à Python, ou l'avez-vous déjà rencontré ailleurs dans ce cours ?

2 Exercices cumulatifs (chapitres 3 à 15)

Exercice 4 — Bilan final : reconstruire et vérifier le revenu des chapitres 3–14

On reconstruit, à partir des classes de revenu des chapitres 3 à 14 ($[0, 10[$: 200 ménages de centre 5 ; $[10, 20[$: 150 de centre 15 ; $[20, 40[$: 100 de centre 30 ; $[40, 80[$: 50 de centre 60), un tableau `x` de 500 valeurs en répétant chaque centre de classe autant de fois que son effectif (`x = np.repeat(centres, effectifs)`).

- (a) Que renverrait `x.mean()` ? Comparer à la moyenne $\bar{x} = 18,5$ établie au chapitre 5.
- (b) Que renverrait `x.var()` (tableau numpy, `ddof=0` par défaut) ? Comparer à $V(x) = 275,25$ établi au chapitre 7.
- (c) Un collègue calcule `pd.Series(x).var()` sur ce même tableau et obtient un résultat légèrement différent. Calculer cette valeur, et expliquer pourquoi elle diffère de celle de la question (b) alors que les données sont rigoureusement identiques.

3 Applications en sciences économiques

Exercice 5 — Harmoniser les conventions dans une équipe de recherche

Une équipe de recherche en économie du travail prépare un rapport commun. L'analyste A utilise R et `sd()`, l'analyste B utilise pandas et `.std()`, l'analyste C utilise numpy et `np.std()`, chacun sur le **même** fichier de 2 000 salaires.

- (a) Ces trois analystes obtiendront-ils, sans précaution particulière, exactement le même écart-type ? Justifier à partir des conventions par défaut de chaque outil.
- (b) Sur un échantillon de 2 000 observations, l'écart relatif entre les conventions n et $n - 1$ est-il susceptible d'être visible à l'œil nu dans un rapport arrondi à l'unité, ou reste-t-il négligeable ? Est-ce toujours le cas pour un sous-groupe de 8 observations dans une analyse détaillée par région ?
- (c) Proposer une règle de gestion de projet (une phrase) que cette équipe devrait adopter pour garantir que son rapport final soit reproductible, quel que soit le logiciel utilisé par chaque analyste.

Exercice 6 — L'ambiguïté de `fisher` dans un rapport de risque financier

On reprend les rendements journaliers du chapitre 8 (exercice 5) : 0,5, -0,3, 0,2, -0,1, 3,0, -2,8, 0,4 (en %), pour lesquels $\gamma_2 \approx 3,32$ (convention du cours).

- (a) Un analyste utilise `scipy.stats.kurtosis(rendements)` sans argument et obtient 0,32. Vérifier que ce chiffre correspond bien à l'excès d'aplatissement.
- (b) L'analyste écrit dans son rapport : « aplatissement = 0,32, proche de zéro, la distribution est quasiment normale ». Un collègue, habitué à la convention γ_2 (référence 3), pourrait-il mal interpréter cette phrase si on lui rapportait seulement le chiffre 0,32 sans préciser la convention ?
- (c) Pourquoi une confusion sur ce seul chiffre pourrait-elle avoir des conséquences concrètes dans un contexte de gestion des risques de marché (faire le lien avec la mise en garde du chapitre 8 sur la Value at Risk gaussienne) ? Quelle bonne pratique rédactionnelle élimine totalement ce risque de confusion ?