

# Chapitre 14

Mise en œuvre sur R

**Corrigé**

---

**Jaouad Madkour**

Faculté d'Économie et de Gestion de Tanger  
Exercices et corrigés · Statistique descriptive

## 1 Exercices du chapitre

### Correction — Exercice 1

(a)  $\text{var}(x)$  calcule  $\frac{1}{n-1} \sum (x_i - \bar{x})^2$ . Or  $\sum (x_i - \bar{x})^2 = n \times V(x) = 8 \times 22,1875 = 177,5$ . Donc  $\text{var}(x) = 177,5/7 \approx 25,357$ .

(b)  $\text{sd}(x) = \sqrt{25,357} \approx 5,036$ .

(c) L'instruction `sd(x) * sqrt((n-1)/n)` redonne l'écart-type descriptif :  $5,036 \times \sqrt{7/8} = 5,036 \times 0,9354 \approx 4,710$ , exactement la valeur  $\sigma_x \approx 4,71$  calculée à la main au chapitre 7.

`var(x)` : divise par  $n - 1 = 7 \rightarrow 25,357$

↓ correction

$\times (n - 1)/n$  : variance **descriptive**  $\rightarrow 22,1875$

### Correction — Exercice 2

(a) La colonne `salaire` devrait normalement être de type `int` ou `num` (variable quantitative continue).

(b) La cause probable est que certaines lignes du fichier source notent les montants avec une **espace** comme séparateur de milliers et une **virgule** comme séparateur décimal (« 4 380,50 »), une convention française que R, configuré par défaut en anglo-saxon, ne reconnaît pas comme un nombre : il lit alors toute la colonne comme du texte, donc comme un facteur.

(c) `mean(sal$salaire)` renverrait soit une **erreur**, soit (si R force malgré tout une conversion) la moyenne des **codes numériques internes** des niveaux du facteur — un nombre totalement dénué de sens, sans aucun rapport avec le salaire moyen réel, et sans qu'aucun message ne signale nécessairement le problème de façon évidente à l'utilisateur inattentif. La première commande à exécuter après tout `import` est `str()`, précisément pour vérifier le **type** de chaque colonne avant tout calcul.

### Correction — Exercice 3

(a) Selon la convention  $[a ; b[$  utilisée depuis le chapitre 3, un revenu de 10 appartient à la classe  $[10, 20[$  (la borne inférieure est incluse, la supérieure exclue).

(b) Avec les classes par défaut de R,  $]a ; b]$ , un revenu de 10 appartiendrait à la classe  $]0, 10]$  (borne inférieure exclue, supérieure incluse) — c'est-à-dire la classe **précédente**.

(c) Ce n'est pas un détail mineur car, dans un jeu de données réel, de **nombreux** ménages peuvent avoir un revenu arrivant exactement à une borne ronde (10, 20, 40 milliers de dh) — un arrondi de déclaration, un salaire minimum, un seuil réglementaire. Sans `right = FALSE`, **tous ces individus** basculeraient systématiquement dans la classe inférieure à celle prévue par la convention du cours, ce qui décale les effectifs de **plusieurs** classes à la fois (et non d'une seule observation isolée), avec un effet potentiellement important sur l'histogramme, la médiane par interpolation, et tous les indicateurs qui en découlent.

## 2 Exercices cumulatifs (chapitres 3 à 14)

### Correction — Exercice 4

(a) `cov()` et `var()` divisent par  $n - 1 = 5$  au lieu de  $n = 6$ . Somme des produits croisés =  $n \times \text{cov}_{\text{desc}} = 6 \times 1900 = 11\,400$ , donc `cov(anciennete, salaire)` =  $11\,400/5 = 2\,280$ . Somme des carrés des écarts de l'ancienneté =  $n \times V_{\text{desc}} = 6 \times 7,556 = 45,33$ , donc `var(anciennete)` =  $45,33/5 \approx 9,067$ .

(b)  $2\,280/9,067 \approx 251,47$  — **exactement** la même valeur que  $\hat{b} = 251,47$  calculée à la main (division par  $n$ ) au chapitre 13.

(c) Le facteur de correction  $n/(n-1)$  apparaît à la fois au **numérateur** (dans `cov`) et au **dénominateur** (dans `var`) de  $\hat{b} = \text{cov}/V$  : il se **simplifie exactement** dans le rapport, quel que soit  $n$ . C'est pourquoi la pente d'une régression ne dépend jamais de la convention  $n$  ou  $n-1$  choisie pour la covariance et la variance. **Oui**, la même propriété vaut pour  $r = \text{cov}/(\sigma_x \sigma_y)$  : le facteur  $n/(n-1)$  apparaît une fois au numérateur et, sous la racine, une fois dans chacun des deux écarts-types au dénominateur, et se simplifie de la même manière. C'est pour cette raison que `cor(z, y)` en R donne directement le même  $r$  que le calcul manuel du chapitre 13, sans qu'aucune correction ne soit nécessaire.

### 3 Applications en sciences économiques

#### Correction — Exercice 5

- (a) R attribuerait très probablement le type `Factor` (ou `character`) à cette colonne, puisqu'elle mélange des valeurs numériques et des chaînes de caractères (« ne sait pas », « refuse de répondre ») dans le même champ.
- (b) La moyenne, la médiane, l'écart-type et les quantiles deviendraient tous **impossibles** à calculer directement : ce sont des opérations arithmétiques qui exigent une variable numérique, alors qu'un facteur ne contient, du point de vue de R, que des catégories sans ordre de grandeur exploitable.
- (c) La démarche nécessaire est de **recoder** les réponses non numériques (« ne sait pas », « refuse ») en valeurs manquantes explicites (NA) avant de reconverter la colonne en type numérique, puis de décider comment traiter ces manquants (exclusion, imputation) selon le protocole de l'enquête. `str()` est l'outil qui permet de détecter ce problème **en amont**, immédiatement après l'import, avant qu'une moyenne ou un indicateur erroné (ou simplement NA) ne soit calculé silencieusement et, dans le pire des cas, publié comme statistique officielle et utilisé pour orienter une décision de politique économique.

#### Correction — Exercice 6

- (a) `sort(v)` trie le vecteur par ordre **croissant**. C'est indispensable car la formule  $G = \frac{2 \sum i x_i}{n \sum x_i} - \frac{n+1}{n}$  suppose explicitement, dans son énoncé même (chapitre 9), que les  $x_i$  sont « classés par ordre croissant » : le rang  $i$  n'a de sens que si  $x_1 \leq x_2 \leq \dots \leq x_n$ .
- (b) `seq_len(n)` produit le vecteur des rangs  $1, 2, \dots, n$ , c'est-à-dire exactement les valeurs de  $i$  utilisées dans  $\sum i x_i$  de la formule du chapitre 9.
- (c) **Non**, le résultat serait **incorrect** sans le tri préalable : avec  $v = (32, 3, 8, 2, 5)$  non trié, le rang  $i = 1$  serait associé à 32 (la plus grande valeur) au lieu de 2 (la plus petite), ce qui inverserait complètement la pondération croissante par les rangs que la formule impose, et donnerait un indice de Gini n'ayant plus aucun rapport avec la vraie concentration du chiffre d'affaires entre les cinq entreprises. C'est précisément pour éviter cette erreur silencieuse que la fonction commence par `v <- sort(v)`, indépendamment de l'ordre dans lequel l'utilisateur fournit son vecteur.