

Statistique descriptive

Chapitre 14 : Mise en œuvre sur R

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique descriptive

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Le piège n contre $n-1$

On reprend les temps de trajet (en minutes) de 8 employés du chapitre 7 : 15, 22, 18, 30, 25, 20, 28, 24, de moyenne 22,75 et de variance **descriptive** $V(x) = 22,1875$.

- (a) Sachant que la fonction `var()` de R divise par $n - 1$ et non par n , calculer la valeur que `var(x)` afficherait sur ces données.
- (b) En déduire ce qu'afficherait `sd(x)`.
- (c) Quelle instruction R, appliquée au résultat de `sd(x)`, permet de retrouver l'écart-type **descriptif** du chapitre 7 ? Calculer sa valeur numérique.

Exercice 2 — Diagnostiquer une sortie de `str()`

Un étudiant importe un fichier de 500 salariés et obtient la sortie suivante :

```
'data.frame': 500 obs. of 6 variables:
 $ id      : int  1 2 3 4 5 ...
 $ salaire : Factor w/ 498 levels "4 380,50", "4 500", ...: 1 2 3 ...
 $ anciennete: int  10 15 4 ...
```

- (a) Que devrait normalement être le type de la colonne `salaire` ?
- (b) Sachant que le premier niveau affiché est "4 380,50" (avec une espace et une virgule décimale), quelle en est probablement la cause ?
- (c) Que se passerait-il si l'étudiant calculait directement `mean(sal$salaire)` sans corriger ce problème ? Quelle est la première commande à exécuter après tout import de données, d'après le cours ?

Exercice 3 — Le piège `right = FALSE`

On reprend les classes de revenu des chapitres 3 à 9 : bornes 0, 10, 20, 40, 80 (en milliers de dh), avec la convention $[a ; b[$.

- (a) Un ménage a un revenu de **exactement** 10 (milliers de dh). Dans quelle classe doit-il tomber selon la convention $[a ; b[$ utilisée depuis le chapitre 3 ?
- (b) Avec l'instruction `cut(revenu, breaks = c(0, 10, 20, 40, 80))` (sans préciser `right = FALSE`), R utilise par défaut des classes $]a ; b]$. Dans quelle classe ce même ménage serait-il alors classé ?
- (c) Pourquoi cette différence n'est-elle pas un détail technique mineur, mais un problème qui peut fausser les effectifs de **plusieurs** classes lorsque les données comportent de nombreuses valeurs rondes (ici, des revenus arrivant exactement à 10, 20 ou 40) ?

2 Exercices cumulatifs (chapitres 3 à 14)

Exercice 4 — Reproduire en R le calcul du chapitre 13

On reprend le jeu de données `ancienneté-salaire` des chapitres 10, 12 et 13 ($n = 6$) : covariance **descriptive** = 1 900, $V_{\text{descriptive}}(\text{ancienneté}) = 7,556$, pente $\hat{b} = 251,47$.

- (a) Sachant que R calcule `cov()` et `var()` en divisant par $n - 1$, calculer les valeurs que `cov(anciennete, salaire)` et `var(anciennete)` afficheraient dans R sur ces 6 observations.
- (b) Calculer le rapport `cov(anciennete, salaire) / var(anciennete)` à partir de ces deux valeurs « version R ». Comparer au $\hat{b} = 251,47$ calculé « à la main » (division par n) au chapitre 13.
- (c) Expliquer pourquoi la pente $\hat{b}$ d'une régression, contrairement à la covariance et à la variance prises isolément, ne dépend **pas** de la convention n ou $n - 1$ utilisée. Cette même propriété vaut-

elle aussi pour le coefficient de corrélation r ?

3 Applications en sciences économiques

Exercice 5 — Une erreur de type dans une enquête nationale

Un institut national de la statistique publie chaque trimestre une enquête emploi sur un échantillon de 12 000 ménages. Lors d'une actualisation du questionnaire, une nouvelle question sur le « revenu mensuel net » est ajoutée, avec la possibilité de répondre « ne sait pas » ou « refuse de répondre » en toutes lettres dans le même champ que les montants numériques.

- (a) Quel type de variable R attribuerait-il probablement à cette colonne « revenu » une fois le fichier importé ?
- (b) Quelles statistiques usuelles (moyenne, médiane, écart-type, quantiles) deviendraient impossibles à calculer directement, et pourquoi ?
- (c) Proposer, en une phrase, la démarche de nettoyage nécessaire avant tout calcul, et expliquer pourquoi `str()` est l'outil qui permet de détecter ce problème **avant** qu'il ne se propage dans des indicateurs publiés (et potentiellement dans une décision de politique économique fondée dessus).

Exercice 6 — Écrire un script pour l'indice de Gini

On souhaite calculer, en R, l'indice de Gini des cinq entreprises du chapitre 9 (chiffres d'affaires 2, 3, 5, 8, 32 millions de dh, dont on a calculé à la main $G = 0,52$), en utilisant la fonction `gini()` du cours :

```
gini <- function(v) {  
  v <- sort(v); n <- length(v)  
  2*sum(seq_len(n)*v)/(n*sum(v)) - (n+1)/n  
}
```

- (a) Que fait la ligne `v <- sort(v)` ? Pourquoi est-elle indispensable au bon fonctionnement de cette fonction (se référer à la formule du chapitre 9) ?
- (b) Que représente `seq_len(n)` ? Faire le lien avec la variable i de la formule $G = \frac{2 \sum i x_i}{n \sum x_i} - \frac{n+1}{n}$.
- (c) Si un utilisateur appelait `gini(v)` avec un vecteur v non trié (par exemple 32, 3, 8, 2, 5), le résultat serait-il correct ? Justifier à partir du rôle de i dans la formule.

1 Exercices du chapitre

Correction — Exercice 1

(a) $\text{var}(x)$ calcule $\frac{1}{n-1} \sum (x_i - \bar{x})^2$. Or $\sum (x_i - \bar{x})^2 = n \times V(x) = 8 \times 22,1875 = 177,5$. Donc $\text{var}(x) = 177,5/7 \approx 25,357$.

(b) $\text{sd}(x) = \sqrt{25,357} \approx 5,036$.

(c) L'instruction `sd(x) * sqrt((n-1)/n)` redonne l'écart-type descriptif : $5,036 \times \sqrt{7/8} = 5,036 \times 0,9354 \approx 4,710$, exactement la valeur $\sigma_x \approx 4,71$ calculée à la main au chapitre 7.

`var(x)` : divise par $n - 1 = 7 \rightarrow 25,357$

↓ correction

$\times (n - 1)/n$: variance **descriptive** $\rightarrow 22,1875$

Correction — Exercice 2

(a) La colonne `salaire` devrait normalement être de type `int` ou `num` (variable quantitative continue).

(b) La cause probable est que certaines lignes du fichier source notent les montants avec une **espace** comme séparateur de milliers et une **virgule** comme séparateur décimal (« 4 380,50 »), une convention française que R, configuré par défaut en anglo-saxon, ne reconnaît pas comme un nombre : il lit alors toute la colonne comme du texte, donc comme un facteur.

(c) `mean(sal$salaire)` renverrait soit une **erreur**, soit (si R force malgré tout une conversion) la moyenne des **codes numériques internes** des niveaux du facteur — un nombre totalement dénué de sens, sans aucun rapport avec le salaire moyen réel, et sans qu'aucun message ne signale nécessairement le problème de façon évidente à l'utilisateur inattentif. La première commande à exécuter après tout `import` est `str()`, précisément pour vérifier le **type** de chaque colonne avant tout calcul.

Correction — Exercice 3

(a) Selon la convention $[a ; b[$ utilisée depuis le chapitre 3, un revenu de 10 appartient à la classe $[10, 20[$ (la borne inférieure est incluse, la supérieure exclue).

(b) Avec les classes par défaut de R, $]a ; b]$, un revenu de 10 appartiendrait à la classe $]0, 10]$ (borne inférieure exclue, supérieure incluse) — c'est-à-dire la classe **précédente**.

(c) Ce n'est pas un détail mineur car, dans un jeu de données réel, de **nombreux** ménages peuvent avoir un revenu arrivant exactement à une borne ronde (10, 20, 40 milliers de dh) — un arrondi de déclaration, un salaire minimum, un seuil réglementaire. Sans `right = FALSE`, **tous ces individus** basculeraient systématiquement dans la classe inférieure à celle prévue par la convention du cours, ce qui décale les effectifs de **plusieurs** classes à la fois (et non d'une seule observation isolée), avec un effet potentiellement important sur l'histogramme, la médiane par interpolation, et tous les indicateurs qui en découlent.

2 Exercices cumulatifs (chapitres 3 à 14)

Correction — Exercice 4

(a) `cov()` et `var()` divisent par $n - 1 = 5$ au lieu de $n = 6$. Somme des produits croisés = $n \times \text{cov}_{\text{desc}} = 6 \times 1900 = 11\,400$, donc `cov(anciennete, salaire)` = $11\,400/5 = 2\,280$. Somme des carrés des écarts de l'ancienneté = $n \times V_{\text{desc}} = 6 \times 7,556 = 45,33$, donc `var(anciennete)` = $45,33/5 \approx 9,067$.

(b) $2\,280/9,067 \approx 251,47$ — **exactement** la même valeur que $\hat{b} = 251,47$ calculée à la main (division par n) au chapitre 13.

(c) Le facteur de correction $n/(n-1)$ apparaît à la fois au **numérateur** (dans `cov`) et au **dénominateur** (dans `var`) de $\hat{b} = \text{cov}/V$: il se **simplifie exactement** dans le rapport, quel que soit n . C'est pourquoi la pente d'une régression ne dépend jamais de la convention n ou $n-1$ choisie pour la covariance et la variance. **Oui**, la même propriété vaut pour $r = \text{cov}/(\sigma_x \sigma_y)$: le facteur $n/(n-1)$ apparaît une fois au numérateur et, sous la racine, une fois dans chacun des deux écarts-types au dénominateur, et se simplifie de la même manière. C'est pour cette raison que `cor(z, y)` en R donne directement le même r que le calcul manuel du chapitre 13, sans qu'aucune correction ne soit nécessaire.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) R attribuerait très probablement le type `Factor` (ou `character`) à cette colonne, puisqu'elle mélange des valeurs numériques et des chaînes de caractères (« ne sait pas », « refuse de répondre ») dans le même champ.
- (b) La moyenne, la médiane, l'écart-type et les quantiles deviendraient tous **impossibles** à calculer directement : ce sont des opérations arithmétiques qui exigent une variable numérique, alors qu'un facteur ne contient, du point de vue de R, que des catégories sans ordre de grandeur exploitable.
- (c) La démarche nécessaire est de **recoder** les réponses non numériques (« ne sait pas », « refuse ») en valeurs manquantes explicites (NA) avant de reconvertir la colonne en type numérique, puis de décider comment traiter ces manquants (exclusion, imputation) selon le protocole de l'enquête. `str()` est l'outil qui permet de détecter ce problème **en amont**, immédiatement après l'import, avant qu'une moyenne ou un indicateur erroné (ou simplement NA) ne soit calculé silencieusement et, dans le pire des cas, publié comme statistique officielle et utilisé pour orienter une décision de politique économique.

Correction — Exercice 6

- (a) `sort(v)` trie le vecteur par ordre **croissant**. C'est indispensable car la formule $G = \frac{2 \sum i x_i}{n \sum x_i} - \frac{n+1}{n}$ suppose explicitement, dans son énoncé même (chapitre 9), que les x_i sont « classés par ordre croissant » : le rang i n'a de sens que si $x_1 \leq x_2 \leq \dots \leq x_n$.
- (b) `seq_len(n)` produit le vecteur des rangs $1, 2, \dots, n$, c'est-à-dire exactement les valeurs de i utilisées dans $\sum i x_i$ de la formule du chapitre 9.
- (c) **Non**, le résultat serait **incorrect** sans le tri préalable : avec $v = (32, 3, 8, 2, 5)$ non trié, le rang $i = 1$ serait associé à 32 (la plus grande valeur) au lieu de 2 (la plus petite), ce qui inverserait complètement la pondération croissante par les rangs que la formule impose, et donnerait un indice de Gini n'ayant plus aucun rapport avec la vraie concentration du chiffre d'affaires entre les cinq entreprises. C'est précisément pour éviter cette erreur silencieuse que la fonction commence par `<- sort(v)`, indépendamment de l'ordre dans lequel l'utilisateur fournit son vecteur.