

Chapitre 14

Mise en œuvre sur R

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Statistique descriptive

1 Exercices du chapitre

Exercice 1 — Le piège n contre $n-1$

On reprend les temps de trajet (en minutes) de 8 employés du chapitre 7 : 15, 22, 18, 30, 25, 20, 28, 24, de moyenne 22,75 et de variance **descriptive** $V(x) = 22,1875$.

- (a) Sachant que la fonction `var()` de R divise par $n - 1$ et non par n , calculer la valeur que `var(x)` afficherait sur ces données.
- (b) En déduire ce qu'afficherait `sd(x)`.
- (c) Quelle instruction R, appliquée au résultat de `sd(x)`, permet de retrouver l'écart-type **descriptif** du chapitre 7? Calculer sa valeur numérique.

Exercice 2 — Diagnostiquer une sortie de `str()`

Un étudiant importe un fichier de 500 salariés et obtient la sortie suivante :

```
'data.frame': 500 obs. of 6 variables:
 $ id      : int  1 2 3 4 5 ...
 $ salaire : Factor w/ 498 levels "4 380,50","4 500",...: 1 2 3 ...
 $ anciennete: int  10 15 4 ...
```

- (a) Que devrait normalement être le type de la colonne `salaire`?
- (b) Sachant que le premier niveau affiché est "4 380,50" (avec une espace et une virgule décimale), quelle en est probablement la cause?
- (c) Que se passerait-il si l'étudiant calculait directement `mean(sal$salaire)` sans corriger ce problème? Quelle est la première commande à exécuter après tout import de données, d'après le cours?

Exercice 3 — Le piège `right = FALSE`

On reprend les classes de revenu des chapitres 3 à 9 : bornes 0, 10, 20, 40, 80 (en milliers de dh), avec la convention $[a; b[$.

- (a) Un ménage a un revenu de **exactement** 10 (milliers de dh). Dans quelle classe doit-il tomber selon la convention $[a; b[$ utilisée depuis le chapitre 3?
- (b) Avec l'instruction `cut(revenu, breaks = c(0,10,20,40,80))` (sans préciser `right = FALSE`), R utilise par défaut des classes $]a; b]$. Dans quelle classe ce même ménage serait-il alors classé?
- (c) Pourquoi cette différence n'est-elle pas un détail technique mineur, mais un problème qui peut fausser les effectifs de **plusieurs** classes lorsque les données comportent de nombreuses valeurs rondes (ici, des revenus arrivant exactement à 10, 20 ou 40)?

2 Exercices cumulatifs (chapitres 3 à 14)

Exercice 4 — Reproduire en R le calcul du chapitre 13

On reprend le jeu de données ancienneté-salaire des chapitres 10, 12 et 13 ($n = 6$) : covariance **descriptive** = 1900, $V_{\text{descriptive}}(\text{ancienneté}) = 7,556$, pente $\hat{b} = 251,47$.

- (a) Sachant que R calcule `cov()` et `var()` en divisant par $n - 1$, calculer les valeurs que `cov(anciennete, salaire)` et `var(anciennete)` afficheraient dans R sur ces 6 observations.
- (b) Calculer le rapport `cov(anciennete, salaire) / var(anciennete)` à partir de ces deux valeurs « version R ». Comparer au $\hat{b} = 251,47$ calculé « à la main » (division par n) au chapitre 13.
- (c) Expliquer pourquoi la pente $\hat{b}$ d'une régression, contrairement à la covariance et à la variance prises isolément, ne dépend **pas** de la convention n ou $n - 1$ utilisée. Cette même propriété vaut-

3 Applications en sciences économiques

Exercice 5 — Une erreur de type dans une enquête nationale

Un institut national de la statistique publie chaque trimestre une enquête emploi sur un échantillon de 12 000 ménages. Lors d'une actualisation du questionnaire, une nouvelle question sur le « revenu mensuel net » est ajoutée, avec la possibilité de répondre « ne sait pas » ou « refuse de répondre » en toutes lettres dans le même champ que les montants numériques.

- (a) Quel type de variable R attribuerait-il probablement à cette colonne « revenu » une fois le fichier importé ?
- (b) Quelles statistiques usuelles (moyenne, médiane, écart-type, quantiles) deviendraient impossibles à calculer directement, et pourquoi ?
- (c) Proposer, en une phrase, la démarche de nettoyage nécessaire avant tout calcul, et expliquer pourquoi `str()` est l'outil qui permet de détecter ce problème **avant** qu'il ne se propage dans des indicateurs publiés (et potentiellement dans une décision de politique économique fondée dessus).

Exercice 6 — Écrire un script pour l'indice de Gini

On souhaite calculer, en R, l'indice de Gini des cinq entreprises du chapitre 9 (chiffres d'affaires 2, 3, 5, 8, 32 millions de dh, dont on a calculé à la main $G = 0,52$), en utilisant la fonction `gini()` du cours :

```
gini <- function(v) {  
  v <- sort(v); n <- length(v)  
  2*sum(seq_len(n)*v)/(n*sum(v)) - (n+1)/n  
}
```

- (a) Que fait la ligne `v <- sort(v)` ? Pourquoi est-elle indispensable au bon fonctionnement de cette fonction (se référer à la formule du chapitre 9) ?
- (b) Que représente `seq_len(n)` ? Faire le lien avec la variable i de la formule $G = \frac{2 \sum i x_i}{n \sum x_i} - \frac{n+1}{n}$.
- (c) Si un utilisateur appelait `gini(v)` avec un vecteur v non trié (par exemple 32, 3, 8, 2, 5), le résultat serait-il correct ? Justifier à partir du rôle de i dans la formule.