

Statistique descriptive

Chapitre 14 : Mise en œuvre sur R

Jaouad Madkour

24 septembre 2026

Plan du chapitre

Refaire toute la chaîne	2
Le programme	2
Le programme (suite)	2
Charger et explorer	2
L'import	2
L'import (suite)	3
Le contrôle des manquants	3
Le tableau statistique	3
Variable qualitative	3
Variable continue : le découpage en classes	3
Les graphiques	4
Les quatre représentations	4
Les quatre représentations (suite)	4
La boîte à moustaches	4
Les indicateurs univariés	5
Tendance centrale et dispersion	5
Forme et concentration	5
La courbe de Lorenz	5
Forme et concentration (suite)	6
Le bivarié	6
Contingence	6
Conditionnelles et décomposition de la variance	6
Covariance, corrélation, ajustement	7
Le graphique final	7
Le script complet	7
Quinze lignes	7
Ce qu'il faut retenir	8

Refaire toute la chaîne

Le programme

Ce chapitre reprend les quatorze précédents

Étape	Chapitres
Importer et décrire les variables	2
Tableau statistique et classes	3, 4
Les quatre graphiques	5
Tendance centrale, quantiles, dispersion, forme	6 à 9
Lorenz et Gini	10
Contingence et conditionnelles	11, 12
Covariance, corrélation, ajustement	13, 14

Le programme (suite)

Le but n'est pas d'apprendre R

C'est de **vérifier** que les résultats calculés à la main sont bien ceux que produit un logiciel — et de constater que quinze lignes de code remplacent un semestre de calculs.
Comprendre la formule reste indispensable : c'est ce qui permet de savoir **quelle** fonction demander et de reconnaître un résultat aberrant.

Charger et explorer

L'import

```
# Les données : 500 salariés, six colonnes
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)

str(sal)
head(sal)
summary(sal)
```

La sortie de str()

```
'data.frame': 500 obs. of 6 variables:
 $ id      : int  1 2 3 4 5 ...
 $ salaire : int  8540 7100 4380 ...
 $ anciennete: int  10 15 4 ...
 $ diplome  : Factor w/ 3 levels "Bac","Bac+2","Bac+5"
 $ region   : Factor w/ 4 levels "Autres","Casablanca",...
 $ sexe     : Factor w/ 2 levels "F","H"
```

L'import (suite)

Le premier réflexe : vérifier les types

Factor pour les qualitatives, int ou num pour les quantitatives.

Si R a lu salaire comme un facteur, c'est qu'une ligne contient du texte — un espace, une virgule décimale, un « n.d. ». **Toutes les moyennes seraient alors impossibles.**

C'est la première erreur à chercher, et elle survient dans un fichier réel sur deux.

Le contrôle des manquants

```
colSums(is.na(sal))      # combien de valeurs manquantes par colonne
nrow(sal)                # 500
length(unique(sal$salaire)) # 381 valeurs distinctes
```

Pourquoi 381 valeurs distinctes comptent

C'est le critère du chapitre 1 : 381 valeurs pour 500 individus, donc on traitera le salaire comme **continu** et on le regroupera en classes.

Le tableau statistique

Variable qualitative

```
n <- nrow(sal)
ni <- table(sal$diplome)          # effectifs
fi <- prop.table(ni)              # fréquences
Ni <- cumsum(ni)                  # effectifs cumulés
Fi <- cumsum(fi)                  # fréquences cumulées

tableau <- data.frame(ni, fi = as.numeric(fi),
                      Ni = as.numeric(Ni), Fi = as.numeric(Fi))
print(tableau, digits = 3)
```

Le résultat

	Var1	Freq	fi	Ni	Fi
1	Bac	219	0.438	219	0.438
2	Bac+2	174	0.348	393	0.786
3	Bac+5	107	0.214	500	1.000

Exactement le tableau du chapitre 2.

Variable continue : le découpage en classes

```
bornes <- c(2000, 4000, 6000, 8000, 10000, 14000, 20000)
cl <- cut(sal$salaire, breaks = bornes, right = FALSE) # [a ; b[
ni <- table(cl)
ai <- diff(bornes)          # amplitudes
di <- as.numeric(ni) / ai   # densités
```

```
data.frame(classe = names(ni), ni = as.numeric(ni),
           fi = as.numeric(ni)/n, ai, di)
```

L'argument `right = FALSE` est essentiel

Par défaut, R crée des classes $]a; b]$ — **ouvertes à gauche**, fermées à droite. C'est l'inverse de la convention française.

`right = FALSE` rétablit $[a; b[$. Sans lui, tous les effectifs sont décalés aux bornes.

Les graphiques

Les quatre représentations

```
par(mfrow = c(2, 2))

barplot(table(sal$diplome), col = "steelblue",
        main = "Diplôme", ylab = "effectif")

pie(table(sal$region), main = "Région")

hist(sal$salaire, breaks = bornes, freq = FALSE, col = "steelblue",
     main = "Salaire", xlab = "dirhams", ylab = "densité")

plot(ecdf(sal$salaire), main = "Cumulative croissante",
     xlab = "dirhams", ylab = "F(x)")
```

Les quatre représentations (suite)

L'argument qui compte : `freq = FALSE`

Avec `freq = TRUE` (le défaut), `hist` trace les **effectifs** : l'histogramme est faux dès que les amplitudes sont inégales.

`freq = FALSE` trace les **densités** — la règle du chapitre 3. **À écrire systématiquement.**

La boîte à moustaches

```
boxplot(salaire ~ diplome, data = sal,
        col = c("steelblue", "orange", "seagreen"),
        ylab = "salaire (dirhams)")
```

La syntaxe formule

$y \sim x$ se lit « *y* **selon** *x* ». C'est la notation centrale de R, et elle servira à toute la modélisation.

Ici elle produit directement les distributions **conditionnelles** du chapitre 11.

Les indicateurs univariés

Tendance centrale et dispersion

```
x <- sal$salaire

mean(x)          # 7158.26
median(x)        # 6770
quantile(x, c(.10,.25,.50,.75,.90))
IQR(x)          # 3012
var(x) * (n-1)/n # 6750122  variance descriptive
sd(x) * sqrt((n-1)/n) # 2598.10 écart-type descriptif
sd(x)/mean(x)    # 0.363   coefficient de variation
```

Le piège n contre n-1

R divise par n — 1, pas par n . `var()` calcule la variance dite corrigée, celle de l'inférentielle.

La variance **descriptive** du chapitre 7 divise par n . D'où la correction $\ast (n-1)/n$.

Sur 500 observations l'écart est de 0,2% — négligeable en pratique, mais il faut savoir qu'il existe, et il devient sensible sur de petits échantillons. **Un étudiant qui trouve un écart avec son calcul manuel doit vérifier ce point en premier.**

Forme et concentration

```
library(moments)
skewness(x)          # 1.164  asymétrie
kurtosis(x)          # 4.837  aplatissement, référence 3

gini <- function(v) {
  v <- sort(v); n <- length(v)
  2*sum(seq_len(n)*v)/(n*sum(v)) - (n+1)/n
}
gini(x)              # 0.195
```

La courbe de Lorenz

```
# Courbe de Lorenz
v <- sort(x)
F <- seq_len(n)/n
Q <- cumsum(v)/sum(v)
plot(c(0,F), c(0,Q), type = "l", lwd = 2, col = "steelblue",
     xlab = "part cumulée des salariés",
     ylab = "part cumulée de la masse salariale")
abline(0, 1, col = "grey50")
```

Forme et concentration (suite)

Vérifier la convention d'aplatissement

`moments::kurtosis()` donne γ_2 , dont la référence est 3.

D'autres implémentations donnent l'excès $\gamma_2 - 3$, de référence 0. Sur les mêmes données, on lirait alors 1,84.

Les deux sont justes ; il faut savoir laquelle on regarde.

Le bivarié

Contingence

```
T <- table(sal$diplome, sal$region)
addmargins(T)                                # avec les marges
round(prop.table(T, 1), 3)                   # profils-lignes
round(prop.table(T, 2), 3)                   # profils-colonnes
round(chisq.test(T)$expected, 1)             # effectifs théoriques
```

L'argument `margin` de `prop.table`

1 divise par les totaux de **ligne**, 2 par les totaux de **colonne**, rien du tout par le total général.

C'est exactement la distinction conjointe / profil-ligne / profil-colonne du chapitre 10 — et l'erreur d'interprétation la plus fréquente tient à ce seul argument.

Conditionnelles et décomposition de la variance

```
# Moyennes et écarts-types conditionnels
aggregate(salaire ~ diplome, data = sal,
          FUN = function(v) c(n = length(v), moy = mean(v), et = sd(v)))

# Décomposition de la variance
g  <- split(sal$salaire, sal$diplome)
nj <- sapply(g, length)
mj <- sapply(g, mean)
vj <- sapply(g, function(v) mean((v - mean(v))^2))
mg <- mean(sal$salaire)

intra <- sum(nj*vj)/n                # 5010426
inter <- sum(nj*(mj - mg)^2)/n       # 1739696
eta2  <- inter/(intra + inter)       # 0.258
```

Le contrôle à faire

`intra + inter` doit redonner la variance descriptive totale, 6 750 122.

Si ce n'est pas le cas, c'est presque toujours que `vj` a été calculé avec `var()`, donc en $n - 1$.

Le contrôle détecte l'erreur immédiatement.

Covariance, corrélation, ajustement

```
y <- sal$salaire
z <- sal$anciennete

cov(z, y) * (n-1)/n      # 9859.9    covariance descriptive
cor(z, y)                # 0.6363    coefficient de corrélation
cor(z, y)^2              # 0.4049    coefficient de détermination

mod <- lm(salaire ~ anciennete, data = sal)
summary(mod)
```

La sortie de lm()

Coefficients:

	Estimate
(Intercept)	4347.2
anciennete	277.17

Multiple R-squared: 0.4049

$\hat{a} = 4347$, $\hat{b} = 277$, $r^2 = 0,405$: les valeurs du chapitre 13, retrouvées à l'identique.

Le graphique final

```
plot(z, y, pch = 20, col = rgb(0,0,1,0.35),
     xlab = "ancienneté (années)", ylab = "salaire (dirhams)")
abline(mod, col = "orange", lwd = 2)
points(mean(z), mean(y), pch = 19, col = "darkviolet", cex = 1.4)
```

Le contrôle visuel

Le point moyen doit être **sur** la droite. S'il ne l'est pas, le calcul est faux — c'est la propriété du chapitre 13, et elle sert ici de test.

Le script complet

Quinze lignes

```
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
n <- nrow(sal); x <- sal$salaire; z <- sal$anciennete

c(moyenne = mean(x), mediane = median(x),
  ecart_type = sd(x)*sqrt((n-1)/n), CV = sd(x)/mean(x))
quantile(x, c(.10,.25,.50,.75,.90))
c(asym = moments::skewness(x), aplat = moments::kurtosis(x))
gini(x)

table(sal$diplome, sal$region)
aggregate(salaire ~ diplome, sal, mean)
```

```
c(cov = cov(z,x)*(n-1)/n, r = cor(z,x), r2 = cor(z,x)^2)
coef(lm(salaire ~ anciennete, data = sal))
```

Ce que ce script produit

Tout le cours. Les douze indicateurs univariés, le tableau croisé, les conditionnelles, la corrélation et la droite.

Ce qui a demandé quatorze chapitres tient en quinze lignes — et c’est bien ainsi. **Le semestre n’a jamais servi à apprendre à calculer, mais à savoir ce qu’on calcule et comment le lire.**

Ce qu’il faut retenir

Le résumé du chapitre

Six points

1. `str()` d’abord : vérifier que chaque variable a le **bon type**.
2. `cut(..., right = FALSE)` pour des classes $[a; b[$ à la française.
3. `hist(..., freq = FALSE)` pour tracer des **densités**, pas des effectifs.
4. `var()` et `sd()` divisent par $n - 1$: corriger par $(n - 1)/n$ pour la variance descriptive.
5. `prop.table(T, 1)` et `prop.table(T, 2)` : profils-lignes et profils-colonnes, à ne pas confondre.
6. La syntaxe `y ~ x` est la clé de R : `boxplot`, `aggregate`, `lm` l’emploient toutes.

La suite

Le chapitre 15 refait exactement la même chaîne en Python, avec pandas et matplotlib — et retrouve les mêmes nombres.