

Statistique descriptive

Chapitre 1 : Population, variable, modalité

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique descriptive

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Définir la population et l'effectif

Un cabinet de recrutement souhaite étudier les candidatures reçues pour un poste durant le mois de mars : il en dénombre 340.

- (a) Identifier la population, l'individu et l'effectif total n de cette étude.
- (b) Le directeur du cabinet décide finalement de ne s'intéresser qu'aux candidatures ayant passé la présélection (soit 58 dossiers). Cette décision change-t-elle la population étudiée ? Justifier.
- (c) Pourquoi doit-on toujours écrire précisément la définition de la population **avant** tout calcul, plutôt que de la considérer comme un détail sans importance ?

Exercice 2 — Modalités exhaustives et incompatibles

Un questionnaire propose de classer l'ancienneté des salariés (en années) selon les classes suivantes : « moins de 5 », « de 5 à 10 », « de 10 à 20 », « 20 et plus ».

- (a) Un salarié ayant 10 ans d'ancienneté pose-t-il un problème avec ce découpage ? Identifier précisément le défaut.
- (b) Réécrire les quatre classes en respectant la convention « fermées à gauche, ouvertes à droite », afin de résoudre ce problème.
- (c) Ces classes corrigées sont-elles **exhaustives**, c'est-à-dire couvrent-elles bien toutes les anciennetés possibles, de 0 an à la plus élevée observée ? Justifier.

Exercice 3 — Variable binaire et piège du codage arbitraire

Sur 250 dossiers de crédit examinés par une banque, la variable « défaut » vaut 1 si l'emprunteur a fait défaut, 0 sinon. On compte 35 défauts.

- (a) Calculer la moyenne de cette variable binaire sur les 250 dossiers.
- (b) Que représente ce résultat concrètement, en termes de proportion ?
- (c) Une variable de satisfaction client (« Très insatisfait », « Insatisfait », « Neutre », « Satisfait », « Très satisfait ») est codée 1, 2, 3, 4, 5 et l'on en calcule une « moyenne » de 3,4. Pourquoi ce calcul est-il illégitime, contrairement à celui de la question (a) ? Quelle est la différence essentielle entre les deux codages ?

2 Exercices cumulatifs (introduction à chapitre 1)

Exercice 4 — Appliquer le vocabulaire au fichier salaires de l'introduction

Le chapitre d'introduction a présenté le fichier « salaires » : 500 salariés d'une entreprise, avec entre autres la variable `diplome` (modalités Bac, Bac+2, Bac+5).

- (a) En vous appuyant sur la définition donnée en introduction (« les salariés de l'entreprise au 31 décembre »), préciser la population, l'individu et l'effectif total n de cette étude.
- (b) Les trois modalités de `diplome` sont-elles exhaustives et incompatibles pour décrire le niveau de diplôme de **chaque** salarié de cette entreprise ? Que faudrait-il vérifier avant de l'affirmer avec certitude (par exemple, l'existence éventuelle de salariés non diplômés) ?
- (c) L'introduction mentionnait le piège consistant à coder `Bac` = 1, `Bac+2` = 2, `Bac+5` = 3 pour obtenir une « moyenne de diplôme » de 1,78. En utilisant le vocabulaire de ce chapitre (type de variable, sens des écarts), expliquer précisément pourquoi ce calcul est illégitime, et quel type d'indicateur (parmi ceux autorisés pour une variable ordinale) serait légitime à la place.

3 Applications en sciences économiques

Exercice 5 — Le taux de défaut comme moyenne d'une variable binaire

Reprenant l'exercice 3, une banque veut synthétiser son risque de crédit sur ses 250 dossiers examinés (35 défauts).

- (a) Rappeler la valeur de la moyenne de la variable « défaut » calculée à l'exercice 3.
- (b) En quoi cette propriété (« la moyenne d'une variable binaire 0/1 est une proportion ») permet-elle à la banque de calculer aisément un « taux de défaut » à partir d'un simple traitement statistique standard (calcul de moyenne), sans avoir besoin d'une formule spécifique?
- (c) Ce taux de défaut de 14 % suffit-il, à lui seul, pour que la banque fixe son niveau de provisionnement pour créances douteuses? Quelles autres informations (évoquées dans les chapitres à venir) faudrait-il probablement croiser avec ce taux?

Exercice 6 — Définir la population de pauvreté change le taux mesuré

Un pays compte une population totale de 2 000 000 d'habitants. Selon un seuil de pauvreté **strict**, 180 000 personnes sont considérées comme pauvres. Un seuil **élargi** (incluant les personnes en situation de pauvreté relative, proches du seuil) ajouterait 90 000 personnes supplémentaires.

- (a) Calculer le taux de pauvreté au sens strict ($180\,000/2\,000\,000$).
- (b) Calculer le taux de pauvreté au sens élargi (en ajoutant les 90 000 personnes supplémentaires au numérateur, la population totale restant inchangée).
- (c) Un gouvernement souhaite communiquer sur les progrès de sa politique sociale. Pourquoi le choix de la définition de la « population pauvre » (donc du champ retenu pour le calcul) n'est-il jamais un détail technique neutre, mais une décision aux conséquences politiques directes?

1 Exercices du chapitre

Correction — Exercice 1

- (a) Population : l'ensemble des candidatures reçues pour ce poste durant le mois de mars. Individu : une candidature. Effectif total : $n = 340$.
- (b) **Oui**, cela change radicalement la population étudiée : on passe de « toutes les candidatures reçues » ($n = 340$) à « les candidatures ayant passé la présélection » ($n = 58$), un sous-ensemble bien plus restreint et probablement non représentatif de l'ensemble initial (les candidatures présélectionnées sont, par construction, les meilleures selon un premier filtre).
- (c) Parce que le choix de la population détermine n , donc **toutes** les fréquences et moyennes qui en découlent : deux études portant sur des populations différentes (même si elles semblent porter « sur le même sujet ») produiront des chiffres non comparables. Une définition écrite et précise de la population, dès le départ, évite les confusions et permet de savoir exactement à quoi les résultats s'appliquent.

Correction — Exercice 2

- (a) **Oui** : un salarié ayant exactement 10 ans d'ancienneté appartient à la fois à la classe « de 5 à 10 » et à la classe « de 10 à 20 ». Les modalités ne sont pas **incompatibles**.
- (b) $[0, 5[$, $[5, 10[$, $[10, 20[$, $[20, +\infty[$: chaque valeur d'ancienneté appartient désormais à une seule classe.
- (c) **Oui**, ces classes corrigées sont exhaustives : la première classe commence à 0 (aucun salarié ne peut avoir une ancienneté négative) et la dernière classe est ouverte vers l'infini (« 20 et plus »), ce qui garantit qu'aucune valeur d'ancienneté possible n'est exclue du découpage.

Correction — Exercice 3

- (a) Moyenne = $35/250 = 0,14$.
- (b) Ce résultat représente exactement la **proportion** de dossiers en défaut parmi les 250 examinés, soit 14 %.
- (c) Le codage 0/1 de la variable « défaut » est **légitime** car il **compte** littéralement quelque chose (le nombre de défauts) : la somme des 1 est le nombre de défauts, et la moyenne est directement la proportion. Le codage 1,2,3,4,5 de la satisfaction est en revanche **arbitraire** : rien ne garantit que l'écart entre « Insatisfait » (2) et « Neutre » (3) soit « le même » que l'écart entre « Satisfait » (4) et « Très satisfait » (5). Un autre codage tout aussi défendable (par exemple 1,2,4,7,10) donnerait une moyenne complètement différente sur les mêmes données : la moyenne calculée n'a donc aucun sens objectif, contrairement à celle de la variable binaire.

2 Exercices cumulatifs (introduction à chapitre 1)

Correction — Exercice 4

- (a) Population : les salariés de l'entreprise au 31 décembre. Individu : un salarié. Effectif total : $n = 500$.
- (b) Les trois modalités **sont incompatibles** (un salarié ne peut avoir simultanément deux niveaux de diplôme différents pour la variable retenue). Pour être certain qu'elles sont **exhaustives**, il faudrait vérifier qu'**aucun** salarié de l'entreprise ne possède un niveau de diplôme en dehors de ces trois catégories : par exemple, un salarié sans diplôme, ou titulaire d'un doctorat (au-delà de Bac+5), constituerait un cas non couvert par la liste actuelle des modalités, ce qui violerait l'exhaustivité.
- (c) Ce calcul est illégitime car diplôme est une variable **qualitative ordinale** : le codage 1,2,3 impose implicitement que l'écart Bac→Bac+2 soit « égal » à l'écart Bac+2→Bac+5, ce qu'aucune réalité ne garantit (ces écarts ne sont même pas mesurés dans la même unité — nombre d'années d'études après le bac, par exemple, donnerait des écarts différents³). Or la **moyenne** exige que les écarts entre valeurs

aient un sens numérique, ce qui n'est pas le cas ici : c'est précisément la frontière que ce chapitre identifie entre ce qu'une variable ordinale autorise (compter, ordonner, calculer une médiane) et ce qu'elle n'autorise pas (une moyenne). L'indicateur légitime à la place serait donc la **médiane** du diplôme (ou, plus simplement, le mode et la distribution des effectifs par modalité).

introduction : « moyenne de diplôme » = 1,78 — chiffre suspect

↓ diagnostic

chapitre 1 : variable ordinale ⇒ moyenne illégitime, médiane légitime

3 Applications en sciences économiques

Correction — Exercice 5

- (a) La moyenne calculée à l'exercice 3 est 0,14.
- (b) Parce que la moyenne d'une variable binaire codée 0/1 **est**, par construction mathématique, la proportion de 1 dans l'effectif : la banque n'a donc besoin d'aucune formule spécifique au « taux de défaut » — c'est un cas particulier immédiat du calcul de moyenne, déjà connu et généralisable à tout autre indicateur binaire (taux de remboursement anticipé, taux de sinistralité, etc.).
- (c) **Non**, ce seul taux de 14 % ne suffit pas pour fixer un niveau de provisionnement : il faudrait le croiser avec, par exemple, le **montant** moyen des créances en défaut (un taux de défaut élevé sur de petits montants pèse moins qu'un taux plus faible sur de gros montants), la **dispersion** des montants de crédit (étudiée aux chapitres sur la dispersion), et l'évolution de ce taux dans le **temps** (une série chronologique permettrait de savoir si le risque augmente ou diminue). Un seul indicateur, même bien calculé, ne résume jamais entièrement une situation de risque.

Correction — Exercice 6

- (a) Taux strict = $\frac{180\,000}{2\,000\,000} \times 100 = 9\%$.
- (b) Taux élargi = $\frac{180\,000 + 90\,000}{2\,000\,000} \times 100 = \frac{270\,000}{2\,000\,000} \times 100 = 13,5\%$.
- (c) Le choix de la définition de la population pauvre n'est jamais neutre car il détermine directement le chiffre communiqué à l'opinion publique : un gouvernement pourrait être tenté de privilégier la définition (« stricte » ici, 9 %) qui donne l'image la plus favorable de sa politique, tandis qu'une opposition ou une ONG pourrait préférer la définition « élargie » (13,5 %) pour souligner l'ampleur du problème. Aucune des deux mesures n'est « fausse » en soi, mais elles répondent à des questions différentes — exactement l'avertissement donné dès l'introduction du cours à propos du choix entre moyenne et médiane des salaires : le choix de l'indicateur (ou ici, de la population) engage une interprétation, et donc, potentiellement, un enjeu politique.