

Statistique descriptive

Chapitre 3 : Le regroupement en classes

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique descriptive

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Combien de classes ?

On dispose de $n = 250$ observations d'une variable continue.

- (a) Calculer le nombre de classes suggéré par la règle de Sturges, $k \approx 1 + 3,3 \log_{10}(n)$.
- (b) Calculer le nombre de classes suggéré par la règle de la racine, $k \approx \sqrt{n}$.
- (c) Ces deux règles donnent-elles le même résultat ? Quel est, selon le cours, le **véritable** critère pour choisir le nombre de classes ?

Exercice 2 — Amplitude et centre de classe

Le chiffre d'affaires (en milliers de dh) de 200 entreprises est regroupé en quatre classes : $[0, 50[$ (40 entreprises), $[50, 100[$ (80), $[100, 200[$ (50), $[200, 500[$ (30).

- (a) Calculer l'amplitude a_i et le centre c_i de chacune des quatre classes.
- (b) Vérifier que $\sum n_i = 200$.
- (c) Ces classes respectent-elles la règle « fermée à gauche, ouverte à droite » garantissant leur incompatibilité ? Une entreprise à 100 milliers de dh de chiffre d'affaires appartient-elle à la deuxième ou à la troisième classe ?

Exercice 3 — Densité et histogramme à amplitudes inégales

L'âge de 400 clients d'une banque est regroupé en classes d'amplitudes inégales : $[18, 25[$ (90 clients), $[25, 35[$ (150), $[35, 50[$ (120), $[50, 80[$ (40).

- (a) Calculer l'amplitude a_i de chaque classe.
- (b) Calculer la densité $d_i = n_i/a_i$ de chaque classe.
- (c) La classe $[25, 35[$ a le plus grand effectif (150). A-t-elle aussi la plus grande densité ? Pourquoi la hauteur d'un histogramme doit-elle représenter la densité, et non l'effectif brut, lorsque les amplitudes diffèrent ?

2 Exercices cumulatifs (introduction à chapitre 3)

Exercice 4 — Densités et moyenne groupée sur les classes d'ancienneté du chapitre 2

Le chapitre 2 (exercice 4) avait construit le tableau des anciennetés sur $[0, 5[$ (120), $[5, 10[$ (150), $[10, 20[$ (90), et $[20, +\infty[$ (40) pour 400 salariés.

- (a) La dernière classe étant ouverte, fermez-la arbitrairement en lui donnant la même amplitude que la classe précédente ($[10, 20[$, soit une amplitude de 10). Calculer l'amplitude a_i et le centre c_i des quatre classes ainsi obtenues.
- (b) Calculer la densité $d_i = n_i/a_i$ de chaque classe. Quelle classe a la densité la plus forte ? Est-ce la même que celle ayant l'effectif le plus élevé ?
- (c) En utilisant les centres de classe comme approximation de chaque individu, calculer la moyenne d'ancienneté estimée $\bar{x} = \frac{\sum c_i n_i}{n}$. Quelle hypothèse, nommée dans ce chapitre, cette méthode de calcul suppose-t-elle implicitement à l'intérieur de chaque classe ?

3 Applications en sciences économiques

Exercice 5 — Un histogramme de revenus qui induit en erreur

Un rapport économique présente la distribution des revenus (en milliers de dh) de 500 ménages en quatre classes d'amplitudes croissantes : $[0, 10[$ (200 ménages), $[10, 20[$ (150), $[20, 40[$ (100), $[40, 80[$ (50).

- (a) Calculer la densité de chacune des quatre classes.
- (b) Un graphiste construit un histogramme où la hauteur de chaque barre est directement l'effectif n_i (et non la densité). Quelle impression visuelle fausse ce choix donne-t-il en particulier pour la classe $[20, 40[$, comparée à ce que révèle la densité correctement calculée ?
- (c) Pourquoi cette erreur, décrite dans le cours comme « le moyen le plus courant de mentir avec un histogramme », est-elle presque toujours **involontaire** plutôt que malhonnête ?

Exercice 6 — Le coût de l'approximation par centre de classe

On dispose des montants exacts (en dh) de 8 crédits accordés par une coopérative : 12 000, 15 000, 18 000, 22 000, 25 000, 31 000, 38 000, 45 000.

- (a) Calculer la moyenne exacte de ces 8 montants.
- (b) Regrouper ces 8 valeurs en quatre classes de 10 000 dh d'amplitude : $[10\,000, 20\,000[$, $[20\,000, 30\,000[$, $[30\,000, 40\,000[$, $[40\,000, 50\,000[$, puis calculer la moyenne **approchée** à partir des centres de classe.
- (c) Comparer les deux moyennes obtenues. L'écart est-il important ? Ce cas illustre-t-il un regroupement « favorable » (classes fines là où les données sont denses) ou « défavorable » à la précision de l'approximation ?

1 Exercices du chapitre

Correction — Exercice 1

(a) $k \approx 1 + 3,3 \log_{10}(250) = 1 + 3,3 \times 2,398 \approx 1 + 7,91 \approx 8,9$, soit environ 9 classes.

(b) $k \approx \sqrt{250} \approx 15,8$, soit environ 16 classes.

(c) **Non**, les deux règles donnent des résultats très différents (9 contre 16). Selon le cours, elles ne sont qu'**indicatives** : le véritable critère est de juger sur l'**histogramme** lui-même — le bon nombre de classes est celui qui laisse voir la forme de la distribution sans laisser voir le bruit du hasard, ce qui demande souvent d'essayer deux ou trois découpages avant de choisir.

Correction — Exercice 2

(a)

Classe	a_i	c_i
$[0, 50[$	50	25
$[50, 100[$	50	75
$[100, 200[$	100	150
$[200, 500[$	300	350

(b) $40 + 80 + 50 + 30 = 200 \checkmark$.

(c) **Oui**, les classes sont bien écrites fermées à gauche, ouvertes à droite. Une entreprise à exactement 100 milliers de dh appartient à la **troisième** classe, $[100, 200[$ (puisque 100 est **inclus** dans cette classe et **exclu** de $[50, 100[$).

Correction — Exercice 3

(a) $a([18, 25[) = 7$. $a([25, 35[) = 10$. $a([35, 50[) = 15$. $a([50, 80[) = 30$.

(b) $d([18, 25[) = 90/7 \approx 12,86$. $d([25, 35[) = 150/10 = 15$. $d([35, 50[) = 120/15 = 8$. $d([50, 80[) = 40/30 \approx 1,33$.

(c) **Oui**, dans ce cas précis, $[25, 35[$ a bien à la fois l'effectif le plus élevé (150) **et** la densité la plus forte (15) — mais ce n'est pas garanti en général : une classe très large peut avoir un effectif élevé en valeur absolue tout en étant peu « dense » (c'est le cas ici de $[35, 50[$, dont l'effectif 120 est proche de celui de $[18, 25[$ mais dont la densité 8 est nettement inférieure à celle de $[18, 25[$, 12,86). La hauteur d'un histogramme doit représenter la **densité** car c'est l'**aire** du rectangle ($\text{base} \times \text{hauteur} = a_i \times n_i/a_i = n_i$) qui représente fidèlement l'effectif, quelle que soit la largeur choisie ; utiliser l'effectif brut comme hauteur exagérerait visuellement les classes larges.

2 Exercices cumulatifs (introduction à chapitre 3)

Correction — Exercice 4

(a) En fermant arbitrairement la dernière classe en $[20, 30[$ (amplitude 10, comme $[10, 20[$) :

Classe	n_i	a_i	c_i
$[0, 5[$	120	5	2,5
$[5, 10[$	150	5	7,5
$[10, 20[$	90	10	15
$[20, 30[$	40	10	25

(b) $d([0, 5[) = 120/5 = 24$. $d([5, 10[) = 150/5 = 30$. $d([10, 20[) = 90/10 = 9$. $d([20, 30[) = 40/10 = 4$.

La densité la plus forte est celle de $[5, 10[$ (30), qui est **aussi** la classe à l'effectif le plus élevé (150) — ici les deux coïncident car les deux premières classes ont la même amplitude.

$$(c) \bar{x} = \frac{2,5(120) + 7,5(150) + 15(90) + 25(40)}{400} = \frac{300 + 1\,125 + 1\,350 + 1\,000}{400} = \frac{3\,775}{400} = 9,4375 \text{ ans.}$$

Cette méthode suppose l'**hypothèse d'équirépartition** : à l'intérieur de chaque classe, on suppose les individus uniformément répartis, de sorte que le centre de classe représente correctement la valeur « moyenne » des individus de cette classe — une hypothèse d'autant plus fragile ici que la dernière classe a été fermée de façon **arbitraire**, ce qui ajoute une source d'imprécision supplémentaire à cette estimation.

3 Applications en sciences économiques

Correction — Exercice 5

$$(a) d([0, 10[) = 200/10 = 20. \quad d([10, 20[) = 150/10 = 15. \quad d([20, 40[) = 100/20 = 5. \quad d([40, 80[) = 50/40 = 1,25.$$

(b) Avec des hauteurs égales à l'effectif brut, la barre de $[20, 40[$ (effectif 100) semblerait presque aussi haute que celle de $[10, 20[$ (effectif 150), donnant l'impression trompeuse d'une population presque aussi nombreuse dans cette tranche de revenus plus large. Or sa densité réelle (5) est trois fois **plus faible** que celle de $[10, 20[$ (15) : cette classe est en réalité beaucoup moins « dense » en ménages, l'effectif élevé provenant uniquement de sa largeur double.

(c) Cette erreur est presque toujours involontaire car construire un histogramme en effectifs bruts, plutôt qu'en densités, est le réflexe naturel pour quiconque n'a pas explicitement appris la règle « l'aire représente l'effectif » : la plupart des logiciels de tableur, utilisés sans précaution particulière pour des classes d'amplitudes inégales, produisent ce graphique fautif par défaut, sans que son auteur ait la moindre intention de tromper son lecteur.

Correction — Exercice 6

$$(a) \text{ Moyenne exacte } = \frac{12\,000 + 15\,000 + 18\,000 + 22\,000 + 25\,000 + 31\,000 + 38\,000 + 45\,000}{8} = \frac{206\,000}{8} = 25\,750 \text{ dh.}$$

(b) Répartition : $[10\,000, 20\,000[$: 3 valeurs (12 000, 15 000, 18 000), centre 15 000. $[20\,000, 30\,000[$: 2 valeurs (22 000, 25 000), centre 25 000. $[30\,000, 40\,000[$: 2 valeurs (31 000, 38 000), centre 35 000. $[40\,000, 50\,000[$: 1 valeur (45 000), centre 45 000.

$$\text{Moyenne approchée} = \frac{15\,000(3) + 25\,000(2) + 35\,000(2) + 45\,000(1)}{8} = \frac{45\,000 + 50\,000 + 70\,000 + 45\,000}{8} = \frac{210\,000}{8} = 26\,250 \text{ dh.}$$

(c) L'écart est de 500 dh, soit environ 1,9 % — une approximation raisonnable mais non négligeable pour un si petit échantillon. Ce cas est plutôt **défavorable** à la précision : avec seulement 8 observations réparties sur 4 classes (soit 2 observations par classe en moyenne), les classes sont trop « grossières » par rapport à la taille de l'échantillon, et les valeurs à l'intérieur de chaque classe ne sont pas exactement centrées sur le centre de classe (par exemple, dans $[30\,000, 40\,000[$, les deux valeurs 31 000 et 38 000 ne sont pas symétriques autour de 35 000). Ce petit exemple illustre à échelle réduite exactement le phénomène observé sur les 500 salaires du fil rouge du cours.