

# Statistique descriptive

## Chapitre 14 : Corrélation et droite d'ajustement

---

Jaouad Madkour

16 août 2026

Faculté d'Économie et de Gestion de Tanger

Normaliser la covariance

Ce que  $r$  ne dit pas

La droite d'ajustement


La qualité de l'ajustement

Bilan du cours

Ce qu'il faut retenir

Normaliser la covariance

---



### Rappel

La covariance a le bon **signe** mais pas de **valeur** interprétable : elle dépend des unités et n'a pas de bornes.

Cauchy-Schwarz nous a donné la solution :  $|\text{cov}(x, y)| \leq \sigma_x \sigma_y$ . Il suffit de diviser par le majorant.

### Coefficient de corrélation linéaire de Bravais-Pearson

$$r = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y}$$

$r$  est **sans unité** et vérifie toujours  $-1 \leq r \leq +1$ .

Sur nos données

$$r = \frac{9\,860}{5,964 \times 2\,598,10} = \frac{9\,860}{15\,495} = 0,636$$

### L'échelle

| $ r $     | Intensité de la liaison linéaire |
|-----------|----------------------------------|
| 0 à 0,2   | négligeable                      |
| 0,2 à 0,4 | faible                           |
| 0,4 à 0,6 | modérée                          |
| 0,6 à 0,8 | forte                            |
| 0,8 à 1   | très forte                       |

### Les cas extrêmes

- $r = +1$  : tous les points sont **exactement alignés** sur une droite croissante.
- $r = -1$  : alignés sur une droite décroissante.
- $r = 0$  : aucune liaison **linéaire**.



### Ces seuils sont conventionnels


Ils dépendent du domaine. En physique,  $r = 0,9$  est décevant. En sciences sociales,  $r = 0,5$  est un beau résultat.

Notre  $r = 0,636$  est une liaison **forte** pour des données individuelles de salaires : l'ancienneté compte réellement.

Ce que r ne dit pas

---

# Le quartet d'Anscombe



**Le quartet d'Anscombe (1973) :** quatre jeux de onze couples ayant *exactement* les mêmes moyennes, les mêmes variances, le même  $r = 0,82$  et la même droite d'ajustement  $\hat{y} = 3,00 + 0,500x$ . Et pourtant quatre situations sans rapport.

**Les indicateurs ne dispensent jamais de regarder les données.**

## Ce que montre le quartet

Quatre jeux de onze couples ayant **exactement** les mêmes moyennes, les mêmes variances, le même  $r = 0,82$  et la même droite d'ajustement  $\hat{y} = 3,00 + 0,500 x$ .

Et quatre situations sans aucun rapport :

1. une vraie liaison linéaire bruitée;
2. une liaison **parabolique** parfaite — la droite n'a aucun sens;
3. une liaison linéaire parfaite **gâchée par un seul point**;
4. aucune liaison, un seul point isolé créant à lui seul toute la corrélation.


## La leçon

**Les indicateurs ne dispensent jamais de regarder les données.**


C'est le même avertissement que pour les moments au chapitre 9 et pour le Gini au chapitre 10. Ici il est démontré par construction, ce qui le rend irréfutable.

# Les autres limites


$r = 0,95$   
liaison forte, positive




$r = 0,64$   
liaison modérée




$r = 0,09$   
aucune liaison



$r = -0,86$   
liaison forte, négative



$r = -0,02$   
et pourtant...



$r$  ne mesure que la liaison **linéaire** : le dernier nuage est parfaitement structuré, et pourtant  $r \simeq 0$ .  
Un coefficient de corrélation ne se lit jamais sans le nuage de points.

# Trois pièges

## Piège 1 : $r$ ne mesure que le linéaire

Un nuage en cloche, en U, en escalier peut être parfaitement structuré et donner  $r \simeq 0$ .

$r = 0$  signifie « pas de liaison linéaire », jamais « pas de liaison ».

## Piège 2 : corrélation n'est pas causalité

Une corrélation entre  $x$  et  $y$  admet **quatre** explications, et la statistique descriptive ne permet pas de trancher :

1.  $x$  cause  $y$ ;
2.  $y$  cause  $x$ ;
3. une **troisième variable** cause les deux;
4. c'est une **coïncidence**.

Le cas 3 est le plus fréquent et le plus trompeur. Les ventes de crème solaire et les noyades sont fortement corrélées : la chaleur cause les deux.

Aucun calcul ne peut établir une causalité. Seuls un raisonnement économique et, si possible, une expérience le peuvent.

### Piège 3 : le paradoxe de Simpson

Une corrélation peut **changer de signe** quand on conditionne sur une troisième variable.

Il peut exister une corrélation positive entre ancienneté et salaire dans l'ensemble, et négative à l'intérieur de chaque service — si les services les plus anciens sont aussi les moins bien payés.

**Le remède : toujours regarder le nuage par sous-groupes** avant de conclure sur l'ensemble.

## La droite d'ajustement

---



# Le principe des moindres carrés

## Le problème

Parmi toutes les droites  $y = a + b x$ , on cherche celle qui rend minimale la **somme des carrés des résidus** :

$$\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - a - b x_i)^2$$

où  $e_i$  est l'écart **vertical** entre le point observé et la droite.

## Pourquoi les carrés, et pourquoi la verticale

Les **carrés** parce qu'ils annulent les signes tout en restant dérivables — exactement l'argument du chapitre 8 pour la variance.

La **verticale** parce qu'on cherche à prédire  $y$  à partir de  $x$ . L'erreur qui compte est celle qu'on commet sur  $y$ , pas la distance géométrique au nuage.

## Les deux coefficients

$$\hat{b} = \frac{\text{cov}(x, y)}{V(x)}$$

$$\hat{a} = \bar{y} - \hat{b} \bar{x}$$

## Deux lectures immédiates de ces formules

La seconde dit que la droite passe **par le point moyen**  $(\bar{x}; \bar{y})$  : c'est le contrôle annoncé au chapitre 11.


La première dit que la pente a **le signe de la covariance**, puisque  $V(x) > 0$ . Corrélation positive et pente positive vont donc toujours ensemble.

Sur nos données

$$\hat{b} = \frac{9\,860}{35,574} = 277,2 \qquad \hat{a} = 7\,158,26 - 277,17 \times 10,142 = 4\,347$$

$$\widehat{\text{salaire}} = 4\,347 + 277 \times \text{ancienneté}$$

# La solution (fin)



la droite qui rend la **somme des carrés des résidus** minimale.

$$\hat{b} = \frac{\text{cov}(x, y)}{V(x)} = 277$$

$$\hat{a} = \bar{y} - \hat{b}\bar{x} = 4\,347$$

Une année d'ancienneté de plus, c'est 277 dirhams de salaire en plus *en moyenne*.

$r^2 = 0,405$  : l'ancienneté explique 40 % de la variance des salaires.

## Les deux coefficients, en français

$\hat{b} = 277$  : une année d'ancienneté de plus correspond, **en moyenne**, à 277 dirhams de salaire en plus.

$\hat{a} = 4\,347$  : c'est le salaire prédit pour une ancienneté nulle — un salarié qui vient d'être embauché.

Ici la constante a un sens économique, parce que  $x = 0$  appartient au domaine observé. **Ce n'est pas toujours le cas** : si l'ancienneté allait de 10 à 35 ans,  $\hat{a}$  serait une extrapolation sans signification.

## Les mots à employer, et ceux à éviter

Dire : « correspond en moyenne à », « est associé à ».

Ne pas dire : « fait augmenter », « provoque », « entraîne ». Ce sont des affirmations causales, que ce calcul ne permet pas.

La prudence de vocabulaire n'est pas de la coquetterie : c'est la seule chose qui sépare une analyse d'une opinion.

## La qualité de l'ajustement

---

## Le coefficient de détermination

$$r^2 = \frac{\text{variance expliquée}}{\text{variance totale}}$$

C'est le **carré** du coefficient de corrélation, et il représente la part de la variance de  $y$  expliquée par  $x$ .

## Sur nos données

$$r^2 = 0,636^2 = 0,405$$

L'ancienneté explique 40,5 % de la variance des salaires. Les 59,5 % restants tiennent au diplôme, au poste, à la région, à la performance — et à l'arbitraire.

### Un rapprochement avec le chapitre 12

$r^2$  et  $\eta^2$  répondent à la même question — quelle part de la variance est expliquée — mais ne s'appliquent pas aux mêmes données :

|                      | $r^2$               | $\eta^2$         |
|----------------------|---------------------|------------------|
| Variable explicative | quantitative        | qualitative      |
| Forme supposée       | <b>linéaire</b>     | aucune           |
| Sur nos données      | 40,5 % (ancienneté) | 25,8 % (diplôme) |

L'ancienneté explique donc davantage que le diplôme. Une régression **multiple**, qui les combinerait, expliquerait davantage encore — c'est l'objet du cours d'économétrie.



## Un point souvent ignoré

Il existe **deux** droites, selon la variable qu'on cherche à prédire :

$$y \text{ sur } x : \hat{b}_{y/x} = \frac{\text{cov}(x, y)}{V(x)} \qquad x \text{ sur } y : \hat{b}_{x/y} = \frac{\text{cov}(x, y)}{V(y)}$$

## Leur produit

$$\hat{b}_{y/x} \times \hat{b}_{x/y} = \frac{\text{cov}^2}{V(x)V(y)} = r^2$$

### Vérification

$$277,17 \times 0,001461 = 0,405 = r^2 \quad \checkmark$$

### Ce que cela signifie géométriquement

Les deux droites se coupent au point moyen. Elles se confondent si  $r^2 = 1$ , et deviennent perpendiculaires si  $r = 0$ .

**L'angle entre les deux droites mesure donc la qualité de l'ajustement.** C'est une manière visuelle de comprendre  $r^2$  : plus l'ajustement est bon, plus les deux droites se rapprochent l'une de l'autre.


## Bilan du cours

---

## De 500 lignes à un nombre

| Étape                 | Résultat                   |
|-----------------------|----------------------------|
| Données brutes        | $500 \times 6$ valeurs     |
| Tableau statistique   | 6 lignes                   |
| Graphique             | une image                  |
| Indicateurs univariés | 12 nombres                 |
| Liaison bivariée      | $r = 0,636$                |
| Ajustement            | une droite, 2 coefficients |

## Le chemin parcouru (suite)



## Ce que vous savez faire

### La fiche complète de nos 500 salariés

Un salaire moyen de 7 158 dirhams, médian de 6 770, dispersé d'un écart-type de 2 598 — soit un coefficient de variation de 0,36.

Une distribution **étalée à droite** ( $\gamma_1 = 1,16$ ) et à **queues épaisses** ( $\gamma_2 = 4,84$ ), modérément concentrée ( $G = 0,195$ ).

Le **diplôme** explique 25,8 % de la dispersion, l'**ancienneté** 40,5 %, à raison de 277 dirhams par année.

Six lignes pour cinq cents salariés, et rien d'essentiel n'a été perdu.

### Ce que le cours n'a pas permis de dire

Trois choses, et il faut savoir les nommer :

1. Si ces résultats **valent au-delà** de cette entreprise — c'est la statistique **inférentielle**.
2. Si l'ancienneté **cause** le salaire — c'est un problème d'identification, qui exige des hypothèses économiques.
3. Ce que donnerait la prise en compte **simultanée** de plusieurs variables — c'est la régression **multiple**.

Ce qu'il faut retenir

---

## Sept points

1.  $r = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y}$  : sans unité, compris entre  $-1$  et  $+1$ .
2.  $r$  ne mesure que la liaison **linéaire** — le quartet d'Anscombe le démontre.
3. **Corrélation n'est pas causalité** : quatre explications possibles, dont la troisième variable.
4. Moindres carrés :  $\hat{b} = \frac{\text{cov}(x, y)}{V(x)}$  et  $\hat{a} = \bar{y} - \hat{b} \bar{x}$ .
5. La droite passe **toujours** par le point moyen.
6.  $r^2$  est la **part de variance expliquée** : ici 40,5 %.
7. Deux droites de régression, dont le produit des pentes vaut  $r^2$ .

## La suite

Tous ces calculs ont été faits ici à la main, sur un petit nombre de valeurs, pour qu'on en comprenne le mécanisme.

Les deux derniers chapitres refont **toute la chaîne** sur les 500 salariés — en R, puis en Python.