Statistique descriptive

Chapitre 13 : Corrélation et droite d'ajustement

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 12 octobre 2026

Plan du chapitre

Normaliser la covariance

Ce que r ne dit pas

La droite d'ajustement

La qualité de l'ajustement

Bilan du cours

S'entraîner

Ce qu'il faut retenir

Normaliser la covariance

Rappel

La covariance a le bon **signe** mais pas de **valeur** interprétable : elle dépend des unités et n'a pas de bornes. Cauchy-Schwarz nous a donné la solution : $|\mathrm{cov}(x, y)| \leq \sigma_x \sigma_y$. Il suffit de diviser par le majorant.

Coefficient de corrélation linéaire de Bravais-Pearson

$$r = \frac{\mathrm{cov}(x, y)}{\sigma_x \, \sigma_y}$$

r est **sans unité** et vérifie toujours $-1 \leq r \leq +1$.

Les dix salariés du chapitre 12

$\mathrm{cov} = 9{,}7$, $\sigma_x = 5{,}48$ ans, $\sigma_y = 1{,}91$ millier de dirhams :

$$r = \frac{9{,}7}{5{,}48 \times 1{,}91} = \frac{9{,}7}{10{,}46} = 0{,}927$$

Nos 500 salariés

$$r = \frac{9\,860}{5{,}964 \times 2\,598{,}10} = \frac{9\,860}{15\,495} = 0{,}636$$

Même sens, intensité bien moindre : dans la grande entreprise, l'ancienneté laisse beaucoup plus de place à d'autres facteurs.

L'échelle

$\lvert r \rvert$	Intensité de la liaison linéaire
0 à $0{,}2$	négligeable
$0{,}2$ à $0{,}4$	faible
$0{,}4$ à $0{,}6$	modérée
$0{,}6$ à $0{,}8$	forte
$0{,}8$ à 1	très forte

Les cas extrêmes

- $r = +1$: tous les points sont **exactement alignés** sur une droite croissante.
- $r = -1$: alignés sur une droite décroissante.
- $r = 0$: aucune liaison **linéaire**.

Ils dépendent du domaine

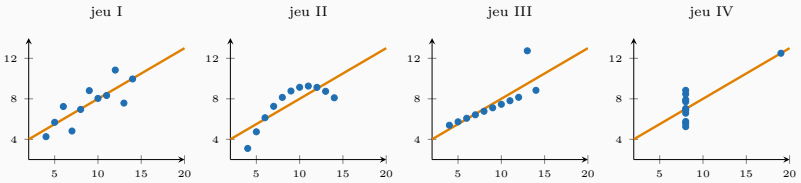
En physique, $r = 0{,}9$ est décevant. En sciences sociales, $r = 0{,}5$ est un beau résultat. Notre $r = 0{,}636$ est une liaison **forte** pour des données individuelles de salaires : l'ancienneté compte réellement.

r ne dépend pas des unités

Salaire en dirhams ou en milliers, ancienneté en années ou en mois : la covariance change, les écarts-types changent dans la même proportion, et r ne bouge pas. C'est exactement ce qu'on cherchait.

Ce que r ne dit pas

Le quartet d'Anscombe



Le quartet d'Anscombe (1973) : quatre jeux de onze couples ayant *exactement* les mêmes moyennes, les mêmes variances, le même $r = 0{,}82$ et la même droite d'ajustement $\hat{y} = 3{,}00 + 0{,}500\,x$. Et pourtant quatre situations sans rapport.

Les indicateurs ne dispensent jamais de regarder les données.

Ce que montre le quartet

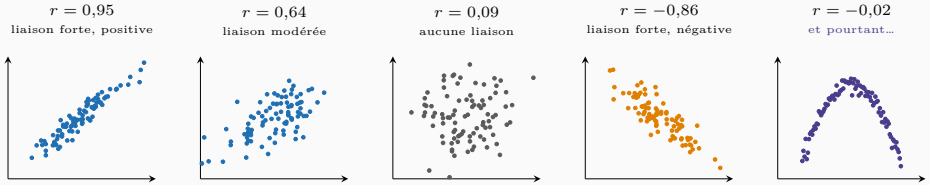
Quatre jeux de onze couples ayant **exactement** les mêmes moyennes, les mêmes variances, le même $r = 0{,}82$ et la même droite d’ajustement $\hat{y} = 3{,}00 + 0{,}500\,x$. Et quatre situations sans aucun rapport :

1. une vraie liaison linéaire bruitée ;
2. une liaison **parabolique** parfaite — la droite n’a aucun sens ;
3. une liaison linéaire parfaite **gâchée par un seul point** ;
4. aucune liaison, un seul point isolé créant à lui seul toute la corrélation.

La leçon

Les indicateurs ne dispensent jamais de regarder les données. C’est le même avertissement que pour les moments au chapitre 8 et pour le Gini au chapitre 9 ; ici il est démontré par construction.

Les autres limites



r ne mesure que la liaison **linéaire** : le dernier nuage est parfaitement structuré, et pourtant $r \simeq 0$.

Un coefficient de corrélation ne se lit jamais sans le nuage de points.

Piège 1 : r ne mesure que le linéaire

Un nuage en cloche, en U, en escalier peut être parfaitement structuré et donner $r \simeq 0$.

$r = 0$ **signifie « pas de liaison linéaire », jamais « pas de liaison ».**

Piège 2 : corrélation n'est pas causalité

Une corrélation entre x et y admet **quatre** explications, et la statistique descriptive ne permet pas de trancher : x cause y ; y cause x ; une **troisième variable** cause les deux ; une **coïncidence**.

Le troisième cas est le plus fréquent et le plus trompeur : les ventes de crème solaire et les noyades sont fortement corrélées, et la chaleur cause les deux. **Aucun calcul ne peut établir une causalité.**

Piège 3 : une corrélation qui change de signe

Une corrélation peut **changer de signe** quand on conditionne sur une troisième variable.

Il peut exister une corrélation positive entre ancienneté et salaire dans l'ensemble, et négative à l'intérieur de chaque service — si les services les plus anciens sont aussi les moins bien payés.

Le remède

Toujours regarder le nuage par sous-groupes avant de conclure sur l'ensemble : c'est le conditionnement du chapitre 11, appliqué à la corrélation.

La droite d’ajustement

Le problème

Parmi toutes les droites $y = a + b\,x$, on cherche celle qui rend minimale la **somme des carrés des résidus** :

$$\sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} (y_i - a - b\,x_i)^2$$

où e_i est l'écart **vertical** entre le point observé et la droite.

Pourquoi les carrés, et pourquoi la verticale

Les **carrés** parce qu'ils annulent les signes tout en restant dérivables — l'argument du chapitre 7. La **verticale** parce qu'on cherche à prédire y à partir de x : l'erreur qui compte est celle qu'on commet sur y.

Les deux coefficients

$$\boxed{\widehat{b} = \frac{\operatorname{cov}(x, y)}{V(x)}} \qquad \boxed{\widehat{a} = \overline{y} - \widehat{b}\,\overline{x}}$$

Deux lectures immédiates de ces formules

La seconde dit que la droite passe **par le point moyen** $(\overline{x}\,;\overline{y})$: c'est le contrôle annoncé au chapitre 10.

La première dit que la pente a **le signe de la covariance**, puisque $V(x) > 0$. Corrélation positive et pente positive vont donc toujours ensemble.

La droite des dix salariés, à la main

Les coefficients

$V(x) = 30{,}05$, $\mathrm{cov} = 9{,}7$, $\overline{x} = 8{,}5$, $\overline{y} = 7{,}1$:

$$\hat{b} = \frac{9{,}7}{30{,}05} = 0{,}323 \qquad \hat{a} = 7{,}1 - 0{,}323 \times 8{,}5 = 4{,}356$$

$$\hat{y} = 4{,}356 + 0{,}323\,x \quad \text{(milliers de dirhams)}$$

Valeurs ajustées et résidus de quelques salariés

Ancienneté x_i	2	6	8	12	20
Salaire y_i	4,50	7,50	6,00	7,50	11,00
Ajusté $\hat{y}_i$	5,00	6,29	6,94	8,23	10,81
Résidu e_i	−0,50	+1,21	−0,94	−0,73	+0,19

Sur nos données

$$\hat{b} = \frac{9\,860}{35{,}574} = 277{,}2 \qquad \hat{a} = 7\,158{,}26 - 277{,}17 \times 10{,}142 = 4\,347$$

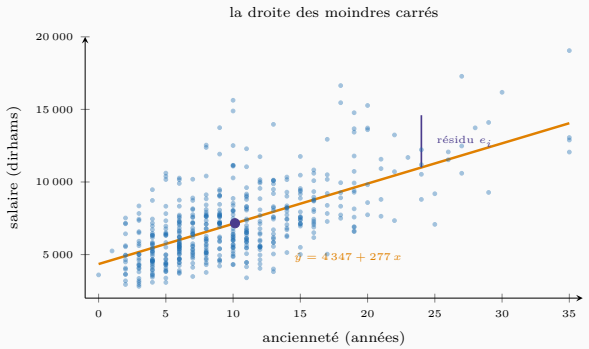
$$\boxed{\widehat{\text{salaire}} = 4\,347 + 277 \times \text{ancienneté}}$$

Deux prévisions

À 5 ans : $4\,347 + 277 \times 5 = 5\,733$ dirhams. À 20 ans : $4\,347 + 277 \times 20 = 9\,891$ dirhams.

Ce sont des salaires **moyens** prévus : à ancienneté donnée, les salaires réels s'en écartent en moyenne de $2\,000$ dirhams.

La droite sur le nuage



la droite qui rend la **somme des carrés des résidus** minimale.

$$\hat{b} = \frac{\mathrm{cov}(x, y)}{V(x)} = 277$$

$$\hat{a} = \overline{y} - \hat{b}\,\overline{x} = 4\,347$$

Une année d'ancienneté de plus, c'est 277 dirhams de salaire en plus *en moyenne.*

$r^2 = 0{,}405$: l'ancienneté explique 40 % de la variance des salaires.

Les deux coefficients, en français

$\widehat{b} = 277$: une année d'ancienneté de plus correspond, **en moyenne**, à 277 dirhams de salaire en plus.

$\widehat{a} = 4\,347$: le salaire prédit pour une ancienneté nulle — un salarié qui vient d'être embauché. La constante a ici un sens, parce que $x = 0$ appartient au domaine observé ; si l'ancienneté allait de 10 à 35 ans, $\widehat{a}$ serait une extrapolation sans signification.

Les mots à employer, et ceux à éviter

Dire : « correspond en moyenne à », « est associé à ». Ne pas dire : « fait augmenter », « provoque », « entraîne » : ce sont des affirmations causales, que ce calcul ne permet pas.

La prudence de vocabulaire est la seule chose qui sépare une analyse d'une opinion.

La qualité de l’ajustement

Résidu et décomposition

Le résidu $e_i = y_i - \hat{y}_i$ est la part du salaire que la droite n'explique pas. Les moindres carrés garantissent $\sum e_i = 0$, et

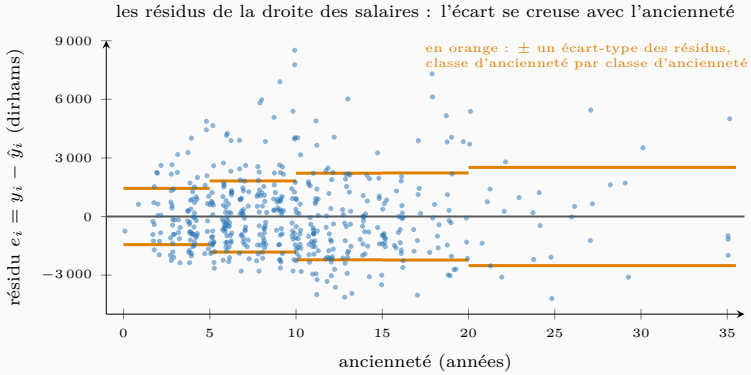
$$V(y) = V(\hat{y}) + V(e)$$

La variance totale se partage entre la variance **expliquée** par la droite et la variance **résiduelle** — comme au chapitre 11.

Les dix salariés

$V(y) = 3{,}640$; $V(\hat{y}) = \hat{b}^2\, V(x) = 0{,}323^2 \times 30{,}05 = 3{,}131$; $V(e) = 0{,}509$. La droite explique $3{,}131 / 3{,}640 = 86\,\%$ de la variance.

Regarder les résidus



Une dispersion qui grandit

L'écart-type des résidus passe de $1\,440$ dirhams avant 5 ans à $2\,514$ au-delà de 20 ans : **les carrières se différencient avec le temps**. La droite n'en dit rien ; l'économétrie appelle cela l'hétéroscédasticité.

Le coefficient de détermination

$$r^2 = \frac{\text{variance expliquée}}{\text{variance totale}} = \frac{V(\hat{y})}{V(y)}$$

C'est le **carré** du coefficient de corrélation : la part de la variance de y expliquée par x.

Sur nos données

$$r^2 = 0{,}636^2 = 0{,}405$$

L'ancienneté explique $40{,}5\,\%$ de la variance des salaires. Les $59{,}5\,\%$ restants tiennent au diplôme, au poste, à la région, à la performance — et à l'arbitraire.

La même question, deux types de données

r^2 et η^2 répondent à la même question — quelle part de la variance est expliquée — mais ne s'appliquent pas aux mêmes données :

	r^2	η^2
Variable explicative	quantitative	qualitative
Forme supposée	**linéaire**	aucune
Sur nos données	$40{,}5\,\%$ (ancienneté)	$25{,}8\,\%$ (diplôme)

L'ancienneté explique davantage que le diplôme. Une régression **multiple**, qui les combinerait, expliquerait davantage encore — c'est l'objet du cours d'économétrie.

Un point souvent ignoré

Il existe **deux** droites, selon la variable qu'on cherche à prédire :

$$y \text{ sur } x : \quad \hat{b}_{y/x} = \frac{\mathrm{cov}(x,y)}{V(x)} \qquad\qquad x \text{ sur } y : \quad \hat{b}_{x/y} = \frac{\mathrm{cov}(x,y)}{V(y)}$$

Leur produit : $\hat{b}_{y/x} \times \hat{b}_{x/y} = \dfrac{\mathrm{cov}^2}{V(x)V(y)} = r^2.$

Vérification

$$277{,}17 \times 0{,}001461 = 0{,}405 = r^2 \quad \checkmark$$

Une lecture géométrique de r^2

Les deux droites se coupent au point moyen. Elles se confondent si $r^2 = 1$, et deviennent perpendiculaires si $r = 0$ — l'une horizontale, l'autre verticale.

L'angle entre les deux droites mesure donc la qualité de l'ajustement : plus l'ajustement est bon, plus elles se rapprochent.

La bonne droite est celle de la question

Pour prévoir le salaire à partir de l'ancienneté, on utilise y sur x. Pour estimer l'ancienneté d'un salarié dont on ne connaît que le salaire, x sur y — et non l'inverse de la première.

Bilan du cours

De 500 lignes à un nombre

Étape	Résultat
Données brutes	500×6 valeurs
Tableau statistique	6 lignes
Graphique	une image
Indicateurs univariés	12 nombres
Liaison bivariée	$r = 0{,}636$
Ajustement	une droite, 2 coefficients

Le fil conducteur, refermé



La fiche complète de nos 500 salariés

Un salaire moyen de $7\,158$ dirhams, médian de $6\,770$, dispersé d'un écart-type de $2\,598$ — soit un coefficient de variation de $0{,}36$.

Une distribution **étalée à droite** ($\gamma_1 = 1{,}16$) et à **queues épaisses** ($\gamma_2 = 4{,}84$), modérément concentrée ($G = 0{,}195$).

Le **diplôme** explique $25{,}8\,\%$ de la dispersion, l'**ancienneté** $40{,}5\,\%$, à raison de 277 dirhams par année.

Quelques lignes pour cinq cents salariés, et rien d'essentiel n'a été perdu.

Ce que le cours n'a pas permis de dire

Trois questions pour la suite

1. Si ces résultats **valent au-delà** de cette entreprise — c'est la statistique **inférentielle**.
2. Si l'ancienneté **cause** le salaire — c'est un problème d'identification, qui exige des hypothèses économiques.
3. Ce que donnerait la prise en compte **simultanée** de plusieurs variables — c'est la régression **multiple**.

Ces trois questions sont l'objet des cours suivants du parcours. Ce cours-ci vous a donné les objets sur lesquels ils travaillent.

S’entraîner

Publicité et ventes sur 8 mois

Budget publicitaire x et chiffre d'affaires y, en milliers de dirhams :

$$n = 8 \qquad \sum x_i = 40 \qquad \sum y_i = 400$$

$$\sum x_i^2 = 240 \qquad \sum y_i^2 = 21\,000 \qquad \sum x_i\, y_i = 2\,160$$

1. Calculer $\overline{x}$, $\overline{y}$, $V(x)$, $V(y)$ et $\mathrm{cov}(x, y)$.
2. En déduire r et r^2.
3. Déterminer la droite des moindres carrés de y en x, et prévoir les ventes pour un budget de $7\,000$ dirhams.
4. Peut-on dire que la publicité fait vendre ?

Exercice 1 : solution

Moments et corrélation

1. $\overline{x} = 5, \overline{y} = 50$; $V(x) = 240/8 - 25 = 5$; $V(y) = 21\,000/8 - 2\,500 = 125$; $\mathrm{cov} = 2\,160/8 - 5 \times 50 = 20$.
2. $r = 20/\sqrt{5 \times 125} = 20/25 = 0{,}8$ et $r^2 = 0{,}64$.

Droite, prévision, interprétation

3. $\widehat{b} = 20/5 = 4$ et $\widehat{a} = 50 - 4 \times 5 = 30$: $\widehat{y} = 30 + 4\,x$. Pour $x = 7$: $\widehat{y} = 58$ milliers de dirhams.
4. Non : chaque millier de dirhams de publicité est **associé** à $4\,000$ dirhams de ventes en moyenne, mais une saison favorable peut augmenter à la fois le budget et les ventes. La publicité explique $64\,\%$ de la variance des ventes, sans que le calcul prouve qu'elle les cause.

Les dix salariés, avec la droite $\square$ = 4,356 + 0,323 x

1. Calculer le salaire ajusté et le résidu du salarié qui a 10 ans d'ancienneté et gagne $8\,500$ dirhams.
2. Parmi les résidus du tableau de la diapositive « La droite des dix salariés », lequel désigne le salarié le mieux payé **compte tenu de son ancienneté** ?
3. Que vaut la somme des dix résidus ? Pourquoi ?
4. Prévoir le salaire d'un salarié ayant 25 ans d'ancienneté. Quelle réserve formuler ?

Exercice 2 : solution

Résidus et prévision

1. $\hat{y} = 4{,}356 + 0{,}323 \times 10 = 7{,}58$ milliers, soit $7\,580$ dirhams ; résidu $8\,500 - 7\,580 = +920$ dirhams.
2. Le salarié de 6 ans : résidu $+1\,210$ dirhams, le plus élevé. Il gagne autant que celui de 12 ans d'ancienneté.
3. **Zéro** : la droite passe par le point moyen, et les moindres carrés équilibrent exactement les résidus positifs et négatifs.
4. $\hat{y} = 4{,}356 + 0{,}323 \times 25 = 12{,}43$ milliers. Mais l'ancienneté observée s'arrête à 20 ans : c'est une **extrapolation**, rien ne garantit que la relation reste linéaire au-delà.

Ce qu’il faut retenir

Le résumé du chapitre

Sept points

1. $r = \dfrac{\operatorname{cov}(x, y)}{\sigma_x \sigma_y}$: sans unité, compris entre -1 et $+1$.
2. r ne mesure que la liaison **linéaire** — le quartet d'Anscombe le démontre.
3. **Corrélation n'est pas causalité** : quatre explications possibles, dont la troisième variable.
4. Moindres carrés : $\hat{b} = \dfrac{\operatorname{cov}(x, y)}{V(x)}$ et $\hat{a} = \overline{y} - \hat{b}\,\overline{x}$; la droite passe par le point moyen.
5. Les **résidus** somment à zéro ; $V(y) = V(\hat{y}) + V(e)$. Il faut aussi les regarder.
6. r^2 est la **part de variance expliquée** : ici $40{,}5\,\%$.
7. Deux droites de régression, dont le produit des pentes vaut r^2.

La suite

Les deux derniers chapitres refont **toute la chaîne** sur les 500 salariés — en R, puis en Python — et retrouvent chacun des nombres du cours.