

Chapitre 1 — Données et statistiques

Licence Sciences économiques · Statistique descriptive et inférentielle

Support de cours — aspects théoriques

2026

Plan du chapitre

Introduction : qu'est-ce que la statistique ?

Les données

Obtenir les données : sources et méthodes

Des données à l'information

Synthèse

Introduction : qu'est-ce que la statistique ?

Définition


La **statistique** est l'art et la science de **collecter**, **analyser**, **présenter** et **interpréter** des données afin d'en tirer une information utile à la décision.

Le mot recouvre deux réalités qu'il faut distinguer :

- au singulier, *la statistique* = la discipline (méthodes et raisonnement) ;
- au pluriel, *des statistiques* = des résultats chiffrés (moyennes, taux, indices).

Intuition

Une donnée brute ne « parle » pas. Toute la démarche du cours consiste à transformer des données en information, puis l'information en décision.



On **décrit** d'abord les données observées ; les **probabilités** fournissent le langage du hasard ; l'**inférence** permet de généraliser d'un échantillon à une population ; l'**économétrie** relie enfin les variables entre elles pour tester des théories économiques.

Les deux grandes branches

Statistique descriptive

Résumer et présenter les données *effectivement observées* (tableaux, graphiques, moyennes, dispersion).

Inférence statistique

Tirer des conclusions sur une *population* à partir d'un *échantillon*, en quantifiant l'incertitude.

Application en sciences économiques

Pour le PIB d'un pays, on *décrit* son évolution passée (descriptif) ; pour le taux de chômage, on l'*estime* à partir d'une enquête sur quelques dizaines de milliers de ménages (inférence).

Les données

Définition

Un **ensemble de données** rassemble toutes les données d'une étude. Il se lit comme un tableau.

- **Élément** : l'entité observée (une ligne) — un pays, un ménage, une entreprise ;
- **Variable** : une caractéristique mesurée (une colonne) — le PIB, le revenu ;
- **Observation** : l'ensemble des valeurs d'un même élément (une ligne complète).

Intuition

Nombre de valeurs = nombre d'observations $\times$ nombre de variables.

Tab. 1 : Une **ligne** = une observation (un élément) ; une **colonne** = une variable.


Pays	PIB/tête	Chômage (%)	Note
France	35 000	7,3	AAA
Espagne	30 100	12,9	A
Kenya	1 700	5,7	B+

Application en sciences économiques

Un panel de 60 pays décrits par 5 variables (PIB/tête, solde commercial, note souveraine...) forme un ensemble de $60 \times 5 = 300$ valeurs.

Les échelles de mesure

L'échelle de mesure d'une variable détermine **l'information contenue** et donc **les calculs autorisés**.



Exemple

Nominale : statut OMC (membre/observateur). **Ordinale** : note Fitch (AAA > AA > A...).
Intervalle : température, année. **Rapport** : PIB, revenu (un revenu nul existe, et 30 000 vaut deux fois 15 000).

Échelles de mesure : pourquoi cela compte


Intuition

La question centrale : *le zéro veut-il dire « rien », et les rapports ont-ils un sens ?* Si oui, échelle de rapport ; sinon, on descend l'échelle.

Application en sciences économiques

Dire « le PIB du pays A est **deux fois** celui de B » a un sens (échelle de rapport). Dire « il fait deux fois plus chaud à 20 °C qu'à 10 °C » n'en a pas : l'échelle de température est seulement de type intervalle. En économie, revenus, prix et quantités sont presque toujours des variables de rapport, ce qui autorise indices, taux de croissance et élasticités.

Qualitatif ou quantitatif ? Discret ou continu ?



Exemple

Qualitative : secteur d'activité. **Quantitative discrète** : nombre d'employés (0, 1, 2...).

Quantitative continue : chiffre d'affaires, temps de travail (toute valeur d'un intervalle).

Intuition

La nature de la variable **dicte l'analyse** : sur du qualitatif on *compte* (effectifs, proportions) ; sur du quantitatif on peut aussi *calculer* (moyenne, variance).


Application en sciences économiques

Sur un panel d'entreprises : la *forme juridique* (qualitative) se résume par des parts de marché en % ; le *chiffre d'affaires* (quantitatif continu) se résume par une moyenne, une médiane, un écart-type. Coder « SARL = 1, SA = 2 » ne rend pas la moyenne de ce code interprétable.

Coupe transversale vs séries temporelles


Coupe transversale

Données collectées sur *plusieurs éléments* au même moment.



Série temporelle

Données collectées sur *un même élément* à plusieurs dates.



Application en sciences économiques

Le PIB *par pays* en 2024 = coupe transversale. Le PIB *de la France* de 2000 à 2024 = série temporelle. L'économétrie combine souvent les deux (données de **panel**).


Obtenir les données : sources et méthodes

- **Sources existantes** : registres d'entreprise, données publiques (INSEE, Eurostat, Banque mondiale), bases commerciales. Rapides et peu coûteuses.
- **Données nouvelles** : produites pour l'étude, par enquête ou expérience. Plus coûteuses mais sur mesure.

Application en sciences économiques

Pour étudier l'inflation, l'économiste mobilise des *sources existantes* (indices de prix INSEE). Pour mesurer l'effet d'une formation sur les salaires, il faut souvent *produire* de nouvelles données.

Étude expérimentale vs étude empirique



Intuition

La distinction est **cruciale pour la causalité** : seule l'expérience contrôlée (ou une bonne approximation) permet d'isoler un effet *causal*. L'observation donne surtout des *corrélations*.

Erreur de collecte

Écart entre la valeur enregistrée et la vraie valeur (erreur de saisie, question mal comprise, valeur aberrante).

Intuition

Utiliser des données erronées est souvent *pire* que de ne pas en avoir : on décide avec une fausse assurance.

Exemple

Un individu de 22 ans déclarant 20 ans d'expérience signale une incohérence à contrôler. Ces valeurs suspectes seront détectées au chapitre 3 (valeurs aberrantes).

Des données à l'information

Définition

Résumés des données observées sous forme de **tableaux**, de **graphiques** ou de **mesures numériques** (moyenne, médiane, écart-type).

Exemple

Sur 60 pays : un *diagramme en barres* des perspectives de note (négative / stable / positive) et un *histogramme* du PIB/tête résument instantanément la structure des données.

Application en sciences économiques

Le PIB/tête moyen des 60 pays ($\approx 21\,400$ \$) est une statistique descriptive : une mesure de **tendance centrale** qui condense 60 valeurs en un seul chiffre.

Inférence statistique : population et échantillon

Population


L'ensemble *de tous* les éléments d'intérêt.

Échantillon

Un *sous-ensemble* de la population.

Recensement : on observe toute la population.


Enquête : on observe un échantillon.



Inférence statistique

Estimer une caractéristique de la population, et *tester des hypothèses*, à partir des seules données de l'échantillon.

Le cycle de l'inférence



Intuition

Une estimation ponctuelle s'accompagne toujours d'une **marge d'erreur** : $\bar{x}$ n'est qu'une *approximation* de μ .

Exemple

Norris teste 200 ampoules (échantillon) d'un nouveau filament : durée de vie moyenne $\bar{x} = 76$ h, marge ± 4 h. On *infère* que la durée de vie moyenne de *toute* la production se situe entre 72 h et 80 h.


Application en sciences économiques

Le **taux de chômage** publié chaque trimestre n'est pas un recensement : c'est une *estimation* issue de l'enquête Emploi (quelques dizaines de milliers de ménages), assortie d'un intervalle de confiance. Tout le raisonnement de l'inférence — chapitres 7 à 11 — sert à garantir la fiabilité de ce type de chiffre.

Synthèse

L'essentiel du chapitre 1

- La statistique = collecter, analyser, présenter, interpréter des données.
- Vocabulaire : élément, variable, observation.
- Échelles : nominale $\subset$ ordinale $\subset$ intervalle $\subset$ rapport.
- Qualitatif / quantitatif ; discret / continu.
- Coupe transversale vs série temporelle (vs panel).
- Deux démarches : **décrire** (descriptif) et **généraliser** (inférence).



Intuition

Chaque chapitre ajoute une brique : nous savons désormais *ce qu'est* une donnée ; nous allons apprendre à la *décrire*, puis à *raisonner sous incertitude*, et enfin à *expliquer* une variable par d'autres.