

Statistique descriptive

Chapitre 3 : Méthodes numériques

Jaouad Madkour

27 juillet 2026

Faculté d'Économie et de Gestion de Tanger

Plan du chapitre

Où en sommes-nous ?

Tendance centrale

Dispersion

Position et forme

Relation entre deux variables

Synthèse

Où en sommes-nous ?

Le chapitre 2 *montrait* la distribution (tableaux, graphiques). Le chapitre 3 la **résume par des nombres**.

Trois questions

- **Où** se situe le centre des données? → *tendance centrale*
- **Quelle** est leur variabilité? → *dispersion*
- **Comment** deux variables évoluent-elles ensemble? → *association*

Intuition

Un seul nombre bien choisi peut résumer des milliers d'observations — à condition de savoir ce qu'il capture et ce qu'il masque.

Tendance centrale

La moyenne

Définition

La **moyenne arithmétique** est la somme des valeurs divisée par leur nombre :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (\text{échantillon}), \quad \mu = \frac{1}{N} \sum_{i=1}^N x_i \quad (\text{population}).$$

Intuition

La moyenne est le **point d'équilibre** de la distribution : $\sum (x_i - \bar{x}) = 0$. Elle utilise toute l'information, mais elle est **sensible aux valeurs extrêmes**.

Application en sciences économiques

La **moyenne pondérée** $\bar{x}_w = \frac{\sum w_i x_i}{\sum w_i}$ est partout en économie : un indice des prix pondère chaque bien par sa part dans la consommation ; le taux de croissance moyen d'un portefeuille pondère chaque actif par son poids.

Médiane

La valeur qui **partage** la série ordonnée en deux moitiés égales (50 % en dessous, 50 % au-dessus).


Mode

La valeur (ou classe) la **plus fréquente**. Seule mesure valable pour du qualitatif.

Intuition

La médiane est **robuste** : ajouter une valeur très grande ne la déplace presque pas, alors qu'elle tire la moyenne vers le haut.

Moyenne ou médiane ?



Application en sciences économiques

Sur des revenus (distribution étalée à droite), on a **Mode** < **Médiane** < **Moyenne**. Le *revenu médian* décrit mieux le ménage « typique » que le revenu moyen, gonflé par les très hauts revenus. C'est pourquoi les statistiques publiques privilégient la médiane.

Définition

Le p -ième **percentile** est la valeur en dessous de laquelle se trouvent environ $p\%$ des observations. Les **quartiles** découpent en quarts :

$$Q_1 = P_{25}, \quad Q_2 = P_{50} = \text{médiane}, \quad Q_3 = P_{75}.$$

Application en sciences économiques

Déciles et **quantiles** de revenu structurent toute l'analyse des inégalités : le rapport interdécile D_9/D_1 compare le haut et le bas de la distribution.

Dispersion

Étendue

$$\text{étendue} = x_{\max} - x_{\min}.$$

Simple, mais dictée par les deux extrêmes.

Écart interquartile

$$IQR = Q_3 - Q_1.$$

Étendue des **50 % centraux** : robuste aux extrêmes.

Intuition

Deux séries peuvent avoir la **même moyenne** et des dispersions très différentes. Mesurer la variabilité est aussi important que mesurer le centre.

Définition


La **variance** mesure la dispersion moyenne autour de la moyenne ; l'**écart-type** est sa racine (même unité que les données) :

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}, \quad \sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}, \quad s = \sqrt{s^2}.$$

Pourquoi $n - 1$?

Sur un **échantillon**, diviser par $n - 1$ (degrés de liberté) corrige la sous-estimation de la variance de la population : c'est l'estimateur *sans biais* (justifié au ch. 7).

Comparer des dispersions



Coefficient de variation

$$CV = \frac{s}{\bar{x}} \times 100 \%$$

Dispersion **relative**, sans unité : compare des séries d'échelles différentes.

Application en sciences économiques

En finance, l'écart-type des rendements mesure le **risque** d'un actif. Le CV compare le risque *par unité de rendement* de deux actifs — un même écart-type ne pèse pas pareil sur un actif à 2 % et un actif à 10 %.

Position et forme

Les scores z (standardisation)

Définition

Le **score** z d'une observation indique son écart à la moyenne, mesuré en écarts-types :

$$z_i = \frac{x_i - \bar{x}}{s}.$$


Intuition

Standardiser rend comparables des variables d'unités différentes : $z = +2$ signifie « deux écarts-types au-dessus de la moyenne », quelle que soit la variable.

Application en sciences économiques

Comparer la performance d'un pays sur deux indicateurs d'échelles distinctes (PIB/tête et espérance de vie) passe par leur standardisation — principe des indices composites.

Règle empirique et théorème de Chebyshev



Règle empirique

Pour une distribution $\sim$ **symétrique en cloche** : 68 % à $\pm\sigma$, 95 % à $\pm 2\sigma$, 99,7 % à $\pm 3\sigma$.

Chebyshev


Pour **toute** distribution, au moins $(1 - \frac{1}{z^2})$ des données sont à $\pm z\sigma$ ($z > 1$).

Valeurs aberrantes et boîte à moustaches

Détection des valeurs aberrantes

Une observation est **aberrante** si elle sort de l'intervalle

$$[Q_1 - 1,5 IQR ; Q_3 + 1,5 IQR].$$



Résumé en cinq nombres

$x_{\min}$, Q_1 , Me , Q_3 , $x_{\max}$: la **boîte à moustaches** en donne une image immédiate (centre, dispersion, asymétrie, extrêmes).

Relation entre deux variables

Définition

La **covariance** mesure le sens de la variation conjointe de deux variables :

$$s_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1}.$$

Intuition


$s_{xy} > 0$: x et y varient dans le **même sens** ; $s_{xy} < 0$: en sens **opposé**. Mais sa valeur dépend des **unités**, donc elle n'est pas directement interprétable.

Coefficient de corrélation

Définition

Le **coefficient de corrélation linéaire** normalise la covariance :

$$r_{xy} = \frac{s_{xy}}{s_x s_y}, \quad -1 \leq r_{xy} \leq 1.$$



Application en sciences économiques

r quantifie la force du lien linéaire (éducation–salaire, prix–quantité). **Attention** : corrélation n'est pas causalité. et r ne capte que le lien *linéaire*. Isoler un effet causal demande la

Synthèse

L'essentiel du chapitre 3

- **Centre** : moyenne (sensible aux extrêmes), médiane (robuste), mode.
- **Dispersion** : étendue, IQR , variance s^2 , écart-type s , CV (relatif).
- **Position/forme** : scores z , règle empirique, Chebyshev, valeurs aberrantes, boîte à moustaches.
- **Association** : covariance (sens), corrélation $r \in [-1, 1]$ (force du lien linéaire).

Vers le chapitre 4

Ces mesures décrivent des données *observées*. Pour **généraliser** à une population, il faut modéliser le hasard : place aux **probabilités**.