# Statistique descriptive

## Chapitre 14 : Mise en œuvre sur R

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 12 octobre 2026

# Plan du chapitre

Refaire toute la chaîne

Charger et explorer

Le tableau statistique

Les graphiques

Les indicateurs univariés

Le bivarié

Le script complet

S'entraîner

Ce qu'il faut retenir

# Refaire toute la chaîne

## Ce chapitre reprend les treize précédents

| Étape | Chapitres |
|---|---|
| Importer et décrire les variables | 1 |
| Tableau statistique et classes | 2, 3 |
| Les quatre graphiques | 4 |
| Tendance centrale, quantiles, dispersion, forme | 5 à 8 |
| Lorenz et Gini | 9 |
| Contingence et conditionnelles | 10, 11 |
| Covariance, corrélation, ajustement | 12, 13 |

## Le but n'est pas d'apprendre R

C'est de **vérifier** que les résultats calculés à la main sont bien ceux que produit un logiciel — et de constater qu'une quinzaine de lignes de code remplacent un semestre de calculs.

## Ce qu'il faut installer, une seule fois

1. **R**, le langage, et **RStudio**, l'éditeur : tous deux gratuits.
2. Le fichier `salaires.csv` dans le **dossier de travail** de RStudio.
3. Un seul package supplémentaire, pour l'asymétrie et l'aplatissement : `install.packages("moments")`.

## Comprendre la formule reste indispensable

C'est ce qui permet de savoir **quelle** fonction demander, avec **quels** arguments — et de reconnaître un résultat aberrant. Les cinq pièges de ce chapitre sont tous des pièges de **convention**, invisibles pour qui ne connaît pas la formule.

# Charger et explorer

```r
# Les données : 500 salariés, six colonnes
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
str(sal)
```

La sortie de str()

```
'data.frame':   500 obs. of  6 variables:
 $ id         : int  1 2 3 4 5 ...
 $ salaire    : int  8540 7100 4380 11790 ...
 $ anciennete: int  10 15 4 19 19 ...
 $ diplome    : Factor w/ 3 levels "Bac","Bac+2",..: 3 1 1 ...
 $ region     : Factor w/ 4 levels "Autres","Casablanca",..: 3 ...
 $ sexe       : Factor w/ 2 levels "F","H": 2 1 1 ...
```

**Factor pour les qualitatives, int ou num pour les quantitatives**

Si R a lu `salaire` comme un facteur, c'est qu'une ligne contient du texte — un espace, une virgule décimale, un « n.d. ». **Toutes les moyennes seraient alors impossibles.** C'est la première erreur à chercher dans un fichier réel.

```
class(sal$salaire)                          # "integer" : correct
# Fichier français, avec « n.d. » pour les manquants :
sal <- read.csv2("salaires.csv", na.strings = c("", "n.d."))
```

**read.csv ou read.csv2**

`read.csv` attend des virgules entre colonnes et un point décimal ; `read.csv2` attend des **points-virgules** et une **virgule décimale** — le format d'un tableur réglé en français.

# Lire summary()

```
summary(sal[, c("salaire", "anciennete", "diplome")])
```

**La sortie**

```
    salaire        anciennete      diplome
Min.   : 2810   Min.   : 0.00   Bac  :219
1st Qu.: 5318   1st Qu.: 6.00   Bac+2:174
Median : 6770   Median : 9.00   Bac+5:107
Mean   : 7158   Mean   :10.14
3rd Qu.: 8330   3rd Qu.:13.00
Max.   :19050   Max.   :35.00
```

**summary() arrondit à quatre chiffres significatifs**

5318 est le $Q_1 = 5\,317{,}5$ du chapitre 6, 7158 la moyenne $7\,158{,}26$. Pour les valeurs exactes, il faut demander chaque indicateur.

```r
colSums(is.na(sal))            # 0 partout : aucune valeur manquante
nrow(sal)                      # 500
length(unique(sal$salaire))    # 381 valeurs distinctes
```

**Pourquoi 381 valeurs distinctes comptent**

C'est le critère du chapitre 1 : $381$ valeurs pour $500$ individus, donc on traitera le salaire comme **continu** et on le regroupera en classes.

**Un manquant contamine tout**

Avec une seule valeur `NA`, `mean(x)` renvoie `NA`. L'argument `na.rm = TRUE` l'écarte — mais il faut alors **dire** sur combien d'individus porte le calcul.

# Le tableau statistique

```r
n  <- nrow(sal)
ni <- table(sal$diplome)                    # effectifs
fi <- prop.table(ni)                        # fréquences
Ni <- cumsum(ni); Fi <- cumsum(fi)          # cumuls
tableau <- data.frame(ni, fi = as.numeric(fi),
                      Ni = as.numeric(Ni), Fi = as.numeric(Fi))
print(tableau, digits = 3)
```

**Le résultat**

```
   Var1 Freq    fi  Ni    Fi
1   Bac  219 0.438 219 0.438
2 Bac+2  174 0.348 393 0.786
3 Bac+5  107 0.214 500 1.000
```

Exactement le tableau du chapitre 2.

# Variable continue : le découpage en classes

```r
bornes <- c(2000, 4000, 6000, 8000, 10000, 14000, 20000)
cl <- cut(sal$salaire, breaks = bornes, right = FALSE,
          dig.lab = 5)                    # classes [a ; b[
ni <- as.numeric(table(cl))               # effectifs
ai <- diff(bornes)                        # amplitudes
di <- ni / ai                             # densités
print(data.frame(classe = levels(cl), ni, fi = ni/n, ai, di),
      digits = 3)
```

**Les bornes, les amplitudes, les densités**

`bornes` fixe les sept bornes des six classes ; `diff()` en déduit les amplitudes, et la densité divise chaque effectif par son amplitude — la règle du chapitre 3, quand les classes sont inégales.

# Le tableau de référence du chapitre 3

## La sortie de R

| | classe | ni | fi | ai | di |
|---|---|---|---|---|---|
| 1 | [2000,4000) | 31 | 0.062 | 2000 | 0.01550 |
| 2 | [4000,6000) | 157 | 0.314 | 2000 | 0.07850 |
| 3 | [6000,8000) | 166 | 0.332 | 2000 | 0.08300 |
| 4 | [8000,10000) | 79 | 0.158 | 2000 | 0.03950 |
| 5 | [10000,14000) | 57 | 0.114 | 4000 | 0.01425 |
| 6 | [14000,20000) | 10 | 0.020 | 6000 | 0.00167 |

## Ce que la colonne di montre

La classe modale est $[6\,000\,;8\,000[$, de densité $0{,}083$. La cinquième classe compte presque deux fois plus de salariés que la première ($57$ contre $31$), mais sa densité est **plus faible** ($0{,}0143$ contre $0{,}0155$) : elle est deux fois plus large.

## L'argument right = FALSE est essentiel

Par défaut, R crée des classes $]a\,;\,b]$ — **ouvertes à gauche**, fermées à droite. C'est l'inverse de la convention française. `right = FALSE` rétablit $[a\,;\,b[$ ; `dig.lab = 5` évite les bornes en notation scientifique, `[2e+03,4e+03)`.

## Sur nos données, un salarié change de classe

Un salarié gagne **exactement** $6\,000$ dirhams. Avec $[a\,;\,b[$, il est dans la troisième classe ; sans `right = FALSE`, il passe dans la deuxième.

| Classe | $[4\,000\,;6\,000[$ | $[6\,000\,;8\,000[$ |
|---|---|---|
| Avec `right = FALSE` | $157$ | $166$ |
| Sans (défaut de R) | $158$ | $165$ |

Ici l'écart est minime. Sur des salaires arrondis à la centaine, des dizaines d'individus tombent sur les bornes.

# Sur données groupées : moyenne et écart-type

```r
ci <- (head(bornes, -1) + bornes[-1]) / 2   # centres des classes
mg <- sum(ni * ci) / n                       # 7210     moyenne groupée
vg <- sum(ni * ci^2) / n - mg^2              # 7685900  König-Huygens
sqrt(vg)                                     # 2772.35  écart-type groupé
```

## Les valeurs des chapitres 5 et 7, retrouvées

| | Groupé | Exact | Écart |
|---|---|---|---|
| Moyenne | 7 210 | 7 158,26 | +0,7 % |
| Écart-type | 2 772,35 | 2 598,10 | +6,7 % |

Les centres de classe ignorent la répartition **à l'intérieur** des classes : l'écart-type groupé surestime la dispersion, surtout à cause des deux dernières classes, très larges.

```r
k  <- which.max(di)                              # classe modale : la 3e
d1 <- di[k] - di[k-1]; d2 <- di[k] - di[k+1]
bornes[k] + ai[k] * d1 / (d1 + d2)               # 6187.5   mode
Fk <- cumsum(ni) / n
j  <- which(Fk >= 0.5)[1]                        # classe médiane : la 3e
bornes[j] + ai[j] * (0.5 - Fk[j-1]) / (ni[j]/n)   # 6747   médiane
```

**Le code est la formule**

Chaque ligne traduit une formule du chapitre 5 : la classe de **densité** maximale, les deux écarts $\Delta_1$ et $\Delta_2$, puis l'interpolation linéaire dans la classe où $F$ franchit $0{,}5$. Écrire le code oblige à savoir **exactement** ce qu'on calcule.

# Les graphiques

```r
par(mfrow = c(2, 2))            # quatre graphiques sur une page

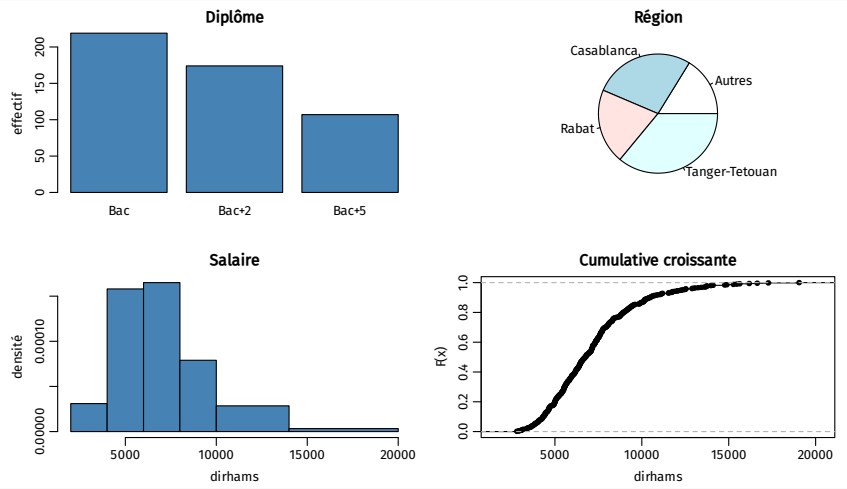
barplot(table(sal$diplome), col = "steelblue",
        main = "Diplôme", ylab = "effectif")

pie(table(sal$region), main = "Région")

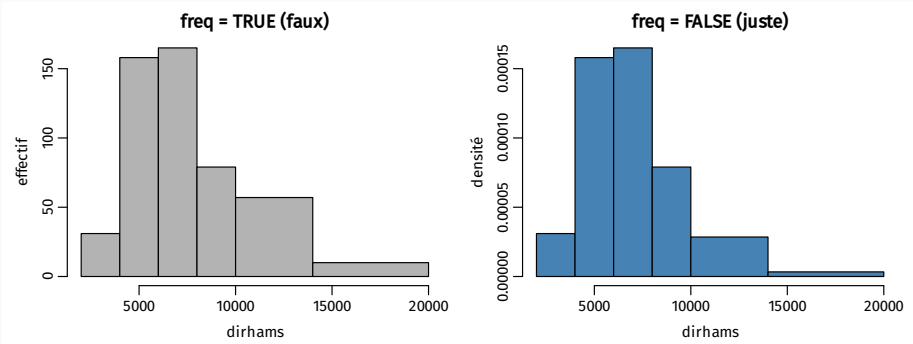
hist(sal$salaire, breaks = bornes, freq = FALSE, col = "steelblue",
     main = "Salaire", xlab = "dirhams", ylab = "densité")

plot(ecdf(sal$salaire), main = "Cumulative croissante",
     xlab = "dirhams", ylab = "F(x)")
```

# Ce que R affiche



# L'argument qui compte : freq = FALSE



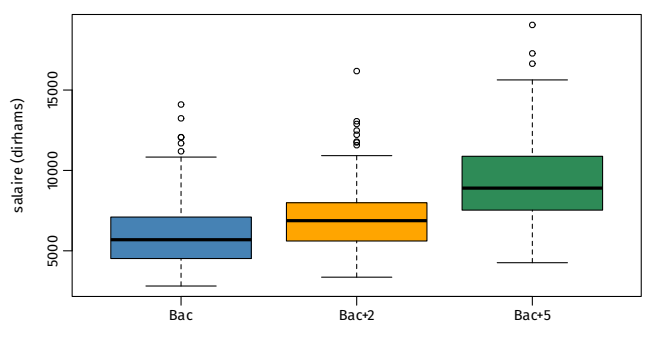

## Deux histogrammes des mêmes données

Avec `freq = TRUE` (le défaut), `hist` trace les **effectifs** : la classe $[10\,000\,;14\,000[$ paraît aussi fournie que $[8\,000\,;10\,000[$. R prévient d'ailleurs : *the AREAS in the plot are wrong*.

`freq = FALSE` trace les **densités**, la règle du chapitre 3.

# La boîte à moustaches

```
boxplot(salaire ~ diplome, data = sal,
        col = c("steelblue", "orange", "seagreen"),
        ylab = "salaire (dirhams)")
```



**y ~ x se lit « y selon x »**

C'est la notation centrale de R, et elle servira à toute la modélisation. Dans `boxplot`, elle produit directement les distributions **conditionnelles** du chapitre 11 : une boîte par diplôme.

```
aggregate(salaire ~ sexe, data = sal, FUN = median)
```

```
  sexe salaire
1    F    6580
2    H    6820
```

**La même syntaxe, une autre fonction**

`aggregate` applique `FUN` à chaque groupe : la médiane des hommes dépasse celle des femmes de $240$ dirhams, alors que les **moyennes** sont égales à quelques centimes près ($7\,158{,}42$ et $7\,158{,}14$). Deux indicateurs, deux lectures — le chapitre 11 l'avait annoncé.

# Les indicateurs univariés

```r
x <- sal$salaire

mean(x)                          # 7158.26
median(x)                        # 6770
quantile(x, c(.10, .25, .50, .75, .90))
                 # 4348  5317.5  6770  8330  10473
IQR(x)                           # 3012.5
var(x) * (n-1)/n                 # 6750122   variance descriptive
sd(x) * sqrt((n-1)/n)            # 2598.10   écart-type descriptif
sd(x) * sqrt((n-1)/n) / mean(x)   # 0.363  CV
```

**Les quantiles de R sont ceux du chapitre 6**

Par défaut, **`quantile()`** place $x_p$ au rang $1 + p\,(n-1)$ et interpole : c'est la convention retenue au chapitre 6.

## R divise par n − 1, pas par n

`var()` et `sd()` calculent la variance dite **corrigée**, celle de la statistique inférentielle. La variance **descriptive** du chapitre 7 divise par $n$ :

$$V_{\text{R}} = \frac{1}{n-1}\sum (x_i - \overline{x})^2 = \frac{n}{n-1}\,V \quad \Longrightarrow \quad V = \frac{n-1}{n}\,V_{\text{R}}$$

## Sur nos 500 salariés

| | `var()`, `sd()` | Descriptif | Rapport |
|---|---|---|---|
| Variance | 6 763 649 | 6 750 122 | 0,998 |
| Écart-type | 2 600,70 | 2 598,10 | 0,999 |

Négligeable sur $500$ observations ; sur $10$, le rapport tombe à $0{,}9$ (exercice 1). **Un écart avec un calcul manuel se vérifie d'abord ici.**

```r
m <- mean(x)
mean((x - m)^3) / mean((x - m)^2)^1.5      # 1.164   asymétrie
mean((x - m)^4) / mean((x - m)^2)^2        # 4.837   aplatissement

library(moments)                           # après install.packages
skewness(x); kurtosis(x)                   # les mêmes valeurs
```

**La formule du chapitre 8, en une ligne**

$\gamma_1 = m_3/\sigma^3$ et $\gamma_2 = m_4/\sigma^4$, avec des moments centrés divisés par $n$ : `mean()` fait exactement cela. Le package ne fait rien de plus.

**Vérifier la convention d'aplatissement**

`moments::kurtosis()` donne $\gamma_2$, de référence $3$. D'autres fonctions donnent l'**excès** $\gamma_2 - 3$, de référence $0$ : on lirait $1{,}84$. Les deux sont justes ; il faut savoir laquelle on regarde.

```r
gini <- function(v) {
  v <- sort(v); n <- length(v)
  2 * sum(seq_len(n) * v) / (n * sum(v)) - (n + 1) / n
}
gini(x)                              # 0.195
tapply(x, sal$diplome, gini)         # Bac 0.181   Bac+2 0.155   Bac+5 0.165
```

**La formule des rangs, vérifiée sur deux cas extrêmes**

Avec les $x_{(i)}$ rangés par ordre croissant, $G = \dfrac{2\sum i\, x_{(i)}}{n \sum x_i} - \dfrac{n+1}{n}$.

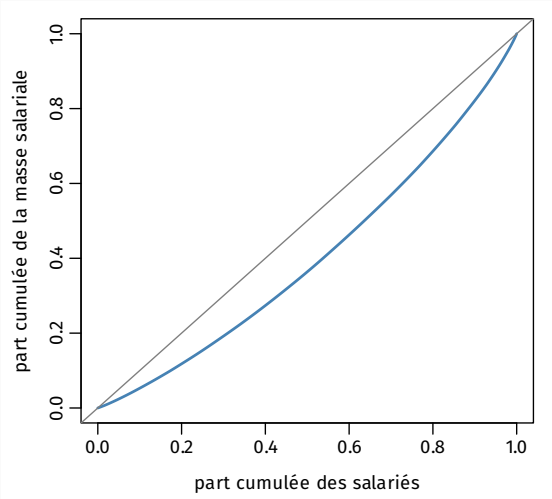
- **Égalité parfaite**, $x_{(i)} = c : \sum i\, c = c\, \frac{n(n+1)}{2}$, d'où $G = \frac{n+1}{n} - \frac{n+1}{n} = 0$.
- **Un seul individu a tout**, $x_{(n)} = S : G = \frac{2nS}{nS} - \frac{n+1}{n} = \frac{n-1}{n}$, proche de $1$.

```r
v <- sort(x)
F <- seq_len(n) / n                  # part cumulée des salariés
Q <- cumsum(v) / sum(v)              # part cumulée de la masse
plot(c(0, F), c(0, Q), type = "l", lwd = 2, col = "steelblue",
     xlab = "part cumulée des salariés",
     ylab = "part cumulée de la masse salariale")
abline(0, 1, col = "grey50")         # la diagonale d'égalité
```

**Le 0 ajouté en tête**

`c(0, F)` et `c(0, Q)` font partir la courbe de l'origine : sans eux, elle commencerait au premier salarié, en $(1/500\,;\, x_{(1)}/S)$.

# La courbe obtenue



# Le bivarié

```r
T <- table(sal$diplome, sal$region)
addmargins(T)                          # avec les marges
round(prop.table(T, 1), 3)             # profils-lignes
round(prop.table(T, 2), 3)             # profils-colonnes
round(chisq.test(T)$expected, 1)       # effectifs théoriques
```

La sortie de addmargins()

| | Autres | Casablanca | Rabat | Tanger-Tetouan | Sum |
|---|---|---|---|---|---|
| Bac | 40 | 59 | 44 | 76 | 219 |
| Bac+2 | 30 | 46 | 35 | 63 | 174 |
| Bac+5 | 11 | 32 | 23 | 41 | 107 |
| Sum | 81 | 137 | 102 | 180 | 500 |

# L'argument margin de prop.table

## 1, 2 ou rien

1 divise par les totaux de **ligne**, 2 par les totaux de **colonne**, rien du tout par le total général. C'est la distinction conjointe / profil-ligne / profil-colonne du chapitre 10.

```
> round(prop.table(T, 2), 3)          # profils-colonnes
       Autres Casablanca Rabat Tanger-Tetouan
  Bac   0.494      0.431 0.431          0.422
  Bac+2 0.370      0.336 0.343          0.350
  Bac+5 0.136      0.234 0.225          0.228
```

## Ce qu'on y lit

Les Bac+5 font $13{,}6\,\%$ des salariés de la région « Autres », contre $22$ à $23\,\%$ ailleurs. Chaque colonne somme à $1$ : on compare des **régions**, à effectifs différents.

```r
# l'écart-type descriptif, en divisant par n
sdd <- function(v) sqrt(mean((v - mean(v))^2))
data.frame(n   = tapply(x, sal$diplome, length),
           moy = tapply(x, sal$diplome, mean),
           et  = tapply(x, sal$diplome, sdd))
```

**Le résultat**

```
        n      moy       et
Bac   219 6058.904 2021.222
Bac+2 174 7080.747 2045.281
Bac+5 107 9534.393 2872.122
```

**Écrire sa propre fonction**

**sdd** règle une fois pour toutes le piège $n - 1$ : deux lignes de code, et tous les écarts-types du chapitre deviennent **descriptifs**.

```r
g  <- split(x, sal$diplome)
nj <- sapply(g, length)
mj <- sapply(g, mean)
vj <- sapply(g, function(v) mean((v - mean(v))^2))

intra <- sum(nj * vj) / n                 # 5010426
inter <- sum(nj * (mj - mean(x))^2) / n   # 1739696
eta2  <- inter / (intra + inter)          # 0.258
```

**Le contrôle à faire**

`intra + inter` doit redonner la variance descriptive totale, $6\,750\,122$. Si ce n'est pas le cas, c'est presque toujours que `vj` a été calculé avec `var()`, donc en $n_j - 1$ (exercice 3).

```r
y <- sal$salaire
z <- sal$anciennete

cov(z, y) * (n-1)/n            # 9859.9   covariance descriptive
cor(z, y)                      # 0.6363   coefficient de corrélation
cor(z, y)^2                    # 0.4049   coefficient de détermination

mod <- lm(salaire ~ anciennete, data = sal)
summary(mod)
```

**cor() n'a pas besoin de correction**

$r = \mathrm{cov}/(\sigma_z\,\sigma_y)$ : le facteur $\frac{n}{n-1}$ apparaît au numérateur et au dénominateur, et disparaît.

Les **rapports** sont indifférents à la convention.

# La sortie de lm()

## Un extrait de summary(mod)

```
Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  4347.23     177.18   24.54   <2e-16 ***
anciennete    277.17      15.06   18.41   <2e-16 ***

Residual standard error: 2008 on 498 degrees of freedom
Multiple R-squared:  0.4049,    Adjusted R-squared:  0.4037
```

## Ce qu'il faut lire, ce qu'on laisse pour plus tard

La colonne **`Estimate`** donne $\widehat{a} = 4\,347$ et $\widehat{b} = 277$ ; **`Multiple R-squared`** donne $r^2 = 0{,}405$ : les valeurs du chapitre 13. Les autres colonnes relèvent de l'**inférence**. Même l'écart-type des résidus, $2\,008$, divise par $n - 2$ : en descriptif, $\sigma_y\sqrt{1 - r^2} = 2\,004$.

```
plot(z, y, pch = 20, col = rgb(0, 0, 1, 0.35),
     xlab = "ancienneté (années)", ylab = "salaire (dirhams)")
abline(mod, col = "orange", lwd = 2)
points(mean(z), mean(y), pch = 19, col = "darkviolet", cex = 1.4)
```

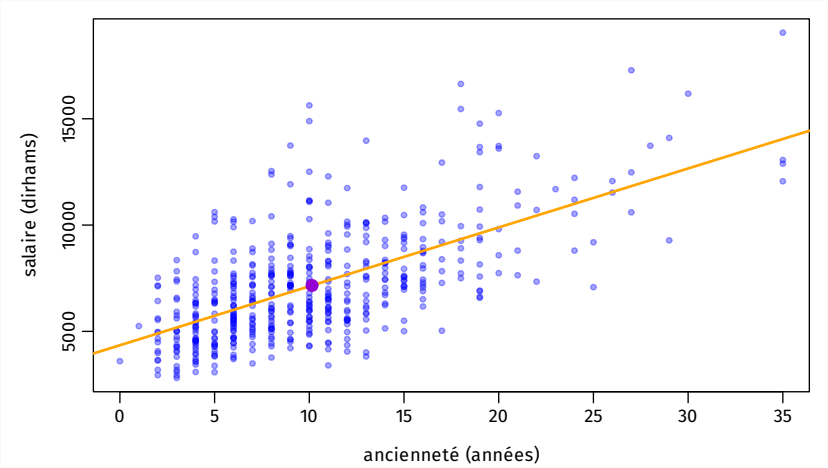
**Le contrôle visuel**

Le point moyen doit être **sur** la droite. S'il ne l'est pas, le calcul est faux — c'est la propriété du chapitre 13, et elle sert ici de test.

**rgb(0, 0, 1, 0.35)**

Du bleu à $35\,\%$ d'opacité : les points superposés apparaissent plus foncés. Avec $500$ salariés et des anciennetés entières, c'est ce qui rend la **densité** du nuage visible.

# Le nuage et sa droite



# Le script complet

## Une quinzaine de lignes

```r
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
n <- nrow(sal); x <- sal$salaire; z <- sal$anciennete
sdd  <- function(v) sqrt(mean((v - mean(v))^2))
gini <- function(v) { v <- sort(v); k <- seq_along(v)
  2 * sum(k * v) / (length(v) * sum(v)) - (length(v) + 1) / length(v) }

c(moyenne = mean(x), mediane = median(x), ecart_type = sdd(x),
  CV = sdd(x) / mean(x), gini = gini(x))
quantile(x, c(.10, .25, .50, .75, .90))
c(asym = moments::skewness(x), aplat = moments::kurtosis(x))
table(sal$diplome, sal$region)
tapply(x, sal$diplome, mean)
c(cov = cov(z, x) * (n-1)/n, r = cor(z, x), r2 = cor(z, x)^2)
coef(lm(salaire ~ anciennete, data = sal))
```

# Ce que ce script produit

**Tout le cours**

Les indicateurs univariés, le tableau croisé, les conditionnelles, la corrélation et la droite.

Ce qui a demandé treize chapitres tient en une quinzaine de lignes — et c'est bien ainsi. **Le semestre n'a jamais servi à apprendre à calculer, mais à savoir ce qu'on calcule et comment le lire.**

**Un script se relit et se rejoue**

Un calcul fait au tableur se perd dans les cellules ; un script se **relit**, se **corrige** et se **rejoue** sur les données de l'année suivante en une seconde. C'est la vraie raison de passer par le code.

# S’entraîner

# Exercice 1 : n ou n − 1 sur dix salariés

**Les dix salariés des chapitres 12 et 13**

```r
x <- c(2, 3, 4, 5, 6, 8, 10, 12, 15, 20)            # années
y <- c(4.5, 5, 6.5, 5.5, 7.5, 6, 8.5, 7.5, 9, 11)   # milliers
var(x)        # 33.38889
cov(x, y)     # 10.77778
cor(x, y)     # 0.9275
```

1. Retrouver la variance descriptive $V(x)$ et la covariance descriptive.
2. Calculer la pente $\widehat{b}$ de deux façons : avec les sorties de R, puis avec les valeurs descriptives. Conclure.
3. Pourquoi `cor()` ne demande-t-elle aucune correction ?

**Le facteur (n − 1)/n = 0,9**

1. $V(x) = 0{,}9 \times 33{,}389 = 30{,}05$, soit $\sigma_x = 5{,}48$ ans ; $\text{cov} = 0{,}9 \times 10{,}778 = 9{,}70$ : les valeurs du chapitre 12.
2. Avec R : $\hat{b} = 10{,}778/33{,}389 = 0{,}323$. En descriptif : $9{,}70/30{,}05 = 0{,}323$. **La même pente** : le facteur $0{,}9$ se simplifie.
3. $r = \text{cov}/(\sigma_x \sigma_y)$ est aussi un rapport : le facteur se simplifie. Seuls les **niveaux** (variance, écart-type, covariance) dépendent de la convention ; les rapports ($r$, $\hat{b}$, $CV$, $\eta^2$) n'en dépendent pas, à condition d'employer la **même** convention en haut et en bas.

# Exercice 2 : la région explique-t-elle le salaire ?

## Une sortie de R à exploiter

```
> tapply(x, sal$region, mean)
       Autres     Casablanca          Rabat Tanger-Tetouan
     6272.346       7887.445       7504.314       6805.833
> table(sal$region)
       Autres     Casablanca          Rabat Tanger-Tetouan
           81            137            102            180
```

1. Calculer la variance **inter-régions** (moyenne générale $7\,158{,}26$).
2. En déduire $\eta^2$, sachant que $V = 6\,750\,122$. Comparer au diplôme ($0{,}258$).
3. Écrire en R une fonction `eta2(y, g)` qui fasse ce calcul.
4. Casablanca compte $23{,}4\,\%$ de Bac+5, « Autres » $13{,}6\,\%$. Qu'en conclure ?

## Variance inter et rapport de corrélation

1. Les écarts à la moyenne générale valent $-885{,}9$ ; $729{,}2$ ; $346{,}1$ ; $-352{,}4$, d'où

$$81 \times 885{,}9^2 + 137 \times 729{,}2^2 + 102 \times 346{,}1^2 + 180 \times 352{,}4^2 \approx 170{,}99 \text{ millions}$$

$$V_{\text{inter}} \approx 170{,}99 \times 10^6 / 500 \approx 341\,980$$

2. $\eta^2 = 341\,980 / 6\,750\,122 = 0{,}051$ : la région explique $5\,\%$ de la dispersion, cinq fois moins que le diplôme.

## Le code et l'effet de structure

3. Le rapport de la variance inter à la variance totale :

```r
eta2 <- function(y, g) {
  m <- mean(y)
  inter <- sum(tapply(y, g, function(v) length(v) * (mean(v) - m)^2))
  inter / sum((y - m)^2)
}
eta2(x, sal$region)        # 0.0507
```

4. Une partie de l'avance de Casablanca vient de sa **composition** : plus de diplômés. C'est l'effet de structure du chapitre 11 ; comparer les régions **à diplôme égal** dirait si un écart subsiste.

# Exercice 3 : cinq erreurs dans un script

**Chaque ligne s'exécute sans message d'erreur**

```r
cl <- cut(sal$salaire, breaks = bornes)                 # (a)
hist(sal$salaire, breaks = bornes)                      # (b)
sigma <- sd(sal$salaire)                                # (c)
prof  <- prop.table(table(sal$diplome, sal$region))     # (d)
vj <- tapply(sal$salaire, sal$diplome, var)             # (e)
intra <- sum(nj * vj) / n
```

Pour chaque ligne : trouver l'erreur, la corriger, et dire ce qu'elle change sur nos données. Pour (d), on voulait les **profils-lignes**.

# Exercice 3 : solution

## (a), (b), (c)

- (a) Classes $]a\,;\,b]$ : ajouter `right = FALSE`. Le salarié à $6\,000$ dh passe de la 3e à la 2e classe ($157/166$ devient $158/165$).
- (b) Histogramme en **effectifs** : ajouter `freq = FALSE`. R affiche un avertissement, mais trace quand même le graphique faux.
- (c) Écart-type corrigé, $2\,600{,}70$ : écrire `sd(...) * sqrt((n-1)/n)`, ou `sdd()`, pour $2\,598{,}10$.

## (d), (e)

- (d) Fréquences **conjointes** : le tableau entier somme à $1$. Écrire `prop.table(..., 1)` pour que chaque ligne somme à $1$.
- (e) Variances en $n_j - 1$ : la variance intra devient $5\,043\,703$ au lieu de $5\,010\,426$, et `intra + inter` dépasse la variance totale de $33\,277$. Le contrôle de la décomposition détecte l'erreur.

# Ce qu’il faut retenir

# Le résumé du chapitre

## Sept points

1. `str()` d'abord : vérifier que chaque variable a le **bon type**.
2. `cut(..., right = FALSE)` pour des classes $[a\,;\,b[$ à la française.
3. `hist(..., freq = FALSE)` pour tracer des **densités**, pas des effectifs.
4. `var()`, `sd()`, `cov()` divisent par $n-1$ : multiplier par $(n-1)/n$, ou écrire sa fonction.
5. `prop.table(T, 1)` et `prop.table(T, 2)` : profils-lignes et profils-colonnes.
6. La syntaxe `y ~ x` est la clé de R : `boxplot`, `aggregate`, `lm` l'emploient toutes.
7. Dans `summary(lm())`, seuls `Estimate` et `Multiple R-squared` relèvent de ce cours.

## La suite

Le chapitre 15 refait exactement la même chaîne en Python, avec pandas et matplotlib — et retrouve les mêmes nombres.