# Statistique descriptive

## Chapitre 1 : Population, variable, modalité

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 12 octobre 2026

# Plan du chapitre

Les trois mots de base

La variable statistique

La typologie des variables

S'entraîner

Ce qu'il faut retenir

# Les trois mots de base

## Les trois définitions

- La **population** (ou univers) est l'ensemble des éléments sur lesquels porte l'étude.
- Un **individu** (ou unité statistique) est un élément de cette population.
- L'**effectif total**, noté $n$, est le nombre d'individus observés.

## Un individu n'est pas forcément une personne

C'est le point que les étudiants oublient le plus vite. Un individu statistique peut être une entreprise, une commune, un ménage, une transaction, un jour de cotation, un produit en rayon, un contrat d'assurance.

**L'individu est ce qu'on compte.** Rien de plus.

# Définir la population est déjà une décision

## Le champ de l'enquête

« Les salariés de l'entreprise » : à quelle date ? Les intérimaires en font-ils partie ? Les salariés à temps partiel ? Ceux en congé ?

Ces choix ne sont pas des détails : ils changent $n$, donc toutes les fréquences, donc toutes les moyennes. **Une étude statistique commence toujours par une définition écrite de la population** : c'est le premier endroit où regarder quand deux chiffres officiels se contredisent.

## Avec ou sans les intérimaires

Notre entreprise emploie aussi $60$ intérimaires, dont $45$ femmes.

- Sans eux : $n = 500$ et la part des femmes vaut $215/500 = 43{,}0\,\%$.
- Avec eux : $n = 560$ et elle vaut $(215 + 45)/560 = 260/560 = 46{,}4\,\%$.

Même entreprise, même date : **trois points et demi d'écart**, dus à la seule définition.

# La variable statistique

### Variable statistique et modalité

Une **variable statistique** est le caractère observé sur chaque individu. Les **modalités** sont les valeurs que cette variable peut prendre.

### Deux exigences sur les modalités

Les modalités doivent être :

- **exhaustives** : chaque individu en possède au moins une ;
- **incompatibles** : chaque individu n'en possède qu'une seule.

Autrement dit, elles forment une **partition** de la population.

# Des modalités mal construites

## Une exigence qui n'est pas théorique

Un questionnaire propose comme réponses : « moins de $5\,000$ », « de $5\,000$ à $10\,000$ », « plus de $10\,000$ ». Un salarié à $5\,000$ dirhams coche laquelle ?

Les deux premières conviennent : les modalités ne sont **pas incompatibles**. Le tableau sera faux, quelle que soit la qualité des calculs qui suivront.

La convention à retenir : les classes s'écrivent **fermées à gauche, ouvertes à droite**, $[5\,000\,;10\,000[$.

## Et l'oubli d'une modalité

Une question « Votre statut : salarié, indépendant, chômeur » laisse sans réponse l'étudiant et le retraité : les modalités ne sont **pas exhaustives**. On ajoute alors une modalité « autre », et l'on vérifie qu'elle reste marginale.

# Une ligne, une colonne, une case

| id | salaire | anciennete | diplome | region | sexe |
|---|---|---|---|---|---|
| 1 | 8 540 | 10 | Bac+5 | Rabat | H |
| 2 | 7 100 | 15 | Bac | Rabat | F |
| 3 | 4 380 | 4 | Bac | Autres | F |
| 4 | 11 790 | 19 | Bac+2 | Casablanca | F |
| 5 | 13 430 | 19 | Bac+5 | Tanger-Tétouan | H |
| 6 | 6 650 | 7 | Bac+2 | Tanger-Tétouan | H |
| ⋮ | ⋮ | ⋮ | ⋮ | ⋮ | ⋮ |

une ligne : **un individu** (le salarié n° 3)

une case : **une modalité** (H, pour le salarié n° 5)

en tout : 500 lignes, 6 colonnes

une colonne : **une variable** (le salaire)

## Lire un fichier de données

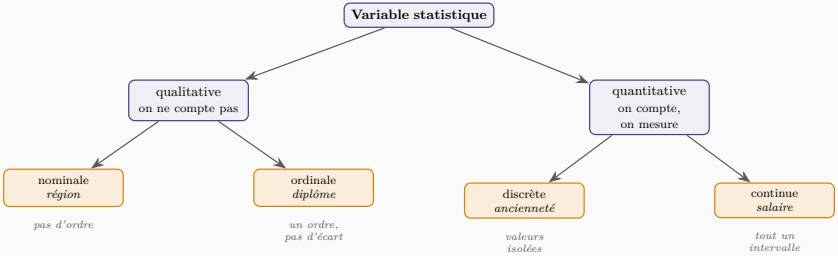
Un fichier statistique est toujours rangé de la même façon : **un individu par ligne, une variable par colonne**, et dans chaque case la modalité prise par cet individu pour cette variable.

## Sur nos 500 salariés

| Élément | Ce que c'est ici |
|---|---|
| Population | les salariés de l'entreprise au 31 décembre |
| Individu | un salarié |
| Effectif total | $n = 500$ |
| Variables | salaire, ancienneté, diplôme, région, sexe |
| Modalités du diplôme | Bac, Bac+2, Bac+5 |
| Modalités du sexe | F, H |

# La typologie des variables

# L'arbre à connaître



## Qualitative nominale

Les modalités sont des **catégories sans ordre**.

*Exemples* : la région, le secteur d'activité, la forme juridique, le sexe.

On peut **compter** les individus de chaque modalité. On ne peut ni les ordonner, ni faire de moyenne.

## Qualitative ordinale

Les modalités sont **ordonnées**, mais les écarts entre elles n'ont pas de sens numérique.

*Exemples* : le diplôme, un niveau de satisfaction, une notation financière (AAA, AA, A…), une catégorie socio-professionnelle hiérarchisée.

On peut compter **et** ordonner — donc calculer une médiane. On ne peut pas faire de moyenne.

# Le piège de la variable ordinale codée

## Une « moyenne de diplôme »

On code souvent Bac $= 1$, Bac+2 $= 2$, Bac+5 $= 3$, et l'on obtient une « moyenne de diplôme ». Ce nombre suppose que l'écart Bac $\longrightarrow$ Bac+2 vaut l'écart Bac+2 $\longrightarrow$ Bac+5, alors que rien ne le dit.

**Un codage numérique ne transforme pas une variable qualitative en variable quantitative.**
C'est l'erreur la plus fréquente dans les mémoires d'étudiants.

## Trois codages, trois moyennes

| Codage (Bac, Bac+2, Bac+5) | Calcul | « Moyenne » |
|---|---|---|
| $1, 2, 3$ | $(219 + 2 \times 174 + 3 \times 107)/500$ | $1{,}78$ |
| $1, 2, 5$ | $(219 + 2 \times 174 + 5 \times 107)/500$ | $2{,}20$ |
| $1, 3, 6$ | $(219 + 3 \times 174 + 6 \times 107)/500$ | $2{,}77$ |

Le codage était arbitraire, la moyenne l'est donc aussi.

## Le diplôme médian

On range les $500$ salariés par diplôme et l'on cherche celui du milieu, aux rangs $250$ et $251$.

| Diplôme | Effectif | Effectif cumulé |
|---|---|---|
| Bac | $219$ | $219$ |
| Bac+2 | $174$ | $393$ |
| Bac+5 | $107$ | $500$ |

## La lecture

Les rangs $1$ à $219$ ont le Bac, les rangs $220$ à $393$ un Bac+2. Les rangs $250$ et $251$ tombent dans ce second groupe : **le diplôme médian est Bac+2**. Ce résultat ne dépend d'aucun codage — seulement de l'ordre.

### Quantitative discrète

Les valeurs sont **isolées**, généralement entières, et on peut les énumérer.

*Exemples* : l'ancienneté en années, le nombre d'enfants, le nombre de salariés, le nombre de transactions.

### Quantitative continue

La variable peut prendre **toutes** les valeurs d'un intervalle. On est obligé de la **regrouper en classes**.

*Exemples* : le salaire, le chiffre d'affaires, la durée, le taux de rentabilité.

## La frontière est une question de pratique, pas de principe

Le salaire s'exprime en dirhams et centimes : il est discret au sens strict. Mais la liste de ses valeurs ne résumerait rien : on le traite comme continu. **Règle pratique :** si le nombre de valeurs distinctes est du même ordre que $n$, on traite la variable comme continue.

## Compter les valeurs distinctes

| Variable | Valeurs distinctes sur $500$ | Traitement |
|---|---|---|
| `salaire` | $381$ | continue : classes |
| `ancienneté` | $32$ | discrète, ou classes |
| `région` | $4$ | qualitative nominale |
| `diplôme` | $3$ | qualitative ordinale |
| `sexe` | $2$ | binaire |

## Le tableau des opérations permises

| | Nominale | Ordinale | Discrète | Continue |
|---|---|---|---|---|
| Effectifs, fréquences | oui | oui | oui | oui |
| Mode | oui | oui | oui | oui |
| Effectifs **cumulés** | non | oui | oui | oui |
| Médiane, quantiles | non | oui | oui | oui |
| Moyenne, écart-type | non | non | oui | oui |
| Diagramme en bâtons | oui | oui | oui | non |
| Histogramme | non | non | non | oui |

# Deux frontières à retenir

## Comment lire ce tableau

Les colonnes sont **emboîtées** : chaque type autorise tout ce que le précédent autorise, plus quelque chose.

Il suffit donc de retenir les **deux frontières** :

- le **cumul** exige un ordre ;
- la **moyenne** exige des écarts qui aient un sens.

Toutes les erreurs de ce cours viennent d'un franchissement de l'une de ces deux frontières.

## Sur le fil rouge

- Région : on peut dire « la plus représentée est Tanger-Tétouan », jamais « la région médiane ».
- Diplôme : « le diplôme médian est Bac+2 », jamais « le diplôme moyen ».
- Salaire et ancienneté : tout est permis.

## Deux modalités, codées 0 et 1

Une variable qualitative à **deux** modalités — le sexe, oui/non, en défaut ou non.

Codée $0$ et $1$, elle possède une propriété remarquable : sa **moyenne est la proportion** de $1$. En effet, la somme des $x_i$ compte les individus codés $1$ :

$$\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{\text{nombre de } 1}{n}$$

## Vérification

En codant $1$ pour les femmes : la somme vaut $215$, et la moyenne $215/500 = 0{,}43$ — exactement la part des femmes.

C'est la seule variable qualitative dont on puisse légitimement calculer la moyenne : le codage $0/1$ n'est pas arbitraire, **il compte**.

## La part des Bac+5, par sexe

On code $1$ un salarié titulaire d'un Bac+5, $0$ sinon, et l'on fait la moyenne dans chaque groupe :

| | Effectif | Bac+5 | Moyenne de la variable $0/1$ |
|---|---|---|---|
| Femmes | $215$ | $48$ | $48/215 = 0{,}223$ |
| Hommes | $285$ | $59$ | $59/285 = 0{,}207$ |
| Ensemble | $500$ | $107$ | $107/500 = 0{,}214$ |

## Pourquoi c'est important

Toute la statistique des proportions, en inférentielle, repose sur ce fait : une proportion **est** une moyenne, et tous les résultats sur les moyennes s'y appliquent. Un taux de chômage, un taux de défaut, une part de marché en sont des exemples.

# S’entraîner

# Exercice 1 : classer les variables d'une enquête

## Une enquête auprès des ménages

Une enquête relève, pour chaque ménage d'un quartier de Tanger :

1. le nombre de personnes du ménage ;
2. le statut d'occupation du logement : propriétaire, locataire, logé gratuitement ;
3. le revenu mensuel du ménage, en dirhams ;
4. la satisfaction à l'égard du quartier : faible, moyenne, forte ;
5. le milieu de résidence d'origine : urbain, rural ;
6. la dépense alimentaire mensuelle, en dirhams.

Pour chaque variable, donner son type, puis dire si l'on peut calculer un mode, une médiane, une moyenne. Laquelle peut-on coder $0/1$ ?

# Exercice 1 : solution

## Le classement

| Variable | Type | Mode | Médiane | Moyenne |
|---|---|---|---|---|
| 1. Nombre de personnes | quantitative discrète | oui | oui | oui |
| 2. Statut d'occupation | qualitative nominale | oui | non | non |
| 3. Revenu mensuel | quantitative continue | oui | oui | oui |
| 4. Satisfaction | qualitative ordinale | oui | oui | non |
| 5. Milieu d'origine | qualitative nominale | oui | non | non |
| 6. Dépense alimentaire | quantitative continue | oui | oui | oui |

## La variable binaire

Le **milieu d'origine** n'a que deux modalités : codé $1$ pour rural, sa moyenne donne la **proportion** de ménages d'origine rurale. Revenu et dépense, qui prennent presque autant de valeurs que de ménages, se traitent comme continus.

# Exercice 2 : cinq entreprises

## Un fichier d'entreprises

| Entreprise | Secteur | Salariés | Exportatrice | Taille |
|---|---|---|---|---|
| A | textile | 180 | oui | moyenne |
| B | agroalimentaire | 45 | non | petite |
| C | textile | 620 | oui | grande |
| D | services | 12 | non | petite |
| E | automobile | 310 | oui | moyenne |

1. Quels sont la population, l'individu et l'effectif total ?
2. Donner le type de chacune des quatre variables.
3. Coder « exportatrice » en $0/1$ et calculer sa moyenne. Que représente-t-elle ?
4. Déterminer la taille médiane. Peut-on parler de « secteur médian » ?

# Exercice 2 : solution

## Vocabulaire et types

1. Population : ces cinq entreprises ; individu : **une entreprise** — pas une personne ; $n = 5$.
2. Secteur : qualitative nominale. Salariés : quantitative discrète. Exportatrice : qualitative nominale **binaire**. Taille : qualitative ordinale (petite $<$ moyenne $<$ grande).

## Moyenne binaire et médiane ordinale

3. Codage $1, 0, 1, 0, 1$ : moyenne $3/5 = 0{,}6$, soit $60\,\%$ **d'entreprises exportatrices**.
4. On range les tailles : petite, petite, moyenne, moyenne, grande. Avec $n = 5$, la médiane est la valeur de rang $3$ : **la taille médiane est « moyenne »**. Le secteur n'a pas d'ordre : un « secteur médian » n'a aucun sens ; seul le mode existe ici, le textile.

# Ce qu’il faut retenir

# Le résumé du chapitre

## Sept points

1. **Population, individu, effectif total** $n$ : à définir par écrit avant tout calcul ; changer la définition change les chiffres.
2. Une **variable** prend des **modalités**, **exhaustives** et **incompatibles**.
3. Un fichier : un individu par ligne, une variable par colonne.
4. Quatre types : nominale, ordinale, discrète, continue.
5. Le **cumul** exige un ordre ; la **moyenne** exige des écarts qui aient un sens.
6. Coder une variable qualitative en nombres ne la rend pas quantitative ; une ordinale a une médiane, pas de moyenne.
7. Une variable **binaire** codée $0/1$ a pour moyenne la proportion.

## La suite

Le vocabulaire est en place. On peut maintenant construire l'objet qui résume à lui seul toute une variable : le **tableau statistique**. C'est le chapitre 2.