

# Statistique descriptive

## Chapitre 3 : Le regroupement en classes

---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 24 septembre 2026

Pourquoi des classes

Combien de classes

Amplitudes inégales, le prix

Le centre de classe

Ce qu'il faut retenir

# Pourquoi des classes

---

## Le tableau du chapitre 2 est impossible ici

Le salaire prend 381 valeurs différentes sur 500 salariés. Un tableau à 381 lignes ne résume rien : il est plus long que la question qu'il prétend traiter.

Pour une variable continue, on n'a pas le choix : il faut **regrouper les valeurs en intervalles**.

## Classe

Une **classe** est un intervalle  $[e_{i-1} ; e_i[$ , fermé à gauche et ouvert à droite.

- $e_{i-1}$  et  $e_i$  sont les **bornes** ;
- $a_i = e_i - e_{i-1}$  est l'**amplitude** ;
- $c_i = \frac{e_{i-1} + e_i}{2}$  est le **centre de classe**.

### La convention d'écriture n'est pas décorative

$[4\,000 ; 6\,000[$  signifie : de 4 000 inclus à 6 000 **exclu**.

Un salarié à 6 000 dirhams appartient à la classe suivante, et à elle seule. C'est ce qui garantit que les modalités sont **incompatibles**, exigence posée au chapitre 1.

Un tableau écrit avec des classes  $[4\,000 ; 6\,000]$  et  $[6\,000 ; 8\,000]$  est faux.

## Combien de classes

---

## Deux règles empiriques

règle de Sturges :  $k \approx 1 + 3,3 \log_{10}(n)$

règle de la racine :  $k \approx \sqrt{n}$

## Sur nos données

Sturges :  $1 + 3,3 \times \log_{10}(500) = 1 + 3,3 \times 2,70 = 9,9$ , soit une dizaine de classes.

Racine :  $\sqrt{500} = 22,4$ .

Les deux règles ne s'accordent pas. **Elles ne sont qu'indicatives.**

### Le vrai critère est l'arbitrage

Trop peu de classes : on écrase la forme de la distribution, tout devient plat.

Trop de classes : le tableau redevient bruité, chaque classe contient trop peu d'individus pour être stable.

**Le bon nombre est celui qui laisse voir la forme sans laisser voir le hasard.** Il se juge sur l'histogramme, pas sur une formule — et il faut souvent essayer deux ou trois découpages.

### Trois principes

1. Des bornes **rondes** et lisibles : 4 000, 6 000, 8 000 — jamais 4 137.
2. Aucune classe **vide** à l'intérieur du tableau.
3. Des classes **plus larges là où les données sont rares** — c'est-à-dire dans les queues.

## Le choix des bornes (suite)

### Le découpage retenu pour les salaires

| Classe            | $n_i$      | $f_i$        | $a_i$ | $N_i$ | $F_i$ |
|-------------------|------------|--------------|-------|-------|-------|
| [2 000 ; 4 000[   | 31         | 0,062        | 2 000 | 31    | 0,062 |
| [4 000 ; 6 000[   | 157        | 0,314        | 2 000 | 188   | 0,376 |
| [6 000 ; 8 000[   | 166        | 0,332        | 2 000 | 354   | 0,708 |
| [8 000 ; 10 000[  | 79         | 0,158        | 2 000 | 433   | 0,866 |
| [10 000 ; 14 000[ | 57         | 0,114        | 4 000 | 490   | 0,980 |
| [14 000 ; 20 000[ | 10         | 0,020        | 6 000 | 500   | 1,000 |
| <b>Total</b>      | <b>500</b> | <b>1,000</b> |       |       |       |

### Pourquoi les deux dernières classes sont plus larges



Au-delà de 10 000 dirhams, les salariés se raréfient. Découper de 2 000 en 2 000 jusqu'à 20 000 donnerait des classes à 3 ou 4 individus, illisibles et instables.

**Mais élargir les classes a un prix, et il faut le payer :** l'histogramme ne peut plus se lire en effectifs.

## **Amplitudes inégales, le prix**

---

# L'erreur qu'il faut voir une fois



classes d'amplitudes inégales : 2 000, 2 000, 2 000, 2 000, 4 000, 6 000 dirhams

## Densité de fréquence

$$d_i = \frac{n_i}{a_i} \quad \text{ou, en fréquences,} \quad \frac{f_i}{a_i}$$

Dans un histogramme, **c'est la densité qui donne la hauteur** du rectangle, jamais l'effectif.

## La règle, en une phrase

**Dans un histogramme, c'est l'aire qui représente l'effectif, pas la hauteur.**

Aire du rectangle = base  $\times$  hauteur =  $a_i \times \frac{n_i}{a_i} = n_i$ . L'amplitude se simplifie :  
chaque rectangle a une aire égale à son effectif, quelles que soient les largeurs choisies.

### Le calcul complet sur nos classes

| Classe            | $n_i$ | $a_i$ | $d_i = n_i/a_i$ |
|-------------------|-------|-------|-----------------|
| [2 000 ; 4 000[   | 31    | 2 000 | 0,0155          |
| [4 000 ; 6 000[   | 157   | 2 000 | 0,0785          |
| [6 000 ; 8 000[   | 166   | 2 000 | 0,0830          |
| [8 000 ; 10 000[  | 79    | 2 000 | 0,0395          |
| [10 000 ; 14 000[ | 57    | 4 000 | 0,0143          |
| [14 000 ; 20 000[ | 10    | 6 000 | 0,0017          |

### Ce que la correction change

Sur l'histogramme en effectifs, la classe  $[10\,000 ; 14\,000[$  paraît deux fois plus fournie que la première classe. En densité, elle est en réalité **au même niveau**.

Un lecteur non averti aurait conclu que les hauts salaires sont plus nombreux qu'ils ne le sont. **C'est le moyen le plus courant de mentir avec un histogramme, et il est presque toujours involontaire.**

# Un cas particulier fréquent

## La classe ouverte

Un tableau publié se termine souvent par « 20 000 dirhams et plus » : la borne supérieure est inconnue.

On ne peut alors ni calculer la densité, ni le centre de classe, ni donc la moyenne.

## Les deux solutions

1. **Fermer arbitrairement** la classe, en lui donnant l'amplitude de la précédente. C'est la convention la plus répandue.
2. **Renoncer à la moyenne** et travailler avec la médiane, qui n'a pas besoin des valeurs extrêmes.

La seconde est plus honnête. C'est aussi pourquoi les revenus se publient en médiane : la classe la plus haute est toujours ouverte.

## Le centre de classe

---

## Le centre de classe

$$c_i = \frac{e_{i-1} + e_i}{2}$$

Pour tous les calculs qui suivent — moyenne, variance, moments — **on remplace chaque individu de la classe par le centre de sa classe.**

## L'hypothèse d'équirépartition

On suppose que les individus sont **uniformément répartis** à l'intérieur de chaque classe. C'est faux en général, mais les erreurs se compensent partiellement d'une classe à l'autre.

## Une hypothèse qu'on oublie (suite)

### Le coût de l'approximation, chiffré

Moyenne calculée sur les 500 valeurs exactes : 7 158 dirhams.

Moyenne calculée à partir du tableau en classes, avec les centres :

$$\bar{x} = \frac{3000(31) + 5000(157) + 7000(166) + 9000(79) + 12000(57) + 17000(10)}{500} = 7\,210$$

Écart : 52 dirhams, soit 0,7 %.

### La leçon

L'approximation est excellente **tant que les classes sont fines là où les données sont denses**.

Ici l'essentiel de l'écart vient des deux dernières classes, larges et asymétriquement remplies : à l'intérieur de  $[10\,000 ; 14\,000[$ , les salariés se pressent près de la borne basse, si bien que le centre 12 000 les surestime.

## Ce qu'il faut retenir

---

# Le résumé du chapitre

## Six points

1. Une variable continue **doit** être regroupée en classes  $[e_{i-1} ; e_i[$ .
2. Sturges et la racine donnent un ordre de grandeur, pas une réponse : le nombre de classes se juge sur l'histogramme.
3. Bornes rondes, aucune classe vide, classes plus larges dans les queues.
4. **Densité**  $d_i = n_i/a_i$  : c'est elle qui donne la hauteur d'un histogramme, jamais l'effectif.
5. Dans un histogramme, **l'aire représente l'effectif**.
6. Le **centre de classe** remplace les individus dans tous les calculs : approximation excellente si les classes denses sont fines.

## La suite

Le tableau est construit. Chacune de ses colonnes appelle maintenant sa propre représentation graphique — et le choix du graphique dépend, une fois encore, du type de la variable.