Statistique descriptive

Chapitre 3 : Le regroupement en classes

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 12 octobre 2026

Plan du chapitre

Pourquoi des classes

Combien de classes

Amplitudes inégales, le prix

Le centre de classe

S'entraîner

Ce qu'il faut retenir

Pourquoi des classes

Le tableau du chapitre 2 est impossible ici

Le salaire prend 381 valeurs différentes sur 500 salariés. Un tableau à 381 lignes ne résume rien : il est plus long que la question qu'il prétend traiter.

Pour une variable continue, on n'a pas le choix : il faut **regrouper les valeurs en intervalles**.

Classe

Une **classe** est un intervalle $[e_{i-1}\,;\,e_i[$, fermé à gauche et ouvert à droite.

- e_{i-1} et e_i sont les **bornes** ;
- $a_i = e_i - e_{i-1}$ est l'**amplitude** ;
- $c_i = \dfrac{e_{i-1} + e_i}{2}$ est le **centre de classe**.

Elle n'est pas décorative

$[4\,000\,;6\,000[$ signifie : de $4\,000$ inclus à $6\,000$ **exclu**.

Un salarié à $6\,000$ dirhams appartient à la classe suivante, et à elle seule. C'est ce qui garantit que les modalités sont **incompatibles**, exigence posée au chapitre 1. Un tableau écrit avec des classes $[4\,000\,;6\,000]$ et $[6\,000\,;8\,000]$ est faux.

Bornes, amplitude, centre

Classe	e_{i-1}	e_i	a_i	c_i
$[4\,000\,;6\,000[$	$4\,000$	$6\,000$	$2\,000$	$5\,000$
$[10\,000\,;14\,000[$	$10\,000$	$14\,000$	$4\,000$	$12\,000$
$[14\,000\,;20\,000[$	$14\,000$	$20\,000$	$6\,000$	$17\,000$

Combien de classes

Sturges et la racine

règle de Sturges : $k \approx 1 + 3{,}3 \log_{10}(n)$ règle de la racine : $k \approx \sqrt{n}$

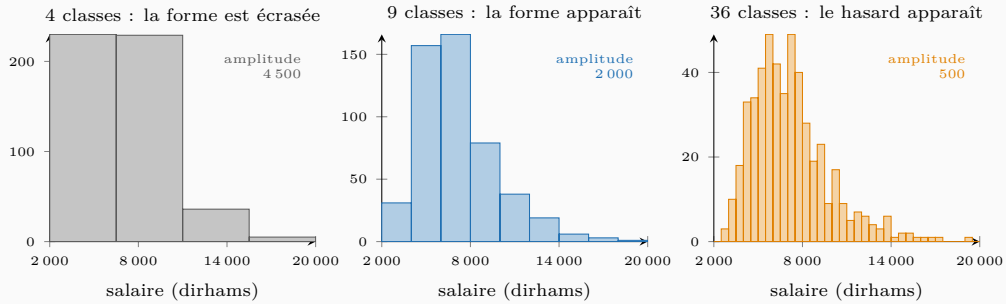
Sur nos données

Sturges : $1 + 3{,}3 \times \log_{10}(500) = 1 + 3{,}3 \times 2{,}70 = 9{,}9$, soit une dizaine de classes.

Racine : $\sqrt{500} = 22{,}4$.

Les deux règles ne s'accordent pas. **Elles ne sont qu'indicatives.**

Trop peu, assez, trop



Le vrai critère est l'arbitrage

Trop peu de classes écrase la forme ; trop de classes laisse voir le hasard, chaque classe contenant trop peu d'individus pour être stable. **Le bon nombre laisse voir la forme sans laisser voir le hasard** : il se juge sur l'histogramme, en essayant deux ou trois découpages.

Le choix des bornes

Trois principes

1. Des bornes **rondes** et lisibles : $4\,000$, $6\,000$, $8\,000$ — jamais $4\,137$.
2. Aucune classe **vide** à l'intérieur du tableau.
3. Des classes **plus larges là où les données sont rares** — c'est-à-dire dans les queues.

Le raisonnement, pas à pas, sur les salaires

1. Étendue : $19\,050 - 2\,810 = 16\,240$ dirhams.
2. Sturges propose $k \approx 10$, soit une amplitude d'environ $16\,240/10 \approx 1\,600$, arrondie à $2\,000$.
3. Bornes rondes de $2\,000$ à $20\,000$: neuf classes de $2\,000$.
4. Au-delà de $10\,000$, les cinq dernières classes ne comptent que 38, 19, 6, 3 et 1 salariés : on les fusionne en $[10\,000\,;14\,000[$ et $[14\,000\,;20\,000[$.

Le découpage retenu pour les salaires

Six classes, dont deux plus larges

Classe	n_i	f_i	a_i	N_i	F_i
$[2\,000\,;4\,000[$	31	0,062	2 000	31	0,062
$[4\,000\,;6\,000[$	157	0,314	2 000	188	0,376
$[6\,000\,;8\,000[$	166	0,332	2 000	354	0,708
$[8\,000\,;10\,000[$	79	0,158	2 000	433	0,866
$[10\,000\,;14\,000[$	57	0,114	4 000	490	0,980
$[14\,000\,;20\,000[$	10	0,020	6 000	500	1,000
Total	**500**	**1,000**			

Pourquoi les deux dernières classes sont plus larges

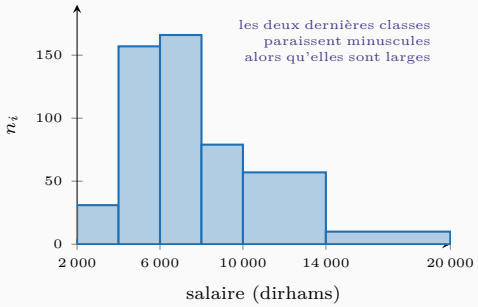
Découper de $2\,000$ en $2\,000$ jusqu'à $20\,000$ donnerait des classes à 1, 3 ou 6 individus, illisibles et instables. **Mais élargir les classes a un prix :** l'histogramme ne peut plus se lire en effectifs.

Amplitudes inégales, le prix

L'erreur qu'il faut voir une fois

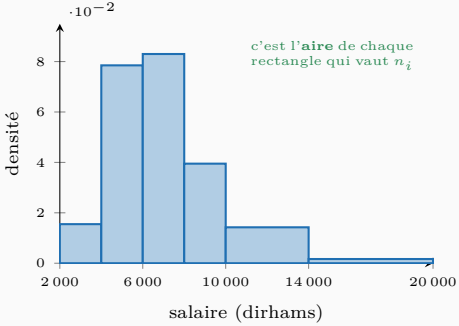
la hauteur est l'*effectif*

c'est faux



la hauteur est la *densité* n_i/a_i

c'est juste



classes d'amplitudes inégales : 2 000, 2 000, 2 000, 2 000, 4 000, 6 000 dirhams

Densité de fréquence

$$d_i = \frac{n_i}{a_i} \qquad \text{ou, en fréquences,} \qquad \frac{f_i}{a_i}$$

Dans un histogramme, **c'est la densité qui donne la hauteur** du rectangle, jamais l'effectif.

La règle, en une phrase

Dans un histogramme, c'est l'aire qui représente l'effectif, pas la hauteur.

Aire du rectangle = base $\times$ hauteur $= a_i \times \frac{n_i}{a_i} = n_i$. L'amplitude se simplifie : chaque rectangle a une aire égale à son effectif, quelles que soient les largeurs choisies.

Le calcul complet sur nos classes

Classe	n_i	a_i	$d_i = n_i / a_i$
$[2\,000\,;4\,000[$	31	$2\,000$	0,0155
$[4\,000\,;6\,000[$	157	$2\,000$	0,0785
$[6\,000\,;8\,000[$	166	$2\,000$	0,0830
$[8\,000\,;10\,000[$	79	$2\,000$	0,0395
$[10\,000\,;14\,000[$	57	$4\,000$	0,0143
$[14\,000\,;20\,000[$	10	$6\,000$	0,0017

La densité se lit en salariés **par dirham** ; multipliée par $1\,000$, en salariés par tranche de $1\,000$ dirhams : 83 dans la classe modale.

Une erreur presque toujours involontaire

Sur l'histogramme en effectifs, la classe $[10\,000\,;14\,000[$ paraît deux fois plus fournie que la première classe. En densité, elle est en réalité **au même niveau** : $0{,}0143$ contre $0{,}0155$.

Un lecteur non averti aurait conclu que les hauts salaires sont plus nombreux qu'ils ne le sont.

C'est le moyen le plus courant de mentir avec un histogramme.

Une vérification qui ne trompe pas

La somme des aires $a_i\,d_i$ redonne l'effectif total :

$$2\,000 \times 0{,}2165 + 4\,000 \times 0{,}0143 + 6\,000 \times 0{,}0017 = 433 + 57 + 10 = 500$$

Un cas particulier fréquent

Un tableau publié se termine souvent par « $14\,000$ dirhams et plus » : la borne supérieure est inconnue. On ne peut alors calculer ni la densité, ni le centre de classe, ni donc la moyenne.

Les deux solutions

1. **Fermer arbitrairement** la classe, en lui donnant l'amplitude de la précédente. C'est la convention la plus répandue.
2. **Renoncer à la moyenne** et travailler avec la médiane, qui n'a pas besoin des valeurs extrêmes.

La seconde est plus honnête. C'est aussi pourquoi les revenus se publient en médiane : la classe la plus haute est toujours ouverte.

Deux fermetures, deux moyennes

Supposons la dernière classe publiée comme « $14\,000$ et plus », avec ses 10 salariés.

- Fermée à $20\,000$: centre $17\,000$, moyenne groupée $7\,210$ dirhams.
- Fermée avec l'amplitude précédente, à $18\,000$: centre $16\,000$, et

$$\overline{x} = 7\,210 - \frac{10 \times (17\,000 - 16\,000)}{500} = 7\,210 - 20 = 7\,190$$

Peu de salariés, mais un effet visible

Dix salariés sur 500 déplacent la moyenne de 20 dirhams selon une convention que personne ne peut vérifier. **La médiane, elle, ne bouge pas.**

Le centre de classe

Le centre de classe

$$c_i = \frac{e_{i-1} + e_i}{2}$$

Pour tous les calculs qui suivent — moyenne, variance, moments — **on remplace chaque individu de la classe par le centre de sa classe**.

L'hypothèse d'équirépartition

On suppose que les individus sont **uniformément répartis** à l'intérieur de chaque classe. C'est faux en général, mais les erreurs se compensent partiellement d'une classe à l'autre.

Ce que gagnent vraiment les salariés de chaque classe

Classe	Centre c_i	Moyenne réelle	Écart
$[2\,000\,;4\,000[$	$3\,000$	$3\,528$	-528
$[4\,000\,;6\,000[$	$5\,000$	$5\,078$	-78
$[6\,000\,;8\,000[$	$7\,000$	$6\,995$	$+5$
$[8\,000\,;10\,000[$	$9\,000$	$8\,838$	$+162$
$[10\,000\,;14\,000[$	$12\,000$	$11\,470$	$+530$
$[14\,000\,;20\,000[$	$17\,000$	$15\,927$	$+1\,073$

La lecture

Dans les classes centrales, le centre est presque exact. Aux deux bouts, il **pousse les salariés vers l'extérieur** : trop bas en bas, trop haut en haut. On s'en souviendra pour la variance, au chapitre 7.

La moyenne à partir du tableau

Moyenne sur les 500 valeurs exactes : $7\,158$ dirhams. À partir du tableau, chaque salarié est remplacé par son centre ; en milliers de dirhams :

$$\sum n_i\, c_i = 3 \times 31 + 5 \times 157 + 7 \times 166 + 9 \times 79 + 12 \times 57 + 17 \times 10 = 3\,605$$

$$\overline{x} = 3\,605\,000 / 500 = 7\,210 \text{ dirhams}$$

Écart : 52 dirhams, soit $0{,}7\,\%$.

La leçon

L'approximation est excellente **tant que les classes sont fines là où les données sont denses**. L'essentiel de l'écart vient des deux dernières classes, larges et remplies surtout près de leur borne basse. La moyenne sur données groupées reste une **approximation**, à ne pas donner au dirham près.

Une proportion entre deux valeurs quelconques

Sous l'hypothèse d'équirépartition, la part d'une classe située sous une valeur x est proportionnelle à la longueur parcourue :

$$n_i \times \frac{x - e_{i-1}}{a_i}$$

Combien gagnent moins de 5 000 dirhams ?

Toute la première classe, 31 salariés, plus la moitié de $[4\,000\,;6\,000[$:

$$31 + 157 \times \frac{5\,000 - 4\,000}{2\,000} = 31 + 78{,}5 = 109{,}5 \text{ salariés, soit } 21{,}9\,\%$$

Le fichier exact en compte 98 : les salariés de cette classe sont un peu plus nombreux dans sa moitié haute. C'est le même calcul qui donnera la médiane au chapitre 6.

S’entraîner

Les temps de trajet de 24 salariés

Durée du trajet domicile–travail, en minutes, rangée par ordre croissant :

$$8,\ 12,\ 15,\ 18,\ 20,\ 22,\ 25,\ 25,\ 28,\ 30,\ 32,\ 35,\ 35,\ 38,\ 40,\ 42,\ 45,\ 48,\ 50,\ 55,\ 60,\ 70,\ 85,\ 110.$$

1. Calculer l'étendue et le nombre de classes proposé par Sturges.
2. On retient les classes $[0\,;20[$, $[20\,;40[$, $[40\,;60[$, $[60\,;80[$ et $[80\,;120[$. Dresser le tableau : n_i, f_i, a_i, d_i, F_i.
3. Quelle classe a la plus forte densité ? Pourquoi la dernière classe est-elle plus large, et quelle hauteur lui donner dans l'histogramme ?

Étendue, Sturges et tableau

1. Étendue $110 - 8 = 102$ minutes ; Sturges :
   $1 + 3{,}3 \times \log_{10}(24) = 1 + 3{,}3 \times 1{,}38 = 5{,}6$, soit cinq ou six classes.

Classe	n_i	f_i	a_i	d_i	F_i
$[0\,;20[$	4	0,167	20	0,20	0,167
$[20\,;40[$	10	0,417	20	0,50	0,583
$[40\,;60[$	6	0,250	20	0,30	0,833
$[60\,;80[$	2	0,083	20	0,10	0,917
$[80\,;120[$	2	0,083	40	0,05	1,000

Densité et dernière classe

3. La plus forte densité est celle de $[20\,;40[$: $0{,}5$ salarié par minute, soit 10 salariés pour 20 minutes.

La dernière classe est élargie parce que les longs trajets sont rares : en $[80\,;100[$ et $[100\,;120[$, on n'aurait qu'un salarié chacune. Sa hauteur est sa **densité**, $2/40 = 0{,}05$: moitié de celle de $[60\,;80[$, alors que les deux classes ont le même effectif.

À retenir

Deux classes de même effectif mais d'amplitudes différentes n'ont **pas** la même hauteur. C'est l'aire, $a_i \times d_i = 2$, qui est la même.

Les salaires entre 7 000 et 9 000 dirhams

On n'a que le tableau en six classes des 500 salaires (diapositive « Le découpage retenu »).

1. Sous l'hypothèse d'équirépartition, estimer le nombre de salariés dont le salaire est compris entre $7\,000$ et $9\,000$ dirhams.
2. Le fichier exact en compte 136. Calculer l'erreur relative de l'estimation.
3. Estimer de même la part des salariés gagnant au moins $12\,000$ dirhams.

Deux moitiés de classes

1. La moitié haute de $[6\,000\,;8\,000[$ et la moitié basse de $[8\,000\,;10\,000[$:

$$166 \times \frac{8\,000 - 7\,000}{2\,000} + 79 \times \frac{9\,000 - 8\,000}{2\,000} = 83 + 39{,}5 = 122{,}5 \text{ salariés}$$

2. Erreur : $(122{,}5 - 136)/136 = -9{,}9\,\%$. L'estimation sous-évalue : dans ces deux classes, les salariés ne sont pas uniformément répartis.
3. La moitié haute de $[10\,000\,;14\,000[$ plus toute la dernière classe :

$$57 \times \frac{14\,000 - 12\,000}{4\,000} + 10 = 28{,}5 + 10 = 38{,}5 \text{ salariés, soit } 7{,}7\,\%$$

Ce qu’il faut retenir

Le résumé du chapitre

Sept points

1. Une variable continue **doit** être regroupée en classes $[e_{i-1}\,;\,e_i[$.
2. Sturges donne un ordre de grandeur ; le nombre de classes se juge sur l'histogramme.
3. Bornes rondes, pas de classe vide, classes plus larges dans les queues.
4. **Densité** $d_i = n_i/a_i$: c'est elle qui donne la hauteur d'un histogramme ; **l'aire représente l'effectif**.
5. Une classe ouverte doit être fermée par convention — ou l'on renonce à la moyenne.
6. Le **centre de classe** remplace les individus dans les calculs : bonne approximation au centre, biaisée aux deux bouts.
7. Sous l'équirépartition, on **interpole** à l'intérieur d'une classe.

La suite

Chaque colonne du tableau appelle maintenant sa représentation graphique, qui dépend du type de la variable. C'est le chapitre 4.