

Statistique descriptive

Chapitre 2 : Tableaux et graphiques

Jaouad Madkour

26 juillet 2026

Faculté d'Économie et de Gestion de Tanger

Où en sommes-nous ?

Résumer une variable qualitative

Résumer une variable quantitative


Résumer deux variables

Bonnes pratiques de visualisation

Synthèse

Où en sommes-nous ?

Après avoir défini ce qu'est une **donnée** (ch. 1), nous apprenons à la **résumer** pour la rendre lisible.



Intuition

Un tableau de données brutes est illisible. Un **tableau de synthèse** ou un **graphique** révèle d'un coup d'œil la structure : catégories dominantes, forme, valeurs typiques.

Ce chapitre : résumer **une** variable (qualitative, puis quantitative), puis **deux** variables.

Résumer une variable qualitative

Définition

Une **distribution de fréquence** est un tableau qui indique, pour chaque catégorie (ou classe), le **nombre d'observations** (f_i) qui lui appartiennent.

Propriété fondamentale : $\sum_{i=1}^k f_i = n$ (la somme des effectifs vaut le nombre total d'observations).

Exemple

Sur 45 entreprises réparties par secteur : Agriculture 6, Industrie 12, Services 18, Public 9. Le tableau condense 45 observations en 4 nombres.

Fréquences relatives et en pourcentage

Définition

La **fréquence relative** d'une catégorie est sa part dans le total :

$$f_i^{\text{rel}} = \frac{f_i}{n}, \quad \text{fréquence en \%} = 100 \times \frac{f_i}{n}.$$

Intuition

La fréquence relative rend les distributions **comparables** entre échantillons de tailles différentes : 18 sur 45 (40 %) se compare directement à 200 sur 500 (40 %).

Application en sciences économiques

La **structure sectorielle de l'emploi** (part de l'agriculture, de l'industrie, des services dans l'emploi total) est une distribution de fréquences relatives ; sa déformation dans le temps décrit la *tertiarisation* d'une économie.

Diagramme en barres et diagramme circulaire

Diagramme en barres — une barre par catégorie, hauteur = fréquence. Compare les effectifs.





Diagramme circulaire — parts d'un tout (angles $\propto$ fréquences relatives).



Intuition

Barres pour **comparer** des catégories ; secteurs pour montrer des **parts d'un tout**. Au-delà de 5–6 parts, le circulaire devient illisible.

Résumer une variable quantitative

Pour une variable quantitative, on regroupe les valeurs en **classes** juxtaposées. Trois décisions :

- **Nombre de classes** k : en général 5 à 20 (souvent $k \approx \sqrt{n}$) ;
- **Largeur** approximative : $L \approx \frac{\text{valeur max} - \text{valeur min}}{k}$;
- **Limites** : bornes claires, sans chevauchement ni trou.

Intuition

Trop peu de classes $\Rightarrow$ on masque la structure ; trop de classes $\Rightarrow$ on rajoute du bruit. Le bon nombre fait apparaître la *forme* sans hacher les données.

Définition

La **fréquence cumulée** d'une classe est le nombre d'observations **inférieures** à sa borne supérieure. En pourcentage cumulé, la dernière classe atteint 100 %.


Application en sciences économiques

Les **déciles de revenu** reposent sur la distribution cumulée : le 1^{er} décile est le revenu en dessous duquel se trouvent 10 % des ménages. C'est la base des mesures d'inégalité.

Histogramme

Définition

Un **histogramme** représente une distribution de fréquence quantitative : des rectangles **contigus** dont la surface est proportionnelle à l'effectif de la classe.



Exemple

La forme d'une distribution


Étalée à droite



Symétrique



Étalée à gauche



Intuition

L'**asymétrie** (*skewness*) se lit sur l'histogramme. Une queue à droite (asymétrie positive) signale quelques valeurs très élevées.


Application en sciences économiques

Les distributions de **revenu** et de **patrimoine** sont typiquement **étalées à droite** : une minorité de très hauts revenus tire la moyenne au-dessus de la médiane. Cette asymétrie justifie l'usage de la médiane (ch. 3).

Distributions cumulées : l'ogive

Définition

L'**ogive** est la courbe des fréquences cumulées : en abscisse les bornes de classes, en ordonnée le pourcentage cumulé.



Lecture

On lit directement : « quel % des observations est en dessous d'un seuil ? »
— utile pour les quantiles.

Définition

Le diagramme « **tiges et feuilles** » (*stem-and-leaf*) classe les valeurs en conservant leurs chiffres : la « tige » (dizaines) à gauche, les « feuilles » (unités) à droite.

Intuition

Contrairement à l'histogramme, il montre la **forme ET les valeurs exactes**. Idéal à la main, sur de petits jeux de données.

Résumer deux variables

Définition

Une **tabulation croisée** (tableau de contingence) résume simultanément **deux** variables : les catégories de l'une en lignes, de l'autre en colonnes ; chaque cellule contient un effectif.

Table 1 – Croisement niveau de diplôme $\times$ statut d'activité (effectifs).

Diplôme \ Statut	Emploi	Chômage	Total
Supérieur	320	30	350
Secondaire	210	90	300
Total	530	120	650

Le paradoxe de Simpson

Intuition

Une relation observée dans les données **agrégées** peut **s'inverser** lorsqu'on tient compte d'une troisième variable (l'effet de composition).


Application en sciences économiques

Un écart salarial hommes-femmes apparent au niveau global peut se réduire, voire s'inverser, une fois contrôlés le secteur et l'expérience. Le paradoxe de Simpson est un avertissement : **toujours se demander quelle variable cachée structure les données** — c'est la porte d'entrée de l'économétrie (ch. 12–13).

Nuage de points et tendance

Définition

Un **nuage de points** représente chaque observation par un point (x_i, y_i) ; il visualise la **relation** entre deux variables quantitatives.




Lecture

Points alignés vers le haut $\Rightarrow$ relation positive. La **droite de tendance** résume le lien — préfiguration de la régression.

Application en sciences économiques

Nuage (dépense publicitaire, ventes) ou (revenu, consommation) : la pente de la tendance

Barres empilées et côte-à-côte



Deux variantes

Côte-à-côte : compare les catégories groupe par groupe. **Empilées** : montre en plus le total et la composition.

Bonnes pratiques de visualisation

Principes

- Un **titre** clair et des **axes légendés** (avec unités) ;
- Commencer l'axe des ordonnées à **zéro** pour ne pas exagérer les écarts ;
- Choisir le type adapté : **barres/secteurs** (qualitatif), **histogramme** (quantitatif), **nuage** (deux quantitatives), **série temporelle** (évolution).

Intuition

Un graphique doit *révéler* l'information, pas la décorer ni la déformer. La clarté prime sur l'esthétique.

Synthèse

L'essentiel du chapitre 2

- **Qualitatif** : distribution de fréquence (absolue, relative, %), diagrammes en barres et circulaire.
- **Quantitatif** : classes, histogramme, forme (asymétrie), distribution cumulée / ogive, tiges-et-feuilles.
- **Deux variables** : tabulation croisée (attention au paradoxe de Simpson), nuage de points, barres groupées/empilées.
- Un graphique bien construit **révèle** la structure des données.

Vers le chapitre 3

Les tableaux et graphiques *montrent* la distribution. Le chapitre 3 va la **résumer par des nombres** : tendance centrale (moyenne, médiane) et dispersion (variance, écart-type).