

Chapitre 17

L'analyse de la variance

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Statistique inférentielle

1 Exercices du chapitre

Correction — Exercice 1

(a) $H_0 : m_A = m_B = m_C$; H_1 : au moins une moyenne diffère des autres.

$$(b) \bar{x} = \frac{12 \times 45,2 + 15 \times 48,7 + 13 \times 51,3}{40} = \frac{1939,8}{40} = 48,495.$$

$$SCE = 12(45,2 - 48,495)^2 + 15(48,7 - 48,495)^2 + 13(51,3 - 48,495)^2 \approx 233,20.$$


$$SCR = 11 \times 4,1^2 + 14 \times 3,8^2 + 12 \times 4,5^2 \approx 630,07.$$

(c)

Source	Somme de carrés	ddl	Carré moyen
Entre (SCE)	233,20	2	116,60
Résiduelle (SCR)	630,07	37	17,03
Totale	863,27	39	

$$F = \frac{116,60}{17,03} \approx 6,85.$$

(d) $6,85 > F_{0,95;2;37} = 3,252$: on **rejette** H_0 . Les trois engrais ne produisent pas le même rendement moyen.



Correction — Exercice 2

$$(a) SCT = 233,20 + 630,07 = 863,27. \eta^2 = \frac{233,20}{863,27} \approx 0,270.$$

(b) Le choix de l'engrais explique environ 27 % de la dispersion des rendements observés ; les 73 % restants viennent d'autres facteurs (qualité du sol, ensoleillement, irrigation, hasard d'échantillonnage des parcelles).

(c) **Non** : le rejet de H_0 signale seulement que l'effet est **réel** (peu probable d'être dû au hasard), pas qu'il est **important**. Avec $\eta^2 \approx 0,27$, l'effet est réel et notable, mais il est loin d'être le facteur dominant du rendement – exactement la distinction entre significativité statistique et ampleur économique rappelée au chapitre 14.

Correction — Exercice 3

$$(a) \binom{6}{2} = \frac{6 \times 5}{2} = 15 \text{ paires.}$$

$$(b) P(\text{au moins un rejet à tort}) = 1 - (0,95)^{15} \approx 0,537.$$

(c) Le risque réel (53,7 %) est plus de dix fois supérieur au risque affiché de 5 % par test : en multipliant les comparaisons deux à deux, on est presque certain de « trouver » au moins une différence significative même si aucun visuel ne diffère réellement des autres. L'ANOVA résout ce problème car elle pose une seule question globale (« les six moyennes sont-elles toutes égales ? ») tranchée par un unique test au seuil de 5 % réellement respecté, plutôt que 15 questions séparées dont le risque global s'accumule.

2 Exercices cumulatifs (chapitres 1 à 17)

Correction — Exercice 4


(a)

Source	Somme de carrés	ddl	Carré moyen
Entre (SCE)	869 847 811	2	434 923 906
Résiduelle (SCR)	2 505 213 175	497	5 040 671
Totale	3 375 060 986	499	

$$F = \frac{434\,923\,906}{5\,040\,671} \approx 86,28.$$

(b) $86,28 \gg F_{0,95;2;497} = 3,01$: on **rejette très largement** H_0 ($p < 0,0001$). $\eta^2 = \frac{869\,847\,811}{3\,375\,060\,986} \approx 0,258$.

(c) Les deux tests ne comparent pas la même chose. Le test du chapitre 16 compare deux moyennes définies par le **sexe** : il ne trouve, dans cette entreprise, aucun écart détectable entre les rémunérations moyennes des hommes et des femmes. L'ANOVA de cette question compare trois moyennes définies par le **diplôme**, et trouve un effet massif ($F = 86,28$). Mis côte à côte, ces deux résultats dessinent une image cohérente et informative de l'entreprise : la dispersion des salaires n'est **pas** liée au sexe des salariés, mais elle est très fortement liée à leur niveau de diplôme – avec cependant $\eta^2 \approx 0,258$, ce qui rappelle (chapitre 17, exercice 2) que même ce facteur dominant n'explique qu'un peu plus d'un quart de la dispersion totale : ancienneté, poste, performance individuelle et hasard jouent aussi un rôle réel.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $N = 40 + 35 + 38 + 42 = 155$. $\bar{x} = \frac{40 \times 285 + 35 \times 310 + 38 \times 298 + 42 \times 275}{155} \approx 291,12$ dh. $SCE \approx 26\,687$; $SCR \approx 398\,217$. $ddl = (3, 151)$. $F = \frac{26\,687/3}{398\,217/151} = \frac{8\,896}{2\,637} \approx 3,373$. Comme $3,373 > 2,665$, on **rejette** H_0 .

(b) $\eta^2 = \frac{26\,687}{26\,687 + 398\,217} \approx 0,063$. **Non** : le canal de vente a un effet statistiquement réel mais économiquement **modeste** – il n'explique qu'environ 6 % de la dispersion des montants de panier, très loin d'en être le facteur déterminant.

(c) **Non** : l'ANOVA rejette « en bloc » et dit seulement qu'au moins un canal diffère des autres, pas

lequel. Conclure directement que l'application mobile est « le meilleur » canal reviendrait à lire les moyennes de l'échantillon sans test complémentaire; il faudrait des **comparaisons multiples** avec un seuil corrigé (rappelées au chapitre 17) pour identifier statistiquement quelles paires de canaux diffèrent réellement.

Correction — Exercice 6

(a) $N = 395$. $\bar{x} \approx 12,00$. $SCE \approx 165,35$; $SCR \approx 4\,340,27$. $F = \frac{165,35/2}{4\,340,27/392} = \frac{82,68}{11,07} \approx 7,47$. Comme $7,47 > 3,019$, on **rejette** H_0 : le temps d'attente moyen diffère selon le format de magasin.

(b) $\eta^2 = \frac{165,35}{165,35 + 4\,340,27} \approx 0,037$. Cette apparente tension (rejet net, mais η^2 très faible) n'a rien de contradictoire : avec $N = 395$ observations, même un écart modeste entre moyennes (9,1 à 12,4 minutes) devient statistiquement détectable, exactement comme au chapitre 13 un grand échantillon donne une forte puissance même pour de petits effets. Significativité statistique et importance économique de l'effet (mesurée par η^2) sont deux informations distinctes, toutes deux nécessaires.

(c) L'ANOVA suppose des variances **comparables** entre groupes; avec seulement 15 observations dans le groupe « proximité » contre 200 et 180 dans les deux autres, l'estimation de $s_{\text{proximité}}$ repose sur un échantillon bien plus fragile, et le déséquilibre des effectifs amplifie la sensibilité du test à toute hétérogénéité réelle des variances – le cours le rappelle explicitement : l'ANOVA supporte bien l'inégalité des variances quand les effectifs sont équilibrés, mal quand ils ne le sont pas, ce qui est précisément le cas ici.

