Statistique inférentielle

Chapitre 17 : L'analyse de la variance

Jaouad Madkour

31 octobre 2026

Plan du chapitre

Pourquoi un outil de plus **2**
La question . . . 2
Le problème des tests multiples . . . 2

La décomposition **3**
Ce que l'ANOVA regarde . . . 3
Trois sommes de carrés . . . 4
Le calcul de SCE . . . 4
Le calcul de SCR . . . 5

Le rapport de Fisher **5**
La statistique de test . . . 5
Les degrés de liberté . . . 6

L'application **7**
Le tableau d'analyse de la variance . . . 7
Le verdict . . . 7
La lecture . . . 8
Ce que dit la population . . . 8
Dix échantillons, dix analyses . . . 8

Ce que l'ANOVA ne dit pas **9**
Elle rejette en bloc . . . 9
Les comparaisons sur notre échantillon . . . 9
Les conditions de validité . . . 9
L'ANOVA de Welch . . . 10
Deux groupes : l'ANOVA retrouve le test t . . . 10

S'entraîner **11**
Exercice 1 : compléter un tableau . . . 11
Exercice 1 : solution . . . 11
Exercice 2 : partir des résumés . . . 11
Exercice 2 : solution . . . 11
Exercice 3 : significatif et important . . . 12

Exercice 3 : solution 12

Ce qu'il faut retenir **12**
Le résumé du chapitre 12
La suite 12

Pourquoi un outil de plus

La question

Le diplôme influence-t-il le salaire ?

Dans l'échantillon de 50 salariés : 20 Bac, payés en moyenne 6 217 dirhams ; 17 Bac+2, à 6 869 ; 13 Bac+5, à 8 398.
Les trois moyennes diffèrent. Ces écarts reflètent-ils des écarts réels dans l'entreprise, ou le seul hasard du tirage ?

Trois groupes, et non plus deux

Le test de Welch du chapitre 16 compare **deux** moyennes. Avec trois groupes, la tentation est de l'appliquer trois fois.
C'est précisément ce qu'il ne faut pas faire.

Le problème des tests multiples

Trois groupes, trois comparaisons

Bac contre Bac+2, Bac+2 contre Bac+5, Bac contre Bac+5. Trois tests à 5 % chacun.

$$P(\text{au moins un rejet à tort}) \approx 1 - (0{,}95)^3 = 0{,}143$$

Le risque réel n'est plus 5 % mais 14 % ; 40 % avec cinq groupes (dix comparaisons).

La solution

Un **test unique**, portant sur les trois moyennes à la fois :

$$H_0 : m_1 = m_2 = m_3 \qquad H_1 : \text{au moins une diffère}$$

Le risque annoncé redevient le risque réel.

Démonstration : Le risque cumulé de plusieurs comparaisons deux à deux

Chaque comparaison, prise seule, se trompe avec la probabilité $\alpha = 0{,}05$ quand les moyennes sont égales. Pour m comparaisons, la probabilité d'au moins un faux rejet est **au plus** $m\alpha$ (inégalité de l'union : la probabilité d'une réunion ne dépasse pas la somme des probabilités). Elle vaudrait $1 - (1-\alpha)^m$ si les tests étaient indépendants :

groupes k	3	4	5
comparaisons $m = k(k-1)/2$	3	6	10

$1-0{,}95^m$	0,143	0,265	0,401

Mais les comparaisons ne sont pas indépendantes : chaque groupe intervient dans $k-1$ d'entre elles. On peut calculer le risque exact pour des groupes de même effectif, de moyennes égales et de variance connue. Les moyennes réduites $Z_i = (\overline{X}_i - m)\big/(\sigma/\sqrt{n})$ sont alors k variables $\mathcal{N}(0\,;1)$ indépendantes, et un faux rejet a lieu dès que l'une des différences $|Z_i - Z_j|$ dépasse $1{,}96\sqrt{2}$, c'est-à-dire dès que l'étendue R des Z_i dépasse ce nombre. La fonction de répartition de l'étendue (on conditionne sur le plus petit Z_i, de densité $k\varphi(x)[1-\Phi(x)]^{k-1}$) donne

$$P(R \le r) = k \int_{-\infty}^{+\infty} \varphi(x)\,\big[\Phi(x+r) - \Phi(x)\big]^{k-1}\,dx,$$

d'où le risque exact $1 - P\big(R \le 1{,}96\sqrt{2}\big)$:

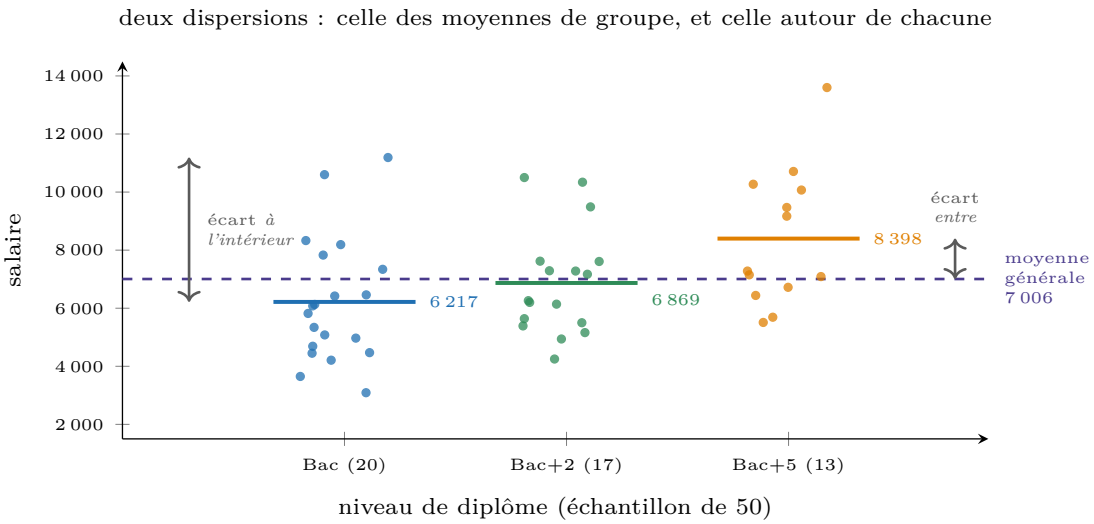
groupes k	3	4	5
risque exact	0,122	0,203	0,286

Ce que cela dit. Le risque réel dépasse nettement 5 % dès trois groupes, et il grandit avec k : c'est le fond du problème. Les chiffres du calcul « indépendant » (14 % pour trois groupes, 40 % pour cinq) sont des ordres de grandeur légèrement trop élevés ; en tenant compte du partage des groupes, on trouve environ 12 % et 29 %. Un test unique, lui, garde exactement son niveau α.

■

La décomposition

Ce que l'ANOVA regarde



Trois sommes de carrés

La décomposition, déjà vue en descriptive

$$\underbrace{\text{SCT}}_{\text{variation totale}} = \underbrace{\text{SCE}}_{\text{entre les groupes}} + \underbrace{\text{SCR}}_{\text{à l'intérieur}}$$

$$\text{SCT} = \sum_{i,j}(x_{ij} - \overline{x})^2 \qquad \text{SCE} = \sum_{i} n_i(\overline{x}_i - \overline{x})^2 \qquad \text{SCR} = \sum_{i,j}(x_{ij} - \overline{x}_i)^2$$

Le nom du test est trompeur

On appelle cela « analyse de la variance », et l'on y compare pourtant des **moyennes**. La raison est dans la figure : si les moyennes de groupe s'écartaient peu, la dispersion entre elles serait faible devant la dispersion interne. **C'est en comparant deux dispersions qu'on juge des moyennes.**

Démonstration : La variation totale se décompose exactement

Pour l'observation x_{ij} (individu j du groupe i), on insère la moyenne du groupe : $x_{ij} - \overline{x} = (x_{ij} - \overline{x}_i) + (\overline{x}_i - \overline{x})$. On élève au carré et l'on somme sur tous les individus :

$$\text{SCT} = \underbrace{\sum_{i,j}(x_{ij} - \overline{x}_i)^2}_{\text{SCR}} + \underbrace{\sum_{i,j}(\overline{x}_i - \overline{x})^2}_{\text{SCE}} + 2\sum_{i,j}(x_{ij} - \overline{x}_i)(\overline{x}_i - \overline{x}).$$

Le deuxième terme ne dépend pas de j : le groupe i le répète n_i fois, d'où $\text{SCE} = \sum_i n_i(\overline{x}_i - \overline{x})^2$. Le terme croisé s'annule groupe par groupe, car $\overline{x}_i - \overline{x}$ est constant dans le groupe et que $\sum_j (x_{ij} - \overline{x}_i) = 0$, propriété de la moyenne. Il reste $\text{SCT} = \text{SCE} + \text{SCR}$.

Sur l'échantillon. SCE $=$ 37 946 073 et SCR $=$ 210 331 745 somment à 248 277 818 $=$ $49 \times 2\,250{,}98^2 =$ SCT. La contribution du groupe Bac+5 à SCE est $25\,185\,735/37\,946\,073 = 66\,\%$: le groupe le plus éloigné de $\overline{x}$ pèse plus de deux fois et demie son poids dans l'effectif (26 % des salariés).

Ce que cela dit. La variation totale se partage sans reste entre ce qui sépare les groupes et ce qui les habite. Aucun terme n'est « perdu » ni compté deux fois : c'est ce qui permet de comparer SCE à SCR, et d'écrire $\eta^2 = \text{SCE}/\text{SCT}$ comme une part comprise entre 0 et 1.

■

Le calcul de SCE

Chaque groupe pèse selon son effectif

Avec $\overline{x} = 7\,005{,}80$:

Groupe	n_i	$\overline{x}_i$	$\overline{x}_i - \overline{x}$	$n_i(\overline{x}_i - \overline{x})^2$
Bac	20	6 217,00	−788,80	12 444 109
Bac+2	17	6 869,41	−136,39	316 230
Bac+5	13	8 397,69	+1 391,89	25 185 735
SCE				37 946 073

Les Bac+5 font l'essentiel

Deux tiers de SCE viennent du groupe Bac+5, le plus éloigné de la moyenne générale, bien qu'il soit le moins nombreux.
Les Bac+2, presque à la moyenne, ne contribuent pratiquement pas.

La dispersion à l'intérieur de chaque groupe

$\sum_j (x_{ij} - \overline{x}_i)^2 = (n_i - 1)\, s_i^2$:

Groupe	n_i	s_i	$(n_i - 1)\, s_i^2$
Bac	20	2 163,87	88 964 620
Bac+2	17	1 838,38	54 074 294
Bac+5	13	2 368,07	67 292 831
SCR			210 331 745

La vérification

$\text{SCT} = (n-1)\, s^2 = 49 \times 2\,250{,}98^2 = 248\,277\,818$.
Et $37\,946\,073 + 210\,331\,745 = 248\,277\,818$: la décomposition tombe juste, au dirham carré près.

La statistique de test

$$F = \frac{\text{SCE}/(k-1)}{\text{SCR}/(n-k)} \sim \text{Fisher à } (k-1) \text{ et } (n-k) \text{ degrés de liberté}$$

où k est le nombre de groupes et n l'effectif total.

Pourquoi cette forme

On divise chaque somme de carrés par son nombre de degrés de liberté — la règle du chapitre 3, appliquée deux fois.
Sous H_0, les deux quantités estiment la même variance résiduelle : leur rapport vaut environ

1. Un F nettement supérieur à 1 signale que les moyennes diffèrent.

Démonstration : Sous l'hypothèse nulle, les deux carrés moyens estiment la même variance

On pose $x_{ij} = m_i + \varepsilon_{ij}$, avec des erreurs indépendantes, d'espérance nulle et de variance σ^2, et $m = \sum_i n_i m_i / n$ la moyenne générale vraie.

Le carré moyen résiduel. Dans le groupe i, $\sum_j (x_{ij} - \overline{x}_i)^2$ est la somme des carrés des écarts à la moyenne d'un échantillon de taille n_i : son espérance est $(n_i - 1)\sigma^2$ (chapitre 5). Donc $E(\text{SCR}) = (n-k)\sigma^2$ et $E(\text{SCR}/(n-k)) = \sigma^2$, **quelles que soient** les moyennes m_i.

Le carré moyen entre les groupes. En développant, $\text{SCE} = \sum_i n_i \overline{x}_i^2 - n\overline{x}^2$ (on a $\sum_i n_i \overline{x}_i = n\overline{x}$). Or $E(\overline{x}_i^2) = m_i^2 + \sigma^2/n_i$ et $E(\overline{x}^2) = m^2 + \sigma^2/n$. Donc

$$E(\text{SCE}) = \sum_i n_i m_i^2 + k\sigma^2 - nm^2 - \sigma^2 = (k-1)\sigma^2 + \sum_i n_i (m_i - m)^2,$$

puisque $\sum_i n_i m_i^2 - nm^2 = \sum_i n_i (m_i - m)^2$.

La conclusion. $E(\text{SCE}/(k-1)) = \sigma^2 + \sum_i n_i (m_i - m)^2 \big/ (k-1)$. Sous H_0 (tous les m_i égaux), les deux carrés moyens ont la même espérance σ^2 et F est voisin de 1. Sous H_1, le numérateur a une espérance supérieure d'un terme positif qui mesure l'écart entre les moyennes : F tend à dépasser 1. Diviser par $k - 1$ et par $n - k$ est exactement ce qui rend chaque carré moyen sans biais pour σ^2 : c'est la justification des degrés de liberté du tableau. (Que le rapport suive une loi de Fisher, parce que SCE et SCR sont indépendantes et suivent des lois de khi-deux, est admis ici ; l'argument est celui de la fin du chapitre 20.)

Notre échantillon. Le carré moyen résiduel, 4 475 144, estime σ^2, soit un écart-type de 2 115 dirhams autour de la moyenne de chaque diplôme. Le carré moyen entre groupes, 18 973 037, est 4,24 fois plus grand : l'excès, que l'on attribue aux écarts de moyennes, vaut $18\,973\,037 - 4\,475\,144 \approx 14{,}5$ millions.

Ce que cela dit. Le rapport F n'est pas une construction arbitraire : c'est le rapport de deux estimateurs de la même variance, dont seul le numérateur réagit à des moyennes différentes.

■

Ils s'additionnent, comme les sommes de carrés

Source	SC	ddl	Pourquoi
entre	SCE	$k-1$	k moyennes liées par la moyenne générale
résiduelle	SCR	$n-k$	n écarts, k moyennes estimées
totale	SCT	$n-1$	n écarts, une moyenne estimée

Sur notre échantillon

$k = 3$, $n = 50 : 2 + 47 = 49$.
Le seuil se lit dans la table de Fisher à 2 et 47 degrés de liberté : $F_{0,95} = 3{,}20$, $F_{0,99} = 5{,}09$.

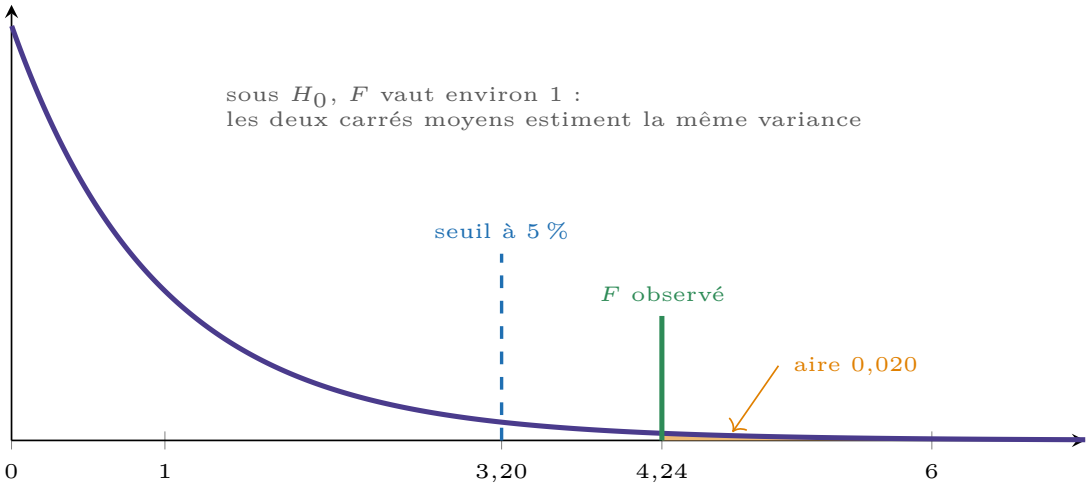
Ce que tout logiciel affiche

Source	Somme de carrés	ddl	Carré moyen	F
Entre (SCE)	37 946 073	2	18 973 037	4,24
Résiduelle (SCR)	210 331 745	47	4 475 144	
Totale	248 277 818	49		

Lire le tableau en une phrase

La variance « entre » (18,97 millions) est 4,24 fois plus grande que la variance « à l'intérieur » (4,48 millions).
Si le diplôme n'avait aucun effet, ces deux nombres seraient du même ordre.

notre $F = 4{,}24$ dépasse le seuil de 3,20 : $p = 0{,}020$



valeur de F si H_0 est vraie : loi de Fisher à 2 et 47 degrés de liberté

Le résultat

$$F = \frac{18\,973\,037}{4\,475\,144} = 4{,}24 \qquad \text{contre un seuil de } 3{,}20$$

$p = 0{,}020$: **on rejette** H_0 au seuil de 5 % (mais pas à 1 %). Les salaires moyens diffèrent selon le diplôme.

Le rapport de corrélation, et ce qu'il ajoute

$$\eta^2 = \frac{\text{SCE}}{\text{SCT}} = \frac{37\,946\,073}{248\,277\,818} = 0{,}153$$

Dans l'échantillon, le diplôme explique 15 % de la dispersion des salaires. Le test dit que l'effet existe ; η^2 dit quelle part il représente.

La vérité, que l'on connaît ici

Diplôme	Effectif	Salaire moyen
Bac	219	6 058,90
Bac+2	174	7 080,75
Bac+5	107	9 534,39

$\eta^2 = 869\,847\,811 / 3\,375\,060\,986 = 0{,}258$.

Le rejet était juste, l'échantillon sous-estimait

Les moyennes diffèrent bien dans la population : H_0 est fausse, et le test l'a vu.
Mais notre échantillon donnait $\eta^2 = 0{,}153$ pour une vraie valeur de 0,258, et un écart Bac / Bac+5 de 2 181 dirhams pour un vrai de 3 475. Un rapport de corrélation calculé sur 50 personnes est **une estimation**, et fort imprécise.

Le même test sur les dix échantillons systématiques

r	0	1	2	3	4	5	6	7	8	9
F	4,2	9,3	9,6	4,2	7,0	17,4	12,9	13,3	14,2	4,6
η^2	0,15	0,28	0,29	0,15	0,23	0,43	0,35	0,36	0,38	0,16

Dix rejets, mais un effet mal mesuré

Les dix échantillons rejettent H_0 : l'effet du diplôme est assez fort pour être vu à $n = 50$. Par simulation, la puissance vaut 0,94.
Mais η^2 va de 0,15 à 0,43 autour de la vraie valeur 0,26. Notre échantillon ($r = 0$) était l'un

des **moins** favorables.

Laquelle diffère ?

« Au moins une moyenne diffère » : l'ANOVA ne dit pas laquelle, ni de combien.
Pour le savoir, on compare ensuite les groupes deux à deux — mais avec un **seuil corrigé**, sinon on retombe dans le problème des tests multiples.

Les comparaisons deux à deux, avec Bonferroni

Trois comparaisons : on multiplie chaque p-value par 3 (ou l'on compare à $0{,}05/3 = 0{,}0167$).

Trois tests de Welch, corrigés

Comparaison	Écart	t	p	p corrigée
Bac / Bac+2	−652	−0,99	0,33	0,98
Bac / Bac+5	−2 181	−2,67	0,013	0,040
Bac+2 / Bac+5	−1 528	−1,93	0,067	0,20

La lecture

Seul l'écart Bac / Bac+5 reste significatif après correction. Avec 50 personnes, l'échantillon ne permet pas de séparer les Bac+2 de leurs voisins.
Dans la population, les trois écarts sont réels (1 022, 3 475 et 2 454 dirhams) : là encore, **non significatif ne veut pas dire nul**.

Trois conditions

1. Échantillons **indépendants**.
2. Population **normale** dans chaque groupe — ou effectifs suffisants.
3. Variances **comparables** entre groupes.

Ce que coûte la troisième, sur nos salaires

Dans la population, l'écart-type des Bac+5 (2 872) dépasse celui des autres groupes (environ 2 030), et c'est le plus petit groupe.
On simule 5 000 échantillons de 50 dans une population où l'on a **égalisé les moyennes** : l'ANOVA rejette à tort dans 7,7 % des cas, pour 5 % annoncés.

La version qui ne suppose pas l'égalité des variances

Comme pour deux groupes, il existe une version de Welch de l'ANOVA. Elle pondère chaque groupe par l'inverse de sa variance et ajuste les degrés de liberté.
Dans la même simulation, son risque réel est de 6,2 %.

Sur notre échantillon

ANOVA de Welch : $F = 3{,}51$ avec 2 et 28,2 degrés de liberté, $p = 0{,}044$.
La conclusion à 5 % est la même, mais plus fragile : p passe de 0,020 à 0,044.

Quand $k = 2$, $F = t^2$

Avec deux groupes, l'ANOVA est exactement le test t à variances égales du chapitre 16 : $F = t^2$, et les deux p-values coïncident.

Hommes et femmes

Test t à variances égales : $t = 0{,}825$, $p = 0{,}414$.
ANOVA à deux groupes : $F = 0{,}680 = 0{,}825^2$, $p = 0{,}414$. **L'ANOVA généralise le test** t, elle ne le remplace pas.

Démonstration : Avec deux groupes, le F de l'ANOVA est le carré du t

Notons $d = \overline{x}_1 - \overline{x}_2$ et $n = n_1 + n_2$. La moyenne générale est $\overline{x} = (n_1\overline{x}_1 + n_2\overline{x}_2)/n$, donc $\overline{x}_1 - \overline{x} = \frac{n_2}{n}\, d$ et $\overline{x}_2 - \overline{x} = -\frac{n_1}{n}\, d$. Alors

$$\mathrm{SCE} = n_1 \frac{n_2^2}{n^2}\, d^2 + n_2 \frac{n_1^2}{n^2}\, d^2 = \frac{n_1 n_2}{n}\, d^2 = \frac{d^2}{\frac{1}{n_1} + \frac{1}{n_2}}.$$

D'autre part $\mathrm{SCR} = (n_1 - 1)s_1^2 + (n_2 - 1)s_2^2 = (n - 2)\, s_p^2$, où s_p^2 est la variance commune du chapitre 16. Avec $k = 2$:

$$F = \frac{\mathrm{SCE}/1}{\mathrm{SCR}/(n-2)} = \frac{d^2}{s_p^2\left(\frac{1}{n_1} + \frac{1}{n_2}\right)} = t^2,$$

où t est la statistique du test à variances égales.

Les p-values. Si T suit Student à ν degrés de liberté, $T^2 = Z^2 \big/ (V/\nu)$ avec $Z^2 \sim \chi^2_1$: c'est un rapport de khi-deux divisés par leurs degrés de liberté, donc T^2 suit Fisher à 1 et ν degrés de liberté. Ainsi $P(F > t^2) = P(|T| > |t|)$: même p-value.

Hommes et femmes. $d = 530{,}65$ et $n_1 n_2/n = 28 \times 22/50 = 12{,}32$ donnent $\mathrm{SCE} = 12{,}32 \times 530{,}65^2 = 3\,469\,173$; $\mathrm{SCR} = 244\,808\,645$ et $\mathrm{SCR}/48 = 5\,100\,180$. D'où $F = 3\,469\,173/5\,100\,180 = 0{,}680 = 0{,}825^2$.

Ce que cela dit. Les deux tests ne sont pas rivaux : à $k = 2$ ils sont le même calcul écrit de deux façons. L'ANOVA ne diffère du test t que lorsqu'il y a plus de deux groupes, là où le test t ne sait plus répondre par une seule statistique.

■

Quatre méthodes de vente

On compare le chiffre d'affaires de 40 commerciaux répartis en 4 groupes, un par méthode de vente. On obtient SCE $= 600$ et SCR $= 1\,800$.

1. Compléter le tableau d'analyse de la variance.
2. Conclure au seuil de 5 % ($F_{0,95\,;3\,;36} = 2{,}87$).
3. Calculer et interpréter η^2.

Degrés de liberté, carrés moyens, F

1. ddl 3, 36 et 39 ; carrés moyens $600/3 = 200$ et $1\,800/36 = 50$; $F = 200/50 = 4{,}00$.
2. $4{,}00 > 2{,}87$: on rejette H_0 ($p = 0{,}015$). Au moins une méthode donne un chiffre d'affaires moyen différent.
3. $\eta^2 = 600/2\,400 = 0{,}25$: la méthode explique un quart de la dispersion des chiffres d'affaires.

Trois agences, dix clients chacune

Durée d'attente (en minutes) dans trois agences, 10 clients par agence :

Agence	A	B	C
moyenne	12	15	18
écart-type	3	4	3,5

1. Calculer SCE et SCR.
2. Tester l'égalité des durées moyennes ($F_{0,95\,;2\,;27} = 3{,}35$).

SCE par les moyennes, SCR par les écarts-types

1. Moyenne générale 15. SCE $= 10\times(3^2+0^2+3^2) = 180$. SCR $= 9\times(3^2+4^2+3{,}5^2) = 335{,}25$.
2. $F = (180/2)/(335{,}25/27) = 90/12{,}42 = 7{,}25 > 3{,}35$: **rejet**, $p = 0{,}003$.

$\eta^2 = 180/515{,}25 = 0{,}35$. L'agence C fait nettement attendre plus longtemps.

Six régions, cinq mille clients

Une enquête compare le panier moyen de 5 000 clients répartis dans 6 régions. L'ANOVA donne $F = 20{,}4$, $p < 0{,}0001$ et $\eta^2 = 0{,}02$.

1. Un analyste avait d'abord prévu de comparer les régions deux à deux au seuil de 5 %. Quel aurait été le risque d'au moins une fausse découverte ?
2. Le directeur commercial veut adapter sa politique à chaque région. Que lui dire ?

Le test et l'ampleur

1. $1 - 0{,}95^{15} = 0{,}54$. Plus d'une chance sur deux de « découvrir » un écart inexistant.
2. L'effet de la région est **réel** (p minuscule), mais il n'explique que 2 % de la dispersion des paniers.

Avec 5 000 clients, un effet aussi faible devient significatif. Il ne justifie pas, à lui seul, six politiques différentes.

Six points

1. Comparer k groupes deux à deux **gonfle le risque réel** : 14 % pour trois groupes, 40 % pour cinq. L'ANOVA teste toutes les moyennes en **un seul test**.
2. $\text{SCT} = \text{SCE} + \text{SCR}$: la décomposition du cours de statistique descriptive.
3. F compare deux dispersions pour juger des **moyennes** ; sous H_0 il vaut environ 1.
4. Sur l'échantillon : $F = 4{,}24$, $p = 0{,}020$, $\eta^2 = 0{,}153$ — pour un vrai η^2 de 0,258.
5. L'ANOVA rejette **en bloc** ; les comparaisons deux à deux se font avec un seuil corrigé.
6. Variances inégales et groupes déséquilibrés faussent le risque : l'ANOVA de Welch le corrige.

Deux variables qualitatives

Il reste un type de données non traité : les **effectifs de tableau**, quand les deux variables sont qualitatives — le diplôme et le sexe, par exemple.

Le prochain chapitre

Le chapitre 18 y consacre le dernier test du cours, le khi-deux — celui qui ferme la boucle avec le tableau de contingence de la statistique descriptive.