Statistique inférentielle

Chapitre 16 : Comparer deux groupes

Jaouad Madkour

22 octobre 2026

Plan du chapitre

Comparer deux moyennes **2**
- La question . . . 2
- Le principe . . . 2
- Les variances s'additionnent, même pour une différence . . . 2
- La statistique de test . . . 3
- Les degrés de liberté de Welch . . . 3
- Welch ou variances égales . . . 3
- L'application . . . 4
- Le calcul complet . . . 4
- L'intervalle de l'écart . . . 5
- Ce que dit la population . . . 5
- Dix échantillons, aucun rejet . . . 5
- La conclusion, et ce qu'elle ne dit pas . . . 6

Comparer deux proportions **6**
- La statistique . . . 6
- Un exemple de gestion . . . 6
- L'intervalle et la taille nécessaire . . . 7
- Sur nos données : les Bac+5 selon le sexe . . . 7

Les échantillons appariés **8**
- Un cas particulier fréquent . . . 8
- Un exemple : la formation des commerciaux . . . 8
- Le calcul, apparié . . . 8
- Le même calcul, à tort non apparié . . . 9
- Pourquoi c'est bien plus puissant . . . 9
- La règle de reconnaissance . . . 9

S'entraîner **10**
- Exercice 1 : deux magasins . . . 10
- Exercice 1 : solution . . . 10
- Exercice 2 : deux méthodes de scoring . . . 10
- Exercice 2 : solution . . . 10

Exercice 3 : apparier ou non 10
Exercice 3 : solution 11

Ce qu'il faut retenir **11**
Le résumé du chapitre 11
La suite 11

Comparer deux moyennes

La question

Les hommes sont-ils mieux payés que les femmes ?

Dans l'échantillon de 50 salariés : 28 hommes, payés en moyenne 7 239 dirhams, et 22 femmes, payées 6 709 dirhams.
L'écart observé vaut 531 dirhams. Est-il le signe d'un écart réel dans l'entreprise, ou un simple effet du tirage ?

Une question nouvelle

Au chapitre 15, on comparait **un** paramètre à une valeur fixée. Ici, on compare **deux** paramètres inconnus entre eux, m_H et m_F.
Les deux moyennes d'échantillon fluctuent : l'écart entre elles fluctue donc aussi, et davantage.

Le principe

On teste l'écart, pas les moyennes

$$H_0 : m_1 = m_2 \qquad \text{c'est-à-dire} \qquad H_0 : m_1 - m_2 = 0$$

La statistique porte sur la **différence**, qui est elle-même une variable aléatoire.

L'écart-type de l'écart

Les deux groupes étant indépendants, les variances s'additionnent — c'est un résultat du cours de probabilités :

$$\sigma(\overline{X}_1 - \overline{X}_2) = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

Les variances s'additionnent, même pour une différence

Soustraire n'enlève pas de bruit

$\overline{X}_1$ peut être trop haute et $\overline{X}_2$ trop basse **en même temps** : leurs erreurs ne se compensent pas, elles s'ajoutent.

$$V(\overline{X}_1 - \overline{X}_2) = V(\overline{X}_1) + V(\overline{X}_2)$$

Le signe moins disparaît parce qu'une variance ne mesure que l'ampleur des écarts, pas leur sens.

Sur notre échantillon

Erreur-type des hommes : $2\,345/\sqrt{28} = 443$; des femmes : $2\,142/\sqrt{22} = 457$.
Erreur-type de l'écart : $\sqrt{443^2 + 457^2} = 636$, plus grande que chacune des deux.

La statistique de test

Le test de Welch

$$t = \frac{\overline{x}_1 - \overline{x}_2}{\sqrt{\dfrac{s_1^2}{n_1} + \dfrac{s_2^2}{n_2}}}$$

C'est la version qui **ne suppose pas** l'égalité des variances. C'est celle qu'appliquent R et Python par défaut.

Toujours la même architecture

L'écart observé, moins l'écart prévu par H_0 (zéro), divisé par son erreur-type : un **écart en nombre d'erreurs-types**, comme au chapitre 12.

Les degrés de liberté de Welch

La formule de Welch

Sous H_0, t suit approximativement une loi de Student à ν degrés de liberté :

$$\nu = \frac{(v_1 + v_2)^2}{v_1^2/(n_1 - 1) + v_2^2/(n_2 - 1)}, \qquad v_i = s_i^2/n_i.$$

Sur nos données

$v_H = 2\,344{,}9^2/28 = 196\,371$ et $v_F = 2\,142{,}0^2/22 = 208\,555$:

$$\nu = \frac{404\,926^2}{196\,371^2/27 + 208\,555^2/21} = 46{,}9.$$

Le logiciel s'en charge ; ν est toujours compris entre le plus petit des $n_i - 1$ et $n_1 + n_2 - 2 = 48$.

Welch ou variances égales

La version à variances égales

Si l'on suppose $\sigma_1 = \sigma_2$, on estime une variance commune

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

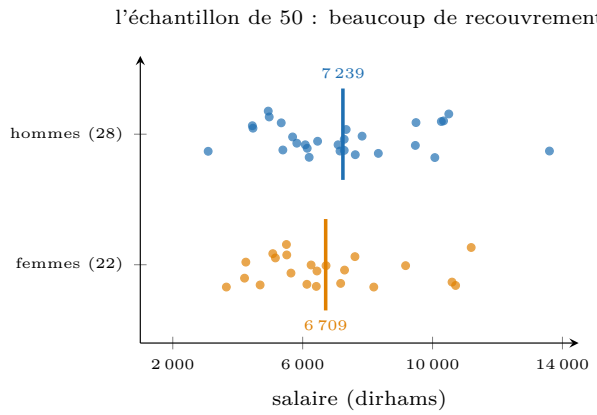
et l'on utilise $n_1 + n_2 - 2$ degrés de liberté.

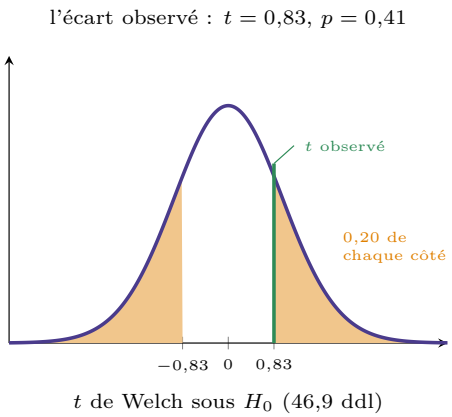
Sur nos données, les deux versions

Version	Erreur-type	t	ddl	p
Welch	636,3	0,834	46,9	0,409
variances égales	643,4	0,825	48	0,414

Elle exige une hypothèse de plus et ne gagne presque rien. **Welch d'abord, toujours.**

L'application





Le calcul complet

Hommes contre femmes, sur l'échantillon de 50

Groupe	n	Moyenne	Écart-type
Hommes	28	7 239,29	2 344,86
Femmes	22	6 708,64	2 142,01

$$t = \frac{530{,}65}{636{,}34} = 0{,}834 \qquad p_{\text{bilatéral}} = 0{,}41$$

La lecture

Un écart de 531 dirhams, soit 0,83 erreur-type : c'est tout à fait ordinaire sous H_0. Quatre échantillons sur dix donneraient un écart au moins aussi grand, dans un sens ou dans l'autre, si les moyennes étaient égales.

On ne rejette pas H_0.

L'intervalle de l'écart

Intervalle de confiance de $m_1 - m_2$

$$(\overline{x}_1 - \overline{x}_2) \pm t_{0{,}975\,;\nu} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Sur nos données

$530{,}65 \pm 2{,}012 \times 636{,}34 = [-750\,;\,1\,811]$ dirhams.

L'intervalle contient 0 : cohérent avec le non-rejet. Mais il contient aussi des écarts de 1 500 dirhams en faveur des hommes, ou de 700 en faveur des femmes.

Ce que dit la population

La vérité, que l'on connaît ici

Groupe	Effectif	Salaire moyen	Écart-type
Hommes	285	7 158,14	2 448,48
Femmes	215	7 158,42	2 795,58

L'écart réel vaut $-0{,}28$ dirham : les deux moyennes sont pratiquement égales.

Le test avait raison, l'échantillon exagérait

H_0 est vraie à quelques centimes près. Le test ne l'a pas rejetée : c'est la bonne décision. L'écart de 531 dirhams de l'échantillon était donc **entièrement** dû au hasard du tirage. Sur la population entière, il n'y a plus rien à tester : on lit directement l'écart.

Dix échantillons, aucun rejet

Le même test sur les dix échantillons systématiques

r	0	1	2	3	4	5	6	7	8	9
écart	531	−441	−19	430	−658	−530	−309	367	727	265
p	0,41	0,56	0,98	0,55	0,52	0,54	0,72	0,58	0,30	0,72

Quand H_0 est vraie

Les écarts d'échantillon vont de -658 à $+727$ dirhams, dans les deux sens, alors que l'écart réel est nul.
Aucun des dix tests ne rejette : c'est ce qu'on attend quand H_0 est vraie, où l'on ne rejette qu'une fois sur vingt.

La conclusion, et ce qu'elle ne dit pas

Ne pas rejeter n'est pas démontrer

Ici, nous savons que l'écart réel est nul. **Un analyste qui ne disposerait que de l'échantillon ne le saurait pas** : il n'a pas prouvé l'égalité, il a constaté qu'aucun écart n'est détectable.

Ce qu'il faut ajouter pour que la conclusion serve

Avec ces effectifs, l'erreur-type de l'écart vaut 636 dirhams. Le chapitre 13 l'a chiffré : puissance 0,08 pour un écart réel de 300 dirhams, 0,35 pour 1 000 ; il faut un écart de 1 783 pour le détecter huit fois sur dix.
C'est cela qu'il faut écrire dans le rapport, et non simplement « pas de différence significative ».

Comparer deux proportions

La statistique

Le test de deux proportions

$$z = \frac{f_1 - f_2}{\sqrt{\hat{p}(1-\hat{p})\left(\dfrac{1}{n_1} + \dfrac{1}{n_2}\right)}} \qquad \text{avec} \qquad \hat{p} = \frac{k_1 + k_2}{n_1 + n_2}$$

Pourquoi une proportion commune

Sous H_0, les deux groupes ont **la même** proportion. La meilleure estimation de cette valeur unique utilise donc les deux échantillons réunis.
C'est la même logique qu'au chapitre 15, où l'on employait p_0 et non f : **sous H_0, on calcule comme si H_0 était vraie.**

Un exemple de gestion

Deux agences, deux taux de conversion

Agence A : 48 ventes sur 300 visites, soit 16,0 %. Agence B : 72 ventes sur 360 visites, soit 20,0 %.

$$\hat{p} = \frac{120}{660} = 0{,}1818 \qquad z = \frac{-0{,}04}{\sqrt{0{,}1818 \times 0{,}8182 \times \left(\frac{1}{300} + \frac{1}{360}\right)}} = -1{,}33$$

$|-1{,}33| < 1{,}96$: on ne rejette pas, $p = 0{,}18$.

La décision, malgré l'absence de significativité

Quatre points d'écart de conversion représentent des sommes considérables sur l'année. Le test dit seulement qu'avec six cent soixante visites, on ne peut pas exclure le hasard. **La bonne décision n'est pas d'ignorer l'écart : c'est de prolonger l'observation** jusqu'à pouvoir trancher.

L'intervalle et la taille nécessaire

Ce que l'on sait de l'écart

Pour l'intervalle, chaque groupe garde sa propre proportion :

$$-0{,}04 \pm 1{,}96\sqrt{\frac{0{,}16 \times 0{,}84}{300} + \frac{0{,}20 \times 0{,}80}{360}} = [-0{,}099\,;\, 0{,}019].$$

L'agence B pourrait convertir jusqu'à dix points de plus que A, ou deux de moins.

Combien de visites pour trancher ?

Pour détecter un écart de quatre points avec une puissance de 80 % :

$$n = \frac{(1{,}96 + 0{,}84)^2 \times (0{,}16 \times 0{,}84 + 0{,}20 \times 0{,}80)}{0{,}04^2} \approx 1\,445 \text{ par agence.}$$

Plus de quatre fois les effectifs actuels : la question ne se tranchera pas en une semaine.

Sur nos données : les Bac+5 selon le sexe

Dans l'échantillon de 50

8 Bac+5 sur 28 hommes (28,6 %), 5 sur 22 femmes (22,7 %). Proportion commune $13/50 = 0{,}26$.
$z = 0{,}059/0{,}125 = 0{,}47$ et $p = 0{,}64$: aucun écart détectable.

La vérification

Dans la population, 20,7 % des hommes et 22,3 % des femmes sont Bac+5 : l'écart réel est minime, et va même dans l'autre sens.
Avec 28 et 22 personnes, un test de proportions ne peut déceler que des écarts **énormes**.

Les échantillons appariés

Un cas particulier fréquent

Quand les deux mesures portent sur les mêmes individus

Avant et après une formation, avant et après un changement de tarif, deux méthodes sur les mêmes clients.
On ne compare **pas** deux groupes : on calcule les n **différences individuelles**, et l'on teste si leur moyenne est nulle.

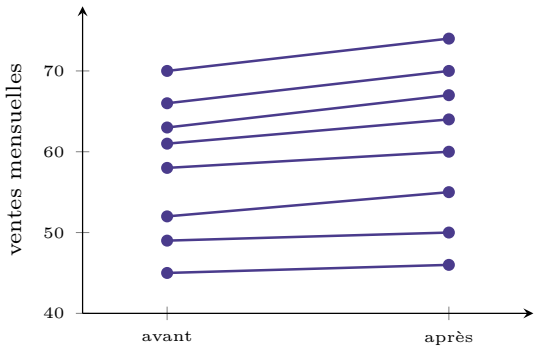
C'est le test du chapitre 15, appliqué aux écarts

$$t = \frac{\overline{d}}{s_d/\sqrt{n}} \sim \text{Student à } n-1 \text{ ddl}$$

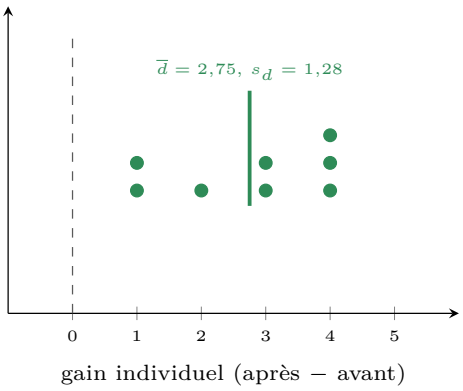
Aucune formule nouvelle : on a transformé un problème à deux échantillons en un problème à un seul.

Un exemple : la formation des commerciaux

les niveaux : très dispersés d'un vendeur à l'autre



les écarts : tous positifs, peu dispersés



Le calcul, apparié

Huit commerciaux, avant et après

Vendeur	1	2	3	4	5	6	7	8
avant	52	61	45	70	58	66	49	63
après	55	64	46	74	60	70	50	67
écart d	3	3	1	4	2	4	1	4

$\overline{d} = 2{,}75$, $s_d = 1{,}28$: $t = 2{,}75/(1{,}28/\sqrt{8}) = 6{,}07$, pour un seuil $t_{0{,}975\,;7} = 2{,}365$. **Rejet**, $p = 0{,}0005$.

Le même calcul, à tort non apparié

Si l'on traite avant et après comme deux groupes

Avant : moyenne 58,0, écart-type 8,7. Après : moyenne 60,75, écart-type 9,8.
Welch : erreur-type $\sqrt{8{,}7^2/8 + 9{,}8^2/8} = 4{,}64$, $t = 2{,}75/4{,}64 = 0{,}59$, $p = 0{,}56$. **Aucun effet détecté.**

Même écart moyen, erreur-type dix fois plus grande

Apparié, l'erreur-type vaut 0,45 ; non apparié, 4,64. L'écart moyen est le même, 2,75 ventes. Tout tient à ce que mesure le dénominateur : les écarts **entre vendeurs** (grands), ou les progrès **de chaque vendeur** (réguliers).

Pourquoi c'est bien plus puissant

La variance d'une différence corrélée

$$V(X_{\text{après}} - X_{\text{avant}}) = \sigma^2_{\text{après}} + \sigma^2_{\text{avant}} - 2\,\rho\,\sigma_{\text{après}}\,\sigma_{\text{avant}}$$

Quand les deux mesures sont fortement corrélées (ρ proche de 1), le dernier terme annule presque les deux premiers.

L'appariement élimine la variabilité individuelle

Ici $\rho = 0{,}998$: un bon vendeur reste bon après la formation. L'appariement retire ce niveau individuel et ne garde que le progrès.
C'est la faute la plus coûteuse de ce chapitre : conduire une étude avant-après, l'analyser comme deux groupes indépendants, et conclure à tort qu'il n'y a pas d'effet.

La règle de reconnaissance

Choisir le test de comparaison

Situation	Test	Statistique
groupes distincts, moyennes	Welch	$(\overline{x}_1 - \overline{x}_2)$/erreur-type
groupes distincts, proportions	z, proportion commune	$(f_1 - f_2)$/erreur-type
mêmes individus, deux mesures	Student sur les écarts	$\overline{d}/(s_d/\sqrt{n})$

La question à se poser

Si l'on peut **mettre les observations deux par deux** — même personne, même magasin, même mois —, il faut apparier.
Sinon, les groupes sont indépendants, et l'on additionne les variances.

S'entraîner

Exercice 1 : deux magasins

Le panier moyen diffère-t-il ?

Magasin A : 40 tickets, $\overline{x}_A = 245$ dirhams, $s_A = 50$. Magasin B : 50 tickets, $\overline{x}_B = 265$ dirhams, $s_B = 60$.

1. Tester au seuil de 5 % l'égalité des paniers moyens (on prendra $t_{0,975} \approx 1{,}99$ pour $\nu = 88$).
2. Calculer l'intervalle de confiance de l'écart.
3. Le directeur conclut « les deux clientèles dépensent autant ». Qu'en penser ?

Exercice 1 : solution

Welch, puis l'intervalle

1. Erreur-type $\sqrt{50^2/40 + 60^2/50} = \sqrt{62{,}5 + 72} = 11{,}60$. $t = -20/11{,}60 = -1{,}72$, $|t| < 1{,}99$: non-rejet, $p = 0{,}088$.
2. $-20 \pm 1{,}99 \times 11{,}60 = [-43\,;\,3]$ dirhams.
3. Conclusion abusive : l'intervalle va jusqu'à 43 dirhams d'écart en faveur de B. Les données ne permettent ni d'affirmer un écart, ni de l'exclure.

Exercice 2 : deux méthodes de scoring

Le nouveau score réduit-il les impayés ?

Sur 500 crédits accordés avec l'ancien score, 45 impayés (9 %). Sur 500 crédits accordés avec le nouveau, 28 impayés (5,6 %).

1. Écrire les hypothèses.
2. Calculer la statistique de test et conclure au seuil de 5 %.

Exercice 2 : solution

Proportion commune sous H_0

1. $H_0 : p_{\text{ancien}} = p_{\text{nouveau}}$ contre $H_1 : p_{\text{ancien}} > p_{\text{nouveau}}$ (unilatéral : on cherche une baisse).
2. $\hat{p} = 73/1\,000 = 0{,}073$. Erreur-type $\sqrt{0{,}073 \times 0{,}927 \times 2/500} = 0{,}0165$. $z = 0{,}034/0{,}0165 = 2{,}07 > 1{,}645$: **rejet**, $p = 0{,}019$.

Le nouveau score réduit significativement le taux d'impayés.

Exercice 3 : apparier ou non

Six agences, avant et après une campagne

Chiffre d'affaires hebdomadaire (en milliers de dirhams) de six agences :

Agence	1	2	3	4	5	6
avant	12	15	9	14	11	13
après	13	17	10	15	13	14

1. Faire le test apparié au seuil de 5 % ($t_{0{,}975\,;5} = 2{,}571$).
2. Le test de Welch donnerait $t = 1{,}03$. Expliquer la différence.

Exercice 3 : solution

Le progrès de chaque agence

1. Écarts : $1, 2, 1, 1, 2, 1$. $\overline{d} = 1{,}33$, $s_d = 0{,}516$, $t = 1{,}33/(0{,}516/\sqrt{6}) = 6{,}32 > 2{,}571$: **rejet**, $p = 0{,}001$.
2. Les agences diffèrent beaucoup entre elles (de 9 à 15), mais chacune progresse de 1 ou 2. Welch mesure les écarts entre agences et noie l'effet ; l'appariement mesure le progrès de chacune.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. On teste la **différence** : $H_0 : m_1 - m_2 = 0$. Les variances s'additionnent : $\sqrt{s_1^2/n_1 + s_2^2/n_2}$.
2. Utiliser **Welch** par défaut : il ne suppose pas l'égalité des variances, et ne coûte presque rien.
3. Sur l'échantillon, $t = 0{,}83$, $p = 0{,}41$; l'intervalle $[-750\,;\,1\,811]$ montre ce que le test ne dit pas.
4. Dans la population, l'écart vaut $-0{,}28$ dirham : le non-rejet était juste, mais l'échantillon ne permettait pas de le savoir.
5. Deux proportions : on estime une proportion **commune** sous H_0.
6. Si les observations vont **deux par deux**, il faut apparier : le gain de puissance est considérable.

La suite

Trois groupes ou davantage

Comparer les trois niveaux de diplôme deux à deux ferait trois tests, donc un risque réel de fausse découverte bien supérieur à 5 % (chapitre 14).

Le prochain chapitre

Le chapitre 17 introduit l'outil conçu pour cela, l'analyse de la variance — et l'on y retrouvera la décomposition de la variance du cours de statistique descriptive.