# Statistique inférentielle

Chapitre 16 : Comparer deux groupes

Jaouad Madkour

31 octobre 2026

## Plan du chapitre

**Comparer deux moyennes** **2**
- La question . . . 2
- Le principe . . . 2
- Les variances s'additionnent, même pour une différence . . . 2
- La statistique de test . . . 3
- Les degrés de liberté de Welch . . . 4
- Welch ou variances égales . . . 5
- L'application . . . 5
- Le calcul complet . . . 6
- L'intervalle de l'écart . . . 6
- Ce que dit la population . . . 6
- Dix échantillons, aucun rejet . . . 7
- La conclusion, et ce qu'elle ne dit pas . . . 7

**Comparer deux proportions** **7**
- La statistique . . . 7
- Un exemple de gestion . . . 8
- L'intervalle et la taille nécessaire . . . 8
- Sur nos données : les Bac+5 selon le sexe . . . 9

**Les échantillons appariés** **9**
- Un cas particulier fréquent . . . 9
- Un exemple : la formation des commerciaux . . . 10
- Le calcul, apparié . . . 10
- Le même calcul, à tort non apparié . . . 10
- Pourquoi c'est bien plus puissant . . . 11
- La règle de reconnaissance . . . 12

**S'entraîner** **12**
- Exercice 1 : deux magasins . . . 12
- Exercice 1 : solution . . . 12
- Exercice 2 : deux méthodes de scoring . . . 12
- Exercice 2 : solution . . . 13

Exercice 3 : apparier ou non . . . . . 13
Exercice 3 : solution . . . . . 13

**Ce qu'il faut retenir** **13**
Le résumé du chapitre . . . . . 13
La suite . . . . . 14

# Comparer deux moyennes

## La question

**Les hommes sont-ils mieux payés que les femmes ?**

Dans l'échantillon de 50 salariés : 28 hommes, payés en moyenne 7 239 dirhams, et 22 femmes, payées 6 709 dirhams.
L'écart observé vaut 531 dirhams. Est-il le signe d'un écart réel dans l'entreprise, ou un simple effet du tirage ?

**Une question nouvelle**

Au chapitre 15, on comparait **un** paramètre à une valeur fixée. Ici, on compare **deux** paramètres inconnus entre eux, $m_H$ et $m_F$.
Les deux moyennes d'échantillon fluctuent : l'écart entre elles fluctue donc aussi, et davantage.

## Le principe

**On teste l'écart, pas les moyennes**

$$H_0 : m_1 = m_2 \qquad \text{c'est-à-dire} \qquad H_0 : m_1 - m_2 = 0$$

La statistique porte sur la **différence**, qui est elle-même une variable aléatoire.

**L'écart-type de l'écart**

Les deux groupes étant indépendants, les variances s'additionnent — c'est un résultat du cours de probabilités :

$$\sigma(\overline{X}_1 - \overline{X}_2) = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

## Les variances s'additionnent, même pour une différence

**Soustraire n'enlève pas de bruit**

$\overline{X}_1$ peut être trop haute et $\overline{X}_2$ trop basse **en même temps** : leurs erreurs ne se compensent pas, elles s'ajoutent.

$$V(\overline{X}_1 - \overline{X}_2) = V(\overline{X}_1) + V(\overline{X}_2)$$

Le signe moins disparaît parce qu'une variance ne mesure que l'ampleur des écarts, pas leur sens.

**Sur notre échantillon**

Erreur-type des hommes : $2\,345/\sqrt{28} = 443$ ; des femmes : $2\,142/\sqrt{22} = 457$.
Erreur-type de l'écart : $\sqrt{443^2 + 457^2} = 636$, plus grande que chacune des deux.

**Démonstration : La variance d'une différence est la somme des variances**

Soient $A$ et $B$ deux variables de moyennes $a$ et $b$. En développant le carré,

$$V(A-B) = E\big[((A-a)-(B-b))^2\big] = V(A) + V(B) - 2\,\mathrm{Cov}(A,B).$$

Si $A$ et $B$ sont indépendantes, $\mathrm{Cov}(A,B) = 0$ et il reste $V(A-B) = V(A) + V(B)$. Avec $A = \overline{X}_1$ et $B = \overline{X}_2$ (deux groupes tirés indépendamment), $V(\overline{X}_i) = \sigma_i^2/n_i$ : on retrouve l'écart-type de l'écart du cours.

*Le signe disparaît.* Le carré de $(A-a)-(B-b)$ contient $(A-a)^2$ et $(B-b)^2$ avec le signe $+$ : c'est le seul terme croisé, nul en moyenne, qui pourrait dépendre du signe moins.

*Nos données.* $443{,}14^2 + 456{,}68^2 = 404\,926$, donc $\sqrt{404\,926} = 636{,}34$ : plus grand que 456,68, le plus grand des deux termes. Avec deux groupes de même effectif et de même variance, l'erreur-type de l'écart vaut $\sqrt{2}\,\sigma/\sqrt{n}$, soit 1,41 fois celle d'une seule moyenne.

**Ce que cela dit.** Comparer deux moyennes coûte de la précision : l'écart entre elles est plus incertain que chacune. C'est pourquoi un écart doit être jugé contre 636 dirhams et non contre 443 ou 457.

■

## La statistique de test

**Le test de Welch**

$$t = \frac{\overline{x}_1 - \overline{x}_2}{\sqrt{\dfrac{s_1^2}{n_1} + \dfrac{s_2^2}{n_2}}}$$

C'est la version qui **ne suppose pas** l'égalité des variances. C'est celle qu'appliquent R et Python par défaut.

**Toujours la même architecture**

L'écart observé, moins l'écart prévu par $H_0$ (zéro), divisé par son erreur-type : un **écart en nombre d'erreurs-types**, comme au chapitre 12.

## Les degrés de liberté de Welch

### La formule de Welch

Sous $H_0$, $t$ suit approximativement une loi de Student à $\nu$ degrés de liberté :

$$\nu = \frac{(v_1 + v_2)^2}{v_1^2/(n_1 - 1) + v_2^2/(n_2 - 1)}, \qquad v_i = s_i^2/n_i.$$

### Sur nos données

$v_H = 2\,344{,}9^2/28 = 196\,371$ et $v_F = 2\,142{,}0^2/22 = 208\,555$ :

$$\nu = \frac{404\,926^2}{196\,371^2/27 + 208\,555^2/21} = 46{,}9.$$

Le logiciel s'en charge ; $\nu$ est toujours compris entre le plus petit des $n_i - 1$ et $n_1 + n_2 - 2 = 48$.

### Démonstration : D'où vient la formule de Welch, et pourquoi elle reste entre deux bornes

*L'idée.* Sous l'hypothèse nulle, $t = (\overline{x}_1 - \overline{x}_2)/\sqrt{\widehat{V}}$ avec $\widehat{V} = \widehat{V}_1 + \widehat{V}_2$ et $\widehat{V}_i = s_i^2/n_i$. Le numérateur est normal. Si $\widehat{V}$ était de la forme $V\,\chi^2_\nu/\nu$ (un khi-deux mis à l'échelle), $t$ suivrait exactement une loi de Student à $\nu$ degrés de liberté. Ce n'est pas le cas : $\widehat{V}$ est une somme de deux khi-deux d'échelles différentes. Welch choisit le $\nu$ qui donne à $\widehat{V}$ la même espérance et la même variance que ce khi-deux.

*Le calcul.* Pour des données normales, $(n_i - 1)s_i^2/\sigma_i^2 \sim \chi^2_{n_i - 1}$, de variance $2(n_i - 1)$. Avec $V_i = \sigma_i^2/n_i$ (valeurs vraies) :

$$E(\widehat{V}_i) = V_i, \qquad V(\widehat{V}_i) = \frac{\sigma_i^4}{n_i^2} \cdot \frac{2}{n_i - 1} = \frac{2V_i^2}{n_i - 1}.$$

Les groupes étant indépendants, $E(\widehat{V}) = V_1 + V_2$ et $V(\widehat{V}) = 2\sum_i V_i^2/(n_i - 1)$. Un $V\chi^2_\nu/\nu$ a pour espérance $V$ et pour variance $2V^2/\nu$. Égaler les variances donne

$$\frac{2(V_1 + V_2)^2}{\nu} = 2\sum_i \frac{V_i^2}{n_i - 1} \quad \Longleftrightarrow \quad \nu = \frac{(V_1 + V_2)^2}{\dfrac{V_1^2}{n_1 - 1} + \dfrac{V_2^2}{n_2 - 1}},$$

et l'on remplace $V_i$ par $v_i = s_i^2/n_i$ : c'est la formule du cours.

*Les bornes.* Notons $a = n_1 - 1$, $b = n_2 - 1$ et $m = \min(a, b)$. Par l'inégalité de Cauchy-Schwarz,

$$(v_1 + v_2)^2 = \left(\sqrt{a}\,\frac{v_1}{\sqrt{a}} + \sqrt{b}\,\frac{v_2}{\sqrt{b}}\right)^2 \le (a + b)\left(\frac{v_1^2}{a} + \frac{v_2^2}{b}\right),$$

donc $\nu \le a + b = n_1 + n_2 - 2$. Dans l'autre sens, $\dfrac{v_1^2}{a} + \dfrac{v_2^2}{b} \le \dfrac{v_1^2 + v_2^2}{m} \le \dfrac{(v_1 + v_2)^2}{m}$, donc $\nu \ge m$.

*Nos données.* $v_H = 196\,371$ et $v_F = 208\,555$ donnent $\nu = 46{,}86$, bien entre 21 et 48.

*Pourquoi Welch d'abord.* Le test à variances égales n'est exact que si $\sigma_1 = \sigma_2$. Quand ce n'est pas le cas et que les effectifs diffèrent, son niveau réel s'écarte beaucoup de 5 %. Simulation

de 20 000 tirages normaux : avec $n_1 = 8$, $\sigma_1 = 3$ et $n_2 = 32$, $\sigma_2 = 1$, le test à variances égales rejette à tort dans 25,8 % des cas, Welch dans 5,2 % ; avec $n_1 = 32$, $\sigma_1 = 3$ et $n_2 = 8$, $\sigma_2 = 1$, le premier ne rejette presque jamais (0,2 %), Welch dans 4,7 %.

**Ce que cela dit.** Les degrés de liberté de Welch ne sont pas une recette : ils ajustent la loi de référence à la variabilité de l'estimation de la variance, et la formule se ramène à $n_1 + n_2 - 2$ quand les deux groupes sont comparables. Sur nos données, Welch et la version à variances égales concluent de même ; l'écart se verrait avec des effectifs et des dispersions inégaux.

■

## Welch ou variances égales

### La version à variances égales

Si l'on suppose $\sigma_1 = \sigma_2$, on estime une variance commune

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

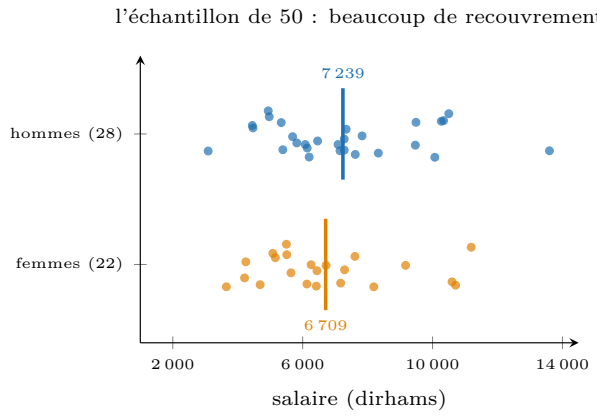
et l'on utilise $n_1 + n_2 - 2$ degrés de liberté.

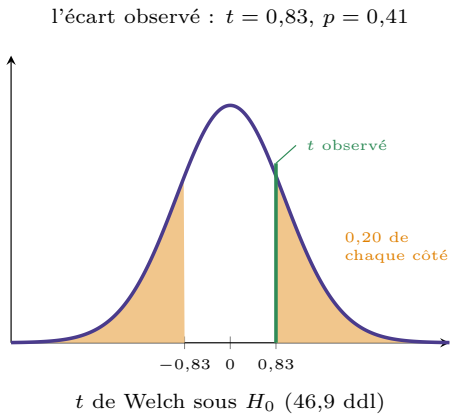
### Sur nos données, les deux versions

| Version | Erreur-type | $t$ | ddl | $p$ |
|---|---|---|---|---|
| Welch | 636,3 | 0,834 | 46,9 | 0,409 |
| variances égales | 643,4 | 0,825 | 48 | 0,414 |

Elle exige une hypothèse de plus et ne gagne presque rien. **Welch d'abord, toujours.**

## L'application



### Le calcul complet

**Hommes contre femmes, sur l'échantillon de 50**

| Groupe | $n$ | Moyenne | Écart-type |
|---|---|---|---|
| Hommes | 28 | 7 239,29 | 2 344,86 |
| Femmes | 22 | 6 708,64 | 2 142,01 |

$$t = \frac{530{,}65}{636{,}34} = 0{,}834 \qquad p_{\text{bilatéral}} = 0{,}41$$

**La lecture**

Un écart de 531 dirhams, soit 0,83 erreur-type : c'est tout à fait ordinaire sous $H_0$. Quatre échantillons sur dix donneraient un écart au moins aussi grand, dans un sens ou dans l'autre, si les moyennes étaient égales.
**On ne rejette pas $H_0$.**

### L'intervalle de l'écart

**Intervalle de confiance de $m_1 - m_2$**

$$(\overline{x}_1 - \overline{x}_2) \pm t_{0{,}975\,;\nu} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

**Sur nos données**

$530{,}65 \pm 2{,}012 \times 636{,}34 = [-750\,;\ 1\,811]$ dirhams.
L'intervalle contient 0 : cohérent avec le non-rejet. Mais il contient aussi des écarts de 1 500 dirhams en faveur des hommes, ou de 700 en faveur des femmes.

### Ce que dit la population

**La vérité, que l'on connaît ici**

| Groupe | Effectif | Salaire moyen | Écart-type |
|---|---|---|---|
| Hommes | 285 | 7 158,14 | 2 448,48 |
| Femmes | 215 | 7 158,42 | 2 795,58 |

L'écart réel vaut $-0{,}28$ dirham : les deux moyennes sont pratiquement égales.

**Le test avait raison, l'échantillon exagérait**

$H_0$ est vraie à quelques centimes près. Le test ne l'a pas rejetée : c'est la bonne décision. L'écart de 531 dirhams de l'échantillon était donc **entièrement** dû au hasard du tirage. Sur la population entière, il n'y a plus rien à tester : on lit directement l'écart.

### Dix échantillons, aucun rejet

**Le même test sur les dix échantillons systématiques**

| $r$ | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 |
|---|---|---|---|---|---|---|---|---|---|---|
| écart | 531 | −441 | −19 | 430 | −658 | −530 | −309 | 367 | 727 | 265 |
| $p$ | 0,41 | 0,56 | 0,98 | 0,55 | 0,52 | 0,54 | 0,72 | 0,58 | 0,30 | 0,72 |

**Quand $H_0$ est vraie**

Les écarts d'échantillon vont de −658 à +727 dirhams, dans les deux sens, alors que l'écart réel est nul.
Aucun des dix tests ne rejette : c'est ce qu'on attend quand $H_0$ est vraie, où l'on ne rejette qu'une fois sur vingt.

### La conclusion, et ce qu'elle ne dit pas

**Ne pas rejeter n'est pas démontrer**

Ici, nous savons que l'écart réel est nul. **Un analyste qui ne disposerait que de l'échantillon ne le saurait pas** : il n'a pas prouvé l'égalité, il a constaté qu'aucun écart n'est détectable.

**Ce qu'il faut ajouter pour que la conclusion serve**

Avec ces effectifs, l'erreur-type de l'écart vaut 636 dirhams. Le chapitre 13 l'a chiffré : puissance 0,08 pour un écart réel de 300 dirhams, 0,35 pour 1 000 ; il faut un écart de 1 783 pour le détecter huit fois sur dix.
**C'est cela qu'il faut écrire dans le rapport**, et non simplement « pas de différence significative ».

## Comparer deux proportions

### La statistique

**Le test de deux proportions**

$$z = \frac{f_1 - f_2}{\sqrt{\hat{p}(1-\hat{p})\left(\dfrac{1}{n_1} + \dfrac{1}{n_2}\right)}} \qquad \text{avec} \qquad \hat{p} = \frac{k_1 + k_2}{n_1 + n_2}$$

**Pourquoi une proportion commune**

Sous $H_0$, les deux groupes ont **la même** proportion. La meilleure estimation de cette valeur unique utilise donc les deux échantillons réunis.
C'est la même logique qu'au chapitre 15, où l'on employait $p_0$ et non $f$ : **sous $H_0$, on calcule comme si $H_0$ était vraie.**

## Un exemple de gestion

### Deux agences, deux taux de conversion

Agence A : 48 ventes sur 300 visites, soit 16,0 %. Agence B : 72 ventes sur 360 visites, soit 20,0 %.

$$\hat{p} = \frac{120}{660} = 0{,}1818 \qquad z = \frac{-0{,}04}{\sqrt{0{,}1818 \times 0{,}8182 \times \left(\frac{1}{300} + \frac{1}{360}\right)}} = -1{,}33$$

$|-1{,}33| < 1{,}96$ : on ne rejette pas, $p = 0{,}18$.

### La décision, malgré l'absence de significativité

Quatre points d'écart de conversion représentent des sommes considérables sur l'année. Le test dit seulement qu'avec six cent soixante visites, on ne peut pas exclure le hasard. **La bonne décision n'est pas d'ignorer l'écart : c'est de prolonger l'observation** jusqu'à pouvoir trancher.

## L'intervalle et la taille nécessaire

### Ce que l'on sait de l'écart

Pour l'intervalle, chaque groupe garde sa propre proportion :

$$-0{,}04 \pm 1{,}96\sqrt{\frac{0{,}16 \times 0{,}84}{300} + \frac{0{,}20 \times 0{,}80}{360}} = [-0{,}099\,;\, 0{,}019].$$

L'agence B pourrait convertir jusqu'à dix points de plus que A, ou deux de moins.

### Combien de visites pour trancher ?

Pour détecter un écart de quatre points avec une puissance de 80 % :

$$n = \frac{(1{,}96 + 0{,}84)^2 \times (0{,}16 \times 0{,}84 + 0{,}20 \times 0{,}80)}{0{,}04^2} \approx 1\,445 \text{ par agence.}$$

Plus de quatre fois les effectifs actuels : la question ne se tranchera pas en une semaine.

### Démonstration : Deux proportions, la proportion commune et la taille nécessaire

*La proportion commune.* Sous l'hypothèse nulle, les deux groupes ont la même proportion $p$ : $E(f_1 - f_2) = 0$ et, les groupes étant indépendants, $V(f_1 - f_2) = p(1-p)(\frac{1}{n_1} + \frac{1}{n_2})$. Il reste à estimer $p$. Les $k_1 + k_2$ succès viennent des $n_1 + n_2$ essais d'une même loi ; l'estimation naturelle est la fréquence globale, qui est aussi la moyenne des deux fréquences pondérée par les effectifs :

$$\hat{p} = \frac{k_1 + k_2}{n_1 + n_2} = \frac{n_1 f_1 + n_2 f_2}{n_1 + n_2}.$$

Pour les agences, $\hat{p} = 120/660 = 0{,}1818$, l'erreur-type vaut 0,03015 et $z = -0{,}04/0{,}03015 = -1{,}327$, soit $p = 0{,}185$. Pour l'intervalle, aucune égalité n'est supposée : chaque groupe garde

sa fréquence et l'erreur-type est 0,02987.

*La taille nécessaire.* On veut rejeter avec la probabilité $1-\beta$ quand l'écart vrai est $\delta = p_2 - p_1$. Avec $n$ observations par groupe, $f_2 - f_1$ est à peu près normale, d'espérance $\delta$ et d'écart-type $\sqrt{(p_1 q_1 + p_2 q_2)/n}$, où $q = 1 - p$. On rejette quand $f_2 - f_1$ dépasse $z_{1-\alpha/2}$ écarts-types (en négligeant l'autre queue et l'écart entre les deux écarts-types, sous $H_0$ et sous $H_1$). Cela arrive avec la probabilité $1 - \beta$ quand $\delta$ dépasse ce seuil de $z_{1-\beta}$ écarts-types, c'est-à-dire

$$\delta = (z_{1-\alpha/2} + z_{1-\beta})\sqrt{\frac{p_1 q_1 + p_2 q_2}{n}} \quad \Longleftrightarrow \quad n = \frac{(z_{1-\alpha/2} + z_{1-\beta})^2 \, (p_1 q_1 + p_2 q_2)}{\delta^2}.$$

Avec $z_{0,975} = 1{,}95996$ et $z_{0,80} = 0{,}84162$ : $n = 7{,}849 \times 0{,}2944/0{,}0016 = 1\,444{,}2$, soit 1 445 par agence. Les valeurs arrondies 1,96 et 0,84 donneraient 1 442,6, soit 1 443.

**Ce que cela dit.** La taille croît comme $1/\delta^2$ : détecter un écart deux fois plus petit (deux points au lieu de quatre) exige quatre fois plus de visites : pour 16 % contre 18 %, le même calcul donne environ 5 500 par agence. Voilà pourquoi une différence d'un ou deux points de conversion ne se tranche presque jamais sur une semaine d'observation.

■

### Sur nos données : les Bac+5 selon le sexe

**Dans l'échantillon de 50**

8 Bac+5 sur 28 hommes (28,6 %), 5 sur 22 femmes (22,7 %). Proportion commune $13/50 = 0{,}26$.
$z = 0{,}059/0{,}125 = 0{,}47$ et $p = 0{,}64$ : aucun écart détectable.

**La vérification**

Dans la population, 20,7 % des hommes et 22,3 % des femmes sont Bac+5 : l'écart réel est minime, et va même dans l'autre sens.
Avec 28 et 22 personnes, un test de proportions ne peut déceler que des écarts **énormes**.

## Les échantillons appariés

### Un cas particulier fréquent

**Quand les deux mesures portent sur les mêmes individus**

Avant et après une formation, avant et après un changement de tarif, deux méthodes sur les mêmes clients.
On ne compare **pas** deux groupes : on calcule les $n$ **différences individuelles**, et l'on teste si leur moyenne est nulle.

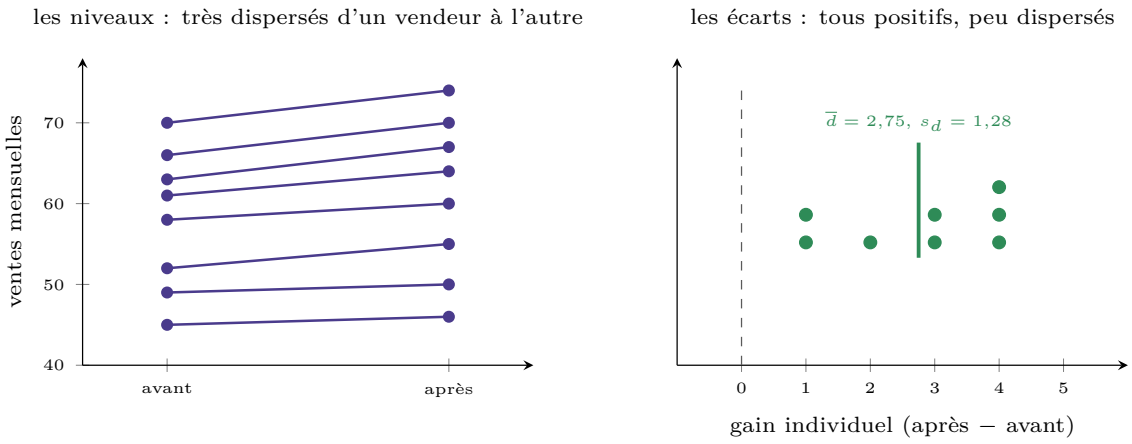
**C'est le test du chapitre 15, appliqué aux écarts**

$$t = \frac{\overline{d}}{s_d/\sqrt{n}} \;\sim\; \text{Student à } n-1 \text{ ddl}$$

Aucune formule nouvelle : on a transformé un problème à deux échantillons en un problème

à un seul.

### Un exemple : la formation des commerciaux




### Le calcul, apparié

**Huit commerciaux, avant et après**

| Vendeur | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 |
|---|---|---|---|---|---|---|---|---|
| avant | 52 | 61 | 45 | 70 | 58 | 66 | 49 | 63 |
| après | 55 | 64 | 46 | 74 | 60 | 70 | 50 | 67 |
| écart $d$ | 3 | 3 | 1 | 4 | 2 | 4 | 1 | 4 |

$\overline{d} = 2{,}75$, $s_d = 1{,}28$ : $t = 2{,}75/(1{,}28/\sqrt{8}) = 6{,}07$, pour un seuil $t_{0{,}975\,;7} = 2{,}365$. **Rejet**, $p = 0{,}0005$.

### Le même calcul, à tort non apparié

**Si l'on traite avant et après comme deux groupes**

Avant : moyenne 58,0, écart-type 8,7. Après : moyenne 60,75, écart-type 9,8.
Welch : erreur-type $\sqrt{8{,}7^2/8 + 9{,}8^2/8} = 4{,}64$, $t = 2{,}75/4{,}64 = 0{,}59$, $p = 0{,}56$. **Aucun effet détecté.**

**Même écart moyen, erreur-type dix fois plus grande**

Apparié, l'erreur-type vaut 0,45 ; non apparié, 4,64. L'écart moyen est le même, 2,75 ventes. Tout tient à ce que mesure le dénominateur : les écarts **entre vendeurs** (grands), ou les progrès **de chaque vendeur** (réguliers).

### Pourquoi c'est bien plus puissant

**La variance d'une différence corrélée**

$$V(X_{\text{après}} - X_{\text{avant}}) = \sigma^2_{\text{après}} + \sigma^2_{\text{avant}} - 2\,\rho\,\sigma_{\text{après}}\,\sigma_{\text{avant}}$$

Quand les deux mesures sont fortement corrélées ($\rho$ proche de 1), le dernier terme annule presque les deux premiers.

**L'appariement élimine la variabilité individuelle**

Ici $\rho = 0{,}998$ : un bon vendeur reste bon après la formation. L'appariement retire ce niveau individuel et ne garde que le progrès.
**C'est la faute la plus coûteuse de ce chapitre** : conduire une étude avant-après, l'analyser comme deux groupes indépendants, et conclure à tort qu'il n'y a pas d'effet.

**Démonstration : Pourquoi l'appariement réduit l'erreur-type**

Pour des mesures $x_i$ (avant) et $y_i$ (après) sur les mêmes individus, la différence $d_i = y_i - x_i$ a pour moyenne $\overline{d} = \overline{y} - \overline{x}$. En développant $\sum (d_i - \overline{d})^2 = \sum \big((y_i - \overline{y}) - (x_i - \overline{x})\big)^2$ :

$$s_d^2 = s_x^2 + s_y^2 - 2\,r\,s_x s_y, \qquad r = \frac{\sum (x_i - \overline{x})(y_i - \overline{y})}{(n-1)\,s_x s_y}.$$

C'est la formule $V(A-B) = V(A) + V(B) - 2\,\mathrm{Cov}(A,B)$, appliquée aux données. L'erreur-type du test apparié est $s_d/\sqrt{n}$ ; celle du test non apparié est $\sqrt{(s_x^2 + s_y^2)/n}$. Leur rapport est

$$\frac{\text{non apparié}}{\text{apparié}} = \sqrt{\frac{s_x^2 + s_y^2}{s_x^2 + s_y^2 - 2\,r\,s_x s_y}},$$

égal à 1 si $r = 0$, supérieur à 1 dès que $r > 0$, et d'autant plus grand que $r$ est proche de 1 ; inférieur à 1 si $r < 0$, où l'appariement ferait perdre de la précision.

*Nos données.* $s_x = 8{,}685$, $s_y = 9{,}838$ et $r = 0{,}9982$ :

$$s_d^2 = 75{,}43 + 96{,}79 - 2 \times 0{,}9982 \times 8{,}685 \times 9{,}838 = 1{,}643, \qquad s_d = 1{,}282.$$

Erreur-type apparié : $1{,}282/\sqrt{8} = 0{,}453$. Non apparié : $\sqrt{(75{,}43 + 96{,}79)/8} = 4{,}640$. Le rapport vaut 10,2. L'appariement coûte des degrés de liberté (7 au lieu d'environ 14) et relève donc le seuil de Student de 2,15 à 2,365, soit 10 % : cette perte est négligeable devant le facteur 10 gagné sur l'erreur-type.

**Ce que cela dit.** Le gain de l'appariement est exactement la corrélation entre les deux mesures. Quand un bon vendeur reste bon, $r \approx 1$ et presque toute la variabilité entre vendeurs disparaît de la différence. C'est ce que le test non apparié ne sait pas faire, et ce qui le rend aveugle à un progrès pourtant régulier.

■

### La règle de reconnaissance

**Choisir le test de comparaison**

| Situation | Test | Statistique |
|---|---|---|
| groupes distincts, moyennes | Welch | $(\overline{x}_1 - \overline{x}_2)$/erreur-type |
| groupes distincts, proportions | $z$, proportion commune | $(f_1 - f_2)$/erreur-type |
| mêmes individus, deux mesures | Student sur les écarts | $\overline{d}/(s_d/\sqrt{n})$ |

**La question à se poser**

Si l'on peut **mettre les observations deux par deux** — même personne, même magasin, même mois —, il faut apparier.
Sinon, les groupes sont indépendants, et l'on additionne les variances.

## S'entraîner

### Exercice 1 : deux magasins

**Le panier moyen diffère-t-il ?**

Magasin A : 40 tickets, $\overline{x}_A = 245$ dirhams, $s_A = 50$. Magasin B : 50 tickets, $\overline{x}_B = 265$ dirhams, $s_B = 60$.

1. Tester au seuil de 5 % l'égalité des paniers moyens (on prendra $t_{0,975} \approx 1{,}99$ pour $\nu = 88$).
2. Calculer l'intervalle de confiance de l'écart.
3. Le directeur conclut « les deux clientèles dépensent autant ». Qu'en penser ?

### Exercice 1 : solution

**Welch, puis l'intervalle**

1. Erreur-type $\sqrt{50^2/40 + 60^2/50} = \sqrt{62{,}5 + 72} = 11{,}60$. $t = -20/11{,}60 = -1{,}72$, $|t| < 1{,}99$ : non-rejet, $p = 0{,}088$.
2. $-20 \pm 1{,}99 \times 11{,}60 = [-43\,;\,3]$ dirhams.
3. Conclusion abusive : l'intervalle va jusqu'à 43 dirhams d'écart en faveur de B. Les données ne permettent ni d'affirmer un écart, ni de l'exclure.

### Exercice 2 : deux méthodes de scoring

**Le nouveau score réduit-il les impayés ?**

Sur 500 crédits accordés avec l'ancien score, 45 impayés (9 %). Sur 500 crédits accordés avec le nouveau, 28 impayés (5,6 %).

1. Écrire les hypothèses.
2. Calculer la statistique de test et conclure au seuil de 5 %.

### Exercice 2 : solution

**Proportion commune sous $H_0$**

1. $H_0 : p_{\text{ancien}} = p_{\text{nouveau}}$ contre $H_1 : p_{\text{ancien}} > p_{\text{nouveau}}$ (unilatéral : on cherche une baisse).
2. $\hat{p} = 73/1\,000 = 0{,}073$. Erreur-type $\sqrt{0{,}073 \times 0{,}927 \times 2/500} = 0{,}0165$. $z = 0{,}034/0{,}0165 = 2{,}07 > 1{,}645$ : **rejet**, $p = 0{,}019$.

Le nouveau score réduit significativement le taux d'impayés.

### Exercice 3 : apparier ou non

**Six agences, avant et après une campagne**

Chiffre d'affaires hebdomadaire (en milliers de dirhams) de six agences :

| Agence | 1 | 2 | 3 | 4 | 5 | 6 |
|---|---|---|---|---|---|---|
| avant | 12 | 15 | 9 | 14 | 11 | 13 |
| après | 13 | 17 | 10 | 15 | 13 | 14 |

1. Faire le test apparié au seuil de 5 % ($t_{0{,}975\,;5} = 2{,}571$).
2. Le test de Welch donnerait $t = 1{,}03$. Expliquer la différence.

### Exercice 3 : solution

**Le progrès de chaque agence**

1. Écarts : $1, 2, 1, 1, 2, 1$. $\overline{d} = 1{,}33$, $s_d = 0{,}516$, $t = 1{,}33/(0{,}516/\sqrt{6}) = 6{,}32 > 2{,}571$ : **rejet**, $p = 0{,}001$.
2. Les agences diffèrent beaucoup entre elles (de 9 à 15), mais chacune progresse de 1 ou 2. Welch mesure les écarts entre agences et noie l'effet ; l'appariement mesure le progrès de chacune.

## Ce qu'il faut retenir

### Le résumé du chapitre

**Six points**

1. On teste la **différence** : $H_0 : m_1 - m_2 = 0$. Les variances s'additionnent : $\sqrt{s_1^2/n_1 + s_2^2/n_2}$.
2. Utiliser **Welch** par défaut : il ne suppose pas l'égalité des variances, et ne coûte presque rien.
3. Sur l'échantillon, $t = 0{,}83$, $p = 0{,}41$ ; l'intervalle $[-750\,;\,1\,811]$ montre ce que le test ne dit pas.
4. Dans la population, l'écart vaut $-0{,}28$ dirham : le non-rejet était juste, mais l'échantillon ne permettait pas de le savoir.
5. Deux proportions : on estime une proportion **commune** sous $H_0$.
6. Si les observations vont **deux par deux**, il faut apparier : le gain de puissance est considérable.

### La suite

**Trois groupes ou davantage**

Comparer les trois niveaux de diplôme deux à deux ferait trois tests, donc un risque réel de fausse découverte bien supérieur à 5 % (chapitre 14).

**Le prochain chapitre**

Le chapitre 17 introduit l'outil conçu pour cela, l'analyse de la variance — et l'on y retrouvera la décomposition de la variance du cours de statistique descriptive.