Statistique inférentielle

Chapitre 7 : Construire un estimateur

Jaouad Madkour

31 octobre 2026

Plan du chapitre

Deux méthodes **2**
Pourquoi il faut une méthode . . . 2
Le cadre commun . . . 2

La méthode des moments **2**
Le principe . . . 2
Un exemple complet : les pannes d'une machine . . . 3
Deux paramètres, deux équations . . . 3
Ses mérites et ses limites . . . 3

Le maximum de vraisemblance **4**
Retourner la question des probabilités . . . 4
La définition . . . 4
La technique de calcul . . . 4
La même courbe que dans l'introduction . . . 5
Le cas général de Bernoulli . . . 5
L'exponentielle, par la vraisemblance . . . 5
La loi normale, par la vraisemblance . . . 6
L'uniforme : là où les deux méthodes divergent . . . 7
Ce que montre la courbe . . . 7
Les deux méthodes, simulées . . . 7

Les propriétés du maximum de vraisemblance **8**
Pourquoi il domine . . . 8
L'invariance, au travail . . . 9
Ses limites . . . 9
Postuler une loi : ce que cela coûte . . . 10
Une loi normale pour nos salaires ? . . . 10

S'entraîner **11**
Exercice 1 : les réclamations quotidiennes . . . 11
Exercice 1 : solution . . . 11
Exercice 2 : la durée des appels . . . 11

Exercice 2 : solution 11
Exercice 3 : le taux d'attrition 12
Exercice 3 : solution 12

Ce qu'il faut retenir **12**
Le résumé du chapitre 12
La suite 12

Deux méthodes

Pourquoi il faut une méthode

L'évidence s'arrête vite

Pour estimer une moyenne, on prend la moyenne : personne n'hésite.
Mais pour estimer le paramètre λ d'une loi exponentielle, la borne supérieure d'une loi uniforme, ou la probabilité de défaut d'un portefeuille observé partiellement ? L'intuition ne suffit plus.

Les deux méthodes du cours

La **méthode des moments** : on égale les moments théoriques aux moments observés.
Le **maximum de vraisemblance** : on retient la valeur du paramètre qui rendait les données les plus plausibles.

Le cadre commun

Un modèle paramétrique

On suppose que les observations suivent une loi **connue à un paramètre près** : Bernoulli de paramètre p, exponentielle de paramètre λ, normale de paramètres m et σ.
Estimer, c'est alors choisir, dans cette famille, la loi qui s'accorde le mieux avec les données.

Une hypothèse forte

Les chapitres 5 et 6 jugeaient un estimateur sans supposer de loi. Ici, la loi est **posée** : c'est ce qui permet de construire l'estimateur, et c'est aussi sa faiblesse, que la fin du chapitre examine.

La méthode des moments

Le principe

Une équation par paramètre

On écrit l'espérance théorique en fonction du paramètre, on l'égale à la moyenne observée, et on résout.

$$E(X) = g(\theta) \quad \Longrightarrow \quad \overline{x} = g(\hat{\theta}) \quad \Longrightarrow \quad \hat{\theta} = g^{-1}(\overline{x})$$

Trois applications immédiates

Loi	Relation	Estimateur
Bernoulli $\mathcal{B}(p)$	$E(X) = p$	$\hat{p} = \overline{x} = f$
Poisson $\mathcal{P}(\lambda)$	$E(X) = \lambda$	$\hat{\lambda} = \overline{x}$
Exponentielle	$E(X) = 1/\lambda$	$\hat{\lambda} = 1/\overline{x}$

Un exemple complet : les pannes d'une machine

Cinq durées entre deux pannes

Une machine a connu des intervalles de 12, 30, 7, 45 et 6 jours entre deux pannes. On suppose une loi exponentielle de paramètre λ, le taux de panne par jour.
$E(X) = 1/\lambda$ et $\overline{x} = 100/5 = 20$ jours, d'où

$$\hat{\lambda} = \frac{1}{20} = 0{,}05 \text{ panne par jour}$$

Ce que l'on peut en tirer

La loi exponentielle étant estimée, on peut calculer tout ce qu'elle implique : la probabilité de tenir plus de 30 jours sans panne vaut $e^{-0{,}05\times 30} = e^{-1{,}5} = 0{,}223$.
C'est l'intérêt d'un modèle : une fois le paramètre estimé, toutes les probabilités en découlent.

Deux paramètres, deux équations

Le cas de la loi normale

Deux paramètres, m et σ^2 : on égale les deux premiers moments.

$$E(X) = m \;\Rightarrow\; \widehat{m} = \overline{x} \qquad E(X^2) = \sigma^2 + m^2 \;\Rightarrow\; \hat{\sigma}^2 = \frac{1}{n}\sum x_i^2 - \overline{x}^2$$

La seconde équation donne la variance **divisée par** n : $\hat{\sigma}^2 = s_n^2$.

Sur notre échantillon

$\widehat{m} = 7\,005{,}80$ et $\hat{\sigma} = s_n = 2\,228{,}35$, au lieu de $s = 2\,250{,}98$.
La méthode des moments retrouve les estimateurs usuels — avec le biais du chapitre 5 pour la variance.

Ses mérites et ses limites

Simple, mais rustique

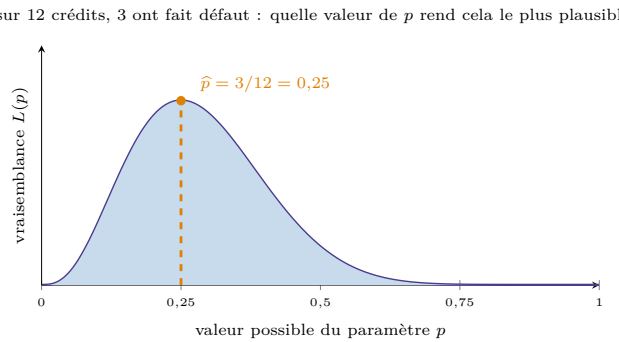
Elle ne demande aucun calcul difficile, et donne souvent le bon résultat du premier coup.
Mais elle n'utilise que les premiers moments — donc pas toute l'information de l'échantillon.
Elle peut produire des estimateurs manifestement inefficaces, voire absurdes.

Un cas où elle échoue

Sur une loi uniforme sur $[0\,;b]$, $E(X) = b/2$ et la méthode donne $\widehat{b} = 2\,\overline{x}$.
Avec les observations 1, 2, 3 et 9 : $2\,\overline{x} = 2 \times 3{,}75 = 7{,}5$. L'estimateur affirme que le maximum possible est 7,5 — **alors qu'on a observé** 9.

Le maximum de vraisemblance

Retourner la question des probabilités



Le maximum de vraisemblance

On retourne la question des probabilités.

Le cours de probabilités demandait : *p étant donné, quelle chance d'observer 3 défauts ?*

L'inférence demande : *3 défauts étant observés, quelle valeur de p rendait cela le plus vraisemblable ?*

La réponse est la fréquence observée. Ce n'est pas une coïncidence : pour Bernoulli, le maximum de vraisemblance *est* la proportion empirique.

En pratique on maximise $\ln L$, qui a le même maximum et transforme les produits en sommes.

La définition

Fonction de vraisemblance

Pour un échantillon $x_1, \dots, x_n$ indépendant, la **vraisemblance** est la probabilité d'observer exactement ces données, vue comme une fonction du paramètre :

$$L(\theta) = \prod_{i=1}^{n} f(x_i\,;\theta)$$

L'estimateur du maximum de vraisemblance est la valeur $\widehat{\theta}$ qui maximise L.

Le renversement, en une phrase

Le cours de probabilités demandait : *le paramètre étant donné, quelle chance d'observer ces données ?*
L'inférence demande : *ces données étant observées, quelle valeur du paramètre les rendait les plus vraisemblables ?* Même fonction, lue dans l'autre sens.

La technique de calcul

On maximise le logarithme

$$\ln L(\theta) = \sum_{i=1}^{n} \ln f(x_i\,;\theta)$$

Le logarithme est croissant : il a le même maximum. Et il transforme le produit en **somme**,

ce qui rend la dérivation praticable.

Le cas de Bernoulli, entièrement traité

Sur $n = 12$ crédits, $k = 3$ défauts :

$$L(p) = p^3(1-p)^9 \qquad \ln L(p) = 3\ln p + 9\ln(1-p)$$

$$\frac{\mathrm{d}\ln L}{\mathrm{d}p} = \frac{3}{p} - \frac{9}{1-p} = 0 \quad \Longrightarrow \quad \hat{p} = \frac{3}{12} = 0{,}25$$

La même courbe que dans l'introduction

Treize Bac+5 sur cinquante

La courbe de l'introduction donnait, pour chaque p, la probabilité d'observer 13 Bac+5 sur 50. C'était, à un coefficient près, la vraisemblance

$$L(p) = p^{13}(1-p)^{37} \qquad \frac{13}{p} - \frac{37}{1-p} = 0 \implies \hat{p} = \frac{13}{50} = 0{,}26$$

Le coefficient binomial ne compte pas

$\binom{50}{13}$ ne dépend pas de p : il multiplie la courbe sans déplacer son maximum. On l'omet toujours dans la vraisemblance.
Le sommet de la courbe était en 0,26 : c'était déjà l'estimateur du maximum de vraisemblance.

Le cas général de Bernoulli

k succès sur n essais

$$\ln L(p) = k\ln p + (n-k)\ln(1-p) \qquad \frac{k}{p} - \frac{n-k}{1-p} = 0 \implies \hat{p} = \frac{k}{n}$$

La dérivée seconde, $-k/p^2 - (n-k)/(1-p)^2$, est négative : c'est bien un maximum.

La fréquence observée n'était pas un choix arbitraire

Le maximum de vraisemblance **redonne** la proportion empirique. Ce que le cours de probabilités posait comme une définition intuitive se révèle être la solution d'un problème d'optimisation.

L'exponentielle, par la vraisemblance

Les cinq durées entre pannes

Pour la densité $f(x\,;\lambda) = \lambda\, e^{-\lambda x}$:

$$\ln L(\lambda) = n\ln\lambda - \lambda\sum x_i \qquad \frac{n}{\lambda} - \sum x_i = 0 \implies \hat{\lambda} = \frac{n}{\sum x_i}$$

Avec $n = 5$ et $\sum x_i = 100$: $\hat{\lambda} = 0{,}05$, exactement la valeur des moments.

Quand les deux méthodes s'accordent

Pour Bernoulli, Poisson, exponentielle et normale, moments et vraisemblance donnent le **même** estimateur. Ce n'est pas un hasard : ces lois sont entièrement résumées par leur moyenne, et la moyenne contient toute l'information utile.

La loi normale, par la vraisemblance

Deux équations

$$\ln L(m, \sigma^2) = -\frac{n}{2}\ln(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum (x_i - m)^2$$

En dérivant par rapport à m, puis à σ^2 :

$$\widehat{m} = \overline{x} \qquad \hat{\sigma}^2 = \frac{1}{n}\sum (x_i - \overline{x})^2 = s_n^2$$

Démonstration : Le maximum de vraisemblance de la loi normale

Notons $S = \sum_i (x_i - \overline{x})^2$. On décompose autour de $\overline{x}$ (chapitre 3) : $\sum_i (x_i - m)^2 = S + n\,(\overline{x} - m)^2$, donc

$$\ln L(m, \sigma^2) = -\frac{n}{2}\ln(2\pi\sigma^2) - \frac{S}{2\sigma^2} - \frac{n\,(\overline{x} - m)^2}{2\sigma^2}.$$

En m. Pour toute valeur de σ^2, le dernier terme est négatif ou nul et ne s'annule que pour $m = \overline{x}$: le maximum en m est atteint en $\widehat{m} = \overline{x}$. C'est aussi ce que dit la dérivée, $\dfrac{\partial \ln L}{\partial m} = \dfrac{n\,(\overline{x} - m)}{\sigma^2}$.

En σ^2. Pour $m = \overline{x}$, posons $v = \sigma^2$ et $g(v) = -\frac{n}{2}\ln v - \dfrac{S}{2v}$ (le terme $-\frac{n}{2}\ln 2\pi$ est constant). Alors

$$g'(v) = -\frac{n}{2v} + \frac{S}{2v^2} = \frac{n}{2v^2}\Big(\frac{S}{n} - v\Big),$$

positive pour $v < S/n$ et négative pour $v > S/n$: g croît puis décroît, et son maximum global est en $\hat{\sigma}^2 = S/n = s_n^2$.

Les moments aboutissent au même résultat. L'identité $\sum_i (x_i - \overline{x})^2 = \sum_i x_i^2 - 2\overline{x}\sum_i x_i + n\overline{x}^2 = \sum_i x_i^2 - n\overline{x}^2$ montre que $\frac{1}{n}\sum_i x_i^2 - \overline{x}^2 = s_n^2$.

Ce que cela dit. Sur le fil rouge, $\widehat{m} = 7\,005{,}80$ et $\hat{\sigma} = s_n = 2\,228{,}35$. Le diviseur est n, pas $n - 1$: le maximum de vraisemblance ne corrige pas le biais, il cherche la valeur qui rend les données les plus plausibles.

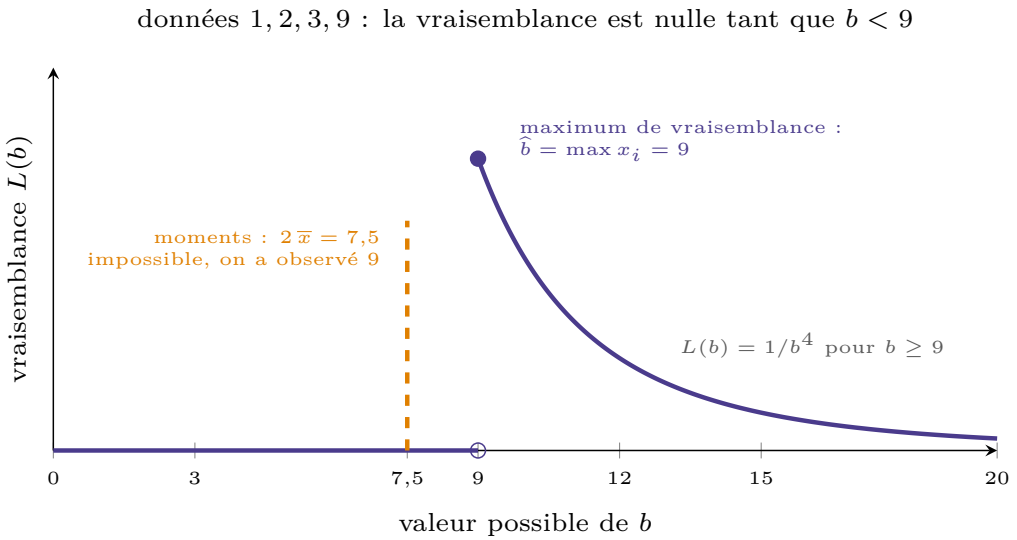
■

Un estimateur biaisé à distance finie

Le maximum de vraisemblance divise par n : il est biaisé, comme le chapitre 5 l'a montré, mais asymptotiquement sans biais.

Le chapitre 6 l'a aussi montré : en erreur quadratique moyenne, diviser par n fait **mieux** que diviser par $n-1$.

L'uniforme : là où les deux méthodes divergent



Ce que montre la courbe

Une vraisemblance qui saute

Pour une loi uniforme sur $[0\,;b]$, $f(x\,;b) = 1/b$ si $0 \leq x \leq b$, et 0 sinon. Si un seul x_i dépasse b, la vraisemblance est nulle :

$$L(b) = \begin{cases} 0 & \text{si } b < \max x_i \\ 1/b^n & \text{si } b \geq \max x_i \end{cases}$$

$1/b^n$ décroît : le maximum est atteint au plus petit b permis, $\widehat{b} = \max x_i = 9$.

Le maximum de vraisemblance respecte les données

Il ne propose jamais une valeur incompatible avec ce qu'on a observé. Il est biaisé vers le bas — le plus grand observé ne dépasse jamais b —, d'où la correction $\frac{n+1}{n} \max x_i$ du chapitre 5.

Les deux méthodes, simulées

Loi uniforme sur [0 ; 10], vingt mille échantillons de 10

Estimateur	Biais	Écart-type	$\sqrt{\text{EQM}}$	Sous le max observé
Moments $2\,\overline{x}$	0,0	1,82	1,82	28,5 %

Vraisemblance $\max x_i$	$-0{,}90$	0,82	1,22	jamais
Corrigé $\frac{11}{10}\max x_i$	0,0	0,90	0,90	jamais

Démonstration : Les lignes du tableau, par le calcul exact

Avec $\theta = b = 10$ et $n = 10$, les résultats de l'exercice sur le plus grand numéro (chapitre 5) donnent, pour $M = \max x_i$: $E(M) = \dfrac{n}{n+1}\,\theta$, $V(M) = \dfrac{n\,\theta^2}{(n+1)^2(n+2)}$.

- **Moments, $2\overline{x}$.** Sans biais, $V(\overline{X}) = \dfrac{\theta^2}{12\,n}$ pour une uniforme, donc $V(2\overline{X}) = \dfrac{\theta^2}{3n} = \dfrac{100}{30}$ et l'écart-type vaut 1,83.
- **Vraisemblance, M.** Biais $-\dfrac{\theta}{n+1} = -0{,}91$; écart-type $\sqrt{\dfrac{10\times 100}{121\times 12}} = 0{,}83$; $\sqrt{\text{EQM}} = \sqrt{0{,}91^2 + 0{,}83^2} = 1{,}23$.
- **Corrigé, $\frac{n+1}{n}M$.** Sans biais, variance $\dfrac{\theta^2}{n(n+2)} = \dfrac{100}{120}$ et écart-type 0,91, qui est aussi sa racine d'EQM.

Ce que cela dit. Ces valeurs exactes retrouvent le tableau simulé à la fluctuation d'échantillonnage près (1,82 ; $-0{,}90$, 0,82, 1,22 ; 0,90). Le gain de précision du maximum vient de ce que sa variance décroît en $1/n^2$, alors que celle de $2\overline{x}$ décroît en $1/n$.

■

Ce que la simulation tranche

Dans plus d'un échantillon sur quatre, la méthode des moments propose une borne **inférieure** à la plus grande valeur observée. La vraisemblance corrigée est sans biais et deux fois plus précise.

Les propriétés du maximum de vraisemblance

Pourquoi il domine

Ses quatre propriétés

1. **Convergent** — il s'approche du vrai paramètre.
2. **Asymptotiquement sans biais** — le biais s'efface quand n grandit.
3. **Asymptotiquement efficace** — aucun autre ne fait mieux à grand échantillon.
4. **Invariant** — l'estimateur de $g(\theta)$ est $g(\widehat{\theta})$, sans recalcul.

Démonstration : L'invariance du maximum de vraisemblance

Soit $\eta = g(\theta)$ la grandeur qui nous intéresse. La vraisemblance **de** η est la plus grande vraisemblance parmi les valeurs de θ qui donnent cette valeur de η :

$$L^*(\eta) = \max_{\theta\,:\,g(\theta)=\eta} L(\theta).$$

(Quand g est bijective, un seul θ convient, $\theta = g^{-1}(\eta)$, et $L^*(\eta) = L(g^{-1}(\eta))$: c'est la même courbe, simplement lue avec une autre graduation de l'axe.)

Pour tout η, il existe un θ avec $g(\theta) = \eta$ et $L^*(\eta) = L(\theta) \leq L(\hat{\theta})$, puisque $\hat{\theta}$ maximise L. L'égalité $L^*(\eta) = L(\hat{\theta})$ est atteinte pour $\eta = g(\hat{\theta})$, car $\hat{\theta}$ est alors l'un des θ admis. Donc le maximum de L^* est atteint en $\hat{\eta} = g(\hat{\theta})$.

Sur les durées de panne. $\hat{\lambda} = 0{,}05$ donne, sans recalcul, $1/\hat{\lambda} = 20$ jours et $e^{-30\hat{\lambda}} = e^{-1{,}5} = 0{,}223$.

Ce que cela dit. Il suffit d'estimer le paramètre une fois ; toute grandeur qui s'en déduit est estimée en y substituant $\hat{\theta}$. Attention : cela vaut pour le maximum de vraisemblance, pas pour l'absence de biais (chapitre 5) : $\sqrt{S^2}$ n'est pas sans biais pour σ.

■

La portée de l'efficacité

À grand échantillon, le maximum de vraisemblance extrait **toute** l'information que contiennent les données sur le paramètre. Aucune autre recette ne fait mieux — c'est ce qui en fait la méthode de référence.

L'invariance, au travail

Trois grandeurs dérivées, sans nouveau calcul

Grandeur	Fonction du paramètre	Estimation
Durée moyenne entre pannes	$1/\lambda$	20 jours
Probabilité de tenir 30 jours	$e^{-30\lambda}$	0,223
Écart-type des salaires	$\sqrt{\sigma^2}$	2 228,35

Ce qui en fait un outil de gestion

Un actuaire estime une fois le paramètre d'une loi de sinistres, puis en déduit la prime pure, la probabilité de ruine, la réserve nécessaire : chaque grandeur est l'estimateur du maximum de vraisemblance de ce qu'elle mesure.

Ses limites

Trois réserves à connaître

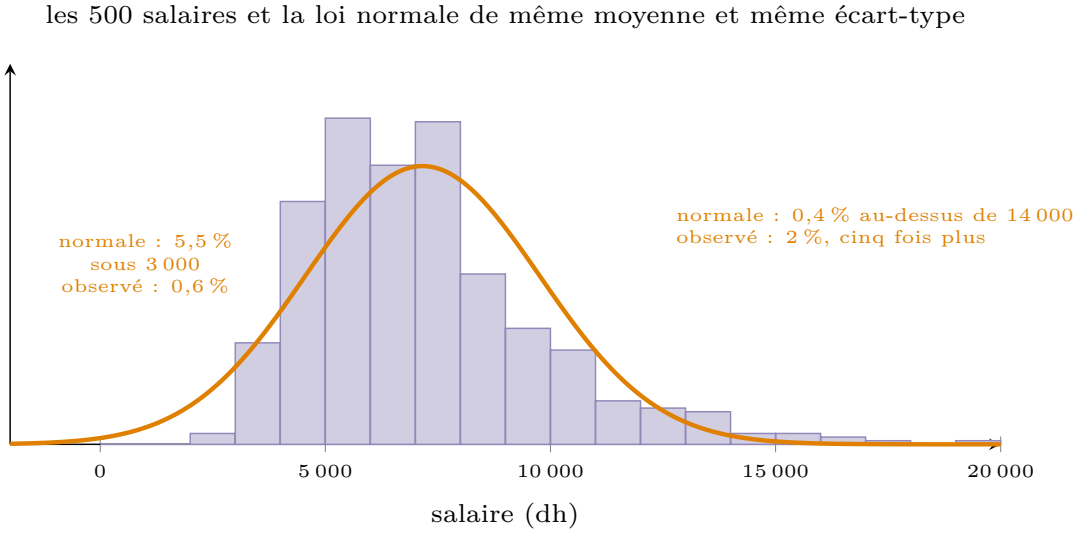
- Il peut être **biaisé à distance finie** : sur une population normale, il estime σ^2 en divisant par n, pas par $n-1$.
- Il exige de **postuler une loi**. Si la loi supposée est fausse, l'estimateur est faux — et rien ne le signale.
- Le maximum n'a pas toujours de forme explicite : il faut alors le chercher numériquement.

Sa portée réelle

C'est pourtant la méthode d'estimation la plus employée : régression logistique, modèles GARCH, économétrie des données de panel, apprentissage statistique.

Ce qui n'est pas une régression linéaire ordinaire relève, presque toujours, du maximum de vraisemblance.

Postuler une loi : ce que cela coûte



Une loi normale pour nos salaires ?

Ce que la normale prédit, ce que l'on observe

Événement	Loi normale ajustée	Observé sur les 500
salaire négatif	0,3 %	0
salaire inférieur à 3 000	5,5 %	0,6 %
salaire supérieur à 12 000	3,1 %	5,8 %
salaire supérieur à 14 000	0,4 %	2,0 %

La moyenne est juste, les queues sont fausses

Le maximum de vraisemblance normal estime correctement la moyenne et l'écart-type. Mais toute probabilité calculée **dans les queues** avec cette loi est fausse : elle prévoit cinq fois trop peu de très hauts salaires.
Pour une grille de rémunération des cadres, ou pour un risque de perte extrême, c'est précisément la queue qui compte.

S'entraîner

Exercice 1 : les réclamations quotidiennes

Une loi de Poisson

Un service client relève sur 8 jours le nombre de réclamations : 3, 1, 4, 0, 2, 5, 1, 0. On suppose une loi de Poisson de paramètre λ.

1. Estimer λ par la méthode des moments.
2. Écrire $\ln L(\lambda)$, sachant que $P(X = k) = e^{-\lambda}\lambda^k/k!$, et trouver l'estimateur du maximum de vraisemblance.
3. Estimer la probabilité d'une journée sans réclamation.

Exercice 1 : solution

Les deux méthodes s'accordent

1. $E(X) = \lambda$: $\hat{\lambda} = \overline{x} = 16/8 = 2$ réclamations par jour.
2. $\ln L(\lambda) = -n\lambda + (\sum x_i)\ln\lambda - \sum \ln(x_i!)$. La dérivée $-n + \sum x_i/\lambda$ s'annule en $\hat{\lambda} = \sum x_i/n = 2$.
3. Par invariance : $\widehat{P}(X = 0) = e^{-\hat{\lambda}} = e^{-2} = 0{,}135$, soit environ une journée sur sept.

Exercice 2 : la durée des appels

Une loi exponentielle

Cinq appels à un service d'assistance ont duré 2, 5, 1, 8 et 4 minutes. On suppose une loi exponentielle de paramètre λ.

1. Calculer l'estimateur du maximum de vraisemblance de λ.
2. En déduire la durée moyenne estimée d'un appel.
3. Estimer la probabilité qu'un appel dure plus de 6 minutes.

Exercice 2 : solution

Une estimation, toutes les probabilités

1. $\hat{\lambda} = n/\sum x_i = 5/20 = 0{,}25$ par minute.
2. Par invariance, $1/\hat{\lambda} = 4$ minutes — c'est aussi $\overline{x}$.
3. $\widehat{P}(X > 6) = e^{-0{,}25\times 6} = e^{-1{,}5} = 0{,}223$.

La réserve

Avec cinq appels, $\hat{\lambda}$ est très imprécis, et la loi exponentielle n'est qu'une hypothèse. Avant de dimensionner un centre d'appels sur ce calcul, on vérifierait la forme de la distribution sur bien plus de données.

Exercice 3 : le taux d'attrition

Des clients qui partent

Sur 200 abonnés suivis pendant un an, 34 ont résilié leur contrat.

1. Écrire la log-vraisemblance et trouver $\hat{p}$.
2. Vérifier qu'il s'agit d'un maximum.
3. Les marketeurs raisonnent en **cote** $p/(1-p)$. Estimer la cote de résiliation.

Exercice 3 : solution

Bernoulli, puis l'invariance

1. $\ln L(p) = 34 \ln p + 166 \ln(1-p)$; la dérivée $34/p - 166/(1-p)$ s'annule en $\hat{p} = 34/200 = 0{,}17$.
2. La dérivée seconde $-34/p^2 - 166/(1-p)^2$ est négative partout : c'est un maximum.
3. Par invariance, $\hat{p}/(1-\hat{p}) = 0{,}17/0{,}83 = 0{,}205$: environ une résiliation pour cinq abonnés qui restent.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Un estimateur se **construit** ; il ne se devine pas.
2. **Méthode des moments** : égaler moments théoriques et moments observés. Simple, parfois absurde — $2\,\overline{x}$ sous le maximum observé.
3. **Maximum de vraisemblance** : retenir la valeur qui rendait les données les plus plausibles ; on maximise $\ln L$.
4. Pour Bernoulli, Poisson, exponentielle et normale, il redonne les estimateurs usuels.
5. Convergent, asymptotiquement sans biais et efficace, **invariant**.
6. Il exige de **postuler une loi** : une loi fausse donne des probabilités fausses, surtout dans les queues.

La suite

Une estimation ponctuelle est presque sûrement fausse

La probabilité que $\overline{x}$ vaille exactement m est nulle. Annoncer 7 005,80 sans rien d'autre est donc une information incomplète.
La quatrième partie ajoute ce qui manque : **la précision**.

La question, chiffrée

L'erreur-type de notre estimation vaut 318 dirhams. Peut-on en tirer un intervalle dont on sait, à l'avance, qu'il contient m dans 95 % des cas ?
Le chapitre 8 construit le principe ; le chapitre 9 l'applique à notre échantillon.