

Statistique inférentielle

Chapitre 2 : La distribution d'échantillonnage de la moyenne

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique inférentielle

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Erreur-type et calcul de probabilité

Le solde moyen des comptes clients d'une grande banque est $m = 15\,000$ dh, d'écart-type $\sigma = 4\,000$ dh (population très grande, on ignore ici la correction d'exhaustivité). On tire un échantillon aléatoire de $n = 64$ comptes.

- (a) Calculer l'erreur-type de la moyenne d'échantillon.
- (b) Calculer les valeurs centrées réduites Z correspondant à $\bar{X} = 14\,000$ et à $\bar{X} = 16\,000$.
- (c) En utilisant la règle empirique selon laquelle environ 95,4 % des valeurs d'une loi normale se situent à moins de 2 écarts-types de la moyenne, donner un ordre de grandeur de $P(14\,000 \leq \bar{X} \leq 16\,000)$.

Exercice 2 — La correction de population finie

Une usine possède un parc de $N = 800$ machines dont la durée de vie moyenne a un écart-type $\sigma = 50$ heures. On tire un échantillon de $n = 100$ machines pour une étude de maintenance prédictive.

- (a) Calculer l'erreur-type **sans** correction de population finie.
- (b) L'échantillon représente-t-il plus de 5 % de la population ? La correction de population finie doit-elle être appliquée ?
- (c) Calculer le facteur de correction $\sqrt{(N-n)/(N-1)}$, puis l'erreur-type **corrigée**. De quel pourcentage l'erreur-type a-t-elle été réduite par cette correction ?

Exercice 3 — Le théorème central limite s'applique-t-il ?

On considère deux variables : (i) les notes d'un examen, dont la distribution est à peu près symétrique, sur laquelle on prélève un échantillon de $n = 25$ copies ; (ii) le montant des sinistres déclarés à une compagnie d'assurance, dont la distribution est **très fortement** étalée à droite (la plupart des sinistres sont petits, quelques-uns sont énormes), sur laquelle on prélève également un échantillon de $n = 25$ dossiers.

- (a) Pour laquelle des deux variables la convention $n \geq 30$ (ici non atteinte, avec $n = 25$) est-elle malgré tout la moins risquée pour approximer la distribution de $\bar{X}$ par une loi normale ?
- (b) Pour l'autre variable, pourquoi un échantillon de 25 dossiers serait-il probablement encore insuffisant pour invoquer le théorème central limite, même si n atteignait 30 ou 40 ?
- (c) Quel réflexe, rappelé dans le cours, permet de juger si une taille d'échantillon donnée est suffisante, plutôt que de se fier aveuglément à un seuil unique comme $n \geq 30$?

2 Exercices cumulatifs (introduction à chapitre 2)

Exercice 4 — L'échantillon fil rouge, rigoureusement testé

On reprend le fil rouge : population de $N = 500$ salariés, $m = 7\,158,26$ dh, $\sigma = 2\,598,10$ dh ; échantillon systématique de $n = 50$ salariés, de moyenne $\bar{x} = 7\,005,80$ dh.

- (a) Calculer l'erreur-type $\sigma/\sqrt{n}$ **sans** correction de population finie.
- (b) L'échantillon représentant 10 % de la population (bien au-delà du seuil de 5 %), calculer le facteur de correction $\sqrt{(N-n)/(N-1)}$ puis l'erreur-type **corrigée**.
- (c) Calculer la valeur centrée réduite $Z = (\bar{x} - m)/\sigma(\bar{X})$ en utilisant l'erreur-type corrigée. Cette valeur de Z est-elle en elle-même une valeur « extrême » pour une loi normale centrée réduite ? Que peut-on en conclure, à ce stade du cours, sur la compatibilité de cet échantillon particulier avec un tirage sans biais dans la population des 500 salariés (on complètera ce raisonnement de

3 Applications en sciences économiques

Exercice 5 — La taille d'échantillon comme variable de décision

Une entreprise d'études de marché souhaite estimer le montant moyen du panier d'achat en ligne d'un site de commerce électronique, dont on sait par des études antérieures que l'écart-type est d'environ $\sigma = 80$ dh.

- (a) Calculer l'erreur-type pour un échantillon de $n = 30$, $n = 100$, puis $n = 300$ clients.
- (b) Chaque entretien client coûtant 40 dh à l'entreprise, calculer le coût total de collecte pour chacune des trois tailles d'échantillon.
- (c) Un directeur commercial se satisfait d'une précision « à 15 dh près » sur l'estimation du panier moyen. Lequel des trois échantillons proposés est le plus proche de ce niveau de précision (en interprétant l'erreur-type comme un ordre de grandeur de l'erreur typique)? Ce choix est-il également le plus économique compatible avec cette exigence?

Exercice 6 — Le danger d'une approximation normale hâtive en assurance

Un actuaire junior souhaite estimer la provision moyenne à constituer pour les sinistres automobiles d'une compagnie, sur la base d'un échantillon de $n = 40$ sinistres, en supposant que la moyenne d'échantillon suit une loi normale (théorème central limite, « $n \geq 30$ »).

- (a) Sachant que les montants de sinistres sont typiquement très fortement asymétriques (une grande masse de petits sinistres, une minorité de sinistres catastrophiques bien plus coûteux), ce choix de $n = 40$ est-il, au vu du cours, nécessairement suffisant pour garantir une approximation normale fiable?
- (b) Quelle erreur concrète l'actuaire risque-t-il de commettre s'il calcule un intervalle de confiance ou une provision réglementaire à partir d'une approximation normale mal justifiée, dans un contexte où les sinistres extrêmes sont justement ceux qui pèsent le plus sur la solvabilité de la compagnie?
- (c) Quelle recommandation méthodologique, tirée de ce chapitre, l'actuaire senior devrait-il donner à son junior avant qu'il ne présente ses résultats à la direction?


1 Exercices du chapitre

Correction — Exercice 1

$$(a) \sigma(\bar{X}) = \frac{4\,000}{\sqrt{64}} = \frac{4\,000}{8} = 500 \text{ dh.}$$

$$(b) Z_{14\,000} = \frac{14\,000 - 15\,000}{500} = -2. \quad Z_{16\,000} = \frac{16\,000 - 15\,000}{500} = +2.$$

$$(c) P(14\,000 \leq \bar{X} \leq 16\,000) = P(-2 \leq Z \leq 2) \approx 0,954, \text{ soit environ } 95,4\%.$$



Correction — Exercice 2

$$(a) \sigma(\bar{X})_{\text{sans correction}} = \frac{50}{\sqrt{100}} = 5 \text{ heures.}$$

$$(b) n/N = 100/800 = 12,5\% > 5\% : \text{ la correction de population finie } \textbf{doit} \text{ être appliquée.}$$

$$(c) \text{Facteur} = \sqrt{\frac{800 - 100}{800 - 1}} = \sqrt{700/799} \approx 0,936. \text{ Erreur-type corrigée} = 5 \times 0,936 \approx 4,68 \text{ heures.}$$

Réduction $\approx (5 - 4,68)/5 \approx 6,4\%$.

Correction — Exercice 3

(a) Pour les **notes d'examen**, dont la distribution est à peu près symétrique, la convention $n \geq 30$ (même non atteinte avec $n = 25$) est nettement moins risquée : une population déjà proche de la symétrie converge **rapidement** vers la normalité pour $\bar{X}$, y compris pour des tailles d'échantillon modestes.

(b) Pour les **sinistres d'assurance**, très fortement asymétriques, un échantillon de 25 (ou même 30 à 40) dossiers reste probablement insuffisant : plus une population est étirée (skewed), plus il faut un n **grand** pour que le théorème central limite « efface » cette asymétrie dans la distribution de $\bar{X}$. Avec un petit échantillon, un seul sinistre catastrophique peut encore faire basculer fortement la moyenne d'échantillon, empêchant toute approximation normale fiable.

(c) Le réflexe recommandé par le cours est de **toujours regarder l'histogramme** (ou tout indicateur de forme, comme γ_1 vu en statistique descriptive) de la population avant d'invoquer mécaniquement la règle $n \geq 30$: cette convention est commode, mais elle n'est **pas** un théorème, et son adéquation dépend entièrement du degré d'asymétrie de la variable étudiée.

2 Exercices cumulatifs (introduction à chapitre 2)

Correction — Exercice 4

$$(a) \sigma(\bar{X})_{\text{sans correction}} = \frac{2\,598,10}{\sqrt{50}} \approx 367,43 \text{ dh.}$$

$$(b) \text{Facteur} = \sqrt{\frac{500 - 50}{500 - 1}} = \sqrt{450/499} \approx 0,9496. \text{ Erreur-type corrigée} \approx 367,43 \times 0,9496 \approx 348,92 \text{ dh.}$$

$$(c) Z = \frac{7\,005,80 - 7\,158,26}{348,92} = \frac{-152,46}{348,92} \approx -0,437. \text{ Cette valeur de } Z \text{ est } \textbf{très loin} \text{ d'être extrême pour une loi normale centrée réduite (les valeurs « extrêmes » usuelles se situent au-delà de } \pm 1,96, \text{ voire}$$

$\pm 2,58$) : $|Z| \approx 0,44$ est un écart tout à fait **banal**, du type qu'on observerait fréquemment par pur hasard d'échantillonnage. On peut donc dire, à ce stade intuitif du cours, que **rien dans ce résultat ne suggère un biais** de tirage : l'échantillon systématique fil rouge produit une moyenne parfaitement compatible avec un tirage sans biais dans la population des 500 salariés. Le chapitre 9 formalisera ce raisonnement intuitif en un véritable test statistique, avec un seuil de décision explicite.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) $n = 30$: $\sigma(\bar{X}) = 80/\sqrt{30} \approx 14,61$ dh. $n = 100$: $80/\sqrt{100} = 8$ dh. $n = 300$: $80/\sqrt{300} \approx 4,62$ dh.
 (b) Coût $n = 30$: $30 \times 40 = 1\,200$ dh. Coût $n = 100$: $100 \times 40 = 4\,000$ dh. Coût $n = 300$: $300 \times 40 = 12\,000$ dh.
 (c) Le directeur commercial souhaite une précision « à 15 dh près ». Même l'échantillon le plus modeste, $n = 30$ (erreur-type $\approx 14,61$ dh), atteint **déjà** cet objectif, tandis que $n = 100$ (8 dh) et $n = 300$ (4,62 dh) le dépassent largement, à un coût bien supérieur. L'échantillon le plus proche de l'exigence **tout en restant économique** est donc $n = 30$ (1 200 dh) : les échantillons plus grands offrent une précision supplémentaire que le directeur n'a, dans cet énoncé, pas demandée, ce qui illustre concrètement l'idée du cours selon laquelle la taille d'échantillon est une **variable de décision** à arbitrer entre précision et coût, et non un chiffre à maximiser par principe.

Correction — Exercice 6

- (a) **Non**, ce n'est pas nécessairement suffisant : $n = 40$ dépasse certes la convention usuelle $n \geq 30$, mais cette convention est calibrée pour des distributions modérément asymétriques. Pour une distribution de sinistres **très fortement** étalée à droite, avec des valeurs catastrophiques rares mais énormes, un n bien plus grand peut être nécessaire avant que la distribution de $\bar{X}$ ne devienne raisonnablement proche d'une loi normale.
 (b) L'actuaire risque de **sous-estimer** la variabilité réelle de la moyenne des sinistres (en particulier la probabilité de tirer, par malchance d'échantillonnage, une moyenne très éloignée de la vraie moyenne à cause d'un ou deux sinistres catastrophiques non représentés dans l'échantillon), et donc de calculer une provision ou un intervalle de confiance **trop étroit** — c'est-à-dire de sous-évaluer le risque financier réel que ces sinistres extrêmes font peser sur la solvabilité de la compagnie, exactement au moment où une évaluation prudente serait la plus nécessaire.
 (c) La recommandation méthodologique est celle du cours : **examiner d'abord l'histogramme** (ou les coefficients de forme) de la distribution des sinistres avant de choisir une taille d'échantillon et de s'appuyer sur l'approximation normale ; le cas échéant, retenir un échantillon nettement plus grand que 30–40, ou envisager des méthodes moins sensibles à l'asymétrie (transformation des données, méthodes de rééchantillonnage), plutôt que d'appliquer mécaniquement une règle conçue pour des distributions bien plus régulières.