Statistique inférentielle

Chapitre 2 : La distribution d'échantillonnage de la moyenne

Jaouad Madkour

31 octobre 2026

Plan du chapitre

L'objet central du cours **2**
Deux graphiques qui n'ont pas le même objet . . . 2
La définition . . . 2
Une distribution complète, à la main . . . 3
Les seize échantillons . . . 3
Ce que l'énumération montre . . . 3

Les deux premiers moments **4**
Espérance et écart-type de la moyenne . . . 4
La démonstration, en deux lignes . . . 4
Vérification sur nos données . . . 4
La correction de population finie . . . 5
Les trois mesures de la précision, réunies . . . 5

La forme de la distribution **6**
L'effet de la taille de l'échantillon . . . 6
Deux théorèmes, une seule figure . . . 6
Le théorème, sous sa forme utile . . . 6
Quand le théorème tarde . . . 7
La règle des trente, et sa vraie portée . . . 8

Calculer sur la moyenne **9**
La loi de la moyenne de cinquante salariés . . . 9
Encadrer la moyenne d'un échantillon . . . 9
Trois calculs types . . . 9
Les dix échantillons au regard de la théorie . . . 10
L'ordre de grandeur qu'il faut avoir en tête . . . 10
Diviser l'erreur par deux coûte quatre fois plus . . . 11

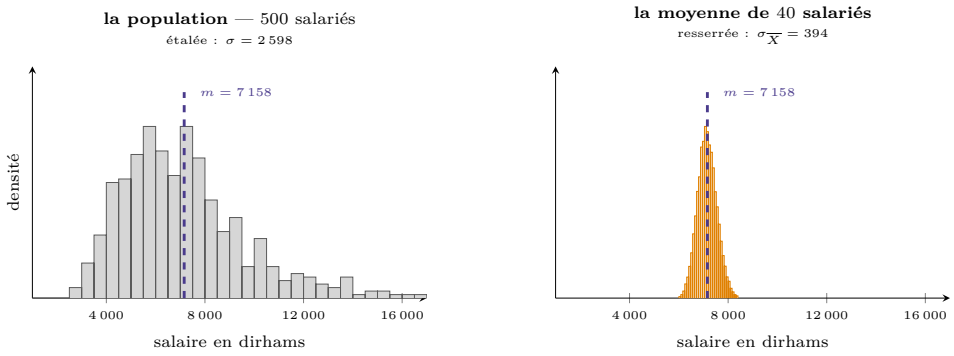
S'entraîner **11**
Exercice 1 : une distribution à la main . . . 11
Exercice 1 : solution . . . 12
Exercice 2 : la durée des appels . . . 12

Exercice 2 : solution 12
Exercice 3 : la masse salariale d'une équipe 12
Exercice 3 : solution 13

Ce qu'il faut retenir **13**
Le résumé du chapitre 13
La suite 13

L'objet central du cours

Deux graphiques qui n'ont pas le même objet



Les deux graphiques n'ont pas le même objet. À gauche, des *salariés*. À droite, des *moyennes d'échantillons*.

Trois tirages de 40 salariés ont donné 6863, 7001 et 7895 dirhams : jamais la même valeur, toujours autour de 7 158. En répétant vingt mille fois, on obtient la cloche de droite — c'est la **distribution d'échantillonnage** de $\overline{X}$, et c'est l'objet central de tout le cours.

Elle est 6,6 fois moins étalée que la population, exactement $\sqrt{40}$ à la correction de population finie près.

La définition

Distribution d'échantillonnage

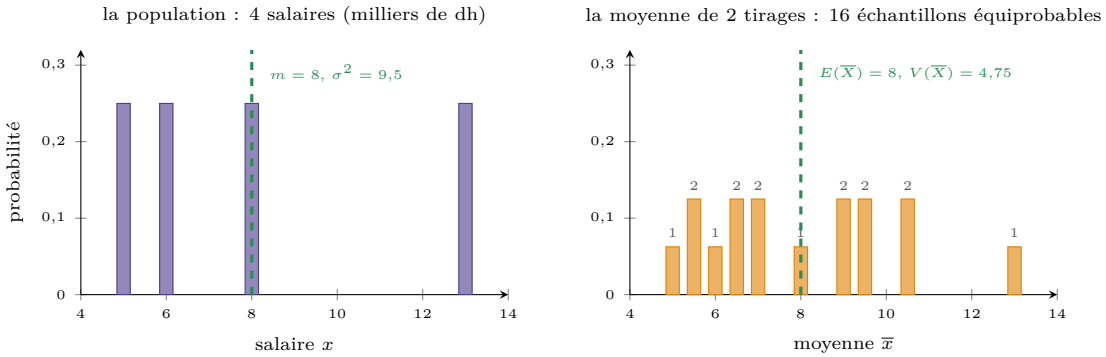
La **distribution d'échantillonnage** d'une statistique est la loi de probabilité des valeurs qu'elle prend lorsqu'on répète le tirage d'échantillons de même taille dans la même population.

Le changement d'objet, à saisir une fois pour toutes

La population des salaires décrit des **salariés**. La distribution d'échantillonnage décrit des **moyennes d'échantillons**.

Ce ne sont pas les mêmes objets, et surtout pas le même étalement. Confondre les deux est l'erreur qui rend le reste du cours incompréhensible.

Une distribution complète, à la main



Les seize échantillons

Quatre salaires, deux tirages avec remise

Une petite entreprise : 4 salariés, payés 5, 6, 8 et 13 milliers de dirhams. On en tire 2 avec remise : $4 \times 4 = 16$ échantillons, tous de probabilité 1/16.

$\overline{x}$	5	5,5	6	6,5	7	8	9	9,5	10,5	13
effectif	1	2	1	2	2	1	2	2	2	1

Par exemple, $\overline{x} = 9{,}5$ provient de $(6\,;13)$ et de $(13\,;6)$.

Ses deux premiers moments

$E(\overline{X}) = \frac{1}{16}(5 + 2 \times 5{,}5 + \cdots + 13) = 8 = m$.
$V(\overline{X}) = 4{,}75$, exactement la moitié de la variance de la population, $\sigma^2 = 9{,}5$: c'est σ^2/n avec $n = 2$.

Ce que l'énumération montre

Trois constats, déjà

1. La moyenne d'échantillon est **centrée** sur m : elle ne se trompe pas en moyenne.
2. Elle est **moins dispersée** que les salaires : les valeurs extrêmes 5 et 13 n'apparaissent qu'une fois sur seize.
3. Sa distribution est **plus ramassée au centre** que celle de la population, qui n'en avait pas.

Pourquoi on ne peut pas faire cela en vrai

Avec 500 salariés et $n = 50$, le nombre d'échantillons avec remise est 500^{50}, un nombre à 135 chiffres.
D'où les deux voies du chapitre : la **théorie**, qui donne la loi sans l'énumérer, et la **simulation**, qui en tire des milliers pour la vérifier.

Les deux premiers moments

Espérance et écart-type de la moyenne

Le résultat, établi au chapitre 1

Pour un échantillon aléatoire simple de taille n, tiré dans une population d'espérance m et d'écart-type σ :

$$E(\overline{X}) = m \qquad \sigma(\overline{X}) = \frac{\sigma}{\sqrt{n}}$$

Erreur-type

La quantité $\sigma/\sqrt{n}$ porte un nom propre : l'**erreur-type** de la moyenne.
Ce n'est pas l'écart-type des données. C'est l'écart-type des **moyennes** — de combien la moyenne d'échantillon se trompe, typiquement.

La démonstration, en deux lignes

Deux règles du cours de probabilités

L'espérance d'une somme est la somme des espérances, toujours. La variance d'une somme est la somme des variances, **si** les termes sont indépendants.
Avec $\overline{X} = \frac{1}{n}(X_1 + \cdots + X_n)$ et le facteur $\frac{1}{n}$ qui sort au carré de la variance :

$$E(\overline{X}) = \frac{n\,m}{n} = m \qquad V(\overline{X}) = \frac{n\,\sigma^2}{n^2} = \frac{\sigma^2}{n}$$

La vérification sur les quatre salaires

$\sigma^2 = \frac{1}{4}(3^2 + 2^2 + 0^2 + 5^2) = 9{,}5$, et $9{,}5/2 = 4{,}75$: c'est bien la variance obtenue en énumérant les seize échantillons.

Vérification sur nos données

Vingt mille échantillons de taille 40

On tire 20 000 fois 40 salariés sans remise parmi les 500 (graine 20261022), et l'on calcule chaque fois la moyenne.

Grandeur	Théorie	Simulation
Espérance de $\overline{X}$	7 158,26	7 158,19
Erreur-type $\sigma/\sqrt{n}$	410,80	394,86

L'écart sur l'erreur-type n'est pas une erreur

394,86 au lieu de 410,80 : la simulation est trop précise, et systématiquement.
La raison est celle du chapitre 1 : nous tirons **sans remise** dans une population de seulement 500 individus. Un échantillon de 40 en représente déjà 8 %.

La correction de population finie

Le facteur d'exhaustivité

$$\sigma(\overline{X}) = \frac{\sigma}{\sqrt{n}} \times \sqrt{\frac{N-n}{N-1}}$$

Ici : $410{,}80 \times \sqrt{460/499} = 410{,}80 \times 0{,}960 = 394{,}42$ — la valeur simulée, à moins d'un dirham près.

Quand faut-il l'appliquer

La règle usuelle : dès que n dépasse 5 % de N.
Elle joue toujours dans le bon sens — elle **réduit** l'erreur-type — et elle s'annule quand $n = N$: sur un recensement complet, la moyenne d'échantillon *est* la moyenne, et son erreur est nulle. La formule le dit toute seule.

Les trois mesures de la précision, réunies

Pour n = 50 sur nos 500 salariés

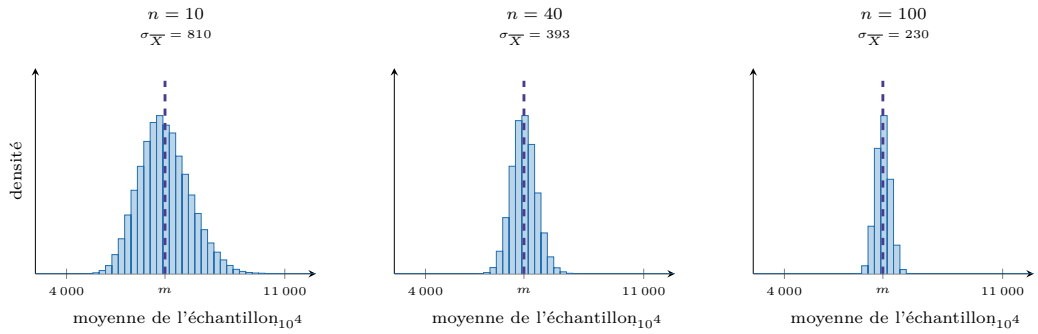
Source	Erreur-type
Formule i.i.d., $\sigma/\sqrt{50}$	367,4
Formule sans remise, avec le facteur 0,950	348,9
20 000 tirages sans remise simulés	346,9
Les dix échantillons systématiques	346,2

Ce que le tableau établit

La théorie **prévoit** la dispersion des moyennes sans tirer un seul échantillon. La simulation et les dix échantillons réels la confirment.
C'est ce qui rend l'inférence possible : avec un seul échantillon, on connaît déjà la précision de toute la méthode.

La forme de la distribution

L'effet de la taille de l'échantillon



Deux choses se produisent en même temps quand n grandit, et il faut les distinguer.

1. La forme devient normale — c'est le théorème central limite. La population des salaires est nettement étirée à droite ; dès $n = 40$, la cloche est là.

2. L'étalement se resserre en $\sigma/\sqrt{n}$ — c'est la loi des grands nombres. De 10 à 100, l'écart-type est divisé par $\sqrt{10} \approx 3{,}2$.

Le premier point autorise à utiliser la table normale ; le second dit combien on gagne à interroger plus de monde.

Deux théorèmes, une seule figure

Ce qui se produit quand n grandit

1. **La forme devient normale** — c'est le théorème central limite (chapitre 20 de Probabilités).
2. **L'étalement se resserre en** $1/\sqrt{n}$ — c'est ce qui fonde la loi des grands nombres (chapitre 19).

Ils ne disent pas la même chose

Le premier autorise à **lire une table normale**, donc à calculer des probabilités.
Le second dit **de combien** on gagne à interroger davantage de monde. Le premier rend l'inférence possible ; le second en fixe le prix.

Le théorème, sous sa forme utile

Les deux cas

Population normale : $\overline{X}$ suit exactement une loi normale, quel que soit n.

Population quelconque, n grand : $\overline{X}$ suit approximativement $\mathcal{N}\left(m\,;\,\dfrac{\sigma}{\sqrt{n}}\right)$.

$$Z = \frac{\overline{X} - m}{\sigma/\sqrt{n}} \;\approx\; \mathcal{N}(0\,;1)$$

Démonstration : Une population normale donne une moyenne exactement normale

Supposons $X_1, \dots, X_n$ indépendantes, de loi $\mathcal{N}(m\,;\sigma)$. Le chapitre 17 de Probabilités a établi deux faits : une somme de normales **indépendantes** est normale, et un multiple d'une normale est normale. Or

$$\overline{X} = \tfrac{1}{n}X_1 + \cdots + \tfrac{1}{n}X_n$$

est une somme de normales indépendantes, chacune multipliée par $\frac{1}{n}$: $\overline{X}$ est donc normale, quel que soit n. Il reste à identifier ses deux paramètres, et le chapitre 1 les a déjà calculés sans hypothèse sur la forme de la loi : $E(\overline{X}) = m$ et $V(\overline{X}) = \sigma^2/n$. Donc

$$\overline{X} \sim \mathcal{N}\left(m\,;\frac{\sigma}{\sqrt{n}}\right) \qquad \text{et} \qquad Z = \frac{\overline{X} - m}{\sigma/\sqrt{n}} \sim \mathcal{N}(0\,;1) \quad \text{exactement.}$$

La standardisation ne fait que retrancher l'espérance et diviser par l'écart-type : $E(Z) = 0$, $V(Z) = 1$, et un décalage suivi d'un changement d'échelle laisse la loi normale.

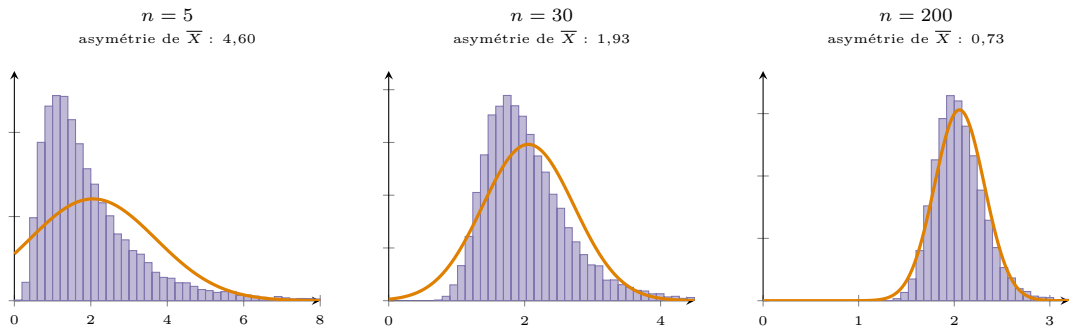
Ce que cela dit. L'adjectif « approximativement » du théorème central limite ne concerne que les populations **non normales**. Pour une population normale, il n'y a rien à approcher, même pour $n = 2$.

■

Standardiser, c'est compter en erreurs-types

Z mesure l'écart entre la moyenne obtenue et la vraie moyenne **en nombre d'erreurs-types**.
Pour notre échantillon : $(7\,005{,}80 - 7\,158{,}26)/367{,}43 = -0{,}41$. La moyenne tombe à moins d'une demi-erreur-type de m : un échantillon tout à fait ordinaire.

Quand le théorème tarde



population log-normale très étirée (asymétrie 11,2) : histogramme de 20 000 moyennes, courbe normale du TCL en orange

La règle des trente, et sa vraie portée

Ce que montre la figure

La population est **très** étirée à droite : une asymétrie de 11, quand nos salaires en ont une de 1,16.
Avec $n = 30$, la moyenne reste nettement asymétrique (1,9) et la courbe normale la décrit mal. Il faut $n = 200$ pour que l'approximation devienne acceptable.

Démonstration : L'asymétrie de la moyenne décroît comme 1 sur racine de n

Mesurons l'asymétrie d'une variable par $\gamma = \mu_3/\sigma^3$, où $\mu_3 = E[(X-m)^3]$ est le moment centré d'ordre 3. Posons $Y_i = X_i - m$, de moyenne nulle, et développons le cube de la somme :

$$E\Big[\Big(\sum_i Y_i\Big)^3\Big] = \sum_i E(Y_i^3) + 3\sum_{i\neq j} E(Y_i^2\,Y_j) + \sum_{i,j,k \text{ distincts}} E(Y_i\,Y_j\,Y_k).$$

Par indépendance, $E(Y_i^2\,Y_j) = E(Y_i^2)\,E(Y_j) = 0$ et $E(Y_i\,Y_j\,Y_k) = 0$: il ne reste que la première somme, soit $n\,\mu_3$. Pour $\overline{X} - m = \frac{1}{n}\sum_i Y_i$, le moment centré d'ordre 3 vaut donc

$$\mu_3(\overline{X}) = \frac{1}{n^3} \times n\,\mu_3 = \frac{\mu_3}{n^2}, \qquad \text{alors que} \qquad \sigma(\overline{X})^3 = \frac{\sigma^3}{n^{3/2}}.$$

En divisant,

$$\gamma(\overline{X}) = \frac{\mu_3/n^2}{\sigma^3/n^{3/2}} = \frac{\gamma}{\sqrt{n}}.$$

Ce que cela dit. L'asymétrie de la moyenne s'éteint, mais lentement : il faut multiplier n par 4 pour la diviser par 2. Pour nos salaires ($\gamma = 1{,}16$), $\gamma/\sqrt{50} = 0{,}16$: la moyenne d'un échantillon de 50 est presque symétrique, d'où la bonne qualité de l'approximation normale. Pour la population très étirée de la figure ($\gamma = 11$), $11/\sqrt{30} \approx 2{,}0$: à $n = 30$, la moyenne reste nettement asymétrique, ce que la règle des trente ne dit pas.

■

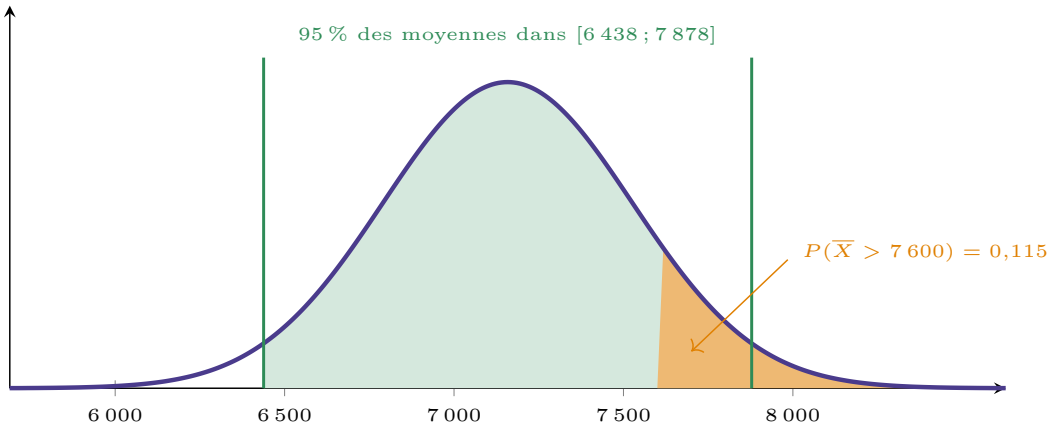
Regarder avant d'invoquer la règle

$n \geq 30$ est une convention commode, pas un théorème. Elle suffit largement pour une population modérément dissymétrique — comme nos salaires.
Pour une distribution très étirée — patrimoines, sinistres d'assurance, durées de chômage — il faut bien davantage. **Le bon réflexe est de regarder l'histogramme avant d'invoquer la règle.**

Calculer sur la moyenne

La loi de la moyenne de cinquante salariés

$\overline{X} \sim \mathcal{N}(7\,158{,}26\,;\,367{,}44)$: deux calculs



Encadrer la moyenne d'un échantillon

Que peut donner un échantillon de 50 ?

Avec $m = 7\,158{,}26$ et $\sigma = 2\,598{,}10$, l'erreur-type vaut $2\,598{,}10/\sqrt{50} = 367{,}43$.

$$P(7\,158{,}26 - 1{,}96 \times 367{,}43 \;\leq\; \overline{X} \;\leq\; 7\,158{,}26 + 1{,}96 \times 367{,}43) = 0{,}95$$

$$\overline{X} \in [\,6\,438{,}10\,;\;7\,878{,}42\,] \text{ dans } 95\,\% \text{ des cas}$$

Attention au sens de lecture

Cet encadrement porte sur $\overline{X}$, **connaissant** m. C'est encore du calcul des probabilités : on descend de la population vers l'échantillon.
Notre moyenne observée, 7 005,80, tombe bien dans cet intervalle. Le chapitre 9 retournera l'inégalité pour encadrer m à partir de $\overline{x}$ — et ce sera enfin de l'inférence.

Trois calculs types

Toujours la même opération : standardiser

1. **Dépasser un seuil.** $P(\overline{X} > 7\,600) = P(Z > \frac{7\,600 - 7\,158{,}26}{367{,}43}) = P(Z > 1{,}20) = 0{,}115$.
2. **Tomber près du but.** $P(|\overline{X} - m| \leq 500) = P(|Z| \leq 1{,}36) = 0{,}826$.
3. **Un seuil rarement franchi.** La valeur dépassée une fois sur vingt est $m \;+\; 1{,}645 \;\times\; 367{,}43 = 7\,762{,}7$.

Avec le facteur de correction

En tenant compte du tirage sans remise (erreur-type 348,9), les trois résultats deviennent 0,103, 0,848 et 7 732,2.
L'écart est faible — c'est pourquoi le cours retient la formule i.i.d., plus simple, sauf mention contraire.

Les dix échantillons au regard de la théorie

Ce que la loi annonce, ce que l'on observe

Écart à m	Probabilité annoncée	Observé sur les dix
moins d'une erreur-type (349 dh)	68 %	8 sur 10
moins de 1,96 erreur-type (684 dh)	95 %	10 sur 10

Dix observations ne prouvent rien, mais elles ne contredisent rien

Huit sur dix au lieu de sept attendues : l'écart est banal avec si peu de tirages. Les 20 000 tirages simulés, eux, donnent 68,8 % et 95,2 %.
La théorie décrit ce qui se passe **sur un grand nombre** d'échantillons — jamais sur le seul que l'on tient.

L'ordre de grandeur qu'il faut avoir en tête

Quelques erreurs-types, sur nos salaires

n	$\sigma/\sqrt{n}$	Sans remise	Écart typique
10	821,6	814,1	énorme
50	367,4	348,9	acceptable
200	183,7	142,4	confortable
500	116,2	0	tout le monde est interrogé

Ce que le gestionnaire doit en conclure

Sur dix bulletins de paie, la moyenne peut se tromper de huit cents dirhams : elle ne permet aucune décision.
Sur deux cents, elle se trompe d'environ deux cents dirhams : on peut négocier une grille salariale. **La taille d'échantillon est une variable de décision** — le chapitre 11 la calculera.

Diviser l'erreur par deux coûte quatre fois plus

La loi de la racine carrée

L'erreur-type est proportionnelle à $1/\sqrt{n}$. Pour la diviser par k, il faut multiplier n par k^2.

Erreur-type visée	367 dh	184 dh	92 dh
Taille nécessaire (formule i.i.d.)	50	200	800

Démonstration : La loi de la racine carrée

On cherche la taille n' pour laquelle l'erreur-type $\sigma/\sqrt{n'}$ est égale à $\dfrac{1}{k}$ fois celle de la taille n, c'est-à-dire $\dfrac{\sigma}{\sqrt{n}}\Big/k$:

$$\frac{\sigma}{\sqrt{n'}} = \frac{1}{k}\,\frac{\sigma}{\sqrt{n}} \iff \sqrt{n'} = k\sqrt{n} \iff n' = k^2\,n.$$

Pour $k=2$, $n'=4n$; pour $k=4$, $n'=16\,n$. Sur le fil rouge, $\sigma = 2\,598{,}10$:

$$n=50 : \frac{2\,598{,}10}{\sqrt{50}} = 367{,}4 \qquad n=200 : \frac{2\,598{,}10}{\sqrt{200}} = 183{,}7 \qquad n=800 : \frac{2\,598{,}10}{\sqrt{800}} = 91{,}9.$$

Ce que cela dit. Le coût en observations croît comme le **carré** du gain de précision recherché : c'est la conséquence directe de $V(\overline{X}) = \sigma^2/n$, où n est au dénominateur d'une **variance**, alors que la précision se lit sur l'écart-type.

■

La précision a un coût croissant

Chaque gain de précision coûte plus cher que le précédent : passer de 50 à 200 salariés divise l'erreur par deux, passer de 200 à 800 la divise encore par deux — pour quatre fois plus d'entretiens.
C'est le principal arbitrage budgétaire de toute enquête.

S'entraîner

Exercice 1 : une distribution à la main

Trois valeurs, deux tirages

Une population compte trois magasins, dont les ventes quotidiennes valent 2, 4 et 9 milliers de dirhams. On en tire 2 **avec remise**.

1. Calculer m et σ^2.
2. Dresser la liste des 9 échantillons et la distribution de $\overline{X}$.
3. Calculer $E(\overline{X})$ et $V(\overline{X})$, et vérifier les formules du cours.

Exercice 1 : solution

Neuf échantillons équiprobables

1. $m = 15/3 = 5$; $\sigma^2 = \frac{1}{3}(9+1+16) = 8{,}667$.
2. Les moyennes : 2 ; 3 (deux fois) ; 4 ; 5,5 (deux fois) ; 6,5 (deux fois) ; 9.

$\overline{x}$	2	3	4	5,5	6,5	9
probabilité	1/9	2/9	1/9	2/9	2/9	1/9

3. $E(\overline{X}) = 45/9 = 5 = m$ et $V(\overline{X}) = 4{,}333 = 8{,}667/2 = \sigma^2/n$.

Exercice 2 : la durée des appels

Un centre d'appels

La durée d'un appel a une moyenne de 6 minutes et un écart-type de 4 minutes ; sa distribution est étirée à droite. On observe 36 appels pris au hasard.

1. Quelle est, approximativement, la loi de la durée moyenne $\overline{X}$? Pourquoi peut-on l'affirmer ?
2. Calculer $P(\overline{X} > 7)$.
3. Entre quelles valeurs, centrées sur 6, la durée moyenne tombe-t-elle dans 95 % des cas ?

Exercice 2 : solution

Le théorème central limite au travail

1. $n = 36$ et une asymétrie modérée : par le théorème central limite, $\overline{X} \approx \mathcal{N}(6\,;4/\sqrt{36}) = \mathcal{N}(6\,;0{,}667)$.
2. $z = (7-6)/0{,}667 = 1{,}5$, d'où $P(\overline{X} > 7) = P(Z > 1{,}5) = 0{,}067$.
3. $6 \pm 1{,}96 \times 0{,}667$, soit $[4{,}69\,;7{,}31]$ minutes.

Ce qu'il faudrait vérifier

Si quelques appels duraient des heures, l'asymétrie serait forte et 36 observations ne suffiraient plus. On regarderait d'abord l'histogramme des durées.

Exercice 3 : la masse salariale d'une équipe

Un budget à prévoir

On constitue une équipe de 50 salariés tirés au hasard (avec remise) parmi nos 500. On s'intéresse à la **somme** T de leurs salaires.

1. Calculer $E(T)$ et $\sigma(T)$.
2. Calculer, approximativement, $P(T > 370\,000)$.
3. Vérifier que l'on obtient la même probabilité en raisonnant sur la moyenne $\overline{X} = T/50$.

Exercice 3 : solution

Total ou moyenne, le même calcul

1. $E(T) = 50\,m = 357\,913$ dirhams et $V(T) = 50\,\sigma^2$, d'où $\sigma(T) = \sqrt{50} \times 2\,598{,}10 = 18\,371$ dirhams.
2. $z = (370\,000 - 357\,913)/18\,371 = 0{,}66$, d'où $P(T > 370\,000) = 0{,}255$.
3. $T > 370\,000$ équivaut à $\overline{X} > 7\,400$, et $(7\,400 - 7\,158{,}26)/367{,}43 = 0{,}66$: la même probabilité.

Le total est plus dispersé, la moyenne l'est moins

L'écart-type du total croît comme $\sqrt{n}$, celui de la moyenne décroît comme $1/\sqrt{n}$. Le risque relatif, rapporté à l'espérance, est le même : $18\,371/357\,913 = 367{,}43/7\,158{,}26 = 5{,}1\,\%$.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. La **distribution d'échantillonnage** est la loi des valeurs prises par une statistique d'un échantillon à l'autre.
2. Elle décrit des **moyennes**, non des individus : ce ne sont pas les mêmes objets.
3. $E(\overline{X}) = m$ et $\sigma(\overline{X}) = \sigma/\sqrt{n}$: cette dernière s'appelle l'**erreur-type**.
4. Au-delà de 5 % de N, la **correction de population finie** réduit l'erreur-type.
5. Le **théorème central limite** rend $\overline{X}$ approximativement normale, d'autant plus vite que la population est peu asymétrique.
6. Diviser l'erreur-type par deux exige **quatre fois** plus d'observations.

La suite

D'autres statistiques que la moyenne

Une moyenne n'est pas la seule statistique utile. Un taux de rebut, un taux d'équipement, une dispersion de qualité : ce sont des **proportions** et des **variances**.
Le chapitre 3 établit leurs distributions d'échantillonnage — et rencontre au passage l'énigme du $n - 1$.

Deux questions sur notre échantillon

13 Bac+5 sur 50, soit 26 %, pour une vraie proportion de 21,4 % : l'écart est-il ordinaire ?
$s = 2\,250{,}98$, pour une vraie dispersion de 2 598,10 : notre échantillon sous-estime-t-il la dispersion par hasard, ou par construction ?