

Chapitre 1

Échantillonner

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Statistique inférentielle

1 Exercices du chapitre

Correction — Exercice 1

- (a) **Aléatoire simple** : chaque numéro de la liste complète a la même chance d'être tiré, sans structure particulière exploitée.
- (b) **Par grappes** : on tire des groupes entiers (les agences) et on interroge **tout le monde** à l'intérieur des groupes sélectionnés.
- (c) **Systématique** : un individu tous les $k = 15$, à intervalle régulier.
- (d) **Stratifié** : la population est découpée en groupes homogènes (les régions), et on tire séparément dans **chacun** d'eux pour garantir leur représentation.

Correction — Exercice 2

- (a) **Un seul** plateau sur les 6 sera contrôlé : le prélèvement, effectué toujours au même instant du cycle, retombe systématiquement sur le même plateau.
- (b) $5/6 \approx 83,3\%$ de la production échappe systématiquement à tout contrôle qualité, quel que soit le nombre de prélèvements effectués — augmenter la fréquence des prélèvements ne changerait rien à ce chiffre tant que l'instant du prélèvement reste synchronisé avec le cycle des plateaux.
- (c) Il faudrait **désynchroniser** le prélèvement du cycle des plateaux : par exemple, faire varier aléatoirement l'instant de prélèvement à chaque cycle, ou choisir un intervalle de prélèvement qui n'est pas un multiple (ni un diviseur) du nombre de plateaux, de sorte que l'échantillon finisse, à terme, par couvrir les 6 plateaux de façon équilibrée.

Correction — Exercice 3

- (a) **Non**, absolument pas : la taille de l'échantillon (50 000 contre 1 200) n'a **aucun rapport** avec la nature de l'écart observé. Un échantillon de 50 000 réponses **auto-sélectionnées** n'est pas plus fiable qu'un petit échantillon **aléatoire**, car augmenter n réduit seulement la variance, jamais le biais.
- (b) La source la plus probable est un **biais d'auto-sélection** (et de champ mal défini) : seules les personnes qui suivent la page du réseau social **et** prennent la peine de répondre sont comptabilisées — un groupe systématiquement différent (et probablement plus mécontent, ou plus mobilisé sur ce sujet) de la population générale.
- (c) Cette affirmation est **fausse**, et illustre exactement la leçon centrale du chapitre : « l'erreur statistique est presque toujours la plus petite erreur d'une enquête ». Un échantillon de 50 000 réponses biaisées reste biaisé, et l'ampleur du biais ne diminue **pas** avec le nombre de réponses ; il est même plus **dangereux** qu'un petit échantillon biaisé, car son grand volume donne une fausse impression de précision et de crédibilité à un résultat qui reste, sur le fond, incorrect. C'est très exactement l'épisode du magazine américain de 1936 vu en cours.

2 Exercices cumulatifs (introduction et chapitre 1)

Correction — Exercice 4

- (a) $m - \bar{x} = 7\,158,26 - 7\,005,80 = 152,46$ dh.
- (b) $\frac{152,46}{318,34} \approx 0,479$ — l'écart représente moins d'une demi erreur-type.
- (c) **Non**, ce résultat ne permet **pas** d'affirmer avec certitude l'absence de tout biais de tri du fichier : il montre seulement que l'écart observé est **compatible** avec un tirage sans biais (un écart de cette ampleur serait tout à fait banal par pur hasard d'échantillonnage). Mais un biais de tri modéré pourrait très bien exister et rester, par coïncidence, à l'intérieur de cette marge de fluctuation normale — la cohérence numérique ne **prouve** rien, elle est seulement **non-contradictoire** avec l'absence de biais. La vérification indépendante et simple que suggère le cours consiste à inspecter directement l'ordre

du fichier source (est-il trié par date d'embauche, par service, par ordre alphabétique du nom — une variable a priori sans lien avec le salaire — ou, à l'inverse, par salaire décroissant, ce qui rendrait tout tirage systématique dangereux?) plutôt que de chercher à déduire l'absence de biais du seul résultat numérique.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Plan A : $1\,200 \times 150 = 180\,000$ dh. Plan B : $1\,200 \times 60 = 72\,000$ dh.
- (b) Le plan A (**stratifié**) offre *a priori* la meilleure précision : en garantissant la présence de chacune des 12 régions dans l'échantillon, il élimine une source de variabilité entre régions que le tirage par grappes ne contrôle pas. Le plan B (**par grappes**) offre le meilleur coût, à plus de deux fois moins cher (72 000 contre 180 000 dh).
- (c) **Non**, le plan B n'est pas exempt de risque : si, par malchance ou par un choix insuffisamment aléatoire, les 5 villes tirées ne sont **pas représentatives** de l'ensemble du pays (villes plus urbaines, plus riches, ou concentrées dans une même zone géographique ou climatique, par exemple), le résultat national sera **biaisé** de façon durable et invisible dans les formules statistiques classiques, qui supposent implicitement que les grappes elles-mêmes ont été correctement tirées au hasard parmi **toutes** les grappes possibles. Aucune formule de marge d'erreur ne peut détecter ce problème : seul un examen critique du choix des villes (et, idéalement, un tirage aléatoire véritable parmi un grand nombre de villes candidates) permet de s'en prémunir.

Correction — Exercice 6

- (a) Les avis en ligne sont laissés **spontanément**, par **auto-sélection** : ce sont surtout les clients **très satisfaits** (qui veulent faire l'éloge du restaurant) et les clients **très mécontents** (qui veulent se plaindre) qui prennent la peine d'écrire un avis. Les clients « normalement satisfaits », la majorité silencieuse, ne laissent presque jamais d'avis, ce qui vide artificiellement la distribution de son centre et produit cette allure bimodale. L'enquête téléphonique, elle, interroge un échantillon **aléatoire** incluant cette majorité silencieuse, d'où une distribution bien plus resserrée autour d'une note centrale.
- (b) La mesure de 3,9/5, issue de l'enquête **aléatoire**, est la plus représentative de la satisfaction moyenne réelle de l'ensemble de la clientèle : contrairement à la note en ligne, elle repose sur un échantillon dont chaque client a une probabilité connue et non nulle d'être interrogé, quelle que soit son intensité d'opinion.
- (c) Le risque économique est de fonder une décision **coûteuse et structurante** (une restructuration) sur une image de la clientèle **déformée** par le biais d'auto-sélection, en réagissant à l'opinion bruyante d'une minorité mécontente plutôt qu'à la réalité vécue par la majorité des clients — qui sont en réalité plutôt satisfaits (3,9/5). Une telle restructuration pourrait s'attaquer à un problème largement exagéré, tout en engageant des coûts et des perturbations bien réels pour l'entreprise, sur la base d'un diagnostic statistiquement infondé.