

Statistique inférentielle

Chapitre 1 : Échantillonner

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique inférentielle

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Identifier le plan de sondage

Pour chacune des situations suivantes, indiquer s'il s'agit d'un échantillonnage **aléatoire simple**, **systématique**, **stratifié** ou **par grappes** :

- (a) Un institut tire au sort, à l'aide d'un générateur de nombres aléatoires, 500 numéros de téléphone dans la liste complète des 80 000 abonnés d'une ville.
- (b) Une entreprise interroge, pour un audit interne, l'ensemble du personnel de 8 agences régionales tirées au hasard parmi ses 60 agences.
- (c) Un contrôle qualité prélève la 15^e, la 30^e, la 45^e pièce, etc., sur la chaîne de production.
- (d) Un ministère de la santé constitue son échantillon en tirant séparément 200 patients dans chacune des 12 régions du pays, afin de garantir la présence de toutes les régions.

Exercice 2 — Le piège du tirage systématique

Une boulangerie industrielle contrôle la cuisson en prélevant **une tranche sur six** à la sortie du four. Le four comporte 6 plateaux qui tournent en cycle, et le prélèvement se fait toujours au même instant du cycle de convoyage.

- (a) Combien de plateaux, sur les 6, seront **effectivement** contrôlés au fil du temps avec ce protocole ?
- (b) Quelle proportion de la production totale échappe donc **systématiquement** à tout contrôle qualité, quel que soit le nombre de prélèvements effectués ?
- (c) Que faudrait-il modifier dans le protocole de prélèvement pour éliminer ce problème, sans changer la fréquence globale d'un prélèvement sur six ?

Exercice 3 — Un grand échantillon peut être trompeur

Une association de consommateurs diffuse, uniquement sur sa page d'un réseau social, un questionnaire sur la satisfaction à l'égard des régimes de retraite. Elle recueille 50 000 réponses, dont 78 % se disent « très insatisfaites ». Une étude officielle, menée par téléphone sur un échantillon aléatoire de 1 200 personnes représentatif de la population, trouve 35 % de « très insatisfaits ».

- (a) L'écart entre les deux résultats (78 % contre 35 %) peut-il s'expliquer par la différence de taille des deux échantillons ?
- (b) Quelle est la source la plus probable de cet écart ?
- (c) Un porte-parole de l'association affirme : « avec 50 000 réponses, notre résultat est forcément plus fiable qu'un sondage sur 1 200 personnes ». Commenter cette affirmation à la lumière du chapitre.

2 Exercices cumulatifs (introduction et chapitre 1)

Exercice 4 — L'échantillon fil rouge est-il compatible avec l'absence de biais ?

L'introduction a présenté l'échantillon fil rouge : un salarié sur dix (tirage systématique, $k = 10$), donnant $n = 50$, de moyenne $\bar{x} = 7\,005,80$ dh et d'erreur-type $s/\sqrt{n} = 318,34$. La population complète des 500 salariés a pour moyenne $m = 7\,158,26$ dh.

- (a) Calculer l'écart $m - \bar{x}$ en dirhams.
- (b) Exprimer cet écart en nombre d'erreurs-types, c'est-à-dire calculer $(m - \bar{x})/(s/\sqrt{n})$.
- (c) Un écart de moins d'une erreur-type est considéré, intuitivement, comme parfaitement compatible avec le simple hasard de l'échantillonnage (les chapitres suivants formaliseront ce raisonnement). Ce résultat permet-il pour autant d'affirmer avec certitude que le fichier des 500

salariés n'était pas trié selon une variable liée au salaire avant le tirage systématique? Quelle vérification simple, indépendante du calcul, permettrait de lever le doute?

3 Applications en sciences économiques

Exercice 5 — Stratifié ou par grappes : un arbitrage budgétaire

Un cabinet d'études doit interroger 1 200 ménages à l'échelle nationale et hésite entre deux plans. Plan A (stratifié) : 100 ménages tirés dans chacune des 12 régions du pays, coût unitaire de collecte de 150 dh par ménage (déplacements dispersés). Plan B (par grappes) : 5 villes tirées au hasard parmi les grandes agglomérations, puis 240 ménages interrogés dans chacune, coût unitaire de 60 dh par ménage (déplacements concentrés).

- (a) Calculer le coût total de collecte de chacun des deux plans.
- (b) Lequel des deux plans offre, *a priori*, la meilleure **précision** statistique pour un résultat national? Lequel offre le meilleur coût?
- (c) Le plan B est-il pour autant exempt de risque, même s'il est moins coûteux? Quel événement, propre aux 5 villes tirées, pourrait fausser durablement le résultat national, sans qu'aucune formule statistique ne puisse le détecter?

Exercice 6 — Avis en ligne contre enquête aléatoire

Une chaîne de restaurants affiche une note moyenne de 3,1/5 sur une plateforme d'avis en ligne, fondée sur 2 000 commentaires spontanés : 60 % de notes de 5/5, 25 % de notes de 1/5, et seulement 15 % de notes intermédiaires. Une enquête de satisfaction menée par téléphone sur un échantillon aléatoire de 300 clients ayant effectivement consommé dans les 30 derniers jours donne une moyenne de 3,9/5, avec une distribution des notes beaucoup plus resserrée autour de 4/5.

- (a) Pourquoi les avis en ligne présentent-ils une distribution « bimodale » (concentrée aux deux extrêmes) alors que l'enquête téléphonique ne la présente pas?
- (b) Quelle des deux mesures (3,1/5 ou 3,9/5) est la plus représentative de la satisfaction **moyenne réelle** de l'ensemble de la clientèle? Justifier.
- (c) La direction de la chaîne, guidée uniquement par la note en ligne, envisage un plan de restructuration coûteux fondé sur l'idée que « la majorité des clients sont mécontents ». Quel est le risque économique d'une décision fondée sur un échantillon auto-sélectionné plutôt que sur une enquête aléatoire?

1 Exercices du chapitre

Correction — Exercice 1

- (a) **Aléatoire simple** : chaque numéro de la liste complète a la même chance d'être tiré, sans structure particulière exploitée.
- (b) **Par grappes** : on tire des groupes entiers (les agences) et on interroge **tout le monde** à l'intérieur des groupes sélectionnés.
- (c) **Systématique** : un individu tous les $k = 15$, à intervalle régulier.
- (d) **Stratifié** : la population est découpée en groupes homogènes (les régions), et on tire séparément dans **chacun** d'eux pour garantir leur représentation.

Correction — Exercice 2

- (a) **Un seul** plateau sur les 6 sera contrôlé : le prélèvement, effectué toujours au même instant du cycle, retombe systématiquement sur le même plateau.
- (b) $5/6 \approx 83,3\%$ de la production échappe systématiquement à tout contrôle qualité, quel que soit le nombre de prélèvements effectués — augmenter la fréquence des prélèvements ne changerait rien à ce chiffre tant que l'instant du prélèvement reste synchronisé avec le cycle des plateaux.
- (c) Il faudrait **désynchroniser** le prélèvement du cycle des plateaux : par exemple, faire varier aléatoirement l'instant de prélèvement à chaque cycle, ou choisir un intervalle de prélèvement qui n'est pas un multiple (ni un diviseur) du nombre de plateaux, de sorte que l'échantillon finisse, à terme, par couvrir les 6 plateaux de façon équilibrée.

Correction — Exercice 3

- (a) **Non**, absolument pas : la taille de l'échantillon (50 000 contre 1 200) n'a **aucun rapport** avec la nature de l'écart observé. Un échantillon de 50 000 réponses **auto-sélectionnées** n'est pas plus fiable qu'un petit échantillon **aléatoire**, car augmenter n réduit seulement la variance, jamais le biais.
- (b) La source la plus probable est un **biais d'auto-sélection** (et de champ mal défini) : seules les personnes qui suivent la page du réseau social **et** prennent la peine de répondre sont comptabilisées — un groupe systématiquement différent (et probablement plus mécontent, ou plus mobilisé sur ce sujet) de la population générale.
- (c) Cette affirmation est **fausse**, et illustre exactement la leçon centrale du chapitre : « l'erreur statistique est presque toujours la plus petite erreur d'une enquête ». Un échantillon de 50 000 réponses biaisées reste biaisé, et l'ampleur du biais ne diminue **pas** avec le nombre de réponses ; il est même plus **dangereux** qu'un petit échantillon biaisé, car son grand volume donne une fausse impression de précision et de crédibilité à un résultat qui reste, sur le fond, incorrect. C'est très exactement l'épisode du magazine américain de 1936 vu en cours.

2 Exercices cumulatifs (introduction et chapitre 1)

Correction — Exercice 4

- (a) $m - \bar{x} = 7\,158,26 - 7\,005,80 = 152,46$ dh.
- (b) $\frac{152,46}{318,34} \approx 0,479$ — l'écart représente moins d'une demi erreur-type.
- (c) **Non**, ce résultat ne permet **pas** d'affirmer avec certitude l'absence de tout biais de tri du fichier : il montre seulement que l'écart observé est **compatible** avec un tirage sans biais (un écart de cette ampleur serait tout à fait banal par pur hasard d'échantillonnage). Mais un biais de tri modéré pourrait très bien exister et rester, par coïncidence, à l'intérieur de cette marge de fluctuation normale — la cohérence numérique ne **prouve** rien, elle est seulement **non-contradictoire** avec l'absence de biais. La vérification indépendante et simple que suggère le cours consiste à inspecter directement l'ordre

du fichier source (est-il trié par date d'embauche, par service, par ordre alphabétique du nom — une variable a priori sans lien avec le salaire — ou, à l'inverse, par salaire décroissant, ce qui rendrait tout tirage systématique dangereux?) plutôt que de chercher à déduire l'absence de biais du seul résultat numérique.

3 Applications en sciences économiques

Correction — Exercice 5

(a) Plan A : $1\,200 \times 150 = 180\,000$ dh. Plan B : $1\,200 \times 60 = 72\,000$ dh.

(b) Le plan **A (stratifié)** offre *a priori* la meilleure précision : en garantissant la présence de chacune des 12 régions dans l'échantillon, il élimine une source de variabilité entre régions que le tirage par grappes ne contrôle pas. Le plan **B (par grappes)** offre le meilleur coût, à plus de deux fois moins cher (72 000 contre 180 000 dh).

(c) **Non**, le plan B n'est pas exempt de risque : si, par malchance ou par un choix insuffisamment aléatoire, les 5 villes tirées ne sont **pas représentatives** de l'ensemble du pays (villes plus urbaines, plus riches, ou concentrées dans une même zone géographique ou climatique, par exemple), le résultat national sera **biaisé** de façon durable et invisible dans les formules statistiques classiques, qui supposent implicitement que les grappes elles-mêmes ont été correctement tirées au hasard parmi **toutes** les grappes possibles. Aucune formule de marge d'erreur ne peut détecter ce problème : seul un examen critique du choix des villes (et, idéalement, un tirage aléatoire véritable parmi un grand nombre de villes candidates) permet de s'en prémunir.

Correction — Exercice 6

(a) Les avis en ligne sont laissés **spontanément**, par **auto-sélection** : ce sont surtout les clients **très satisfaits** (qui veulent faire l'éloge du restaurant) et les clients **très mécontents** (qui veulent se plaindre) qui prennent la peine d'écrire un avis. Les clients « normalement satisfaits », la majorité silencieuse, ne laissent presque jamais d'avis, ce qui vide artificiellement la distribution de son centre et produit cette allure bimodale. L'enquête téléphonique, elle, interroge un échantillon **aléatoire** incluant cette majorité silencieuse, d'où une distribution bien plus resserrée autour d'une note centrale.

(b) La mesure de 3,9/5, issue de l'enquête **aléatoire**, est la plus représentative de la satisfaction moyenne réelle de l'ensemble de la clientèle : contrairement à la note en ligne, elle repose sur un échantillon dont chaque client a une probabilité connue et non nulle d'être interrogé, quelle que soit son intensité d'opinion.

(c) Le risque économique est de fonder une décision **coûteuse et structurante** (une restructuration) sur une image de la clientèle **déformée** par le biais d'auto-sélection, en réagissant à l'opinion bruyante d'une minorité mécontente plutôt qu'à la réalité vécue par la majorité des clients — qui sont en réalité plutôt satisfaits (3,9/5). Une telle restructuration pourrait s'attaquer à un problème largement exagéré, tout en engageant des coûts et des perturbations bien réels pour l'entreprise, sur la base d'un diagnostic statistiquement infondé.