

Chapitre 1

Échantillonner

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Statistique inférentielle

1 Exercices du chapitre

Exercice 1 — Identifier le plan de sondage

Pour chacune des situations suivantes, indiquer s'il s'agit d'un échantillonnage **aléatoire simple**, **systématique**, **stratifié** ou **par grappes** :

- (a) Un institut tire au sort, à l'aide d'un générateur de nombres aléatoires, 500 numéros de téléphone dans la liste complète des 80 000 abonnés d'une ville.
- (b) Une entreprise interroge, pour un audit interne, l'ensemble du personnel de 8 agences régionales tirées au hasard parmi ses 60 agences.
- (c) Un contrôle qualité prélève la 15^e, la 30^e, la 45^e pièce, etc., sur la chaîne de production.
- (d) Un ministère de la santé constitue son échantillon en tirant séparément 200 patients dans chacune des 12 régions du pays, afin de garantir la présence de toutes les régions.

Exercice 2 — Le piège du tirage systématique

Une boulangerie industrielle contrôle la cuisson en prélevant **une tranche sur six** à la sortie du four. Le four comporte 6 plateaux qui tournent en cycle, et le prélèvement se fait toujours au même instant du cycle de convoyage.

- (a) Combien de plateaux, sur les 6, seront **effectivement** contrôlés au fil du temps avec ce protocole ?
- (b) Quelle proportion de la production totale échappe donc **systématiquement** à tout contrôle qualité, quel que soit le nombre de prélèvements effectués ?
- (c) Que faudrait-il modifier dans le protocole de prélèvement pour éliminer ce problème, sans changer la fréquence globale d'un prélèvement sur six ?

Exercice 3 — Un grand échantillon peut être trompeur

Une association de consommateurs diffuse, uniquement sur sa page d'un réseau social, un questionnaire sur la satisfaction à l'égard des régimes de retraite. Elle recueille 50 000 réponses, dont 78 % se disent « très insatisfaites ». Une étude officielle, menée par téléphone sur un échantillon aléatoire de 1 200 personnes représentatif de la population, trouve 35 % de « très insatisfaits ».

- (a) L'écart entre les deux résultats (78 % contre 35 %) peut-il s'expliquer par la différence de taille des deux échantillons ?
- (b) Quelle est la source la plus probable de cet écart ?
- (c) Un porte-parole de l'association affirme : « avec 50 000 réponses, notre résultat est forcément plus fiable qu'un sondage sur 1 200 personnes ». Commenter cette affirmation à la lumière du chapitre.

2 Exercices cumulatifs (introduction et chapitre 1)

Exercice 4 — L'échantillon fil rouge est-il compatible avec l'absence de biais ?

L'introduction a présenté l'échantillon fil rouge : un salarié sur dix (tirage systématique, $k = 10$), donnant $n = 50$, de moyenne $\bar{x} = 7\,005,80$ dh et d'erreur-type $s/\sqrt{n} = 318,34$. La population complète des 500 salariés a pour moyenne $m = 7\,158,26$ dh.

- (a) Calculer l'écart $m - \bar{x}$ en dirhams.
- (b) Exprimer cet écart en nombre d'erreurs-types, c'est-à-dire calculer $(m - \bar{x})/(s/\sqrt{n})$.
- (c) Un écart de moins d'une erreur-type est considéré, intuitivement, comme parfaitement compatible avec le simple hasard de l'échantillonnage (les chapitres suivants formaliseront ce raisonnement). Ce résultat permet-il pour autant d'affirmer avec certitude que le fichier des 500

salariés n'était pas trié selon une variable liée au salaire avant le tirage systématique? Quelle vérification simple, indépendante du calcul, permettrait de lever le doute?

3 Applications en sciences économiques

Exercice 5 — Stratifié ou par grappes : un arbitrage budgétaire

Un cabinet d'études doit interroger 1 200 ménages à l'échelle nationale et hésite entre deux plans. Plan A (stratifié) : 100 ménages tirés dans chacune des 12 régions du pays, coût unitaire de collecte de 150 dh par ménage (déplacements dispersés). Plan B (par grappes) : 5 villes tirées au hasard parmi les grandes agglomérations, puis 240 ménages interrogés dans chacune, coût unitaire de 60 dh par ménage (déplacements concentrés).

- (a) Calculer le coût total de collecte de chacun des deux plans.
- (b) Lequel des deux plans offre, *a priori*, la meilleure **précision** statistique pour un résultat national? Lequel offre le meilleur coût?
- (c) Le plan B est-il pour autant exempt de risque, même s'il est moins coûteux? Quel événement, propre aux 5 villes tirées, pourrait fausser durablement le résultat national, sans qu'aucune formule statistique ne puisse le détecter?

Exercice 6 — Avis en ligne contre enquête aléatoire

Une chaîne de restaurants affiche une note moyenne de 3,1/5 sur une plateforme d'avis en ligne, fondée sur 2 000 commentaires spontanés : 60 % de notes de 5/5, 25 % de notes de 1/5, et seulement 15 % de notes intermédiaires. Une enquête de satisfaction menée par téléphone sur un échantillon aléatoire de 300 clients ayant effectivement consommé dans les 30 derniers jours donne une moyenne de 3,9/5, avec une distribution des notes beaucoup plus resserrée autour de 4/5.

- (a) Pourquoi les avis en ligne présentent-ils une distribution « bimodale » (concentrée aux deux extrêmes) alors que l'enquête téléphonique ne la présente pas?
- (b) Quelle des deux mesures (3,1/5 ou 3,9/5) est la plus représentative de la satisfaction **moyenne réelle** de l'ensemble de la clientèle? Justifier.
- (c) La direction de la chaîne, guidée uniquement par la note en ligne, envisage un plan de restructuration coûteux fondé sur l'idée que « la majorité des clients sont mécontents ». Quel est le risque économique d'une décision fondée sur un échantillon auto-sélectionné plutôt que sur une enquête aléatoire?