

Statistique inférentielle

Chapitre 5 : Estimateur et biais

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique inférentielle

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Estimateur ou estimation ?

Un cabinet interroge un échantillon de 200 ménages pour évaluer le revenu mensuel moyen d'une région, et obtient $\bar{x} = 8\,340$ dh. Il calcule aussi la proportion de ménages propriétaires de leur logement, et obtient $f = 0,62$.

- (a) Pour le revenu moyen, donner la formule de l'**estimateur** utilisé, et distinguer clairement cette formule du **nombre** 8 340 dh.
- (b) Même question pour la proportion de propriétaires.
- (c) Le directeur du cabinet affirme : « 8 340 dh est un bon résultat, puisque notre méthode est fiable ». Expliquer pourquoi cette phrase mélange, à tort, une propriété de la **méthode** (l'estimateur) et un jugement porté sur un **nombre** (l'estimation), alors que ces deux niveaux doivent être distingués.

Exercice 2 — Le biais de la variance non corrigée

On considère une population de variance $\sigma^2 = 800$, et un échantillon de taille $n = 15$ sur laquelle on calcule la variance non corrigée $s_n^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$.

- (a) Rappeler la formule de $E(s_n^2)$ en fonction de σ^2 et de n , puis la calculer numériquement.
- (b) Calculer le biais $E(s_n^2) - \sigma^2$, puis le biais relatif en pourcentage.
- (c) Ce biais est-il positif ou négatif ? Que cela signifie-t-il concrètement pour quelqu'un qui utiliserait s_n^2 pour évaluer la dispersion réelle du phénomène étudié ?

Exercice 3 — Pourquoi s n'est pas sans biais pour σ

Un phénomène ne peut produire, selon l'échantillon tiré, que deux valeurs possibles de la variance corrigée, chacune avec une probabilité de 0,5 : $s^2 = 100$ ou $s^2 = 400$. On suppose que $\sigma^2 = 250$ est la vraie variance de la population, de sorte que s^2 est bien sans biais ($E(s^2) = \sigma^2$).

- (a) Vérifier que $E(s^2) = 0,5 \times 100 + 0,5 \times 400 = 250 = \sigma^2$.
- (b) Calculer $E(s) = 0,5 \times \sqrt{100} + 0,5 \times \sqrt{400}$, puis comparer ce résultat à $\sqrt{E(s^2)} = \sqrt{250}$.
- (c) En déduire que s est un estimateur **biaisé** de σ , bien que s^2 soit sans biais pour σ^2 . Expliquer, en une phrase, pourquoi la concavité de la fonction racine carrée est responsable de ce phénomène (indice : penser à l'inégalité de Jensen évoquée dans le cours).

2 Exercices cumulatifs (chapitres 1 à 5)

Exercice 4 — Sans biais n'est pas exact, sur le fil rouge

On reprend le fil rouge : population de $N = 500$ salariés, de proportion réelle de diplômés Bac+5 $p = 0,214$ et de variance des salaires $\sigma^2 = 6\,750\,122$ dh². Sur l'échantillon systématique de $n = 50$ salariés, on a observé la proportion $f = 0,26$ et la variance corrigée $s^2 = 5\,066\,894$ dh².

- (a) L'estimateur F est sans biais pour p ($E(F) = p$, établi au chapitre 2). L'estimation $f = 0,26$ obtenue ici est-elle pour autant **égale** à $p = 0,214$? Cet écart contredit-il le caractère sans biais de F ?
- (b) Calculer ce qu'aurait donné, sur ce même échantillon, la variance **non corrigée** $s_n^2 = s^2 \times \frac{n-1}{n}$.
- (c) Le service des ressources humaines envisage d'utiliser s_n^2 (division par n , jugée « plus simple ») plutôt que s^2 pour évaluer la dispersion des salaires dans un rapport interne sur les inégalités salariales. Pourquoi ce choix serait-il problématique, compte tenu du sens du biais rappelé dans ce chapitre ?

3 Applications en sciences économiques

Exercice 5 — Un gestionnaire de risques sous-estime la volatilité

Un gestionnaire de risques calcule, sur un échantillon de $n = 20$ rendements journaliers d'un actif financier, la variance non corrigée $s_n^2 = 150$ (en points de pourcentage au carré), qu'il utilise directement dans son modèle de risque.

- (a) Calculer la variance corrigée $s^2 = s_n^2 \times \frac{n}{n-1}$ qu'il aurait dû utiliser.
- (b) Calculer de quel pourcentage le choix de s_n^2 plutôt que s^2 sous-estime la volatilité mesurée par la variance.
- (c) Le cours rappelle qu'« un biais rassurant est le pire de tous ». Expliquer, dans ce contexte de gestion des risques financiers, pourquoi une sous-estimation **systématique** (et non aléatoire) de la volatilité est particulièrement dangereuse, notamment si ce calcul sert à fixer des exigences de capital ou des limites de risque.

Exercice 6 — Précision contre absence de biais dans une statistique publique

Un institut national de la statistique doit choisir entre deux méthodes pour estimer le taux de chômage national : la méthode A, qui interroge un échantillon aléatoire de ménages par visite à domicile (coûteuse mais sans biais connu), et la méthode B, qui interroge par téléphone fixe (moins coûteuse, mais qui exclut systématiquement les ménages sans ligne fixe, souvent parmi les plus précaires et donc les plus touchés par le chômage).

- (a) La méthode B a-t-elle un problème de **biais**, de **précision** (dispersion), ou des deux ? Justifier.
- (b) Un responsable propose d'augmenter fortement la taille de l'échantillon de la méthode B pour « compenser » son défaut. D'après le cours, ce choix peut-il corriger le problème identifié en (a) ?
- (c) Pourquoi un institut de statistique publique, dont les chiffres influencent des décisions de politique économique, devrait-il accorder la priorité à l'absence de biais plutôt qu'à la seule précision, quitte à accepter un coût de collecte plus élevé ?

1 Exercices du chapitre

Correction — Exercice 1


- (a) L'**estimateur** est la formule $\bar{X} = \frac{1}{200} \sum_{i=1}^{200} X_i$, applicable à **n'importe quel** échantillon de 200 ménages; c'est une variable aléatoire. Le nombre 8 340 dh est l'**estimation**, c'est-à-dire la valeur particulière obtenue sur **cet** échantillon précis.
- (b) De même, l'estimateur est $F = \frac{1}{200} \sum_{i=1}^{200} \mathbb{1}_{\{i \text{ propriétaire}\}}$ (une proportion de Bernoulli, comme au chapitre 3); l'estimation est le nombre $f = 0,62$ obtenu sur cet échantillon.
- (c) La fiabilité d'une **méthode** (par exemple, le fait que l'estimateur $\bar{X}$ soit sans biais et suffisamment précis) est une propriété qui se démontre **indépendamment** de tout échantillon particulier, en étudiant la loi de $\bar{X}$. Affirmer que le **nombre** 8 340 dh est « bon » parce que la méthode est fiable est un raccourci trompeur : on ne peut jamais dire si un nombre particulier est proche ou non de la vraie valeur m , puisque m est justement inconnue. Ce qu'on peut affirmer, c'est que la méthode, appliquée à de nombreux échantillons, donnerait en moyenne un résultat proche de m et avec une dispersion connue – pas que 8 340 dh en particulier l'est.

Correction — Exercice 2

- (a) $E(s_n^2) = \frac{n-1}{n} \sigma^2 = \frac{14}{15} \times 800 \approx 746,67$.
- (b) Biais = $746,67 - 800 = -53,33$. Biais relatif = $\frac{-53,33}{800} \times 100 \approx -6,67\%$ (exactement $-1/n \times 100 = -6,67\%$).
- (c) Le biais est **négatif** : s_n^2 **sous-estime** systématiquement, en moyenne sur tous les échantillons possibles, la vraie variance $\sigma^2 = 800$. Quelqu'un qui utiliserait s_n^2 croirait donc, de façon répétée et non aléatoire, que le phénomène étudié est **moins dispersé** qu'il ne l'est réellement.

Correction — Exercice 3

- (a) $E(s^2) = 0,5 \times 100 + 0,5 \times 400 = 50 + 200 = 250 = \sigma^2$: s^2 est bien sans biais.
- (b) $E(s) = 0,5 \times 10 + 0,5 \times 20 = 5 + 10 = 15$. Or $\sqrt{E(s^2)} = \sqrt{250} \approx 15,81$. On a donc $E(s) = 15 < 15,81 \approx \sqrt{E(s^2)}$.
- (c) Puisque $E(s) \neq \sqrt{\sigma^2} = \sigma$ (ici, $\sigma \approx 15,81$ alors que $E(s) = 15$), s est un estimateur **biaisé** de σ (biais $\approx -0,81$), bien que s^2 soit sans biais pour σ^2 : « sans biais » ne traverse pas la transformation racine carrée. La fonction racine carrée étant **concave**, l'inégalité de Jensen garantit que $E(\sqrt{s^2}) \leq \sqrt{E(s^2)}$ dès que s^2 est aléatoire (non constant) : la concavité « tire vers le bas » la moyenne des racines carrées par rapport à la racine carrée de la moyenne.



2 Exercices cumulatifs (chapitres 1 à 5)

Correction — Exercice 4

(a) **Non**, $f = 0,26 \neq p = 0,214$, et cet écart ne contredit **en rien** le caractère sans biais de F : « sans biais » signifie que $E(F) = p$, c'est-à-dire qu'en **moyenne sur tous les échantillons possibles** de taille 50, F vise juste. Un tirage particulier, comme celui-ci, peut parfaitement s'écarter de p par pur hasard d'échantillonnage – exactement l'idée résumée par « sans biais n'est pas exact ».

(b) $s_n^2 = 5\,066\,894 \times \frac{49}{50} = 5\,066\,894 \times 0,98 \approx 4\,965\,556 \text{ dh}^2$.

(c) Ce choix serait problématique car le biais de s_n^2 est **négatif** : il conduirait le service RH à **sous-estimer systématiquement** (ici d'environ 2 %, soit $-1/n$) la dispersion réelle des salaires. Dans un rapport sur les inégalités salariales, une telle sous-estimation **répétée** minimiserait artificiellement l'ampleur des écarts de salaires au sein de l'entreprise, ce qui est précisément le type de biais « rassurant » que le cours identifie comme le plus dangereux, puisqu'il n'incite personne à le corriger.

3 Applications en sciences économiques

Correction — Exercice 5

(a) $s^2 = 150 \times \frac{20}{19} \approx 157,89$.

(b) Sous-estimation relative = $\left(\frac{150}{157,89} - 1 \right) \times 100 \approx -5,0\%$: le choix de s_n^2 sous-estime la volatilité mesurée d'environ 5 %.

(c) Une sous-estimation **aléatoire** de la volatilité (tantôt trop haute, tantôt trop basse) serait gênante mais non structurellement dangereuse, car elle s'annulerait en moyenne sur de nombreuses mesures. Une sous-estimation **systématique** comme celle de s_n^2 signifie au contraire que le modèle de risque **toujours** le même biais du même côté : si ce chiffre sert à fixer des exigences de capital réglementaire ou des limites de position, l'établissement se retrouvera **structurellement sous-capitalisé** face au risque réel, un problème qui ne se révèle qu'au moment d'un choc de marché – précisément le scénario où l'insuffisance de capital est la plus coûteuse. C'est pour cela que « un biais rassurant est le pire de tous » : il ne déclenche aucune alerte tant que le choc ne s'est pas produit.

Correction — Exercice 6

(a) La méthode B souffre d'un problème de **biais** (et pas seulement de précision) : en excluant systématiquement une catégorie de ménages – ceux sans ligne fixe, statistiquement plus touchés par le chômage –, elle sous-représente structurellement les chômeurs dans son échantillon, quel que soit le tirage réalisé. C'est un biais de **champ** (couverture incomplète de la population), analogue au biais d'auto-sélection vu au chapitre 1, mais ici lié au mode de collecte plutôt qu'à la non-réponse.

(b) **Non** : comme rappelé dans ce chapitre (et déjà au chapitre 1), augmenter la taille de l'échantillon réduit la **dispersion** de l'estimateur (son erreur-type), mais ne corrige **en rien** un biais de champ. Interroger 10 fois plus de ménages joignables par téléphone fixe ne fera qu'obtenir une estimation **plus précise... d'une mauvaise cible**, puisque les ménages sans ligne fixe resteront exclus quel que soit n .

(c) Un institut de statistique publique produit des chiffres qui orientent des décisions de politique économique majeures (aides sociales, politiques de l'emploi, allocation de budgets) : un estimateur **biaisé mais précis** donnerait, année après année, une image **fausse mais stable et crédible** de la réalité, ce qui est plus dangereux qu'un estimateur imprécis mais sans biais (dont les erreurs, au moins, ne pousseraient pas systématiquement les politiques publiques dans la même mauvaise direction). Un coût de collecte plus élevé pour garantir l'absence de biais est donc, dans ce contexte, un investissement dans la fiabilité **à long terme** des politiques fondées sur ces chiffres.