Statistique inférentielle

Chapitre 10 : Proportion et variance : les intervalles

Jaouad Madkour

31 octobre 2026

Plan du chapitre

Intervalle pour une proportion **2**
La formule . . . 2
Sur nos données . . . 2
La marge d'erreur, telle qu'on l'annonce . . . 2
Pourquoi les proportions exigent de gros échantillons . . . 3
La formule de Wald tient-elle sa promesse ? . . . 3
Ce que montre la figure . . . 3
L'intervalle de Wilson . . . 4
Une règle de poche : ajouter deux succès et deux échecs . . . 5
Quand on n'observe aucun cas . . . 6

L'intervalle pour une variance **7**
Une construction différente . . . 7
La formule . . . 7
Sur nos données . . . 8
Un intervalle décentré . . . 8
La fragilité de cet intervalle . . . 9
Ce que montre la simulation . . . 9

S'entraîner **10**
Exercice 1 : la satisfaction des clients . . . 10
Exercice 1 : solution . . . 10
Exercice 2 : aucun incident . . . 11
Exercice 2 : solution . . . 11
Exercice 3 : la dispersion d'un usinage . . . 11
Exercice 3 : solution . . . 11

Ce qu'il faut retenir **11**
Le résumé du chapitre . . . 11
La suite . . . 12

Intervalle pour une proportion

La formule

Intervalle de confiance d'une proportion

$$f \pm z_{\alpha/2}\sqrt{\frac{f(1-f)}{n}}$$

valable si $nf \geq 5$ et $n(1-f) \geq 5$. On l'appelle l'intervalle **de Wald**.

Une entorse assumée

L'écart-type théorique fait intervenir p, que l'on cherche justement à estimer. On le remplace donc par f.
C'est une approximation, non un théorème. Elle est acceptable dès que n dépasse quelques dizaines et que p n'est pas trop proche de 0 ou de 1.

Sur nos données

La part de diplômés Bac+5

Sur les 50 salariés de l'échantillon, 13 sont titulaires d'un Bac+5.

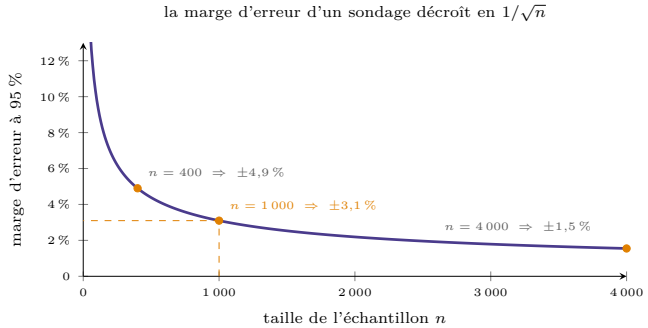
$$f = \frac{13}{50} = 0{,}26 \qquad \sqrt{\frac{0{,}26 \times 0{,}74}{50}} = 0{,}0620$$

$$\mathrm{IC}_{95\,\%} = 0{,}26 \pm 1{,}96 \times 0{,}0620 = [\,0{,}138\ ;\ 0{,}382\,]$$

La vérification, et la leçon

La proportion réelle vaut 0,214 : elle est bien dans l'intervalle.
Mais celui-ci s'étend de 14 % à 38 % — presque du simple au triple. **Cinquante observations ne permettent pas d'estimer une proportion avec finesse.**

La marge d'erreur, telle qu'on l'annonce



D'où vient le « plus ou moins trois points »

$1{,}96\sqrt{\frac{0{,}5 \times 0{,}5}{1\,000}} = 0{,}031$

On prend $p = 0{,}5$ parce que c'est le **cas le plus défavorable** : $p(1-p)$ y est maximal. La marge annoncée est donc toujours une majoration.

La courbe s'aplatit. Passer de 1 000 à 4 000 personnes quadruple le coût et ne gagne que 1,5 point.

C'est pourquoi tous les instituts, dans tous les pays, s'arrêtent autour du millier — ce n'est pas une convention, c'est un calcul.

Pourquoi les proportions exigent de gros échantillons

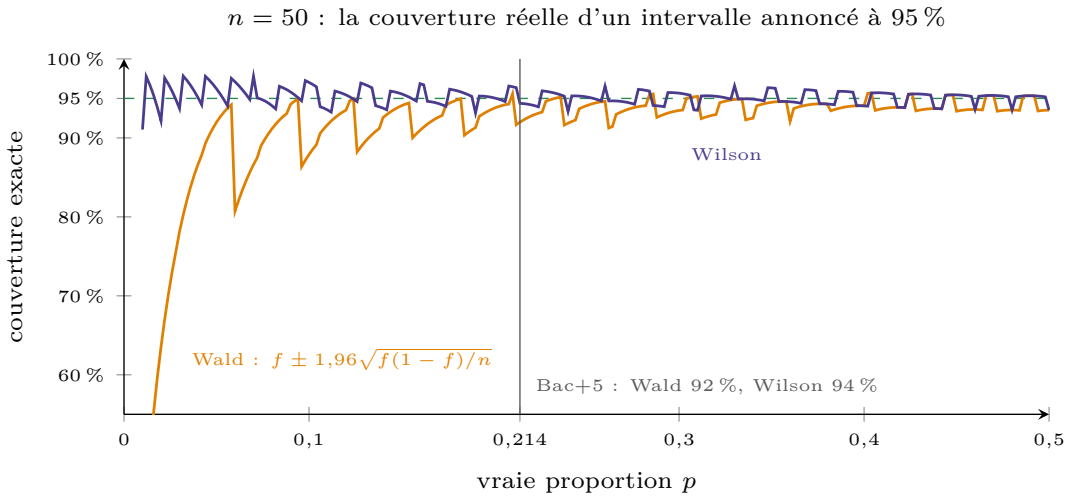
Comparaison des deux paramètres

Paramètre	Estimation	Demi-largeur	En part de la valeur
Moyenne	7 005,80	±640	9 %
Proportion	0,26	±0,122	47 %

L'explication

Une variable indicatrice ne prend que deux valeurs : elle est très pauvre en information. Chaque observation n'apporte qu'un « oui » ou un « non ».
C'est pourquoi les sondages politiques interrogent mille personnes là où une enquête de salaires en interroge cent : **estimer une proportion coûte structurellement plus cher.**

La formule de Wald tient-elle sa promesse ?



Ce que montre la figure

La couverture exacte, calculée par la loi binomiale

Pour chaque valeur de p, on additionne les probabilités binomiales des résultats k dont l'intervalle contient p.

Situation	Wald	Wilson
$n = 50$, $p = 0{,}214$ (nos Bac+5)	92,0 %	94,4 %
$n = 50$, $p = 0{,}05$	92,0 %	96,2 %
$n = 20$, $p = 0{,}05$	63,9 %	92,5 %
$n = 200$, $p = 0{,}214$	94,9 %	95,3 %

Une promesse non tenue près des bords

L'intervalle de Wald annonce 95 % et peut n'en tenir que 64. Le défaut est grave pour les **petites proportions** : taux de défaut, taux d'accident, part de marché d'un nouveau produit.

Démonstration : La couverture exacte de l'intervalle de Wald

Soit $K \sim \mathcal{B}(n\,;p)$ le nombre de succès et $f = K/n$. L'intervalle de Wald ne dépend de l'échantillon que par k ; sa couverture est donc, exactement,

$$C(p) = \sum_{k=0}^{n} \mathbf{1}\{p \in I(k)\} \binom{n}{k} p^k (1-p)^{n-k},$$

où $I(k) = f \pm 1{,}96\sqrt{f(1-f)/n}$: on additionne les probabilités binomiales des résultats k dont l'intervalle contient p.

Le cas $n = 20$, $p = 0{,}05$. Pour $k = 0$, $f = 0$ et $I(0) = [\,0\,;0\,]$ ne contient pas 0,05. Pour $k = 1, \ldots, 4$, l'intervalle contient 0,05 ; par exemple $k = 4$ donne $0{,}20 \pm 0{,}175 = [\,0{,}025\,;0{,}375\,]$. Pour $k \geq 5$, la borne basse dépasse 0,05 ($k = 5$ donne $[\,0{,}060\,;0{,}440\,]$ et elle croît avec k). Donc

$$C(0{,}05) = P(1 \leq K \leq 4) = 1 - P(K = 0) - P(K \geq 5) = 1 - 0{,}358 - 0{,}003 = 0{,}639.$$

Ce que cela dit. Le défaut vient d'abord de l'échantillon vide : l'événement $K = 0$ a la probabilité $(1-p)^n = 0{,}95^{20} = 0{,}358$ et l'intervalle y est un point qui rate p. Pour tout $p > 0$, la couverture de Wald est donc au plus $1 - (1-p)^n$: 92,3 % pour $n = 50$ et $p = 0{,}05$ (on trouve 92,0 %), mais $1 - 0{,}786^{200} \approx 1$ pour $n = 200$ et $p = 0{,}214$, où cette borne ne gêne plus.

■

L'intervalle de Wilson

Une formule plus fiable

On résout $|f - p| \leq z\sqrt{p(1-p)/n}$ en p, sans remplacer p par f sous la racine :

$$\frac{f + \dfrac{z^2}{2n} \pm z\sqrt{\dfrac{f(1-f)}{n} + \dfrac{z^2}{4n^2}}}{1 + \dfrac{z^2}{n}}$$

Sur nos treize Bac+5

Avec $z = 1{,}96$, $n = 50$, $f = 0{,}26$: $[\,0{,}159\,;\ 0{,}396\,]$, contre $[0{,}138\,;0{,}382]$ pour Wald.
L'intervalle de Wilson n'est pas centré sur f : il est attiré vers 0,5.

Démonstration : La formule de Wilson, par la résolution d'une équation du second degré

L'ensemble de Wilson est l'ensemble des p pour lesquels l'événement $|f-p| \le z\sqrt{p(1-p)/n}$ se produit. Les deux membres sont positifs : on peut élever au carré,

$$n(f-p)^2 \le z^2\,p(1-p) \iff (n+z^2)\,p^2 - (2nf+z^2)\,p + nf^2 \le 0.$$

Le coefficient de p^2 est positif : l'inéquation est vraie **entre** les deux racines. Le discriminant vaut

$$(2nf+z^2)^2 - 4(n+z^2)\,nf^2 = 4n^2f^2 + 4nfz^2 + z^4 - 4n^2f^2 - 4nz^2f^2 = z^2(4nf(1-f)+z^2),$$

et les racines sont $p = \dfrac{2nf+z^2 \pm z\sqrt{4nf(1-f)+z^2}}{2(n+z^2)}$. En divisant haut et bas par n, on retrouve la formule du cours.

Le centre. Il vaut $\dfrac{nf+z^2/2}{n+z^2} = \dfrac{n}{n+z^2}\,f + \dfrac{z^2}{n+z^2}\cdot\dfrac{1}{2}$: une moyenne pondérée de f et de $\frac{1}{2}$, ce qui explique l'attraction vers 0,5.

Nos treize Bac+5 ($n = 50$, $f = 0{,}26$, $z^2 = 3{,}8416$). Le centre est $\dfrac{13+1{,}921}{53{,}842} = 0{,}277$ et la demi-largeur $\dfrac{1{,}96\sqrt{9{,}62+0{,}960}}{53{,}842} = 0{,}118$, d'où $[\,0{,}159\,;0{,}396\,]$.

Ce que cela dit. Wald résout la même inéquation après avoir remplacé p par f sous la racine ; Wilson la résout telle quelle. Il ne triche donc jamais sur l'écart-type, et c'est ce qui le rend fiable près des bords.

■

Une règle de poche : ajouter deux succès et deux échecs

L'intervalle d'Agresti et Coull

On remplace $f = k/n$ par $\tilde{p} = (k+2)/(n+4)$, puis on applique la formule de Wald avec $n+4$:

$$\tilde{p} \pm 1{,}96\sqrt{\frac{\tilde{p}(1-\tilde{p})}{n+4}}$$

Sur nos données

$\tilde{p} = 15/54 = 0{,}278$ et $\sqrt{0{,}278\times 0{,}722/54} = 0{,}061$:

$$0{,}278 \pm 0{,}119 = [\,0{,}158\,;\ 0{,}397\,]$$

Presque l'intervalle de Wilson, avec une formule que l'on retient en une phrase.

Démonstration : Pourquoi ajouter deux succès et deux échecs

Posons $\tilde{n} = n + z^2$ et $\tilde{p} = \dfrac{nf + z^2/2}{\tilde{n}}$, le centre de Wilson. Avec $z^2 = 1{,}96^2 = 3{,}84 \approx 4$, on a $\tilde{n} \approx n + 4$ et $\tilde{p} \approx \dfrac{k+2}{n+4}$: c'est la règle « +2 succès, +2 échecs ». Comparons les demi-largeurs. Celle de Wilson est $h = z\sqrt{nf(1-f) + z^2/4}\,/\,\tilde{n}$. Celle d'Agresti et Coull est $h_{AC} = z\sqrt{\tilde{p}(1-\tilde{p})/\tilde{n}}$, avec

$$\tilde{p}(1-\tilde{p}) = \frac{(nf + \frac{z^2}{2})(n(1-f) + \frac{z^2}{2})}{\tilde{n}^{\,2}} = \frac{n^2 f(1-f) + nz^2/2 + z^4/4}{\tilde{n}^{\,2}}.$$

On met h^2 sur le même dénominateur $\tilde{n}^{\,3}$ en multipliant le numérateur par $\tilde{n} = n + z^2$:

$$h^2 = \frac{z^2[n^2 f(1-f) + nz^2/4 + nz^2 f(1-f) + z^4/4]}{\tilde{n}^{\,3}}, \qquad h_{AC}^2 = \frac{z^2[n^2 f(1-f) + nz^2/2 + z^4/4]}{\tilde{n}^{\,3}}.$$

La différence se simplifie, car $\frac{1}{4} - f(1-f) = (f - \frac{1}{2})^2$:

$$h_{AC}^2 - h^2 = \frac{n\,z^4\,(f - \frac{1}{2})^2}{\tilde{n}^{\,3}} \;\geq\; 0.$$

Ce que cela dit. L'intervalle d'Agresti et Coull a le **même centre** que celui de Wilson et une demi-largeur au moins égale, avec égalité pour $f = \frac{1}{2}$. L'écart entre les demi-largeurs est d'ordre $1/n^{3/2}$, alors que la demi-largeur elle-même est d'ordre $1/\sqrt{n}$: il s'évanouit vite quand n grandit. Sur nos données, $[\,0{,}158\,;0{,}397\,]$ contre $[\,0{,}159\,;0{,}396\,]$: un millième de chaque côté.

■

Quand on n'observe aucun cas

La règle de trois

Si l'on observe 0 succès sur n essais, la formule de Wald donne l'intervalle absurde $[0\,;0]$. Une borne supérieure à 95 % est alors, approximativement :

$$p \;\leq\; \frac{3}{n}$$

Zéro défaut sur soixante pièces

$3/60 = 0{,}05$: on peut affirmer, au niveau 95 %, que le taux de défaut ne dépasse pas 5 %. Le calcul exact, $1 - 0{,}05^{1/60}$, donne 4,9 %.
Zéro défaut observé ne prouve jamais un taux de défaut nul.

Démonstration : D'où vient la règle de trois

Si le taux de défaut est p, la probabilité de n'observer **aucun** défaut sur n pièces indépendantes est $(1 - p)^n$. Cette probabilité décroît quand p augmente. Les valeurs de p pour lesquelles voir zéro défaut serait trop rare (probabilité inférieure à 5 %) sont donc celles pour

lesquelles $(1-p)^n < 0{,}05$, c'est-à-dire

$$p \;>\; p_{\max} = 1 - 0{,}05^{1/n}.$$

On les écarte : au niveau 95 %, $p \le p_{\max}$. Comme $0{,}05^{1/n} = e^{(\ln 0{,}05)/n} = e^{-2{,}996/n}$ et que $1 - e^{-x} \le x$,

$$p_{\max} = 1 - e^{-2{,}996/n} \;\le\; \frac{2{,}996}{n} \;<\; \frac{3}{n},$$

avec une différence relative d'environ $x/2 \;=\; 1{,}5/n$: la règle de trois est légèrement trop prudente, jamais trop optimiste.

Les deux applications du cours. Pour $n = 60$, $p_{\max} = 1 - 0{,}05^{1/60} = 4{,}87\,\%$ et $3/60 = 5\,\%$. Pour $n = 150$, $p_{\max} = 1{,}98\,\%$ et $3/150 = 2\,\%$.

Ce que cela dit. Zéro défaut sur n pièces exclut tout taux supérieur à $3/n$, mais aucun taux plus petit : pour passer sous 1 % avec cette seule information, il faudrait 300 pièces sans défaut.

■

L'intervalle pour une variance

Une construction différente

Le pivot utilisé

$$\frac{(n-1)S^2}{\sigma^2} \;\sim\; \chi^2_{n-1}$$

On encadre cette quantité par les deux quantiles du khi-deux, puis on isole σ^2.

Le renversement

$$P\Big(\chi^2_{\alpha/2} \le \frac{(n-1)S^2}{\sigma^2} \le \chi^2_{1-\alpha/2}\Big) = 1 - \alpha$$

On inverse les trois membres — ce qui renverse les inégalités — et l'on multiplie par $(n-1)S^2$.

La formule

Intervalle de confiance d'une variance

$$\left[\; \frac{(n-1)s^2}{\chi^2_{1-\alpha/2\,;\,n-1}} \;;\; \frac{(n-1)s^2}{\chi^2_{\alpha/2\,;\,n-1}} \;\right]$$

Trois différences à repérer

1. L'intervalle **n'est pas symétrique** autour de s^2 : la loi du khi-deux ne l'est pas.
2. Il n'y a **pas de** $\pm$: les deux bornes se calculent séparément.
3. Les quantiles sont **inversés** : le grand quantile va au dénominateur de la borne infé-

rieure.

Démonstration : Renverser le pivot du khi-deux : un intervalle asymétrique et croisé

Le pivot est $Q = (n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$ (chapitre 3). Notons $q_1 = \chi^2_{\alpha/2\,;\,n-1}$ et $q_2 = \chi^2_{1-\alpha/2\,;\,n-1}$, de sorte que $P(q_1 \le Q \le q_2) = 1-\alpha$. Pour un échantillon donné, avec $s^2 > 0$ et $\sigma^2 > 0$:

$$q_1 \le \frac{(n-1)s^2}{\sigma^2} \le q_2 \iff \frac{q_1}{(n-1)s^2} \le \frac{1}{\sigma^2} \le \frac{q_2}{(n-1)s^2} \iff \frac{(n-1)s^2}{q_2} \le \sigma^2 \le \frac{(n-1)s^2}{q_1}.$$

La première équivalence divise par $(n-1)s^2 > 0$; la seconde prend l'inverse de nombres positifs, ce qui **renverse** les inégalités et fait passer le grand quantile q_2 sous la borne inférieure. Les deux bornes ne sont pas équidistantes de s^2, car q_1 et q_2 ne le sont pas de $\nu = n-1$: pour $\nu = 49$, $q_1 = 31{,}555$ est à 17,4 de ν et $q_2 = 70{,}222$ à 21,2.

Sur nos données. $(n-1)s^2 = 49 \times 5\,066\,894 = 248\,277\,806$, d'où, avec les quantiles à quatre décimales (70,2224 et 31,5549), $248\,277\,806/70{,}2224 = 3\,535\,592$ et $248\,277\,806/31{,}5549 = 7\,868\,118$. Rapportées à s^2, les bornes valent $49/70{,}222 = 0{,}698$ fois et $49/31{,}555 = 1{,}553$ fois s^2.

La racine. La fonction racine est croissante : $a \le \sigma^2 \le b \iff \sqrt{a} \le \sigma \le \sqrt{b}$, donc le niveau est conservé : $[\,1\,880{,}3\,;\,2\,805{,}0\,]$.

Ce que cela dit. L'intervalle s'étire vers le haut parce que la loi du khi-deux a une queue droite plus épaisse : c'est le prix de la positivité de σ^2, qui ne peut pas descendre en dessous de zéro mais peut monter sans limite.

■

Sur nos données

Le calcul

$n = 50$, $s^2 = 5\,066\,894$, $\nu = 49$, et $\chi^2_{0{,}975\,;49} = 70{,}222$, $\chi^2_{0{,}025\,;49} = 31{,}555$.

$$\mathrm{IC}_{95\,\%}(\sigma^2) = \left[\frac{49 \times 5\,066\,894}{70{,}222}\ ;\ \frac{49 \times 5\,066\,894}{31{,}555}\right] = [\,3\,535\,592\,;\,7\,868\,118\,]$$

En écart-type

On prend la racine des deux bornes : $\mathrm{IC}_{95\,\%}(\sigma) = [\,1\,880{,}3\ ;\ 2\,805{,}0\,]$.
La valeur réelle, $\sigma = 2\,598{,}10$, est bien dans l'intervalle.

Un intervalle décentré

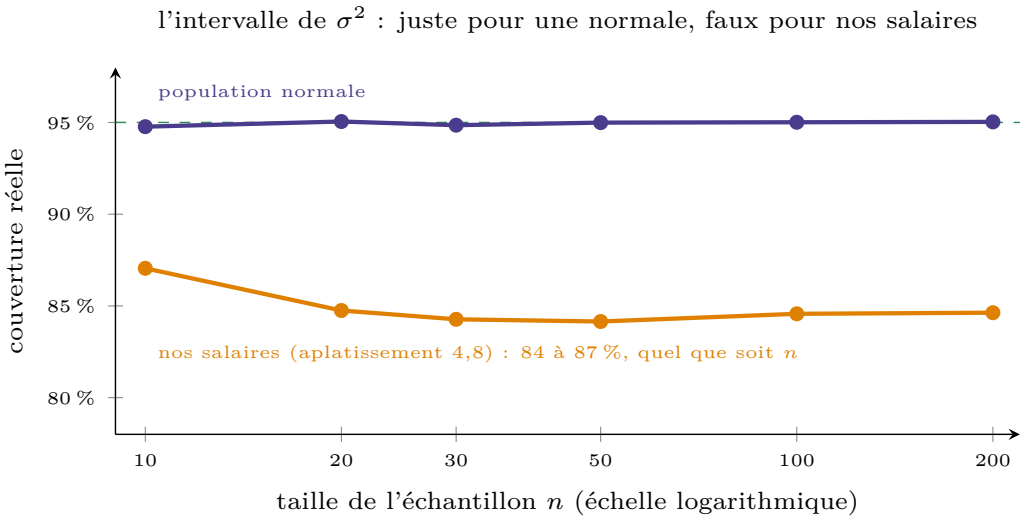
Prendre la racine est ici légitime

La racine est une fonction croissante : elle conserve l'ordre des bornes, donc le niveau de confiance.
Mais le milieu de l'intervalle, 2 342,7, n'est pas $s = 2\,251$: la borne haute est à 554 dirhams de s, la borne basse à 371. L'intervalle s'étire vers le haut, comme la loi du khi-deux.

Les dix échantillons systématiques

Les dix intervalles à 95 % de σ contiennent tous la vraie valeur 2 598,10 : le plus bas, $[1\,835\,;2\,737]$, est celui de $r = 7$.
Dix sur dix : un bon résultat, mais trop peu d'échantillons pour juger la méthode. La simulation qui suit le fait.

La fragilité de cet intervalle



Ce que montre la simulation

Une condition beaucoup plus stricte

Sur 20 000 échantillons par taille, l'intervalle de σ^2 couvre la vraie valeur 95 % du temps pour une population normale, mais seulement 84 **à** 87 % du temps pour nos salaires — et cela **ne s'améliore pas** quand n grandit.
La loi du khi-deux suppose une population normale ; aucun théorème central limite ne vient sauver le cas général.

Le contraste à retenir

$\overline{X}$ est robuste à la non-normalité $\quad$ S^2 ne l'est pas

La variance de S^2 dépend de l'aplatissement de la population (4,8 ici, contre 3 pour une normale). C'est l'une des raisons pour lesquelles l'estimation de la volatilité est un sujet difficile en finance.

Démonstration : Pourquoi l'intervalle de la variance ne s'améliore pas avec n

Population quelconque, d'aplatissement $\kappa = E(X-m)^4/\sigma^4$ fini. Le chapitre 3 donne $V(S^2) \approx$

$\sigma^4(\kappa-1)/n$, et le théorème central limite appliqué aux $(X_i-m)^2$ montre que

$$\sqrt{n}\Big(\frac{S^2}{\sigma^2}-1\Big)\longrightarrow\mathcal{N}(0\,;\kappa-1).$$

Posons $\nu=n-1$ et $Q=\nu S^2/\sigma^2$. Les quantiles du khi-deux valent, pour ν grand, $\chi^2_{\nu\,;p}\approx\nu+z_p\sqrt{2\nu}$ (χ^2_ν est approximativement $\mathcal{N}(\nu\,;2\nu)$). L'intervalle contient donc σ^2 si et seulement si $|Q-\nu|\lesssim 1{,}96\sqrt{2\nu}$. Or

$$\frac{Q-\nu}{\sqrt{2\nu}}=\frac{\nu\,(S^2/\sigma^2-1)}{\sqrt{2\nu}}\approx\frac{1}{\sqrt{2}}\sqrt{n}\Big(\frac{S^2}{\sigma^2}-1\Big)\;\longrightarrow\;\mathcal{N}\Big(0\,;\frac{\kappa-1}{2}\Big).$$

La couverture tend donc, quand $n\to\infty$, vers

$$P\Big(|Z|\le 1{,}96\sqrt{\tfrac{2}{\kappa-1}}\Big)=2\,\Phi\Big(1{,}96\sqrt{\tfrac{2}{\kappa-1}}\Big)-1.$$

Ce que cela dit. Pour $\kappa=3$ (loi normale), on retrouve 0,95. Pour nos salaires, $\kappa=4{,}8$: $1{,}96\sqrt{2/3{,}8}=1{,}42$ et la limite vaut environ 84 %, ce qui est la valeur trouvée par la simulation. Cette limite **ne dépend pas de** n : agrandir l'échantillon ne corrige rien, parce que l'erreur ne vient pas de l'approximation du khi-deux mais de la variance de S^2, que le pivot suppose égale à celle d'une loi normale. À l'inverse, une loi à queues légères ($\kappa<3$) rend l'intervalle trop prudent : pour la loi uniforme, $\kappa=1{,}8$, la limite est 99,8 %.

■

S'entraîner

Exercice 1 : la satisfaction des clients

Une enquête de 400 clients

Sur 400 clients interrogés au hasard, 120 se déclarent très satisfaits.

1. Calculer l'intervalle de Wald à 95 % de la proportion de très satisfaits.
2. Calculer l'intervalle de Wilson. Les deux diffèrent-ils sensiblement ?
3. Quelle taille faudrait-il pour une marge maximale de ± 2 points ?

Exercice 1 : solution

Avec n = 400, les deux formules s'accordent

1. $f=0{,}30$; $\sqrt{0{,}30\times 0{,}70/400}=0{,}0229$; $0{,}30\pm 0{,}045$, soit $[0{,}255\,;0{,}345]$.
2. Wilson : $[0{,}257\,;0{,}347]$. L'écart, deux millièmes, est négligeable : n est grand et p loin des bords.
3. Au pire cas $p=0{,}5$: $1{,}96\times 0{,}5/\sqrt{n}=0{,}02$ donne $\sqrt{n}=49$, soit $n=2\,401$.

Exercice 2 : aucun incident

Une compagnie aérienne régionale

Sur ses 150 derniers vols, une compagnie n'a enregistré **aucun** retard de plus de trois heures.

1. Que donne la formule de Wald ? Pourquoi est-elle inutilisable ?
2. Donner une borne supérieure à 95 % du taux de grand retard par la règle de trois.
3. La compagnie affiche « zéro grand retard ». Que faut-il en penser ?

Exercice 2 : solution

Zéro observé n'est pas zéro

1. $f = 0$ donne $\sqrt{0 \times 1/150} = 0$: l'intervalle $[0\,;0]$, qui prétend que le taux est exactement nul. La formule s'effondre au bord.
2. $3/150 = 0{,}02$: le taux de grand retard ne dépasse pas 2 %, au niveau 95 %. Le calcul exact donne 1,98 %.
3. Le constat est exact, mais il ne prouve qu'un taux **inférieur à** 2 % environ. Un vol sur cinquante pourrait encore connaître un grand retard.

Exercice 3 : la dispersion d'un usinage

Le diamètre de 15 pièces

Le diamètre de pièces usinées est supposé normal. Sur 15 pièces, l'écart-type corrigé vaut $s = 0{,}8$ millimètre. On donne $\chi^2_{0{,}025\,;14} = 5{,}629$ et $\chi^2_{0{,}975\,;14} = 26{,}119$.

1. Construire l'intervalle de confiance à 95 % de σ^2, puis de σ.
2. Le cahier des charges exige $\sigma \leq 1$ mm. Peut-on affirmer qu'il est respecté ?
3. Pourquoi la normalité des diamètres est-elle ici indispensable ?

Exercice 3 : solution

Un intervalle asymétrique

1. $(n-1)s^2 = 14 \times 0{,}64 = 8{,}96$. D'où $[8{,}96/26{,}119\,;8{,}96/5{,}629] = [0{,}343\,;1{,}592]$ pour σ^2, et $[0{,}586\,;1{,}262]$ mm pour σ.
2. **Non** : l'intervalle contient des valeurs supérieures à 1 mm. Les données sont compatibles avec le respect du cahier des charges, mais ne le démontrent pas.
3. L'intervalle de la variance n'est valable que pour une population normale ; sans elle, son niveau réel peut être très inférieur à 95 %, comme pour nos salaires.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. **Proportion** : $f \pm z_{\alpha/2}\sqrt{f(1-f)/n}$, valable si $nf \geq 5$ et $n(1-f) \geq 5$. Sur nos 50 : $[0{,}138\,;0{,}382]$.
2. Près des bords, Wald ne tient pas sa promesse ; **Wilson** ou la règle « +2 succès, +2

échecs » sont plus fiables.

3. Zéro cas sur n : borne supérieure à 95 % d'environ $3/n$.
4. **Variance** : intervalle **asymétrique**, construit sur le khi-deux, sans $\pm$, quantiles **croisés**.
5. Pour σ, on prend la racine des deux bornes : [1 880,3 ; 2 805,0].
6. L'intervalle de la variance exige la **normalité de la population** : sur nos salaires, il ne couvre que 84 à 87 % du temps.

La suite

La question du gestionnaire

Tous ces intervalles se sont révélés larges. La question qui vient naturellement est celle du gestionnaire : **combien d'observations faut-il pour atteindre la précision voulue ?** Le chapitre 11 y répond par une formule, et par un calcul de budget.

Deux objectifs à chiffrer

Connaître le salaire moyen à $\pm$200 dirhams près ; connaître la part des Bac+5 à $\pm$5 points près.
Combien de salariés faut-il interroger dans chaque cas, et lequel des deux objectifs coûte le plus ?