Statistique inférentielle

Chapitre 14 : La p-value

Jaouad Madkour

22 octobre 2026

Plan du chapitre

Ce que c'est **2**
- Le point de départ . . . 2
- L'aire au-delà de ce qu'on a observé . . . 2
- La définition . . . 3
- Pourquoi la règle est équivalente au seuil . . . 3
- Sur notre question . . . 3

Calculer une p-value **4**
- Avec la table de Student . . . 4
- L'approximation normale . . . 4
- Les trois tests du chapitre 12 . . . 4

La p-value est aléatoire **5**
- Dix échantillons, dix p-values . . . 5
- Sa loi, selon que H0 est vraie ou non . . . 5
- Ce que montre la figure . . . 5
- Ce qu'il faut en conclure . . . 6

La forme du test **6**
- Trois façons de répartir le risque . . . 6
- Calculer p selon la forme . . . 6
- Choisir avant, pas après . . . 7

Les trois contresens **7**
- Ce que la p-value n'est pas . . . 7
- Les deux premiers contresens, chiffrés . . . 7
- Ce qui fait varier la part de fausses découvertes . . . 8
- Le troisième contresens est le plus coûteux . . . 8

Les mauvaises pratiques **9**
- La pêche aux résultats . . . 9
- Une expérience sur nos données . . . 9
- Ce que montre l'expérience . . . 9
- La correction de Bonferroni . . . 10

Regarder les données trop souvent . . . 10
Les trois règles d'honnêteté . . . 10

S'entraîner **11**
Exercice 1 : encadrer une p-value . . . 11
Exercice 1 : solution . . . 11
Exercice 2 : corriger un rapport . . . 11
Exercice 2 : solution . . . 11
Exercice 3 : quinze indicateurs . . . 11
Exercice 3 : solution . . . 12

Ce qu'il faut retenir **12**
Le résumé du chapitre . . . 12
La suite . . . 12

Ce que c'est

Le point de départ

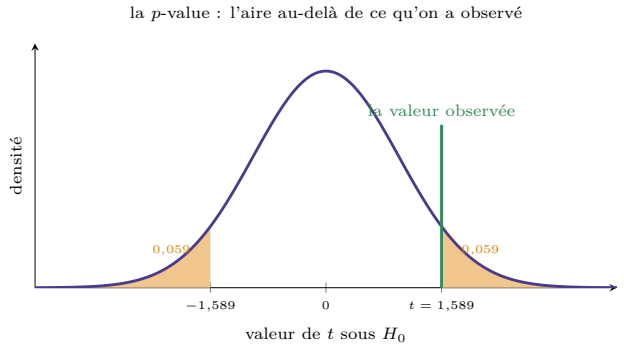
Un verdict binaire ne suffit pas

Notre test donne $t = 1{,}589$ pour un seuil de 1,677 : on ne rejette pas H_0. Un t de 0,2 aurait donné le même verdict.
Les deux situations sont pourtant très différentes : dans la première, les données **frôlent** le rejet ; dans la seconde, elles sont parfaitement ordinaires sous H_0.

Mesurer la surprise

Plutôt que de comparer t à un seuil, on se demande : si H_0 était vraie, **à quel point serait-il rare** d'observer un t aussi grand ?
Cette rareté, exprimée en probabilité, est la p-value.

L'aire au-delà de ce qu'on a observé



La définition, mot pour mot

La probabilité d'obtenir un résultat *au moins aussi extrême* que celui observé, **si H_0 est vraie**.

Ce que la p-value n'est pas

- la probabilité que H_0 soit vraie ;
- la probabilité de se tromper en rejetant ;
- une mesure de l'importance de l'effet.

Une seule chose est vraie : plus elle est petite, moins les données sont compatibles avec H_0.

Ici 0,119 en bilatéral, 0,059 en unilatéral : la conclusion dépend de la question posée *avant* de voir les données.

La définition

Valeur-p

La p-**value** est la probabilité d'obtenir un résultat au moins aussi extrême que celui observé, **si** H_0 **est vraie**.

$$p < \alpha \iff \text{on rejette } H_0$$

Les quatre derniers mots sont l'essentiel

Tout se calcule **sous l'hypothèse que** H_0 **est vraie**. La p-value est une probabilité *conditionnelle à* H_0.
Elle ne dit donc rien sur la probabilité que H_0 soit vraie — c'est le conditionnement inverse, et le cours de probabilités a montré à quel point les deux diffèrent.

Pourquoi la règle est équivalente au seuil

Deux formulations, une décision

Le seuil $t_{1-\alpha}$ laisse à sa droite une aire α. La valeur observée t laisse à sa droite une aire p.

$$t > t_{1-\alpha} \iff p < \alpha$$

Plus t est loin à droite, plus l'aire restante est petite.

Ce que la p-value ajoute

Le seuil donne une réponse oui ou non **pour un** α **fixé**. La p-value donne la réponse **pour tous les** α **à la fois** : on rejette pour tout seuil supérieur à p.
C'est pourquoi les logiciels l'affichent : chaque lecteur peut appliquer son propre seuil.

Sur notre question

Le calcul complet

$t = 1{,}589$ avec 49 degrés de liberté.

$$p_{\text{unilatéral}} = P(T > 1{,}589) = 0{,}059 \qquad p_{\text{bilatéral}} = 2 \times 0{,}059 = 0{,}119$$

Le cas le plus instructif du cours

À $\alpha = 5\,\%$, on ne rejette pas. À $\alpha = 10\,\%$, on rejetterait.
0,059 et 0,05 ne décrivent pas deux mondes différents. **Le seuil est une convention, pas une frontière naturelle** — et présenter 0,051 et 0,049 comme deux conclusions opposées est un abus.

Calculer une p-value

Avec la table de Student

Encadrer quand on n'a pas de logiciel

Quantile de T_{49}	0,90	0,95	0,975	0,99
valeur	1,299	1,677	2,010	2,405
aire à droite	0,10	0,05	0,025	0,01

La lecture

$t = 1{,}589$ tombe entre 1,299 et 1,677 : l'aire à droite est donc entre 0,05 et 0,10.
On écrit $0{,}05 < p < 0{,}10$. C'est suffisant pour décider à 5 % comme à 10 % ; le logiciel précise $p = 0{,}059$.

L'approximation normale

Avec la loi normale au lieu de Student

$P(Z > 1{,}589) = 0{,}056$, contre 0,059 avec Student à 49 degrés de liberté.
L'écart est faible à $n = 50$; il serait important à $n = 10$, où les queues de Student sont nettement plus épaisses.

La normale sous-estime la p-value

Les queues de la loi normale sont plus minces que celles de Student : elle donne des p-values trop petites, donc des rejets trop fréquents.
L'erreur va toujours **dans le sens de l'optimisme** : raison de plus pour utiliser Student dès que σ est estimé.

Les trois tests du chapitre 12

Une même grille de lecture

Question	Statistique	Forme	p	à 5 %
$m > 6\,500$?	$t = 1{,}589$	unilatéral	0,059	non-rejet
$m \neq 7\,500$?	$t = -1{,}552$	bilatéral	0,127	non-rejet
$p > 0{,}15$ (Bac+5) ?	$z = 2{,}178$	unilatéral	0,015	rejet

Une seule échelle pour tous les tests

Chaque test a sa statistique, sa loi et ses degrés de liberté. La p-value les ramène tous à **la même échelle**, entre 0 et 1.
C'est sa grande force pratique : comparer une statistique t, un z et, plus tard, un F ou un χ^2 devient immédiat.

La p-value est aléatoire

Dix échantillons, dix p-values

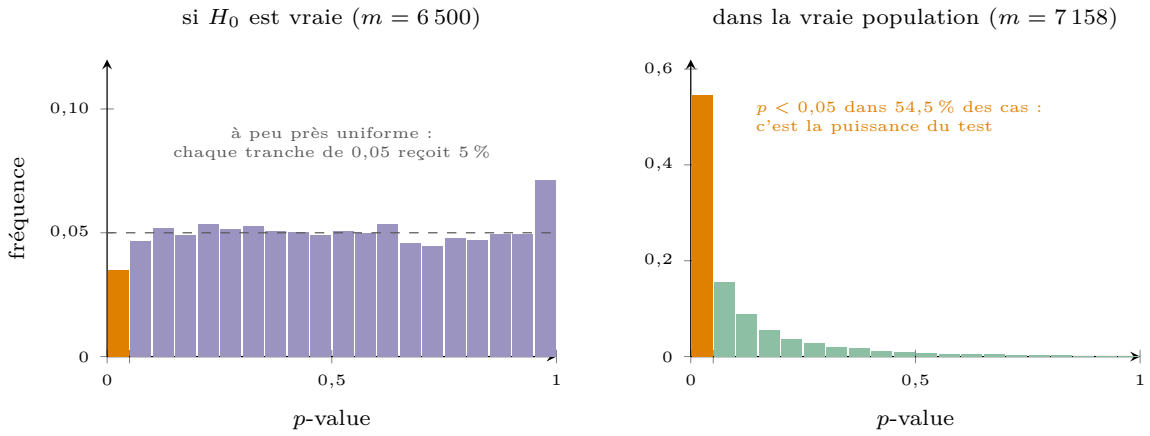
Le test du chapitre 12, sur les dix échantillons systématiques

r	p	décision	r	p	décision
0	0,059	non-rejet	5	0,016	rejet
1	0,032	rejet	6	0,146	non-rejet
2	0,015	rejet	7	0,475	non-rejet
3	0,0003	rejet	8	0,098	non-rejet
4	0,010	rejet	9	0,118	non-rejet

De 0,0003 à 0,48 sur la même population

La p-value est calculée sur l'échantillon : c'est une **statistique**, aussi variable que $\overline{x}$ ou s. Notre échantillon ($r = 0$, $p = 0{,}059$) n'est ni le plus favorable ni le plus défavorable. Une seule p-value ne dit rien de ce qu'aurait donné un autre tirage.

Sa loi, selon que H0 est vraie ou non



Ce que montre la figure

Sous H_0, la p-value est uniforme

Si H_0 est vraie (et la loi du test exacte), $P(p < \alpha) = \alpha$ pour tout α : la p-value suit une loi **uniforme** sur $[0\,;1]$.
C'est la définition du seuil, vue autrement : rejeter quand $p < 0{,}05$, c'est se tromper dans 5 % des cas.

Sur nos salaires

Population recentrée sur 6 500 : 3,5 % des p sont sous 0,05 — un peu moins de 5 %, effet de l'asymétrie des salaires vue au chapitre 4.

Population réelle : 54,5 % des p sont sous 0,05, leur médiane vaut 0,04. On retrouve la **puissance** du chapitre 13.

Ce qu'il faut en conclure

Une petite p-value n'est pas reproductible à coup sûr

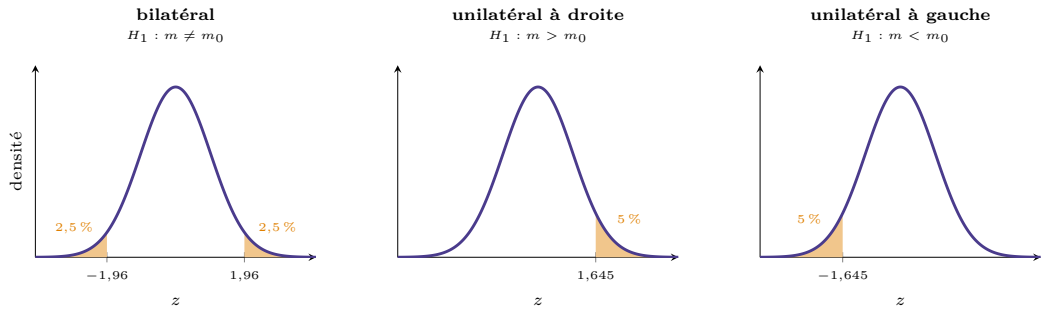
Même quand l'effet est réel, une étude répétée à l'identique ne retrouvera $p < 0{,}05$ qu'avec une probabilité égale à la puissance : ici une fois sur deux.
Qu'une seconde étude « ne confirme pas » la première est donc **attendu** quand les études sont peu puissantes.

La crise de la reproductibilité

Dans plusieurs disciplines, une large part des résultats publiés n'a pas été retrouvée en répétant les études.
L'explication tient en grande partie à ce graphique : des études peu puissantes, et une lecture de la p-value comme un verdict définitif.

La forme du test

Trois façons de répartir le risque



Le même risque $\alpha = 5\,\%$, réparti de trois façons.

Le seuil unilatéral 1,645 est *plus facile à franchir* que le seuil bilatéral 1,96 : à données identiques, un test unilatéral conclut plus souvent au rejet.

D'où la règle déontologique : la forme du test se choisit *avant* de regarder les données, et se justifie par la question posée. Passer au unilatéral après avoir vu le signe de l'écart est une faute — c'est en pratique se donner 10 % de risque en en affichant 5 %.

Calculer p selon la forme

Trois formules

Forme de H_1	p-value
$m > m_0$	$P(T > t)$
$m < m_0$	$P(T < t)$
$m \neq m_0$	$2 \times P(T > \lvert t \rvert)$

Le test de $m = 7\,500$

$t = -1{,}552$. En bilatéral, $p = 2 \times P(T > 1{,}552) = 0{,}127$.
En unilatéral à gauche, $p = P(T < -1{,}552) = 0{,}063$. En unilatéral à droite, $p = 0{,}937$: l'écart va dans le mauvais sens.

Choisir avant, pas après

La règle déontologique

La forme du test — unilatérale ou bilatérale — se décide **avant** de regarder les données, et se justifie par la question posée.

Pourquoi c'est une faute de la changer

Passer au unilatéral après avoir vu le signe de l'écart revient à se donner 10 % de risque tout en en affichant 5 %.
Sur notre exemple, la manœuvre ferait passer p de 0,119 à 0,059 — et changerait une conclusion prudente en conclusion favorable. **Le risque réel a doublé sans que personne ne le voie.**

Les trois contresens

Ce que la p-value n'est pas

Les trois erreurs, dans l'ordre de fréquence

1. Ce **n'est pas** la probabilité que H_0 soit vraie.
2. Ce **n'est pas** la probabilité de se tromper en rejetant.
3. Ce **n'est pas** une mesure de l'importance de l'effet.

La seule chose qui soit vraie

Plus la p-value est petite, moins les données observées sont **compatibles** avec H_0.
Rien de plus. Elle mesure une compatibilité, pas une croyance, et certainement pas une ampleur.

Les deux premiers contresens, chiffrés

Mille campagnes publicitaires testées

Supposons que 100 soient réellement efficaces et 900 inutiles. Chacune est testée au seuil de 5 %, avec la puissance de notre test, 0,55.

	efficaces	inutiles	total
test significatif	55	45	100
test non significatif	45	855	900

45 pour cent de fausses découvertes

Parmi les 100 campagnes déclarées efficaces, 45 ne le sont pas. La probabilité de se tromper **quand on rejette** vaut 0,45, pas 0,05.
$\alpha = P(\text{rejet} \mid H_0)$; ce qui intéresse le décideur est $P(H_0 \mid \text{rejet})$. C'est la formule de Bayes, appliquée au test.

Ce qui fait varier la part de fausses découvertes

Selon la puissance et la part d'idées justes

Effets réels	Puissance	Vrais rejets	Faux rejets	Part de faux
10 %	0,55	55	45	45 %
10 %	0,80	80	45	36 %
20 %	0,80	160	40	20 %
50 %	0,80	400	25	6 %

Deux leçons

Plus les hypothèses testées sont **rarement vraies**, plus un résultat significatif est suspect, à p égal.
Plus les tests sont **puissants**, plus les découvertes sont fiables : la puissance ne sert pas qu'à éviter de manquer un effet.

Le troisième contresens est le plus coûteux

Deux études, même dispersion (σ = 2 600)

Étude	n	Écart estimé	p (bilatéral)	Intervalle à 95 %
A	50	+650 dh	0,077	[−71 ; 1 371]
B	500 000	+12 dh	0,001	[5 ; 19]

Laquelle intéresse le gestionnaire

L'étude B a la plus petite p-value et un effet dérisoire, établi avec certitude. L'étude A n'est pas significative, mais son intervalle n'exclut pas un effet **considérable**.
Une p-value ne se lit jamais seule. Il faut l'écart estimé, son intervalle de confiance, et la taille de l'échantillon.

Les mauvaises pratiques

La pêche aux résultats

Le mécanisme

Tester vingt hypothèses indépendantes, toutes vraies, au seuil de 5 % garantit presque une découverte :

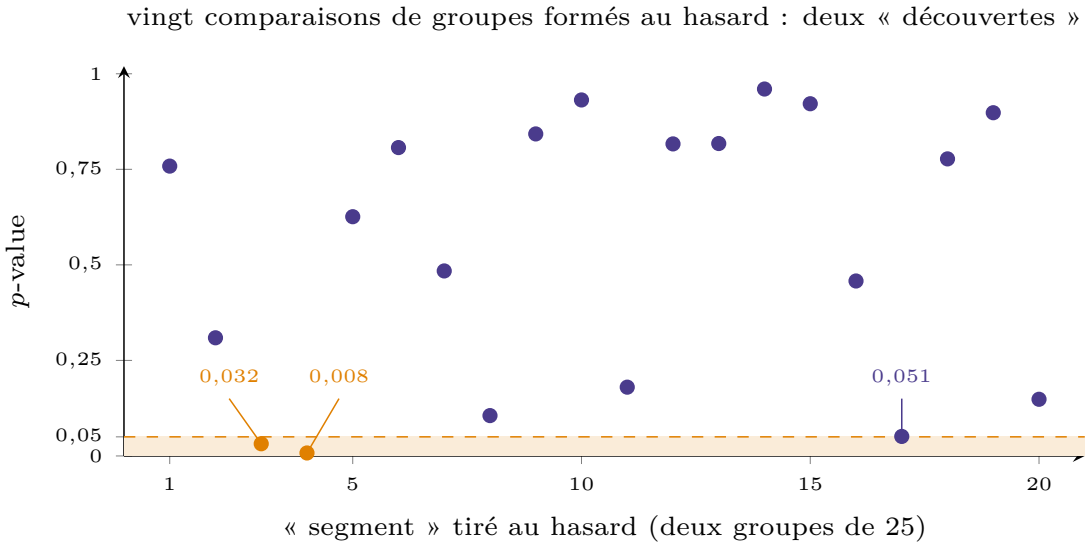
$$P(\text{au moins un rejet à tort}) = 1 - (0{,}95)^{20} = 0{,}64$$

Deux chances sur trois de trouver quelque chose qui n'existe pas.

Ce que cela produit en entreprise

Un service marketing croise trente segments de clientèle et publie les deux qui « ressortent ». Statistiquement, il en aurait trouvé autant sur des données purement aléatoires.

Une expérience sur nos données



Ce que montre l'expérience

Des groupes sans aucune signification

On coupe vingt fois l'échantillon de 50 salariés en deux groupes de 25, **tirés au hasard**, et on compare leurs salaires moyens.
Deux comparaisons sur vingt sont significatives (p = 0,032 et 0,008), une troisième frôle le seuil (0,051). En répétant l'expérience 2 000 fois, 64 % des séries de vingt produisent au moins une « découverte ».

Rien à découvrir, et pourtant

Les groupes ne correspondent à rien : ni sexe, ni diplôme, ni ancienneté. Tout écart entre eux est du pur hasard d'échantillonnage.
Un analyste qui ne rapporterait que les deux comparaisons significatives raconterait une histoire entièrement fausse.

La correction de Bonferroni

Diviser le seuil par le nombre de tests

Pour k tests, on rejette seulement si $p < \alpha/k$. Le risque d'au moins une fausse découverte reste alors inférieur à α.
Avec 20 tests : seuil $0{,}05/20 = 0{,}0025$, et $1 - (1 - 0{,}0025)^{20} = 0{,}049$.

Sur notre expérience

Aucune des vingt p-values n'est sous 0,0025 : la correction élimine les deux fausses découvertes.
Son prix : une puissance réduite pour chaque test. La vraie règle est ailleurs : **annoncer les hypothèses avant de regarder les données**.

Regarder les données trop souvent

L'arrêt opportuniste

Un analyste teste après 10 observations, puis 20, puis 30, jusqu'à 100, et s'arrête dès que $p < 0{,}05$.
Simulé 20 000 fois dans la population recentrée, où H_0 est **vraie** : il conclut à un effet dans 22 % des cas, au lieu de 5 %.

Chaque coup d'œil est un test

Dix regards, ce sont dix tests ; il suffit qu'un seul passe sous le seuil.
La taille de l'échantillon se fixe **avant** la collecte, avec le calcul de puissance du chapitre 13.

Les trois règles d'honnêteté

Ce qu'un rapport statistique doit indiquer

1. Le nombre de tests **réellement effectués**, pas seulement ceux qui ont abouti.
2. L'**ampleur** de l'effet et son intervalle de confiance, à côté de la p-value.
3. Le seuil α, la forme du test et la taille de l'échantillon, **fixés à l'avance**.

Confirmer n'est pas prospecter

La p-value est un outil correct, employé de travers. Elle a été conçue comme un indicateur parmi d'autres, et on en a fait un verdict automatique.
Un test répond à une question posée ; il ne fouille pas des données à la recherche d'une question. Explorer est légitime, mais une piste trouvée en explorant se confirme sur **d'autres** données.

S'entraîner

Exercice 1 : encadrer une p-value

Avec la table seulement

Un test unilatéral à droite donne $t = 2{,}10$ avec 20 degrés de liberté. La table donne $t_{0{,}95\,;20} = 1{,}725$, $t_{0{,}975\,;20} = 2{,}086$ et $t_{0{,}99\,;20} = 2{,}528$.

1. Encadrer la p-value.
2. Conclure aux seuils de 5 %, 2,5 % et 1 %.
3. Que vaudrait la p-value en bilatéral ?

Exercice 1 : solution

Situer t entre deux quantiles

1. $2{,}086 < 2{,}10 < 2{,}528$: l'aire à droite est entre 0,01 et 0,025. Le logiciel donne $p = 0{,}024$.
2. Rejet à 5 % et à 2,5 % ; non-rejet à 1 %.
3. Le double : entre 0,02 et 0,05 (exactement 0,049). Rejet à 5 %, de justesse.

Exercice 2 : corriger un rapport

« 97 pour cent de chances »

Un rapport conclut : « le test donne $p = 0{,}03$; il y a donc 97 % de chances que la nouvelle offre augmente les ventes ».

1. Quelle est l'erreur ?
2. On estime que 20 % des offres testées dans l'entreprise sont réellement efficaces, et les tests ont une puissance de 0,80. Sur 1 000 offres testées à 5 %, quelle part des offres déclarées efficaces le sont vraiment ?

Exercice 2 : solution

Retourner le conditionnement

1. $p = P(\text{données aussi extrêmes} \mid H_0)$. La phrase lui fait dire $P(H_1 \mid \text{données})$: c'est le premier contresens.
2. 200 efficaces, dont 160 détectées ; 800 inutiles, dont 40 déclarées efficaces à tort. Sur 200 offres « efficaces », 160 le sont : 80 %, et non 97 %.

Ce 80 % dépend de la part d'offres efficaces, que la p-value ignore.

Exercice 3 : quinze indicateurs

Le tableau de bord

Un contrôleur de gestion compare deux agences sur 15 indicateurs, chacun testé au seuil de 5 %. Les cinq plus petites p-values sont 0,002 ; 0,011 ; 0,038 ; 0,046 ; 0,12.

1. Si les deux agences étaient en réalité identiques, quelle serait la probabilité d'au moins une différence significative ?
2. Quels écarts restent significatifs après correction de Bonferroni ?

Exercice 3 : solution

Ajuster le seuil au nombre de tests

1. $1 - 0{,}95^{15} = 0{,}54$: plus d'une chance sur deux de « trouver » une différence qui n'existe pas.
2. Seuil corrigé : $0{,}05/15 = 0{,}0033$. Seul l'indicateur à $p = 0{,}002$ reste significatif.

Les trois autres écarts (0,011, 0,038, 0,046) sont des pistes à vérifier sur d'autres données, pas des conclusions.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. La p-value est la probabilité d'un résultat aussi extrême, **si H_0 est vraie**. Règle : $p < \alpha$ conduit au rejet.
2. Sur nos données, $p = 0{,}059$ en unilatéral ; la table permet l'encadrement $0{,}05 < p < 0{,}10$.
3. La p-value est **aléatoire** : uniforme sous H_0, concentrée près de 0 quand l'effet est réel.
4. La forme du test se fixe **avant** de voir les données.
5. Trois contresens : ce n'est ni $P(H_0)$, ni le risque d'erreur quand on rejette, ni une mesure d'importance.
6. Vingt tests à 5 % donnent 64 % de chances d'une fausse découverte ; Bonferroni divise le seuil par le nombre de tests.

La suite

La théorie est complète

La sixième partie l'applique aux situations que rencontre effectivement un gestionnaire : une moyenne, deux groupes, plusieurs groupes, un tableau d'effectifs, une relation entre deux variables.

Le prochain chapitre

Le chapitre 15 commence par le plus simple, une moyenne ou une proportion comparée à une valeur de référence — et boucle au passage avec l'intervalle de confiance.