

Chapitre 21

Mise en œuvre sur R et Python

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Statistique inférentielle

1 Exercices du chapitre

Correction — Exercice 1


- (a) $\text{sd}()$ calcule l'écart-type **d'échantillon**, avec un dénominateur $n - 1$: $\sqrt{\sum_i (x_i - \bar{x})^2 / (n - 1)}$ – l'estimateur **corrigé** du chapitre 3 (celui qui rend s_n^2 sans biais pour σ^2).
- (b) Ici, les 20 mois **sont** la population entière : il faut appliquer le facteur $\sqrt{(n - 1)/n}$ pour retrouver l'écart-type de population (dénominateur n , celui de la statistique descriptive) : $6,8587 \times \sqrt{19/20} \approx 6,8587 \times 0,9747 \approx 6,685$.
- (c) Parce que cette seconde formule (dénominateur n) ne sert qu'en statistique **descriptive**, quand on décrit une population entière déjà en main ; en inférence – l'usage de très loin le plus fréquent d'un logiciel statistique – on ne dispose presque toujours que d'un **échantillon**, pour lequel seul l'estimateur corrigé ($n - 1$) a un sens.

Correction — Exercice 2

- (a) $\bar{x} = \frac{12 + 15 + 14 + 18 + 11 + 16 + 13 + 17 + 15 + 14}{10} = 14,5$. $\sum_i (x_i - \bar{x})^2 = 42,5$.
- (b) Avec $n - 1 = 9$: $s = \sqrt{42,5/9} \approx 2,1731$. Avec $n = 10$: $s = \sqrt{42,5/10} \approx 2,0616$.
- (c) Écart relatif = $\frac{2,1731 - 2,0616}{2,1731} \approx 5,1\%$. **Oui**, cela confirme très précisément l'ordre de grandeur annoncé par le cours (5 % sur dix observations). L'écart entre les deux conventions, en $\sqrt{(n - 1)/n}$, tend vers 1 quand n augmente (par exemple $\sqrt{499/500} \approx 0,999$ sur les 500 salariés du fil rouge) : plus l'échantillon est grand, moins la perte d'un seul degré de liberté au dénominateur pèse relativement.

Correction — Exercice 3

- (a) $z = \frac{0,26 - 0,15}{\sqrt{0,15 \times 0,85/50}} \approx 2,178$. $z^2 \approx 4,745$.
- (b) $\chi_{\text{corr}}^2 = \frac{(|13 - 7,5| - 0,5)^2}{7,5} + \frac{(|37 - 42,5| - 0,5)^2}{42,5} = \frac{5^2}{7,5} + \frac{5^2}{42,5} \approx 3,333 + 0,588 \approx 3,922$.
- (c) $4,745 > 3,841$ (on rejette) mais $3,922 > 3,841$ également (on rejette aussi, de justesse) : dans ce cas précis, les deux versions mènent à la **même** conclusion, bien que la version corrigée soit nettement plus proche du seuil ($p_{\text{corr}} \approx 0,048$ contre $p_{\text{non-corr}} \approx 0,029$) – un cas plus extrême aurait pu les faire diverger. Cela signifie concrètement qu'un rapport d'étude doit **toujours préciser** laquelle des deux versions a été utilisée (et pourquoi), car la conclusion peut en dépendre ; ne pas le préciser expose à ce qu'un tiers reproduise l'analyse avec l'autre convention et obtienne un résultat différent, sans que personne ne puisse expliquer l'écart.




2 Exercices cumulatifs (chapitres 1 à 21)

Correction — Exercice 4

(a) **Non**, ce n'est pas une valeur fixe : le taux de couverture observé (95,03 %) est lui-même calculé sur un tirage – ici, un tirage de 10 000 simulations parmi une infinité de simulations possibles – et constitue donc, exactement comme n'importe quelle proportion f du chapitre 3, une **réalisation d'une variable aléatoire**. Un autre jeu de 10 000 simulations (avec une autre graine aléatoire) donnerait un taux légèrement différent, mais toujours proche de 95 %.

(b) $se = \sqrt{\frac{0,95 \times 0,05}{10\,000}} \approx 0,002179$. $IC_{95\%} = 0,95 \pm 1,96 \times 0,002179 \approx [0,9457; 0,9543]$. Comme $0,9503 \in [0,9457; 0,9543]$ (et $z = (0,9503 - 0,95)/0,002179 \approx 0,14$, très loin de 1,96), le taux observé est **parfaitement compatible** avec un taux vrai de 95,00 % : rien ne permet de dire que la méthode du chapitre 8 est « légèrement fausse ».

(c) La question (b) applique très exactement la phrase-résumé du cours à un objet inattendu : le résultat de la simulation **elle-même** est traité comme une proportion f (chapitre 3), dont on connaît la loi (chapitre 10) et pour laquelle on peut donc mener un test de conformité (chapitre 15) – ici contre la valeur théorique 95 % que la simulation était censée vérifier. Le cours boucle ainsi sur lui-même : l'outil qui sert à juger si une simulation confirme la théorie est le **même** outil que celui que la simulation cherchait à illustrer.



3 Applications en sciences économiques

Correction — Exercice 5

(a) « Sur les 500 salariés étudiés, chaque année d'ancienneté supplémentaire est associée, en moyenne, à une hausse de salaire d'environ 277 dh par mois. Un salarié sans aucune ancienneté aurait, selon ce modèle, un salaire de base estimé à environ 4 347 dh. Ce lien entre ancienneté et salaire est très fiable statistiquement (il ne s'agit presque certainement pas d'un hasard d'échantillonnage) ; en revanche, l'ancienneté n'explique qu'environ 40 % de l'ensemble des écarts de salaire observés entre salariés – les 60 % restants tiennent à d'autres facteurs (poste, diplôme, performance, négociation individuelle). »

(b) **Non** : $R^2 = 0,4049$ ne dit pas que « 40,49 % du salaire d'un employé » vient de son ancienneté – R^2 est une mesure **globale**, calculée sur l'ensemble des 500 salariés, qui indique la part de la **dispersion totale des salaires** (pas du salaire d'un individu) expliquée par l'ancienneté. On ne peut décomposer le salaire d'un employé particulier de cette façon.

(c) La taille du t ne mesure pas « l'importance » d'une variable : elle mesure seulement à quel point l'estimation du coefficient correspondant s'écarte, en unités d'erreur-type, de 0. La constante (4 347 dh) et la pente (277 dh/an) ne se comparent d'ailleurs même pas sur la même échelle (l'une est un salaire, l'autre une pente) ; comparer leurs t pour juger de leur « importance » n'a pas de sens économique – c'est confondre, une nouvelle fois, significativité statistique et ampleur de l'effet, la mise en garde centrale du chapitre 14 et du chapitre 20.

Correction — Exercice 6

(a) $se(\bar{x}) = \frac{1,3833}{\sqrt{15}} \approx 0,3572$. $t = \frac{3,25 - 2,5}{0,3572} \approx 2,100$. Comme $2,100 > t_{0,95;14} = 1,761$, on **rejette** H_0 : la croissance moyenne dépasse significativement l'objectif de 2,5 %.

(b) Avec l'écart-type erroné : $se_{\text{numpy}} = \frac{1,3364}{\sqrt{15}} \approx 0,3451$. $t_{\text{numpy}} = \frac{0,75}{0,3451} \approx 2,174$. Ici, $2,174 > 1,761$ également : dans cet exemple précis, l'erreur **ne change pas** la conclusion finale (rejet dans les deux cas), mais elle gonfle artificiellement la statistique de test (2,174 au lieu de 2,100) et, avec elle, la confiance apparente dans le résultat – un cas légèrement moins net (par exemple $t_{\text{correct}} = 1,70$) aurait pu, lui, faire **basculer** la conclusion d'un « on ne rejette pas » légitime vers un « on rejette » artefactuel, uniquement à cause du choix erroné de dénominateur.

(c) Ce n'est pas un cas isolé mais un **risque systématique**, explicitement signalé par le cours comme « la source d'erreur la plus fréquente du passage de R à Python ». Avant de publier un résultat de test produit par un script, tout analyste devrait vérifier : (i) quelle convention de dénominateur ($n - 1$ ou n) la fonction d'écart-type employée utilise réellement (en consultant sa documentation, pas en la supposant) ; (ii) si possible, reproduire le calcul « à la main » sur un petit sous-échantillon pour confirmer l'ordre de grandeur – exactement la démarche suivie tout au long de ce cours.