

Statistique inférentielle

Chapitre 21 : Mise en œuvre sur R et Python

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Statistique inférentielle

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Écart-type d'échantillon, écart-type de population

Un analyste dispose des $n = 20$ chiffres d'affaires mensuels (en k dh) d'une entreprise, considérés comme la population complète des mois observés depuis son ouverture : $\bar{x} = 49,9$, $\sum_i (x_i - \bar{x})^2 = 1\,303,15$. Il calcule dans R : `sd(ca) # 6.8587`.

- (a) Que calcule exactement la fonction `sd()` de R – la formule utilisée, et son dénominateur ?
- (b) Puisque ces 20 mois constituent ici la population entière (et non un échantillon d'une population plus vaste), quelle correction faut-il appliquer à `sd(ca)` pour obtenir le véritable écart-type de population ? Calculer sa valeur.
- (c) Pourquoi R ne propose-t-il pas directement une fonction pour cette seconde quantité ?

Exercice 2 — Le piège `numpy` contre `pandas`

Un stagiaire calcule l'écart-type d'un petit échantillon de $n = 10$ délais de livraison (en jours) : 12, 15, 14, 18, 11, 16, 13, 17, 15, 14. Il obtient deux résultats différents selon l'outil utilisé, sans comprendre pourquoi.

- (a) Calculer la moyenne, puis $\sum_i (x_i - \bar{x})^2$.
- (b) Calculer l'écart-type avec un dénominateur $n - 1$ (convention `pandas.std()`), puis avec un dénominateur n (convention `numpy.std()` par défaut).
- (c) Calculer l'écart relatif entre les deux résultats. Le cours affirme que « sur cinq cents observations l'écart est invisible ; sur dix il est de 5 % » – votre calcul confirme-t-il cet ordre de grandeur ? Pourquoi l'écart entre les deux conventions se réduit-il quand n augmente ?

Exercice 3 — Avec ou sans correction de continuité

On reprend le test de proportion du fil rouge : $k = 13$ succès sur $n = 50$, $H_0 : p = 0,15$.

- (a) Calculer $z = (f - p_0) / \sqrt{p_0(1 - p_0)/n}$ et z^2 (la statistique **sans** correction de continuité, celle que `prop.test(..., correct=FALSE)` renvoie).
- (b) Calculer la statistique **avec** correction de continuité : $\chi_{\text{corr}}^2 = \frac{(|k - np_0| - 0,5)^2}{np_0} + \frac{(|(n - k) - n(1 - p_0)| - 0,5)^2}{n(1 - p_0)}$ (celle que `prop.test()` renvoie par défaut).
- (c) Comparer les deux statistiques et leurs p -values respectives ($\chi_{0,95;1}^2 = 3,841$). Les deux versions mènent-elles à la même conclusion au seuil de 5 % ? Le cours affirme que « les deux sont défendables ; ce qui ne l'est pas, c'est de ne pas savoir laquelle on emploie » – expliquer ce que cela signifie concrètement pour un rapport d'étude.

2 Exercices cumulatifs (chapitres 1 à 21)

Exercice 4 — La couverture des intervalles, vérifiée par simulation – et re-vérifiée par le cours lui-même

Le cours simule 10 000 échantillons de taille 40, calcule à chaque fois l'intervalle de confiance à 95 % de la moyenne, et compte combien contiennent la vraie moyenne $m = 7\,158,26$. Résultat : 95,03 % des intervalles la contiennent (au lieu d'exactly 95,00 %).

- (a) Un étudiant en conclut que la méthode des intervalles de confiance du chapitre 8 est légèrement fautive, puisqu'elle ne donne pas exactement 95,00 %. Le taux de couverture observé, 95,03 %, est-il lui-même une valeur **fixe**, ou est-ce, comme toute quantité calculée sur un tirage (ici, 10 000 simulations), une variable aléatoire dotée d'une loi ?
- (b) En traitant ce taux de couverture comme une proportion observée sur $n = 10\,000$ « essais »

(chaque essai valant 1 si l'intervalle contient m , 0 sinon), calculer son erreur-type sous $H_0 : p = 0,95$ (formule du chapitre 10 : $\sqrt{p_0(1-p_0)/n}$), puis un intervalle de confiance à 95 % pour ce taux de couverture. La valeur observée de 95,03 % est-elle statistiquement distinguable de 95,00 % ?

- (c) Le cours résume tout son parcours en une phrase : « une statistique calculée sur un échantillon est une variable aléatoire, et l'on connaît sa loi ». Expliquer en quoi la question (b) de cet exercice est elle-même une application, ultime et un peu vertigineuse, de cette phrase – au résultat même de la simulation censée l'illustrer.

3 Applications en sciences économiques

Exercice 5 — Lire un tableau de régression pour un comité de direction

Un logiciel de statistique affiche la sortie suivante pour une régression du salaire sur l'ancienneté :

	Coefficient	Erreur-type	t	p
Constante	4 347,23	177,18	24,54	< 0,0001
Ancienneté	277,17	15,06	18,41	< 0,0001

$$R^2 = 0,4049, \hat{\sigma}_e = 2\,008, F(1; 498) = 338,8.$$

- (a) En une page maximum, rédiger pour un comité de direction (qui n'a jamais suivi ce cours) un paragraphe qui explique ce que dit ce tableau sur le lien entre ancienneté et salaire, sans utiliser les mots « coefficient », « significatif » ou « R^2 » sans les expliquer immédiatement en langage courant.
- (b) Ce même comité demande : « Peut-on dire que 40,49 % du salaire d'un employé vient de son ancienneté ? ». Corriger précisément cette formulation.
- (c) Le comité voit que $t = 24,54$ pour la constante est encore plus grand que $t = 18,41$ pour l'ancienneté, et en déduit que « la constante est le facteur le plus important du modèle ». Expliquer pourquoi ce raisonnement est erroné.

Exercice 6 — Un bug silencieux dans une analyse Python

Un analyste teste, sur $n = 15$ agences commerciales, si le taux de croissance moyen des ventes dépasse significativement un objectif de 2,5 % ($H_0 : m = 2,5$, $H_1 : m > 2,5$). Il trouve $\bar{x} = 3,25$ %. Pour l'écart-type, il utilise par erreur `numpy.std()` (qui divise par n) au lieu de `pandas.Series.std()` (qui divise par $n - 1$), et obtient $s_{\text{numpy}} = 1,3364$, alors que le bon écart-type d'échantillon est $s = 1,3833$.

- (a) Calculer $se(\bar{x}) = s/\sqrt{n}$ correctement (avec $s = 1,3833$), puis calculer t et conclure au seuil de 5 % ($t_{0,95;14} = 1,761$, test unilatéral).
- (b) Refaire le même calcul avec l'écart-type erroné $s_{\text{numpy}} = 1,3364$ (l'erreur de l'analyste). La conclusion change-t-elle ?
- (c) Ce cas est-il un exemple isolé, ou bien – à la lumière du cours – une illustration d'un risque systématique ? Que devrait vérifier tout analyste avant de publier un résultat de test produit par un script Python ou R ?

1 Exercices du chapitre

Correction — Exercice 1


- (a) `sd()` calcule l'écart-type **d'échantillon**, avec un dénominateur $n - 1$: $\sqrt{\sum_i (x_i - \bar{x})^2 / (n - 1)}$ – l'estimateur **corrigé** du chapitre 3 (celui qui rend s_n^2 sans biais pour σ^2).
- (b) Ici, les 20 mois **sont** la population entière : il faut appliquer le facteur $\sqrt{(n - 1)/n}$ pour retrouver l'écart-type de population (dénominateur n , celui de la statistique descriptive) : $6,8587 \times \sqrt{19/20} \approx 6,8587 \times 0,9747 \approx 6,685$.
- (c) Parce que cette seconde formule (dénominateur n) ne sert qu'en statistique **descriptive**, quand on décrit une population entière déjà en main ; en inférence – l'usage de très loin le plus fréquent d'un logiciel statistique – on ne dispose presque toujours que d'un **échantillon**, pour lequel seul l'estimateur corrigé ($n - 1$) a un sens.

Correction — Exercice 2

- (a) $\bar{x} = \frac{12 + 15 + 14 + 18 + 11 + 16 + 13 + 17 + 15 + 14}{10} = 14,5$. $\sum_i (x_i - \bar{x})^2 = 42,5$.
- (b) Avec $n - 1 = 9$: $s = \sqrt{42,5/9} \approx 2,1731$. Avec $n = 10$: $s = \sqrt{42,5/10} \approx 2,0616$.
- (c) Écart relatif = $\frac{2,1731 - 2,0616}{2,1731} \approx 5,1\%$. **Oui**, cela confirme très précisément l'ordre de grandeur annoncé par le cours (5 % sur dix observations). L'écart entre les deux conventions, en $\sqrt{(n - 1)/n}$, tend vers 1 quand n augmente (par exemple $\sqrt{499/500} \approx 0,999$ sur les 500 salariés du fil rouge) : plus l'échantillon est grand, moins la perte d'un seul degré de liberté au dénominateur pèse relativement.

Correction — Exercice 3

- (a) $z = \frac{0,26 - 0,15}{\sqrt{0,15 \times 0,85/50}} \approx 2,178$. $z^2 \approx 4,745$.
- (b) $\chi_{\text{corr}}^2 = \frac{(|13 - 7,5| - 0,5)^2}{7,5} + \frac{(|37 - 42,5| - 0,5)^2}{42,5} = \frac{5^2}{7,5} + \frac{5^2}{42,5} \approx 3,333 + 0,588 \approx 3,922$.
- (c) $4,745 > 3,841$ (on rejette) mais $3,922 > 3,841$ également (on rejette aussi, de justesse) : dans ce cas précis, les deux versions mènent à la **même** conclusion, bien que la version corrigée soit nettement plus proche du seuil ($p_{\text{corr}} \approx 0,048$ contre $p_{\text{non-corr}} \approx 0,029$) – un cas plus extrême aurait pu les faire diverger. Cela signifie concrètement qu'un rapport d'étude doit **toujours préciser** laquelle des deux versions a été utilisée (et pourquoi), car la conclusion peut en dépendre ; ne pas le préciser expose à ce qu'un tiers reproduise l'analyse avec l'autre convention et obtienne un résultat différent, sans que personne ne puisse expliquer l'écart.




2 Exercices cumulatifs (chapitres 1 à 21)

Correction — Exercice 4

(a) **Non**, ce n'est pas une valeur fixe : le taux de couverture observé (95,03 %) est lui-même calculé sur un tirage – ici, un tirage de 10 000 simulations parmi une infinité de simulations possibles – et constitue donc, exactement comme n'importe quelle proportion f du chapitre 3, une **réalisation d'une variable aléatoire**. Un autre jeu de 10 000 simulations (avec une autre graine aléatoire) donnerait un taux légèrement différent, mais toujours proche de 95 %.

(b) $se = \sqrt{\frac{0,95 \times 0,05}{10\,000}} \approx 0,002179$. $IC_{95\%} = 0,95 \pm 1,96 \times 0,002179 \approx [0,9457; 0,9543]$. Comme $0,9503 \in [0,9457; 0,9543]$ (et $z = (0,9503 - 0,95)/0,002179 \approx 0,14$, très loin de 1,96), le taux observé est **parfaitement compatible** avec un taux vrai de 95,00 % : rien ne permet de dire que la méthode du chapitre 8 est « légèrement fausse ».

(c) La question (b) applique très exactement la phrase-résumé du cours à un objet inattendu : le résultat de la simulation **elle-même** est traité comme une proportion f (chapitre 3), dont on connaît la loi (chapitre 10) et pour laquelle on peut donc mener un test de conformité (chapitre 15) – ici contre la valeur théorique 95 % que la simulation était censée vérifier. Le cours boucle ainsi sur lui-même : l'outil qui sert à juger si une simulation confirme la théorie est le **même** outil que celui que la simulation cherchait à illustrer.



3 Applications en sciences économiques

Correction — Exercice 5

(a) « Sur les 500 salariés étudiés, chaque année d'ancienneté supplémentaire est associée, en moyenne, à une hausse de salaire d'environ 277 dh par mois. Un salarié sans aucune ancienneté aurait, selon ce modèle, un salaire de base estimé à environ 4 347 dh. Ce lien entre ancienneté et salaire est très fiable statistiquement (il ne s'agit presque certainement pas d'un hasard d'échantillonnage) ; en revanche, l'ancienneté n'explique qu'environ 40 % de l'ensemble des écarts de salaire observés entre salariés – les 60 % restants tiennent à d'autres facteurs (poste, diplôme, performance, négociation individuelle). »

(b) **Non** : $R^2 = 0,4049$ ne dit pas que « 40,49 % du salaire d'un employé » vient de son ancienneté – R^2 est une mesure **globale**, calculée sur l'ensemble des 500 salariés, qui indique la part de la **dispersion totale des salaires** (pas du salaire d'un individu) expliquée par l'ancienneté. On ne peut décomposer le salaire d'un employé particulier de cette façon.

(c) La taille du t ne mesure pas « l'importance » d'une variable : elle mesure seulement à quel point l'estimation du coefficient correspondant s'écarte, en unités d'erreur-type, de 0. La constante (4 347 dh) et la pente (277 dh/an) ne se comparent d'ailleurs même pas sur la même échelle (l'une est un salaire, l'autre une pente) ; comparer leurs t pour juger de leur « importance » n'a pas de sens économique – c'est confondre, une nouvelle fois, significativité statistique et ampleur de l'effet, la mise en garde centrale du chapitre 14 et du chapitre 20.

Correction — Exercice 6

(a) $se(\bar{x}) = \frac{1,3833}{\sqrt{15}} \approx 0,3572$. $t = \frac{3,25 - 2,5}{0,3572} \approx 2,100$. Comme $2,100 > t_{0,95;14} = 1,761$, on **rejette** H_0 :

la croissance moyenne dépasse significativement l'objectif de 2,5 %.

(b) Avec l'écart-type erroné : $se_{\text{numpy}} = \frac{1,3364}{\sqrt{15}} \approx 0,3451$. $t_{\text{numpy}} = \frac{0,75}{0,3451} \approx 2,174$. Ici, $2,174 >$

1,761 également : dans cet exemple précis, l'erreur **ne change pas** la conclusion finale (rejet dans les deux cas), mais elle gonfle artificiellement la statistique de test (2,174 au lieu de 2,100) et, avec elle, la confiance apparente dans le résultat – un cas légèrement moins net (par exemple $t_{\text{correct}} = 1,70$) aurait pu, lui, faire **basculer** la conclusion d'un « on ne rejette pas » légitime vers un « on rejette » artefactuel, uniquement à cause du choix erroné de dénominateur.

(c) Ce n'est pas un cas isolé mais un **risque systématique**, explicitement signalé par le cours comme « la source d'erreur la plus fréquente du passage de R à Python ». Avant de publier un résultat de test produit par un script, tout analyste devrait vérifier : (i) quelle convention de dénominateur ($n - 1$ ou n) la fonction d'écart-type employée utilise réellement (en consultant sa documentation, pas en la supposant) ; (ii) si possible, reproduire le calcul « à la main » sur un petit sous-échantillon pour confirmer l'ordre de grandeur – exactement la démarche suivie tout au long de ce cours.